

2022 개정 교육과정

광주광역시교육감 인정

22-광주-19-고교-24-011



고등학교 인공지능 기초

◆ 김현철* 임진숙 박종화 김종혜 심희원 ◆



교과서 물려주기 기록표



연도	교과서 사용자				상태
	학년	반	번호	이름	

※ 상태 표기 예시: 매우 좋음, 좋음, 보통, 나쁨



고등학교

인공지능 기초

김현철
임진숙
박종화
김종혜
심희원

머리말



새로운 디지털과 지능 기술의 발전은 우리가 현재 살고 있는 사회를 너무나 빠르게 변화시켜 나가고 있습니다. 특히 인공지능의 기술 중에서도 생성형 인공지능과 같은 혁신적인 기술의 등장은 기존의 패러다임, 그리고 우리의 일상과 직업에까지 큰 변화를 예고하고 있습니다. 이제 인공지능은 단순한 기술을 넘어 사회의 근간을 이루는 핵심 역량으로 자리 잡고 있으며, 미래에 건강한 시민과 직업인으로 살게 될 여러분에게는 더욱 중요한 영역이 될 것입니다.

‘인공지능 기초’ 교과서는 인공지능 기술의 기본적 이해뿐만 아니라, 이를 다양한 삶의 영역에 적용할 수 있는 실질적 능력을 배양하는 데 중점을 두고 있습니다. 이를 통해 여러분은 인공지능이 우리 삶과 사회에 미치는 깊은 영향을 탐구하고, 창의적 사고와 윤리적 판단을 결합해 현명하고 책임 있는 사용자가 되는 방법을 배울 것입니다. 더불어 인공지능이 미래의 직업과 일상에 가져올 변화에 능동적으로 대응하며, 이 지식을 바탕으로 새로운 기술을 활용해 더 나은 세상을 만드는 데 기여할 수 있는 기반을 마련하게 됩니다.



이 교과서에서는 인공지능의 이해, 인공지능과 학습, 인공지능의 사회적 영향, 인공지능 프로젝트의 네 단원으로 구성되어 있습니다.

- I 인공지능의 이해** 단원에서는 실생활의 문제를 인공지능의 관점에서 파악하고, 탐색과 추론 방식을 적용하도록 하였습니다.
- II 인공지능과 학습** 단원에서는 기계학습을 활용하여 해결할 수 있는 문제를 정의하고, 문제를 효과적으로 해결할 수 있도록 하였습니다.
- III 인공지능의 사회적 영향** 단원에서는 인공지능의 발전에 따른 인간의 삶과 진로의 변화를 탐색하고, 인공지능과 관련된 윤리적 문제에 대해 올바른 가치관을 형성할 수 있도록 하였습니다.
- IV 인공지능 프로젝트** 단원에서는 인류가 직면해 있는 문제를 인공지능을 활용하여 해결할 수 있도록 하였습니다.

우리가 꿈꾸는 것은 단순히 기술이 발전하는 세상이 아니라, 그 기술을 통해 인류의 삶을 풍요롭고 지속 가능하게 만드는 것입니다. 인공지능에 대한 깊은 이해와 함께, 실생활에 적용하여 문제를 해결할 수 있는 실질적인 능력을 갖추으로써, 여러분은 이 변화의 시대를 주도할 주역이 될 것입니다. 우리 저자는 여러분이 이러한 새로운 역량을 바탕으로 무한한 가능성을 품은 미래를 자신 있게 개척해 나가길 기대합니다. 그리고 좀 더 나은 사회와 미래에 기여할 수 있는 큰 인물이 되기를 희망합니다.

— 저자 일동



이 책의 구성과 특징



대단원 도입

대단원에 들어가기 전 단원의 성취 기준을 제시하여 학습의 목표를 명확히 하였습니다.



미리 보는 AI

단원에 가장 중점이 되는 내용을 만화나 재미있는 활동으로 제시하여 호기심을 유발하였습니다.



실습

본문과 관련된 실습 문제를 자세한 해결 과정과 함께 제시하여 생활 속 문제를 해결할 수 있도록 하였습니다.

01

학습 목표

- 인공지능의 발전으로 인한 사회 변화를 살펴보고, 인공지능으로 해결할 수 있는 사회적 문제를 분석할 수 있다.
- 인공지능에 의해 변화하는 인간의 삶과 직업의 양상을 이해하고 진로를 탐색할 수 있다.

인공지능의 발전과 사회 변화

학습 요소

인공지능과 사회 변화, 인공지능과 사회적 문제, 인공지능과 진로



1 인공지능과 사회 변화

방대하고 복잡한 데이터를 처리하고 분석할 수 있는 인공지능 기술의 발달은 의료, 금융, 예술 등 다양한 분야에 폭넓게 적용되면서 우리 사회에 많은 변화를 가져왔다. 인공지능은 우리의 삶을 더 편리하고 효율적으로 만들어 주는 중요한 역할을 하고 있으며 앞으로 더욱 확대될 것이다. 다음 사례로 인공지능이 우리 사회에 어떤 변화를 가져왔는지 살펴보자.

사례 1

인간과 인공지능의 협업

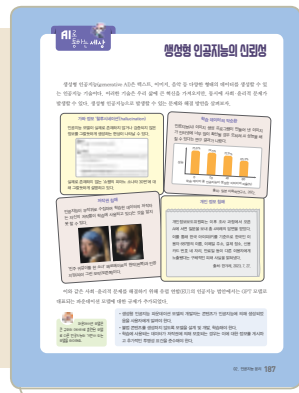
빅데이터를 기반으로 한 인공지능이 환자의 의료 데이터 분석이나 정밀한 수술과 같은 업무를 보조한다. 또한 환자가 인지하지 못하고 있던 질병을 조기에 발견함으로써 의사는 환자의 상담에 더 많은 시간을 할애할 수 있다.



의료 분야 외에 사람과 인공지능이 협업할 수 있는 분야는 무엇이 있을지 알아보자.

170 II. 인공지능의 사회적 영향

본문 중단원별로 학습 목표와 학습 요소를 제시하였고, 효과적인 수업과 학생들의 이해를 위해 다양한 시각 자료를 적절하게 배치하여 효율적인 학습이 가능하도록 하였습니다.



사례 2

업무의 자동화로 인한 생산성 향상

인공지능을 이용한 자동화는 반복적이고 노동 집약적인 업무를 처리한다. 사람의 업무가 단순히 인공지능으로 대체되는 것이 아니라 사람이 더 가치 있는 일에 집중할 수 있고, 자동화·자동화된 인공지능은 산업 분야의 생산성 향상, 비용 절감과 같은 경제적 가치 창출을 돕는다.



자동화 반복되는 작업을 사람의 개입 없이 기계나 프로그램이 스스로 할 수 있게 만드는 것
지능화 기계나 시스템에 사람처럼 생각하고 판단하는 능력을 부여하여 스스로 문제를 해결할 수 있게 만드는 것

● 우리 주변에서 인공지능으로 자동화된 업무는 무엇이 있는지 찾아보자.

사례 3

개인 맞춤형 서비스의 확산

빅데이터와 인공지능의 발전으로 우리는 개인 데이터에 기반한 맞춤형 서비스를 생활에서 쉽게 접할 수 있다. 온라인 쇼핑 사이트에서는 사용자가 자주 검색하는 단어나 과거 방문 기록 등의 데이터를 활용하여 사용자가 좋아할 만한 제품이나 광고를 추천해 준다.



● 영상 시청 사이트는 나의 과거 시청 영상 정보를 이용하여 맞춤형 영상을 추천해 준다. 동영상 시청 사이트에 접속하여 '인공지능'과 관련된 동영상 추천되도록 만들어 보자.

사례 4

새로운 콘텐츠를 생성하는 인공지능

컴퓨터와 대화하듯이 원하는 것을 말하면 인공지능은 학습한 데이터를 기반으로 적절한 답변을 제공한다. 생성형 인공지능의 발전으로 글을 쓰거나 그림을 그리는 데 쓰는 시간을 크게 줄일 수 있게 되었다.

● 실제로 존재하지 않는 사람의 얼굴을 생성하는 인공지능을 체험해 보자.
Random Face Generator
<https://this-person-does-not-exist.com/en>
2016년 Nvidia 엔비디아에서 개발한 StyleGAN 신기술을 이용하여 만들어진 가상 얼굴 생성기이다. 원하는 성별, 나이, 민족성을 입력하면 무작위로 얼굴을 생성해 낸다.




○ 사람의 얼굴을 GAN이 생성한 예



더 알아보기/시로 통하는 세상/나의 꿈 나의 미래

본문 내용과 관련하여 학습에 필요한 보충 및 읽을 거리를 실사례와 함께 필요한 곳에 적절히 제공하였고, 학습의 이해를 돕도록 하였습니다.



대단원 마무리

개념 정리로 핵심 내용을 정리할 수 있도록 하였으며 실력 확인으로 마무리 학습이 이루어질 수 있도록 하였습니다.




창의·융합·코딩 프로젝트

타 교과목과 융합한 프로젝트 활동을 통해 컴퓨팅 사고력, 디지털 문화 소양, 인공지능 소양을 기르도록 하였습니다.

선택 활동

조사, 수집, 발표, 개발, 탐색, 분석, 토의 등 다양한 활동을 포함한 문제를 제시하여 보충·심화 또는 과제용 활동하기로 활용할 수 있도록 하였고, 아울러 자기 주도적 학습이 이루어지도록 구성하였습니다.





I 인공지능의 이해

01

인공지능의 원리

1. 지능의 이해
2. 인공지능의 이해
3. 인공지능 시스템의 이해

02

인공지능과 탐색

1. 문제 해결과 탐색
2. 맹목적 탐색
3. 지능적 탐색
4. 탐색의 다양한 문제 해결 사례

03

지식의 표현과 추론

1. 인공지능과 지식 추론



14

14

16

22

26

27

30

34

38

42

43

II

인공지능과 학습



01

기계학습과 데이터

1. 기계학습과 문제 정의
2. 데이터 수집하기
3. 데이터 탐색과 전처리

02

기계학습 알고리즘

1. 기계학습 유형
2. 모델의 학습과 평가
3. 회귀
4. 분류
5. 군집

03

인공 신경망과 딥러닝

1. 인공 신경망의 이해
2. 신경망 모델 설계와 구현 과정
3. 컴퓨터 비전
4. 음성 인식과 자연어 처리

60

61

67

72

88

89

92

96

106

118

126

127

133

143

155


III 인공지능의 사회적 영향

01 인공지능의 발전과 사회 변화 170

- 1. 인공지능과 사회 변화 170
- 2. 인공지능과 진로 174

02 인공지능 윤리 178

- 1. 인공지능의 윤리적 쟁점 179
- 2. 인공지능과 공존을 위한 노력 188



IV 인공지능 프로젝트

01 지속가능발전목표와 인공지능 200

02 인공지능 프로젝트 204



사전 준비하기




이 교과서에서는 구글 코랩과 오렌지를
인공지능 교육용 도구로 사용합니다.

구글 코랩으로 프로그래밍하기

구글 코랩(Google Colab)은 온라인상에서 파이썬으로 프로그래밍하고 바로 결과를 확인할 수 있는 통합 개발 환경이다.

1. 구글 코랩 파일 생성하기


- (1) 크롬에서 구글 계정으로 로그인하고 (Google 앱) - [드라이브]를 선택한다.
- (2) 드라이브 창에서 [신규] - [더 보기] - [Google Colaboratory]를 선택하여 코랩의 작업 창을 연다.



💡 [Google Colaboratory]가 보이지 않으면
[연결할 앱 더 보기]를 눌러 보자.

2. 코랩의 작업 창 구성 알아보기

코랩은 크게 코드 셀과 텍스트 셀로 구성되어 있다.



3. 코랩에서 코드를 작성하고 실행해 보기

- (1) 구글 코랩의 [새 노트] 창의 코드 셀에 코드를 작성한다.
- (2) (실행) 버튼을 클릭하여 실행 결과를 확인한다.




[참고] 코드 셀에서 단축키의 기능

- **Ctrl + Enter**: 셀을 제자리에서 실행한다.
- **Shift + Enter**: 셀을 실행하고, 다음 셀로 포커스를 이동한다(이동할 셀이 없으면 코드 셀을 추가한다.).
- **Alt + Enter**: 셀을 실행하고 바로 아래에 새로운 코드 셀을 삽입한다.

오렌지3 알아보기

오렌지3(Orange3)는 통계, 기계학습 및 데이터 시각화 등을 할 수 있는 유익한 교육용 프로그램이다. 텍스트 코딩 대신 캔버스에 다양한 위젯을 드래그 앤드 드롭(drag and drop)하여 다양한 작업을 할 수 있다. 검색창에 '오렌지3' 또는 'orange3'를 검색하거나 URL 주소를 입력한다. (<https://orangedatamining.com/>)

1. 오렌지3 기본 화면 구성



2. 위젯 카테고리

위젯은 오렌지3의 계산 유닛으로 캔버스에 위젯을 추가하고 연결하여 데이터 처리, 데이터 시각화, 인공지능 모델 학습, 평가 등의 작업을 수행할 수 있다.

Filter...		
	Data	데이터 입출력 및 정보 관련 위젯
	Transform	데이터 처리 관련 위젯
	Visualize	데이터 시각화 관련 위젯
	Model	모델 관련 위젯
	Evaluate	모델 성능 평가 관련 위젯
	Unsupervised	비지도학습 관련 위젯

※기본으로 제공되는 카테고리 이외의 것들은 프로그램 - [Options] - [Add-ons]에서 추가할 수 있다(관리자 권한으로 실행하여야 한다).

3. 위젯 다루기

(1) 위젯을 추가하는 방법

- ① 카테고리에서 위젯을 골라 클릭하기
- ② 카테고리에서 위젯을 캔버스로 드래그하여 가져오기
- ③ 캔버스의 빈 공간에서 마우스 오른쪽 버튼을 클릭한 후 위젯 이름 검색하기

(2) 위젯 연결 방법

위젯의 왼쪽과 오른쪽에 있는 입출력을 나타내는 표시인 점선에 마우스를 놓고 연결하고자 하는 위젯으로 드래그하여 연결한다.



(3) 위젯 이름 변경 및 삭제 방법

- 이름을 변경할 위젯을 마우스 오른쪽 버튼을 클릭한 후 'Rename'을 선택하여 변경한다.
- 삭제할 위젯을 마우스 오른쪽 버튼을 클릭한 후 'Remove'를 선택하거나, 위젯을 마우스로 클릭한 후 **Delete** 키를 누른다.





I

인공지능의 이해

- 01 인공지능의 원리
- 02 인공지능과 탐색
- 03 지식의 표현과 추론

이 단원을 배우고 나면

인공지능에 대한 이해를 바탕으로 실생활의 문제를 인공지능의 관점에서 파악하고, 지능적 판단을 구현하기 위해 탐색과 추론 방식을 적용하는 능력을 기를 수 있다.





비전자

좌회전할까? 직진할까?
자전거를 끌고 가는 사람이
지나가고 있으니까 기다려야 해.
곧 신호등이 바뀔 것
같으니까 준비하자. 그런데
저 차는 왜 느리게
가는 걸까?

자율주행 자동차

지도, GPS 센서 등으로
들어온 정보, 전체 교통 상황,
교통 법규
"전방의 공사로 속도 저하"
"신호 대기했다가 우회전하면
3분 단축"

DATA

인공지능

AI

상황 인식, 이해
판단과 결정, 행동

문제 해결과 탐색
지식 추론
학습

상황 인식, 이해
판단과 결정, 행동

생활 속 다양한 분야에서의 인공지능 시스템의 역할을 알아볼까?

학교에 들어온 인공지능 시스템



교육용 인공지능 시스템이 학생 개개인의 특성을 반영하여 최적화된 콘텐츠를 제공해요.

인공지능 시스템, 수술에 이용되다



인공지능 의료 기기는 환자의 의료 데이터를 분석하거나 정밀한 수술과 같은 업무를 보조할 수 있어요.

인공지능 시스템이 물건을 이동시킨다고?



인공지능 로봇은 물건의 위치와 이동 경로를 스스로 판단하고 무거운 물건을 통째로 이동할 수 있어요.

집 안에서의 인공지능 시스템



스마트홈 디바이스는 사용자의 생활 방식을 분석하여 개별화된 서비스를 제공해요.

- 인공지능의 지능적 판단에 대한 이해를 바탕으로 인공지능을 활용한 실생활 및 다양한 학문 분야의 문제 해결 사례를 비교·분석할 수 있다.

인공지능의 원리

학습 요소

인공지능 개념,
인공지능 특성,
인공지능 시스템



1 지능의 이해

인간의 지능

- 문제 해결: 문제 상황을 지능적인 전략을 이용하여 해결한다.
- 추론: 이미 가지고 있는 지식으로 새로운 지식을 유도해 낸다.
- 학습: 경험을 통하여 패턴이나 지식을 습득하여 새로운 상황에 적응해 나갈 수 있도록 한다.
- 인식: 자신을 둘러싼 환경을 감지하는 것은 물론 감지된 개체를 분별하고 의미를 파악한다.

지능은 새로운 상황을 이해하고 이에 대한 합리적인 판단과 해결 방법을 이끌어 내는 지적 능력을 말한다.

1 인간의 지능

인간은 지능을 가지고 새로운 대상이나 상황에 따라 적절한 판단과 의사 결정을 하게 되는데, 이를 위해서는 문제 해결, 추론, 학습, 예측, 인식, 생성 등과 같은 세부 지능이 필요하다.



일상생활에서 인간은 지능을 어떻게 활용할까?

인식

화분에 있는 식물의 잎이 노랗게 변하면서 시들고 있어.

추론

식물의 잎이 노랗게 변하고 있다는 것은 햇빛이나 물의 과다 혹은 부족이 원인일 수 있을 거야.

학습

예전에도 화분 식물의 잎이 노랗게 변하는 경우가 있었는데 알맞은 물과 햇빛의 양을 조절하지 못해서였어.



일정한 시간에 맞추어 물을 주면, 식물의 상태가 개선될 거야.

예측

제일 좋은 물과 햇빛의 양을 찾아야지.

문제 해결

식물 성장 일지를 작성해서 소통 공간에 공유해야지!

생성

[그림 1-1] 인간의 지능

2 컴퓨터의 지능

컴퓨터 과학과 인공지능의 아버지로 불리는 앨런 튜링(Turing, Alan)은 디지털 컴퓨터가 인간의 지능을 흉내 낼 수 있을 것으로 생각하였으며, 1950년에 발표한 『컴퓨팅 기계와 지능』이라는 논문에서 컴퓨터의 지능을 판단하는 튜링 테스트를 제안하였다.

이미테이션 게임(모방 게임)

- 논문에서 튜링 테스트를 이미테이션 게임이라고 하였으며, 영화 제목으로도 쓰였다.
- 이미테이션 게임은 기계가 인간을 얼마나 완벽하게 모방할 수 있는지 살피는 게임이다.



튜링 테스트는 어떻게 할까?

독립된 각각의 방에 사람과 컴퓨터가 있고, 바깥의 질문자는 안에 누가 있는지 모르는 상태에서 컴퓨터로 질문을 하고 응답을 받는다. 응답을 받았을 때 인간이 한 응답인지 컴퓨터가 한 응답인지를 질문자가 판단하기 힘들면 컴퓨터는 ‘지능적이다’라고 판단한다.

이후에도 많은 연구자가 인간의 지능을 컴퓨터가 어떻게 모방할 수 있을까에 대한 연구를 진행하고 있다.



[그림 1-2] 튜링 테스트



재미 술술 AI 이야기

‘중국어 방’ 사고 실험

1980년 존 설(Searle, John)은 기계가 인간처럼 생각할 수 있는지 판단하기 위한 튜링 테스트는 적절하지 않다고 주장하며 ‘중국어 방’ 사고 실험을 제안하였다. 이 실험은 방 안에 있는 사람은 중국어를 모르지만, 들어온 질문을 번역 규칙이 적혀 있는 책을 보고 해당 상자에 있는 카드를 꺼내서 방 밖으로 내보낸다면 밖에 있는 사람들에게는 마치 중국어를 잘 하는 것처럼 보인다는 것이다. 그러나 방 안의 사람이 중국어를 이해하는 것은 아니며, 튜링 테스트를 통과했다고 해서 그것이 지능을 가졌는지 판정할 수 없다고 하였다.



● ‘중국어 방’ 사고 실험

2 인공지능의 이해

인공지능

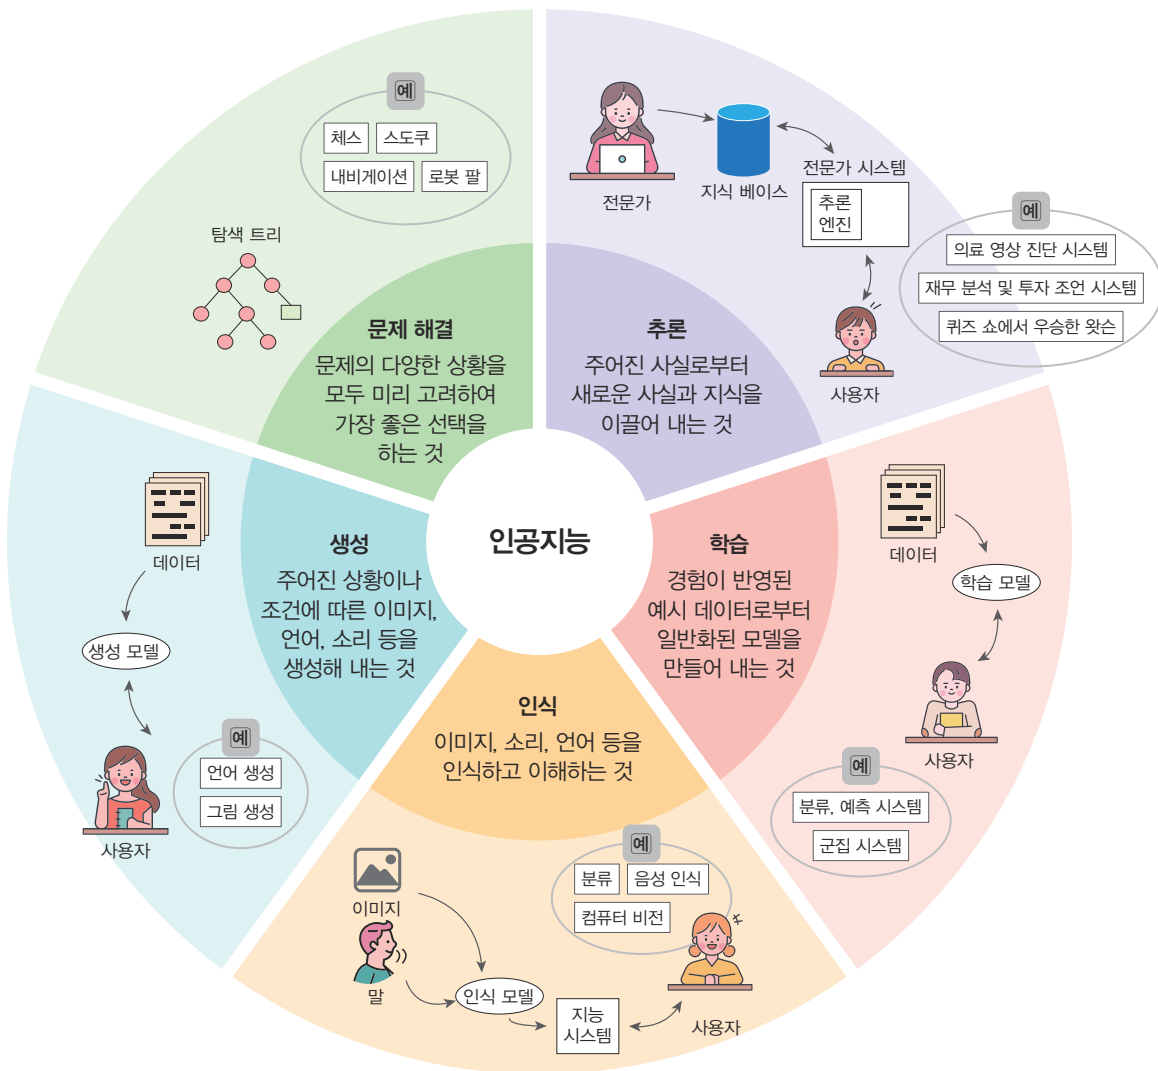
인공지능이라는 용어는 1956년 여름 미국 다트머스 대학교에서 마빈 민스키와 클로드 새넌 등 인공지능 및 정보 처리 이론에 지대한 공헌을 한 사람들이 개최한 학회에서 존 매카시가 처음 사용하였다.

인공지능(AI; Artificial Intelligence)은 인간의 지능적인 판단과 행위를 컴퓨터로 흉내 내어 구현한 것을 말한다.

1 인공지능의 개념과 특성

인공지능은 문제 해결, 추론, 학습, 예측, 인식, 생성 등과 같은 인간의 지능적 특성을 컴퓨터에서 모방하는 것을 말한다.


이러한 인공지능을 포함하고 있는 컴퓨터 시스템을 인공지능 시스템이라고 하는데 알파고, 자율주행 자동차, 챗봇, 맞춤형 상품 추천 시스템, 지능형 의료 영상 진단 시스템 등이 있다.




[그림 1-3] 인공지능 시스템의 특성 및 다양한 문제

자신의 스마트폰에 있는 앱을 실행하여 주변에 있는 다양한 식물의 이름을 알아보자. 앱에는 이미지로 정보를 검색해 주는 기능이 있다.

- 1 구글 또는 네이버 앱을 설치한 후 설치된 앱에서 렌즈 기능을 실행한다.



- 2 앱을 실행한 후 이름을 알고 싶은 식물을 촬영한다. 어떤 결과가 나오는지 확인해 보자.



구글 렌즈



네이버 스마트 렌즈

- 3 이외에도 번역과 쇼핑 등의 메뉴를 활용해 보자.

예 주변 사물을 촬영해서 서로 비교하거나 다른 나라 언어로 된 글을 번역해 보기



재미 놀이

AI 이야기

화성 탐사 로봇에게 필요한 지능적 특성



화성 탐사 로봇이 화성에 간 이유는 무엇일까?

과학자들은 오랜 세월 생명체가 존재하는 또 다른 지구를 찾기 위해 노력해 왔다. 그들은 생명체가 살 수 있는 적당한 온도와 물이 존재할 것으로 예상되는 행성으로 화성을 선택했고, 이곳에서 물이 흐른 흔적을 찾아 화성의 환경을 확인하는 탐사 로봇을 보냈다.



화성 탐사 로봇(큐리오시티)



화성 탐사 로봇에게 필요한 지능적 특성은 무엇일까?

- 문제 해결: 목표 탐사 지점까지 안전하게 이동하려면 다양한 변수를 고려한 경로를 설정해야 한다.
- 추론: 화성의 지질학적 특징을 분석하기 위해 수집된 데이터로 지질학적 구조를 추론할 수 있다.
- 학습: 수집된 데이터와 경험을 바탕으로 이동 경로를 재설정하고, 더 효율적인 자료 수집이나 경로 설정을 할 수 있다.
- 인식: 센서로 주변을 인식하고 장애물을 피하거나 이동할 수 있다.
- 생성: 수집된 데이터를 바탕으로 보고서를 쓰거나 지도를 작성할 수 있다.


2 인공지능의 문제 해결 사례



인공지능 기술은 다양한 분야에서 문제를 해결하고 있어요.

인공지능의 지능적 특성을 바탕으로 기존에는 해결하기 어렵거나 불가능했던 일들이 해결 가능해졌다. 다양한 분야에서 인공지능이 어떤 문제를 해결하는 데 활용되는지 사례로 알아보자.

의료 분야



엑스레이(X-ray)나 자기 공명 영상(MRI) 등의 의료용 이미지를 분석하여 의료 진단(분류와 예측), 암 치료 방법 제안(맞춤형 추천), 유전자 발견(탐색 발견) 등으로 의사의 진료를 돕고 있다.

교통 분야





실시간 교통 데이터를 분석(학습)하여 교통난을 해소하고 교통의 흐름을 원활하게 할 수 있는 방안을 제시(문제 해결)한다.

금융 분야



부적절한 사용자의 패턴 인식(분류), 대출 심사(맞춤형 평가), 금융 상품 추천(맞춤형 추천) 등의 분야에 이용한다.

환경 분야




노란색은 2007년까지, 빨간색은 2007년 이후의 산림 파괴 지역이다.

문화 · 예술 · 스포츠 분야



음악 작곡(생성), 미술 작품 제작(생성), 축구 · 야구 · 농구 · 배구 등에서 빅데이터 분석으로 선수들의 몸 상태 및 상대방의 전력 분석(예측) 등에 이용한다.

아마존 열대 우림을 보호하기 위해 위성 영상 데이터(학습)로 산림 파괴 지역을 모니터링하고, 적합한 대책을 수립하는데 도움을 준다. 또한 환경 데이터를 분석하여 대기질을 예측하고, 이를 토대로 새로운 환경 정책을 수립하는 데에 도움을 준다.



언어학 분야



새로운 방식의 소설 집필(생성)이나 다양한 문헌 분석(분류), 자동 번역(이해와 생성) 등에 이용한다.

맞춤형 추천 서비스



사용자가 들었던 음악이나 평소에 주문했던 제품 등의 과거 정보를 바탕으로(학습) 사용자가 좋아할 만한 새로운 제품이나 노래를 추천하는 데(맞춤형 추천) 이용한다.

과학 분야



물리적 사건 예측, 화학 반응 예측, 가상 화합물의 특성 예측, 단백질 구조 예측, 별과 은하 분류, 새로운 행성 탐색(탐색 발견) 등에 이용한다.

얼굴 사진 인식



사용자의 얼굴을 인식하여 특정 사용자를 구분(학습)하거나 표정 인식으로 감정의 변화를 인식하고, 세상에 없는 새로운 얼굴 이미지를 만들 수(생성) 있다.

사회 과학 분야



사람들이 만들어 내는 수많은 데이터를 분석하여(학습) 사회 변화를 예측하고 이해하는 데 도움을 준다.

스마트홈 디바이스



사용자의 생활 방식을 분석하여(학습) 집 안 온도를 자동으로 조절하는 등 개별화된 서비스를 제공한다.

튜링 테스트



▲ 앨런 튜링

자신의 논문 『컴퓨팅 기계와 지능』에서 기계에 지능이 있는지를 판단하기 위해 튜링 테스트를 제안하였다.

15쪽 [참고](#)




신경망 학습의 시작-퍼셉트론



신경망과 딥러닝의 가장 기본 단위인 퍼셉트론이 처음 만들어졌다.

127쪽 [참고](#)

◀ 프랭크 로젠블랫




결정트리



▲ 로스 퀴난

ID3이라는 결정트리 알고리즘을 발표하여 분류 모델 학습에 큰 기여를 하였다.

107쪽 [참고](#)



인공지능 용어의 등장

다트머스 회의에서 최초로 인공지능이라는 용어를 사용하였다.


16쪽 [참고](#)



역전파 알고리즘

다층 퍼셉트론을 학습시키는 알고리즘으로, 인공 신경망이 기계학습의 중심에 서게 했다.

136쪽 [참고](#)



1950

1956

1958

1966

1972

1980

1986

1996

1997



엘리자(ELIZA)

심리 상담 대화형 프로그램이 개발되었다.

센서와 카메라를 인식하고 경로를 계획하여 자율적으로 움직이는 지능형 로봇

1969

쉐이키(Shakey)
최초의 지능형 로봇이다.



북매치

아마존이 고객 데이터를 분석하여 제공한 책 추천 서비스이다.



마이신(MYCIN)

전문 의학 지식을 이용하여 감염성 혈액 질환을 진단하고, 적절한 항생제를 처방하는 데 도움을 주는 전문가 시스템의 한 예이다.

딥블루

세계 체스 챔피언 대회에서 최초로 인간 세계 챔피언을 이긴 컴퓨터이다.




딥러닝



심층 신경망을 이용한 딥러닝을 구현하였다.

[128쪽 참고](#)


◀ 제프리 힌턴



랜덤 포레스트

결정트리의 단점을 극복한 앙상블 모델이 등장하였다.

[107쪽 참고](#)




생성적 적대 신경망(GAN)



실제 이미지와 같은 이미지를 생성하였다.

[171쪽 참고](#)


◀ 이안 굿펠로우



트랜스포머 구조

BERT, GPT와 같이 대형 언어 모델을 훈련시키는 데 사용되며, 자연어 처리 분야에 큰 진전을 가져 왔다.

[158쪽 참고](#)



2014

2001

2006

2011

2016

2017

2020

2023

왓슨

문장으로 된 질문에 답하는 인공지능 시스템으로 2011년 제퍼디 퀴즈 쇼에 참가하여 인간 챔피언을 이겼다.



2014

알렉사(Alexa)
아마존에서 제작한 인공지능 비서가 탄생하였다.




GPT-3

인공지능 자연어 처리 모델(텍스트 생성, 번역, 요약)



GPT-4 멀티모달 인공지능
이미지를 보고 이해할 수 있다.



인공지능 바둑 프로그램 알파고
인간과 바둑 대결에서 인간 챔피언을 이겼다 (딥러닝, 기계학습).



3 인공지능 시스템의 이해


인공지능 시스템의 예

- 챗봇 시스템
- 맞춤형 도서 추천
- 알파고
- 자율주행 자동차

인공지능은 실제 제품에 사용되기 위해서는 그 자체보다는 컴퓨터 시스템 구조에 통합되어야 한다. 이러한 인공지능 시스템을 이해하기 위해 챗봇 시스템과 로봇 청소기의 구조를 살펴보자.

1 인공지능 시스템의 에이전트 구조


챗봇 시스템은 사용자와 대화를 주고받으면서 사용자의 만족도를 높이는 목표를 달성한다. 이 과정에서 챗봇은 사용자의 대화를 이해하고 의도를 파악하여 답변을 생성하는 지능적인 기능을 사용한다.



[그림 I-4] 챗봇 시스템의 구조

[그림 I-4]처럼 상대방이나 주변 환경과 반복적으로 상호 작용하면서 지능적인 판단과 행동으로 목표를 달성하는 구조를 가진 시스템을 지능형 에이전트라고 한다. 우리가 접하는 인공지능 시스템이나 서비스, 제품은 대부분 이러한 에이전트 구조를 가지고 있다. 지능 에이전트는 목적을 달성하기 위해 지능적이고 합리적인 판단과 행동을 자율적으로 수행한다.

지능 에이전트의 기본 구조



[그림 I-5] 실생활 속 지능 에이전트의 구조 및 활용의 예

2 인공지능 시스템의 특성

(1) 인공지능 기능을 가진 소프트웨어

소프트웨어 시스템은 여러 소프트웨어 구성 요소가 서로 상호 작용하여 특정 목표를 달성하기 위해 작동하는 것을 말한다. 인공지능은 그 안에서 지능적인 기능을 수행한다. 예를 들어 맞춤형 도서 추천 시스템에는 기존의 온라인 도서 쇼핑 시스템에 추가로 소비자의 구매 패턴에 따라 맞춤형으로 책을 추천해 주는 인공지능 기능이 들어가 있다.



[그림 1-6] 온라인 서점의 도서 추천 시스템



일반 소프트웨어와 인공지능 소프트웨어는 어떤 차이가 있을까?

구분	일반 소프트웨어	인공지능 소프트웨어
처리하는 일	단순한 자료 저장, 반복적인 계산, 고정된 반복과 선택	판단과 결정, 추론과 학습, 계획과 예측
분야	대량의 데이터 처리, 수식 계산 등	질병 진단, 맞춤형 추천, 문자와 음성 인식 등

(2) 자율적으로 판단하고 행동하는 지능 에이전트

지능 에이전트 형태의 인공지능 시스템은 스스로 판단하여 자율적으로 행동한다. 이때 주어진 목적을 효율적으로 달성하기 위한 방향으로 판단하고 행동한다. 그러한 판단과 행동은 일반적으로 추론, 학습, 문제 해결 전략, 인식과 이해 등을 포함한다.



(3) 실수 가능성이 있는 시스템

기계학습은 주어진 데이터에 맞추어진 모델을 만들기 때문에 개발자도 모델이 정확히 어떻게 동작할지 완전히 파악하기는 어렵다. 따라서 작은 오류와 실수를 예상하여야 하며, 어느 정도의 오류를 허용하는 곳에서 사용할 수 있다.



공항 안내 로봇은 공항 내에서 장애물을 피해 스스로 주행하고, 여객들의 질문에 응대하여 목적지까지 안내하는 지능적 기능이 있다. 이러한 지능적 기능이 있는 공항 안내 로봇을 인공지능 로봇이라고 한다. 이처럼 어떠한 제품이나 상품의 서비스에 인공지능이라는 이름이 사용되면 그 상품 안에 지능적인 기능이 있다고 생각할 수 있지만, 어떤 기능이 인공지능에 해당하는 것인지를 판단하기가 어려울 때도 있다.



1 우리가 주변에서 보는 서비스나 제품이 인공지능인지를 판단하여 보자.

보기

- ① 회계/세금 소프트웨어의 입력된 수치로 세금을 계산해 주는 기능
- ② 사람이 1시간 이상 방에 없으면 자동으로 꺼지는 에어컨
- ③ 눈에 있는 카메라로 사람의 얼굴을 인식하여 성별이나 나이에 따라 다른 웃음소리나 말을 하는 곰 인형
- ④ 버튼을 눌러서 계산하는 전자계산기
- ⑤ 리모컨으로만 움직이는 장난감 로봇

일반 소프트웨어	인공지능 소프트웨어

2 위 **보기**에 대하여 또 다른 인공지능 기능을 넣을 수 있을지 생각해 보고, 이유를 적어 공유해 보자.

예 지금까지의 지출 습관을 파악해서 지출에 대해 조언할 수 있는 기능(맞춤형), 계산할 것을 말로 이야기하면 간단한 대화로 결판 값을 말해 주는 계산기

인공지능의 성능을 겨루는 대회가 있다고?

지능형 에이전트 형태로 구현되는 인공지능의 성능을 겨루는 다양한 대회가 있다. 이 대회들은 전 세계의 인공지능 연구자들이 최신 기술을 경쟁하면서 발표하는 장으로 인공지능 분야의 발전을 이끌어 왔다. 이러한 대회는 특정한 목적을 달성하는 여부 정도를 에이전트가 만들어 내는 결과물들로 평가한다.

ImageNet Large Scale Visual Recognition Challenge(ILSVRC): 이미지넷(이미지 인식 대회)

컴퓨터 비전 분야에서 유명한 대회 중 하나인 이미지 인식 대회는 전체 약 1,400만 개 이상의 이미지를 사용하여 이미지 내의 개체를 인식하여 정확도를 겨루는 대회이다. 2010년부터 시작되어 2017년까지 매년 열렸으며, 2012년에 'AlexNet'이라는 딥러닝 모델은 다른 참가자들을 크게 앞선 성능으로 우승하였다. AlexNet의 성공은 전 세계 연구자들에게 딥러닝의 놀라운 가능성을 보여 주었다.

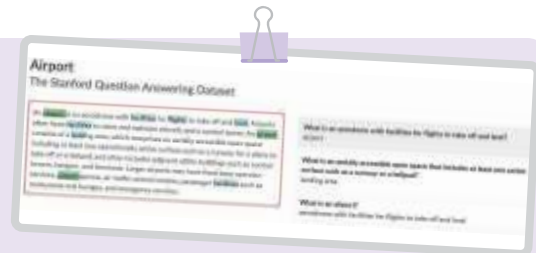


RoboCup: 로보컵

로보컵은 1996년 창설된 인공지능 로봇 대회로 경쟁 부문은 로봇 축구, 홈서비스, 산업 자동화, 재난 구호 등의 분야로 나누어지며 각 분야에서 인공지능의 성능을 겨룬다. 홈서비스 부문은 가정 환경의 인식, 사람과의 언어 및 비언어적 소통, 실내 공간의 자율주행과 로봇의 조작 능력 등을 평가한다. 로보컵 2023 홈서비스 부문에서 국내 대학 연합 팀이 1위를 차지하기도 했다.

Stanford Question Answering Dataset Challenge: SQuAD 대회(문장 독해력 대회)

미국 스탠퍼드 대학이 주최하는 자연어 처리 대회로 참가자들은 주어진 문장이나 문단에서 특정 질문에 대한 답을 정확히 찾아내는 능력으로 서로 경쟁한다. 최근에는 대한민국 팀도 참가하여 좋은 성적을 거두었다.



- 인공지능에서 탐색의 중요성을 이해하고 문제 해결을 위한 탐색 과정을 설계할 수 있다.
- 맹목적 탐색과 정보 이용 탐색의 차이를 중심으로 지능적 탐색의 원리를 파악할 수 있다.
- 지능적 탐색이 필요한 문제를 찾아보고 문제 해결을 위해 정보 이용 탐색 알고리즘을 적용할 수 있다.

인공지능과 탐색


학습 요소

문제 해결, 문제의 표현, 맹목적 탐색, 지능적 탐색



무엇을 배울까?

우리는 잘 모르는 곳에 갈 때는 스마트폰의 지도 앱으로 길을 검색한다. 앱으로 검색하면 출발부터 도착하는 데까지 걸리는 시간과 경로를 자세히 알 수 있다. 지도 앱은 어떻게 이런 정보를 안내할 수 있을까?



탐색 방법에는 맹목적 탐색, 정보 이용 탐색, 지능적 탐색 등 다양한데 각각 어떤 경우에 사용하는지 알아보자.




1 문제 해결과 탐색

‘문제’는 일상에서 여러 의미로 사용되지만, 인공지능에서는 ‘현재 상태와 목표 상태 사이에 차이가 있는 상황’을 말한다.

1 문제 해결

‘문제 해결’은 목표를 달성하는 것을 의미하는데, 현재 상태에서 시도할 수 있는 다양한 선택 중 가장 효율적인 선택을 하여 최종적으로 목표 상태에 이르게 하는 것이다. 예를 들어 집에서 학교로 갈 때, 현재 상태에서 학교에 갈 수 있는 가장 좋은 경로를 찾아 도착(목표 상태)하는 것이 이에 해당한다.



[그림 1-7] 문제 해결 사례


상태

문제의 어느 한 순간의 모습을 말한다.

- 초기 상태: 문제가 시작하는 상태이다.
- 현재 상태: 진행 과정에서 현재의 상태이다.
- 목표 상태: 달성해야 하는 목표를 나타내는 상태이다.

2 탐색

일반적으로 사용되는 문제 해결 기법은 ‘탐색’인데, 탐색 기법은 문제의 해결책을 더 빠르고 효율적으로 찾기 위해 다양한 알고리즘을 사용한다. 여러 탐색 방법 중의 하나인 경로 탐색은 초기 상태에서 목표 상태까지의 다양한 경로 중에서 가장 효율적인 경로를 찾는 탐색을 말한다. [그림 1-7]을 보면 집에서 학교로 가는 방법에는 다양한 경로가 있다. 그중에서 가장 효율적인 경로를 선택하기 위해 장소에서 장소를 이동하는 시간을 측정하거나 최소한으로 장소를 거치는 방법이 있다. 이렇게 문제를 해결하기 위해서는 [그림 1-8]과 같은 과정을 거쳐야 한다.



[그림 1-8] 문제 해결 과정

탐색

주어진 상태에서 선택할 수 있는 경로를 빠르게 살펴보고 답에 이르는 최적의 길을 찾는 것이다. ‘탐색’은 단순 반복 계산에 강한 컴퓨터의 강점을 잘 활용한 문제 해결 전략이다.

간선


상태들 사이의 연결선으로 한 상태에서 다른 상태로 가기 위한 조건 혹은 행동을 나타낸다.

3 문제의 표현

주어진 문제를 ‘탐색’의 문제로 보고 해결하려면 문제를 탐색 가능한 형태로 다시 표현해야 한다. 이때 가장 일반적인 형태는 트리 구조이다.



① 집에서 마트까지 가는 길



[그림 1-9] 트리 구조

초기 상태에서 출발하여 간선을 따라 다음 상태로 이동하다가 목표 상태에 도달하면 경로가 구해지므로 문제가 해결된 것이다.

8퍼즐

비어 있는 칸으로 숫자 타일을 한 칸씩 움직여 원하는 위치로 배치하는 퍼즐이다.



8퍼즐을 해 보자.
<http://bit.ly/8PuzzleGame>

예제

안내를 참고하여 경로 탐색 문제인 8퍼즐로 문제 표현 과정을 알아보자.

안내 탐색으로 문제를 해결하기 위한 문제 표현 과정

- 단계 ①** 상태 정의: 상태를 정의하고, 그중에서 초기 상태와 목표 상태를 설정한다.
- 단계 ②** 간선 정의: 하나의 상태부터 그 다음 상태로 가기 위한 간선을 정의한다.
- 단계 ③** 탐색 트리 구성: 초기 상태에서 목표 상태까지 진행하면서 효율적으로 도달하기 위한 탐색 트리를 구성한다.

단계 ① 상태 정의

상태는 문제의 어느 한 순간의 모습을 말하는데, 8퍼즐의 가능한 숫자 타일 위치를 하나의 상태로 볼 수 있다.

- 초기 상태: 어떤 상태에서도 시작할 수 있으므로 타일 하나를 정한다.
- 목표 상태: 도달하고자 하는 상태를 정의한다.

2	8	3
1		4
7	6	5

① 초기 상태

8퍼즐을 시작하는 상태이다.


1	2	3
8		4
7	6	5

② 목표 상태

8퍼즐이 해결된 상태이다.

단계 ② 간선 정의


실제 모든 숫자 타일의 이동을 간선으로 정의할 수 있지만, 다른 관점에서 생각하면 빈칸이 위, 아래, 오른쪽, 왼쪽으로 이동한다고 볼 수 있다. 따라서 빈칸의 이동 방향인 네 방향을 간선의 조건 혹은 행동으로 정의한다.



단계 ③ 탐색 트리 구성

초기 상태에서 간선의 정의에 따라 자식 상태가 생성되고, 점차 탐색 트리가 확장되면서 목표 상태의 탐색이 진행된다.

상태와 간선으로 이루어진 상태 공간을 탐색을 위한 트리 형태로 나타내면 다음과 같다.



전체 탐색 트리를 완성한 후에 탐색을 실행하는 것이 아니라 탐색을 진행하면서 탐색 트리를 확장해요.

2 맹목적 탐색

맹목적 탐색은 문제에서 사전에 주어진 정보만 가지고 모든 상태를 하나씩 테스트하면서 목표 상태를 찾는 전략이며, 무정보(uninformed) 탐색 전략이라고도 한다. 맹목적 탐색의 경우 탐색에 사용할 아무런 정보가 없을 때와 비용 정보가 사전에 주어질 때로 나눌 수 있다.

예제 안내를 참고하여 8퍼즐로 너비 우선 탐색(BFS) 알고리즘을 알아보자.

초기 상태

2	8	3
1		4
7	6	5



안내 너비 우선 탐색 알고리즘


- 초기 상태가 목표 상태이면 마친다.
- 초기 상태에서 갈 수 있는 간선에 따라 자식 상태를 생성한다.
- 다음 순서의 상태가 목표 상태 인지 테스트한다.
 - 목표 상태이면 작업을 끝낸다.
 - 목표 상태가 아니면 자식 상태를 생성하고, 다음 순서의 상태를 테스트한다(③을 반복한다.).

초기 상태

2	8	3
1		4
7	6	5

목표 상태


1	2	3
8		4
7	6	5



알고리즘을 이용하여 탐색을 시작해 봐요. 이때 빈칸의 이동 방향을 고려하도록 해요.

1 주어진 비용 정보가 없을 때의 탐색

아무 정보가 주어지지 않은 경우에는 모든 간선의 비용이 1이라고 가정하고, 상태를 모두 하나씩 순서대로 테스트해야 한다. 트리 가장 위에서부터 차례대로 각 깊이(레벨)별로 테스트하면서 내려오는 순서대로 진행하는 것을 ‘너비 우선 탐색(BFS; Breadth-First Search)’이라고 한다. 너비 우선 탐색은 트리의 초기 상태에서 하나씩 깊이가 내려가고, 각 깊이에서는 왼쪽부터 오른쪽 방향으로 차례로 진행하면서 목표 상태를 찾는다.





너비 우선 탐색

- 트리에서 너비, 즉 가로 방향으로 먼저 진행하면서 목표 상태를 탐색한다.
- 탐색 순서: a-b-c-d-e-f

깊이 우선 탐색

- 트리에서 깊이, 즉 세로 방향으로 먼저 진행하면서 목표 상태를 탐색한다.
- 탐색 순서: a-b-d-e-c-f



일반적으로 상태의

수가 많은 문제는 상태 공간도 크기 때문에 완전한 탐색 트리를 완성시킨 다음에 탐색을 시작하는 것은 비효율적이거나 불가능해요. 따라서 대 단계에서 상태가 목표 상태인지 테스트하는 과정을 반복하면서 진행해요.

- **누적 비용:** 초기 상태에서 현재 상태까지 오는 경로의 누적된 비용의 합을 말한다.
- **균일 비용 탐색:** 누적 비용 값을 평갯값으로 사용하는 최상 우선 탐색이다.
- **오픈(open) 리스트:** 목표 상태인지 테스트할 후보 상태들을 임시로 보관하고 있는 대기실이다. 이 중에서 테스트가 끝난 상태는 닫힌(closed) 리스트로 옮긴다.
- **최상 우선 탐색:** 상태를 선택할 때, 각 상태에게 주어진 평갯값에 따라 평갯값이 좋은 것부터 순서대로 탐색하는 것이다.


2 비용 정보가 주어졌을 때의 탐색

탐색으로 문제를 해결하려고 할 때, 하나의 상태에서 다른 상태로 이동하기 위해 필요한 조건이나 행동의 비용이 다를 때가 있다. 문제에서 간선의 비용 정보가 주어졌으며, 목표 상태에 이르는 총비용이 가장 작은 경로를 찾고자 한다면 비용이 작은 경로를 먼저 탐색하는 것이 더 효율적이다.

현재 상태에서 그 다음 상태를 선택할 때, 누적 비용의 값을 확인하여 그 값이 가장 작은 상태를 먼저 선택하는 순서로 탐색을 진행하는 알고리즘을 ‘균일 비용 탐색’이라고 한다. 균일 비용 탐색은 생성된 상태들 중에서 아직 목표 상태인지 테스트되지 않은 모든 상태를 오픈 리스트에 넣고, 그중에서 총 누적 비용이 가장 작은 상태를 먼저 선택한다. 만약 모든 비용이 같다면 균일 비용 탐색은 너비 우선 탐색과 동일하게 진행한다.

예제 다음 **문제 상황**으로 균일 비용 탐색 알고리즘을 알아보자.

문제 상황 a, b, c, d, e라는 다섯 곳의 도시를 연결하는 도로망이 만들어졌을 경우, 도시 a를 출발하여 도시 e까지 가는 경로 중에서 시간이 가장 짧은 경로를 찾고자 한다. 도시 간 연결선의 숫자는 비용에 해당하고 도시 간을 이동하는 데 걸리는 시간을 의미한다.



[그림 1-10] 도시 간 이동 시간

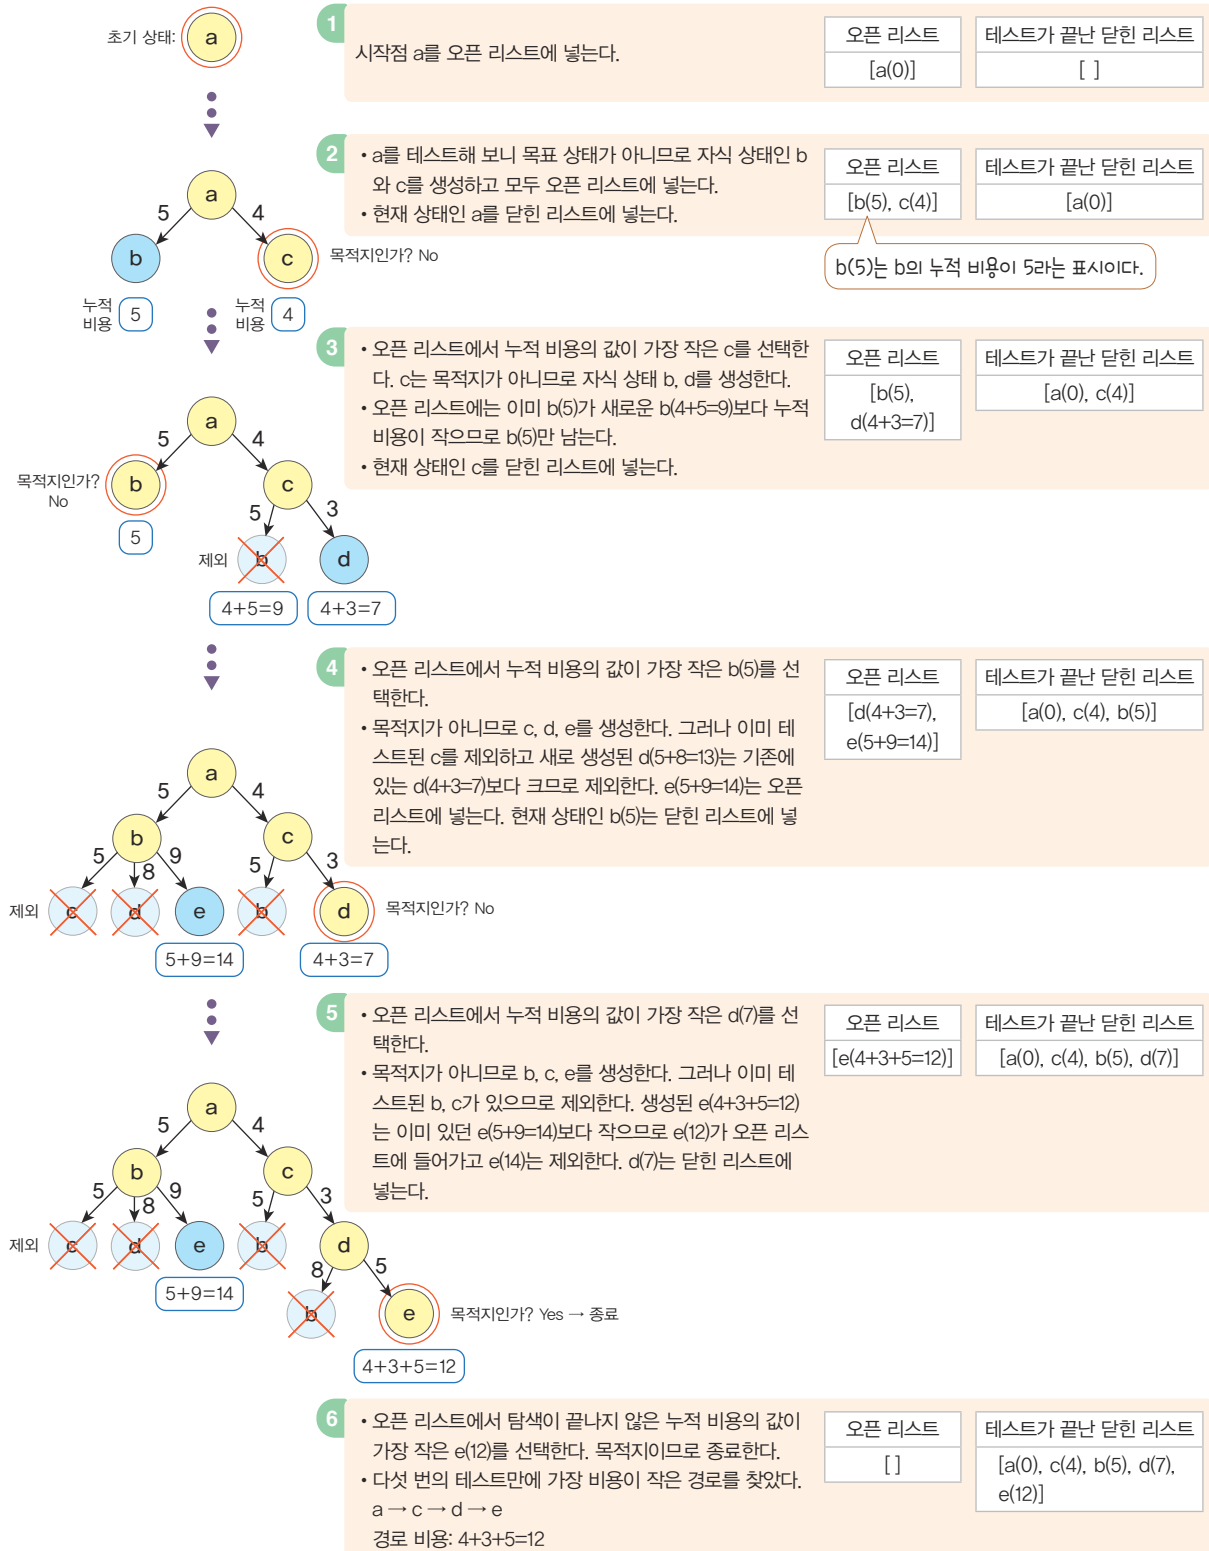


다음 **안내**에 따라 도시 방문 경로 찾기 문제를 균일 비용 탐색 트리로 나타내 보자.

안내 균일 비용 탐색 알고리즘

- ① 초기 상태가 목표 상태이면 마친다.
- ② 초기 상태에서 갈 수 있는 간선에 따라 자식 상태를 생성하여 오픈 리스트에 넣는다.
- ③ 오픈 리스트에서 누적 비용의 값이 가장 작은 상태를 다음 순서로 선택한다.
- ④ 선택된 상태가 목표 상태인지 테스트한다.
 - 목표 상태이면 작업을 끝낸다.
 - 목표 상태가 아니면 자식 상태를 생성하여 오픈 리스트에 넣고 ③으로 돌아간다.
 이때 오픈 리스트에 똑같은 상태 노드가 있으면 그중에 더 작은 비용을 가지는 상태만 남겨 둔다.

균일 비용 탐색 알고리즘 진행 과정



3 지능적 탐색

탐색 시간을 더 줄이기 위해 주어진 비용 정보 이외에도 추정된 정보를 사용할 수 있다. 이러한 추정된 비용 정보를 이용하는 것을 지능적 탐색이라고 한다.

1 맹목적 탐색의 문제

트리 구조에서 탐색할 때 너비 우선 탐색은 목표 상태를 만날 때까지 하나씩 순서대로 테스트하기 때문에 다음과 같은 장단점이 있다.

[표 1-1] 맹목적 탐색의 장단점

맹목적 탐색의 장점	맹목적 탐색의 단점
• 목표 상태를 언젠가 찾는다라는 것이 보장된다. • 목표 상태가 여러 개 있을 때, 너비 우선 탐색은 경로의 길이가 가장 짧은 목표를 찾아 준다.	• 상태 수가 많을수록 탐색 시간이 늘어난다. 예 상태 공간의 크기 - 8 퍼즐: $9! = 362,880$ - 15 퍼즐: $15! = 1,307,674,368,000$ - 24 퍼즐: 6.2×10^{23} - 바둑: $3^{361} \sim 10^{360}$ (우주에 있는 분자의 개수 10^{80} 과 비교)

탐색 방법의 평가 기준

- 완전성: 목표 상태가 있다면 언젠가는 찾는다라는 것을 보장한다.
- 최적성: 목표 상태가 여러 개일 때는 그중에 가장 좋은 것을 찾는다라는 것을 보장한다.
- 시간 복잡도: 현실적으로 가능한 시간 내에 목표 상태를 찾아야 한다.

상태 수가 많아질수록 탐색 시간이 늘어나기 때문에 알고 있는 여러 정보를 사용하기도 하고 추정 지식을 사용하여 탐색 시간을 줄이려고 노력한다. 주어진 정보 외에도 문제에 대해 알고 있는 경험적 지식을 평갓값으로 추정하여 탐색에 사용하는 것을 지능적 탐색이라고 한다.




'순회 외판원 문제'와 시간 복잡도

임의의 도시에서 출발하여 모든 도시를 한 번씩만 모두 다 방문하여 출발 도시로 돌아오는 가장 짧은 경로를 찾는 문제를 '순회 외판원 문제'라고 한다. 다음의 문제를 보고 해결 방법을 생각해 보자.

문제 오른쪽 그림과 같이 네 곳의 도시(A, B, C, D)가 있다. 모든 도시를 한 번씩 방문하는 경로는 모두 몇 개일까?

풀이 도시가 네 곳이므로 경로의 수는 $4! = 4 \times 3 \times 2 \times 1 = 24$ 가지이다. 도시가 다섯 곳으로만 늘어나도 경로의 수는 120가지로 되고, 10곳이면 3,628,800가지로 급격히 늘어난다. 도시가 늘어나면 경로의 수가 너무 많아져서 답을 얻을 수 없는 경우가 생긴다. 이러한 문제를 '가능하지만 실제로는 불가능한 문제'라고 한다.



2 비용의 추정값을 이용한 탐색

(1) 휴리스틱값


탐색 시간을 더 줄이기 위해 경험적인 추정값을 추가로 사용할 수도 있는데, 이러한 탐색 기법을 휴리스틱(heuristics) 탐색이라고 한다.

휴리스틱은 어떤 문제 해결을 위해 알고 있는 경험적 지식을 말한다. 탐색을 할 상태를 선택할 때 목표 상태까지의 예상 비용을 추정하여 사용하는데, 이를 그 상태에서의 휴리스틱값이라고 한다.



도시 방문 경로 찾기(☞ 32쪽 참고)에서 휴리스틱값은 어떻게 사용될까?

균일 비용 탐색 알고리즘에서 보았던 도시 방문 경로 찾기 문제는 각 도시에서 목표 도시(목적지)까지의 '직선거리'를 실제 거리의 추정값인 휴리스틱값으로 사용할 수 있다.



[그림 1-11] 휴리스틱값 예시




휴리스틱값은 경험적 지식을 말하는 것이므로, 사람마다 다르게 정의할 수 있어요.



틱택토 게임에서의 휴리스틱 함수는 어떻게 사용될까?

틱택토 게임에서는 내가 어느 위치에 돌을 놓았을 때 그것을 포함하여 이길 수 있는 선의 개수를 휴리스틱 함수, 즉 이길 수 있는 예측값으로 사용할 수 있다. 그것을 함수로 정의한 것을 휴리스틱 함수라고 한다.




[그림 1-12] 틱택토 게임에서의 휴리스틱 함수 사용 예

(2) A* 탐색

다양한 탐색 방법


- $g(n)$ 값만 사용하여 최상 우선 탐색 방법을 사용한 것은 '균일 비용 탐색'이다.
- $h(n)$ 값만 사용하여 최상 우선 탐색 방법을 사용한 것은 '탐욕적 최상 우선 탐색'이다.
- $f(n)=g(n)+h(n)$ 값을 사용하여 최상 우선 탐색 방법을 사용한 것은 'A* 탐색'이다.

휴리스틱과 같은 지능적 정보를 사용하는 탐색 알고리즘으로 대표적인 것이 A* 알고리즘이다. 이 방법은 탐색을 진행할 때 목표 상태인지 테스트할 상태를 선택할 때에 '초기 상태에서 현재 상태까지의 비용 값'과 '현재 상태에서 목표 상태까지의 비용 추정값'을 합한 값을 사용하여 최상 우선 탐색 방식으로 탐색한다. A* 알고리즘을 사용하면 모든 상태를 다 검토하는 대신에 휴리스틱값과 누적 비용값을 사용하여 빠르고 효율적으로 탐색한다.



[그림 I-13] A* 탐색에서 각 상태의 비용값과 휴리스틱값

33쪽 균일 비용 탐색에서 보았던 도시 방문 경로 찾기 문제(☞ 32쪽 참고)를 A* 탐색을 적용하여 목표 상태에 이르는 과정을 알아보자. 각 도시에서의 f 값은 '(초기 상태에서 후보 상태까지의 비용 값)+(휴리스틱값)'이다. 예를 들면 a에서 b로 간 경우 비용은 5이고 b의 휴리스틱값은 9이므로 b의 f 값은 $5+9=14$ 가 된다.



[그림 I-14] A* 탐색에서의 휴리스틱값 사용



균일 비용 탐색에서는 5개의 상태를 테스트했지만 A* 탐색에서는 4개의 상태만을 테스트해서 더 효율적으로 탐색을 진행했어요!

- 1 초기 상태와 목표 상태는 다음과 같다. 2 휴리스틱값을 어떻게 정할까?

2	8	3
1	6	4
7		5

초기 상태

1	2	3
8		4
7	6	5

목표 상태

$$f(n) = g(n) + h(n)$$

- $f(n)$: 최종 비용 추정치
- $g(n)$: 초기 상태에서 현재 상태까지의 비용
- $h(n)$: 휴리스틱값, 목표 상태와 일치하지 않는 숫자 타일의 수(공백 제외)

예 현재 상태


2	8	3
1		4
7	6	5

목표 상태

1	2	3
8		4
7	6	5

- 일치하는 타일의 번호: 3, 4, 5, 6, 7
- 일치하지 않는 타일의 번호: 1, 2, 8
- 따라서 $h(n) = 3$

- 3 빈 타일을 옮기는 순서는 위쪽, 아래쪽, 왼쪽, 오른쪽(UP, DOWN, LEFT, RIGHT)을 적용하면서 □ 안의 타일에 들어갈 값을 적어 보자.




4 탐색의 다양한 문제 해결 사례

탐색이 적용될 수 있는 문제와 그것을 해결하기 위한 탐색 전략은 다양하다. 경로 탐색 이외에도 여러 다른 탐색 전략이 있으며 다양한 문제를 해결하는 데 사용된다.

1 경로 탐색

문제를 상태와 간선으로 정의하고, 탐색 알고리즘을 적용하여 지도나 미로와 같이 초기 상태와 목표 상태가 주어졌을 때에 가장 효율적인 경로를 찾는다. 대표적인 알고리즘은 A* 알고리즘이다.

사례 1 경로 찾기 문제




캐릭터가 시작 위치에서 목표 위치까지 가장 빠른 경로를 찾을 때 A* 알고리즘을 사용한다. 지도의 각 위치는 트리의 노드처럼 취급하며, 연결된 경로는 간선으로 취급한다.

사례 2 항공 경로 계획



각 공항을 노드로, 두 공항 간의 가능한 비행 경로를 간선으로 생각하고, A* 알고리즘을 사용하여 최적의 경로를 찾을 수 있다.



2 게임 트리 탐색

‘적대적 트리 탐색’이라고도 부른다. 바둑을 둘 때 나에게 유리한 위치에 돌을 놓지만 상대방은 나에게 불리한 위치에 돌을 놓는다. 내가 이기기 위해서는 나와 상대방의 모든 가능한 상태를 테스트하여 가장 유리한 위치를 결정한다. 그러기 위해서 휴리스틱 함수와 Min-Max 알고리즘([39쪽 참고](#))을 사용한다. 최근에는 확률적인 방법과 강화 학습([91쪽 참고](#))의 기법을 적용하기도 한다.

사례 1 대화 시스템 및 협상



대화나 협상하는 상황에서는 상대방의 반응을 예측하고 자신의 말을 결정해야 한다. 이런 상황에서도 게임 트리와 같은 구조를 사용하여 가능한 말과 반응을 예측하고 가장 알맞은 대화 전략을 찾을 수 있다.

사례 2 체스 게임



컴퓨터는 다음 수를 결정하기 위해 게임 트리를 사용한다. 체스는 움직임이 너무 많으므로 모든 움직임을 탐색하는 것은 실제로 불가능하다. 따라서 컴퓨터는 몇 단계 앞만 보고, 그중에서 가장 좋다고 판단되는 움직임을 선택한다.

3 지역 탐색

상태 공간이 너무나 커서 목표 상태가 무엇인지 모를 경우도 있다. 단, 여러 상태를 비교하여 어느 것이 더 좋은 것인지 평가할 수 있으면 하나의 상태에서 시작하여 주변의 조금 더 좋은 상태로 이동하는 과정을 반복한다.

이처럼 주어진 조건에서 최대한 좋은 상태를 찾아가는 것을 ‘지역 탐색’ 혹은 ‘국지적 탐색’이라고 한다. 지역 탐색은 주어진 시간과 조건으로 충분히 좋은 목표 상태를 찾는 경우에 유용하다.

대표적인 알고리즘으로 ‘언덕 오르기 탐색’, ‘유전자 알고리즘’ 등의 최적화 알고리즘을 사용한다.

유전자 알고리즘


생물학적 진화의 원리를 기반으로 한다. 문제를 해결할 때 여러 가지의 후보로 구성된 집단을 생성하고, 이들 집단 간의 교차, 변이, 선택 연산을 반복적으로 수행하여 다음 세대의 새로운 답의 후보를 생성하며 최적화 문제의 답을 찾는다.

최적화 알고리즘

주어진 문제의 가능한 답 중에서 가장 좋은 답을 찾는 알고리즘을 뜻한다. 문제 정의에 따라 ‘가장 좋은’의 기준은 달라질 수 있다.

사례 1

단백질 폴딩



생물학에서 단백질의 접힘 구조는 그 단백질의 기능을 이해하는 데 필수적이다. 지역 탐색을 사용하여 단백질이 특성 조건에 반응하여 취할 가능성이 있는 구조를 찾을 수 있다.

사례 2

항공사의 비행 일정 최적화



항공사들은 현재의 일정을 약간 변화시켜 전체 비용을 줄이는 방향으로 효율적인 일정을 빠르게 찾아낼 수 있다.

활동

4

틱택토 게임 진행하기

틱택토(Tic-Tac-Toe) 게임은 3×3 격자판에 두 명의 플레이어가 번갈아 가며 빈칸에 ‘O, X’를 놓는 게임이다. 가로, 세로 또는 대각선으로 3개의 글자를 먼저 표시하면 이기는 게임이다. Min-Max 알고리즘을 적용하여 만든 다음 사이트에서 게임을 진행해 보고, 컴퓨터를 이길 수 없다면 그 이유를 설명해 보자.

<https://josephpetitti.com/tic-tac-toe>

예 컴퓨터는 Min-Max 알고리즘을 적용하여 모든 가능한 수를 탐색하므로 플레이어는 게임에서 지거나, 비기는 것 두 가지 밖에 할 수 없다.

Min-Max 알고리즘

최적의 수를 선택할 수 있도록 자신의 최대 이익을 확보하고 상대방의 이익을 최소화하는 방식이다.

탐색 분석 발표





파이썬 코딩을 통한 지능적 탐색의 원리 (실제 사이트 실행하기)

탐색

개발

분석

1 크롬 브라우저에서 구글 계정으로 로그인한다.

2 아래 주소를 입력하여 구글 코랩에서 열고, [파일-Drive에 사본 저장] 버튼을 눌러 코랩 파일 사본을 만든다.

 https://bit.ly/search_ipynb

3 각각의 탐색 방법을 8퍼즐에 적용해 본다. 각 탐색 방법의 주석을 해제하고 셀을 실행한다.

(1) 맹목적 탐색

주어진 비용 정보가 없을 때의 탐색

너비 우선 탐색 알고리즘	깊이 우선 탐색 알고리즘
<pre># print("BFS") # dfs(start_state, goal_state)</pre>	<pre># print("DFS") # ucs(start_state, goal_state)</pre>

비용 정보가 주어졌을 때의 탐색

균일 비용 탐색 알고리즘
<pre># print("UCS") # dfs(start_state, goal_state)</pre>

(2) 지능적 탐색

A* 탐색
<pre># print("Astar") # astar(start_state, goal_state)</pre>

4 초기 상태와 목표 상태를 변경하고 3처럼 각 탐색 방법을 적용해 본다.

초기 상태	목표 상태
<pre>start_state = [2, 8, 3, 1, 6, 4, 7, 0, 5]</pre>	<pre>goal_state = [1, 2, 3, 8, 0, 4, 7, 6, 5]</pre>

인공지능

인간처럼 생각하는 프로그램을 만드는 분야입니다.
사람보다 더 지능적인 미래의 시스템을 만들어 나갈
거예요.

필요한 역량

알고리즘 지식, 프로그래밍, 창의성, 데이터 분석 능력



커리어넷
<https://www.career.go.kr/>

자연어 처리 전문가

컴퓨터가 사람의 언어를 이해하고 생
성할 수 있도록 연구하고, 응용 프로그
램을 개발한다. 자동 번역 시스템, 챗
봇 등 다양한 분야에서 인간과 컴퓨
터 간의 소통을 혁신적으로 변화시키
는 역할을 담당한다.

인공지능 연구원

인공지능 연구원은 컴퓨터
시스템이 인간처럼 학습하
고 판단할 수 있도록 하는 인
공지능 기술을 연구하고 개발
하는 직업이다. 다양한 분야
에서 혁신을 이끄는 중요한
역할을 담당한다.



지식의 표현과 추론

학습 요소

추론, 지식 표현 방법,
인공지능 추론 시스템



무엇을
배울까?

이미 어떤 지식이 머릿속에 있다면 우리는 이를 활용하여 새로운 사실을 알아낼 수 있다.

과일 바구니 퍼즐

네 개의 바구니가 있고, 각 바구니에는 사과, 바나나, 오렌지, 체리 중 한 가지가 들어 있어요.
[힌트]를 보고 각 바구니에 어떤 과일이 들어 있는지 맞춰 보세요.


- [힌트] ①번 바구니에는 오렌지가 들어 있지 않습니다.
②번 바구니에는 바나나가 들어 있습니다.
사과는 ①번 바구니 또는 ③번 바구니에 들어 있습니다.
④번 바구니에는 바나나가 들어 있지 않습니다.
체리는 ①번 또는 ④번 바구니에 들어 있습니다.
③번 바구니에는 오렌지가 들어 있습니다.



①



②



③



④



인공지능 연구자들은 지식을 어떻게 컴퓨터에 저장하고 활용할 수 있을지에 관심을 가졌으며, 이를 토대로 컴퓨터가 자동으로 지식과 사실로부터 새로운 지식과 결론을 논리적으로 이끌어 내는 추론 시스템을 개발하는 데 노력해 왔다. 컴퓨터에서 지식 표현과 추론을 어떻게 구현할까?

1 인공지능과 지식 추론

1 추론의 개념과 과정

추론은 ‘어떠한 판단을 근거로 삼아 다른 판단을 이끌어 냄’을 의미하는데 인간의 지능에서 가장 핵심적인 기능이다. 추론을 위한 다양한 접근 방법 중 인간과 인공지능에서의 연역적 추론 방법에 대해 알아보도록 한다.

추론 방법

- 연역적 추론
- 귀납적 추론

(1) 철학과 논리학에서의 연역적 추론

인간은 고대 그리스 시대부터 사고 과정을 추론의 관점에서 탐구하여 정의하고자 하였다. 주로 연역적 추론을 다루는 이유는 명확하고 명시적인 논리적 추론 전개 방식을 따르고 있기 때문이다.




아리스토텔레스가 논리학에서 이룩한 가장 중요한 업적은 삼단 논법 학설이다. 이 논증은 대전제, 소전제, 결론 세 부분으로 구성된다.

[그림 1-15] 아리스토텔레스 논리학 중 삼단 논법

(2) 인공지능에서의 연역적 추론

초기 인공지능 학자들은 인간의 논리적 추론 방식을 컴퓨터로 구현하여 흉내내는 인공지능을 설계하고자 하였다. 그 기본적인 형태는 [그림 1-16]과 같다.



사용자가 A라는 사실을 지식 베이스에 넣으면 지식 베이스 안의 논리 표현에 따라서 A이기 때문에 B가 되고, 다시 B이기 때문에 F가 되는 논리적 추론 과정을 거쳐서 F라는 결과가 나올 수 있다.

[그림 1-16] 인공지능의 논리적 추론 과정

연역적 추론을 흉내 내는 지식의 추론 과정을 살펴보면 다음과 같다.

지식의 추론 과정

- ① 정제된 형태의 지식이 저장된 지식 베이스가 있다.
- ② 새로운 사실(지식)이 들어오면 지식 베이스에 있는 기존 지식들을 기반으로 논리적 추론 규칙을 적용하여 새로운 사실·지식을 생성한다.

2 추론을 위한 지식 표현

지식 기반의 인공지능을 만들려면 컴퓨터를 이용하여 지식을 처리하고 저장할 수 있어야 한다. 이에 논리, 규칙 등을 이용하여 지식을 기호화해 컴퓨터에 저장하고 이를 통해 새로운 사실을 추론해 낸다.

[표 I-2] 컴퓨터의 지식 표현 방법

명제 논리	술어 논리	규칙	의미망	지식 그래프
기호를 사용하여 명제를 표현하는 방법이다.	명제 논리를 확장한 것으로, 술어와 변수를 사용하여 개체와 그들의 속성, 관계를 표현한다.	조건과 행동을 서술하는 표현 방법이다.	거미줄과 같은 구조로 개념 간의 관계를 나타내는 표현 방법이다.	정보를 그래프의 형식으로 나타내는 표현 방법이다.

(1) 명제 논리

논리학에서 명제는 참 또는 거짓을 판별할 수 있는 문장을 뜻한다. 명제 논리는 기호를 사용하여 명제를 표현하며 논리 부정, 논리합, 논리곱, 조건 또는 함축 등의 논리 연산으로 지식을 표현한다. 예를 들어 [표 I-3]처럼 ‘비가 온다.’의 명제는 기호 A, ‘습도가 높아진다.’의 명제는 기호 B, ‘나는 우산을 가지고 있다.’의 명제는 기호 C로 나타낸다면 논리 연산자를 이용하여 [표 I-4]와 같이 복합 명제로 표현할 수 있다.

[표 I-3] 지식을 명제 논리로 표현한 예

명제 기호	명제
A	비가 온다.
B	습도가 높아진다.
C	나는 우산을 가지고 있다.

[표 I-4] 복합 명제 논리로 표현한 예

연산자	복합 명제 기호	복합 명제
논리 부정	NOT A	비가 오지 않는다.
논리곱	A AND B	비가 오고 습도가 높아진다.
논리합	A OR C	비가 오거나 나는 우산을 가지고 있다.
조건 또는 함축	$A \rightarrow B$	비가 오면 습도가 높아진다.

주어는 대상을 말하고, 술부는 그 대상에 대한 설명, 행동, 상태를 나타내는 부분이다.

예 문장: 모든 사람은 죽는다.

모든 사람은 죽는다.


↓
주어

↓
술부

(2) 술어 논리

문장을 주어와 술부로 나누고 변수와 한정자의 개념을 도입해 논리를 표현하므로 지식을 명제 논리에 비해 훨씬 간결하고 풍부하게 표현할 수 있다.

술어 논리의 형식과 이 형식을 사용하여 표현한 예는 다음과 같다.



① 술어 논리의 형식

지식	술어 논리 표현
날씨(오늘, 비)	오늘 비가 온다.
사용(나, 오늘, 우산)	나는 오늘 우산을 쓰고 있다.
사용(Jane, 어제, 우산)	Jane이 어제 우산을 썼다.
$\forall x, \exists y, \text{사용}(x, y, \text{우산}) \rightarrow \text{날씨}(y, \text{비})$	모든 사람이 어떤 날에 우산을 쓰고 있다면, 그 날에는 비가 내리고 있다는 것이다.

② 술어 논리 표현의 예

술어 논리 한정자


• $\forall$: 모든(전칭 기호)

• $\exists$: 어떤(존재 기호)

예 $\forall x$: 모든 x 에 대하여

$\exists y$: 어떤 y 에 대하여

이와 같은 술어 논리를 이용하여 추론하는 예는 다음과 같다.



③ 술어 논리를 사용한 추론의 예

[그림 1-17] 술어 논리의 다양한 예

프로그 언어는 술어 논리를 프로그래밍 언어로 작성하며, 이를 통해 새로운 사실의 추론을 질문하여 수행할 수 있어요.

[50쪽 참고](#)

(3) 규칙

‘~이면 ...이다.’ 또는 ‘~하면 ...한다.’와 같이 조건과 행동을 서술하는 표현 방법을 규칙이라고 한다. IF~THEN 형태로 표현된 규칙은 매우 직관적이기 때문에 이런 형태의 지식은 규칙으로 쉽게 표현하고 이해할 수 있다. [표 1-5]의 예로 지식을 규칙으로 표현하는 방법을 알아보자.

[표 1-5] 규칙 사용 예

조건	IF	신호등이 녹색불이다.
행동	THEN	횡단보도를 건넌다.

또한 조건이나 전제가 여러 개일 경우에는 논리 연산자인 AND(그리고), OR(또는)를 사용하여 연결할 수 있다.


[표 1-6] 논리 연산자 사용 예

조건	IF	눈이 충혈되었다.
	AND	눈을 깜빡일 때 통증이 느껴진다.
행동	THEN	결막염을 진단한다.

조건	IF	눈물의 양이 적다.
	OR	눈에 피로감을 느낀다.
행동	THEN	인공 눈물을 처방한다.

(4) 의미망

의미망(semantic network)은 단어나 개념 간의 관계를 다이어그램으로 표현하여 어떤 단어와 연결된 다른 단어나 개념 간의 관계를 이해하는 데 도움을 준다. 각각의 단어 혹은 개념은 간선으로 연결하여 관계를 시각적으로 쉽게 표현한다. 의미망은 언어 이해, 정보 검색, 자연어 처리에 주로 사용되는데, 단어 간의 유사성, 상하위 개념 등을 나타낸다.




[그림 I-18] 의미망의 예

(5) 지식 그래프



의미망과 지식 그
래프의 차이는 무엇일까요? 의
미망은 주로 개념과 아이디어를
연결하는 데 초점을 맞추고, 지
식 그래프는 실제 세상의 사실
과 그 관계를 나타낸다는 차이
가 있어요.

지식 그래프(knowledge graph)는 현실 세계의 정보를 컴퓨터가 이해할 수 있도록 그래프 형식으로 저장한다. 실제 세계의 사물, 사건, 개념, 인물 등의 관계를 그래프로 표현하기 위해 논리적 객체인 노드와 노드 간의 관계를 보여주는 간선으로 이루어져 있다. 지식 그래프는 인공지능 시스템과 지식 검색, 자동 질문 응답 시스템 등에서 다양하게 사용되며, 사용자의 질문에 대답하거나 관련 정보를 찾는 데 도움을 준다.



지식 그래프를 이용하여 답을 만들 수 있고 진위도 확인할 수 있다.

[그림 I-19] 지식 그래프의 예

1 IF-THEN 형태의 규칙을 두 개 이상 만들어 보자.

IF	예 비가 온다.
THEN	예 우산을 챙긴다.


IF	
THEN	

2 명제를 이용하여 복합 명제를 만들어 보자.

기호	명제
P	예 수업을 듣는다.
Q	예 식사를 한다.
R	예 집에 간다.

복합 명제 기호	복합 명제
NOT P	
P AND Q	
P OR Q	
$P \rightarrow R$	

3 의미망을 이용하여 지식을 표현해 보자.



4 명제 논리와 술어 논리로 삼단 논법을 추론해 보자.

명제 논리로 추론한 삼단 논법	
명제 1	모든 인간은 죽음을 피할 수 없다.
명제 기호	A
명제 2	소크라테스는 인간이다.
명제 기호	B
결론	

술어 논리로 추론한 삼단 논법	
술어 논리	$\forall x, \text{인간}(x) \rightarrow \text{죽음을 피할 수 없다}(x)$
술어 논리 표현	인간(소크라테스)
↓ 변수 x에 소크라테스 대입	
결론	

3 인공지능 추론 시스템

추론 시스템은 주어진 정보나 사실을 기반으로 새로운 정보나 결론을 도출하는 컴퓨터 기술 또는 시스템이다. 이러한 시스템은 주로 논리 표현이나 규칙 기반의 방식을 사용하여 추론을 수행한다.

지식과 추론을 이용한 인공지능은 보편적인 지능보다는 주로 전문적인 지식이 활용되는 분야에서 좋은 성과를 보여 주었다.

[표 1-7] 인공지능 추론 시스템의 사례




퀴즈왕 왓슨

사례 1	마이신	1972년 만들어진 의료 전문가 시스템으로, 감염증 전문 의사 대신 전염성 혈액 질환이 있는 환자를 진단하고 항생제를 처방하도록 설계되었다.
사례 2	퀴즈왕 왓슨	2011년 퀴즈 쇼에서 인간 챔피언을 이긴 인공지능으로, 사회자의 질문을 듣고 버저를 울려 문제에 응답하도록 설계되었다.

(1) 전문가 시스템

특정 분야에서 전문가의 의사 결정 능력을 흉내 내는 프로그램을 전문가 시스템이라고 한다. 전문가 시스템은 지식을 저장하고 추론 엔진과 사용자 인터페이스로 문제를 해결하는 시스템이다. 전문가 시스템의 핵심 구성 요소에는 사용자 인터페이스, 추론 엔진, 지식 베이스가 있다.



[그림 1-20] 추론을 사용하는 전문가 시스템

사용자 인터페이스는 의사가 문진하듯이 주로 대화 형식으로 만들어지는데, 전문가 시스템의 질문에 사용자가 답을 입력하면 입력된 내용으로 전문가 시스템의 추론 결과를 설명해 준다.

지식 베이스는 전문가의 지식을 저장하며, 지식 베이스가 더 잘 만들어질수록 전문가와 유사한 의사 결정을 내릴 수 있다. 추론 엔진은 지식 베이스를 이용해 새로운 사실을 추론한다.

(2) 전문가 시스템의 한계

전문가 시스템은 정해진 절차대로 명령을 실행해 결과를 내는 기존의 문제 해결 방식이 아니라 사람의 의사 결정 방법과 비슷하게 저장된 지식을 활용해 결론은 낸다는 점에서 인공지능으로서 큰 성공을 거두었다.

하지만 지식 베이스에 저장할 충분한 양의 전문가 지식을 구하는 것이 어려웠고 구축한 지식 베이스를 유지하고 관리하기도 쉽지 않았다. 이러한 문제점 때문에 지식 기반 인공지능을 대신해 미리 입력된 지식이 없어도 데이터로부터 새로운 지식을 만들어 낼 수 있는 기계학습 방법에 대한 관심이 커지기 시작했다.



더 알아보기

전문가 시스템이 사용된 사례를 알아볼까?

전문가 시스템은 특정 분야 전문가의 전문 지식을 모델링하여 컴퓨터에서 해당 지식을 활용하도록 하는 인공지능의 한 분야이다.

의료 진단



의료 분야에서 활용되어 환자의 증상을 바탕으로 가능한 진단을 제안하거나 의사의 결정을 지원한다.

지진 예측



지진과 관련된 다양한 데이터를 분석하여 특정 지역의 지진 발생 가능성 예측을 돕는다.

기계 고장 진단



건설업이나 제조업에서 기계나 장비가 고장났을 때, 그 원인을 찾아내거나 수리 방법을 제안하는 데 사용한다.

법률 조언



법률 분야에서 법률 상담이나 판례 검색, 법적 문제의 해석을 도와주는 도구로 활용한다.


이러한 전문가 시스템은 특정 분야의 전문 지식을 바탕으로 다양한 문제 해결에 기여하고 있다. 하지만 시스템이 항상 정확한 결과를 제공하는 것은 아니므로 실제 전문가의 판단과 함께 사용하는 것이 중요하다.



프롤로그(Prolog)는 기존의 컴퓨터 언어와는 달리 논리에 기반을 둔 프로그래밍 언어로서 술어 논리를 사용한다. 즉, 논리를 문제 표현 도구로 사용하고 질문에 답하기 위해 추론 방법을 이용한다.

- 1 프롤로그를 온라인에서 사용할 수 있는 사이트에 접속하여 “Program”을 누른다.

<https://swish.swi-prolog.org/>



- 2 프로그램 화면은 사실과 규칙을 입력할 수 있는 창과 질문 작성과 질문 결과를 볼 수 있는 3개의 영역으로 나뉘어져 있다. 프로그램을 작성하는 창에 아래 표와 같이 사실과 규칙을 입력하고 질문을 작성하여 실행하면 결과를 보여 준다.

구분	예시
사실	mamal(cat). / 고양이는 포유류이다.
규칙	animal(X) :- mamal(X). / 포유류라면 동물이다.
질문	animal(dog) / 결과: False



3 프롤로그는 사실과 규칙을 바탕으로 추론을 수행할 수 있다. 프로그램은 다음과 같다.

```
% 사실
% 대문자 X는 규칙에서 변수에 사용되므로 이름을 지정
fur(fido). % fido는 털이 있다.
fur(kitty). % kitty는 털이 있다.

eatmeat(fido). % fido는 고기를 먹는다.
eatmeat(kitty). % kitty는 고기를 먹는다.

lightbrown(fido). % fido는 황갈색이다.
lightbrown(kitty). % kitty는 황갈색이다.

mane(fido). % fido는 갈기가 있다.
blackstripe(kitty). % kitty는 검은 줄무늬가 있다.

% 규칙
% X가 털이 있다면, X는 포유류이다.
mamal(X) :- fur(X).

% X가 포유류이고 고기를 먹는다면 육식동물이다.
carnivore(X) :- mamal(X), eatmeat(X).

% X가 육식동물이고 황갈색이며 갈기가 있다면 사자이다.
lion(X) :- carnivore(X), lightbrown(X), mane(X).

% X가 육식동물이고 황갈색이며 검은 줄무늬가 있다면 호랑이이다.
tiger(X) :- carnivore(X), lightbrown(X), blackstripe(X).
```

질의문	결과
lion(fido)	
tiger(fido)	
lion(kitty)	
tiger(kitty)	

새로운 사실과 규칙으로
추론해 보자.



나만의 챗봇 만들어 보기

엘리자(ELIZA)는 초기의 자연 언어 처리 컴퓨터 프로그램으로, MIT 인공지능연구소의 조지프 와이젠바움(Weizenbaum, Joseph)이 1964년부터 1966년까지 개발했다. 간단한 패턴 매칭 수법을 사용하는 프로그램인데 일부 사용자는 프로그램이라는 것을 알아차리지 못하는 등 튜링 테스트를 통과한 최초의 프로그램으로도 알려져 있다.



인간과 컴퓨터 간의 간단한 대화 시스템을 만들면서 챗봇의 작동 원리를 알아보고, 패턴 매칭 방식을 활용해 사용자의 입력에 대응하는 간단한 챗봇 프로그램을 만들어 보자.

단계 ① 기본 틀 정하기

사용자의 입력을 받아들이는 파이썬 코드를 다음과 같이 작성한 후 실행해 보자.

```

01 # ELIZA 챗봇 함수 정의하기
02 def eliza():
03     # 시작 메시지 출력하기
04     print("ELIZA: 안녕하세요! 저는 ELIZA입니다. 무엇을 도와드릴까요?")
05     print("(종료하려면 '종료'라고 입력하세요.)")
06     # 무한 루프로 사용자와 지속적인 대화 진행하기
07     while True:
08         # 사용자로부터 입력 받기
09         user_input = input("당신: ")
10         # 사용자가 '종료'라고 입력하면 대화 종료하기
11         if user_input == "종료":
12             print("ELIZA: 안녕히 가세요!")
13             break
14         # 기본적인 응답 설정하기
15         response = "미안합니다, 그에 대한 답변을 준비하지 못했습니다."
16         # ELIZA의 응답 출력하기
17         print(f"ELIZA: {response}")
18 # ELIZA 챗봇 함수 실행하기
19 eliza()

```

실행 결과 예

```

ELIZA: 안녕하세요! 저는 ELIZA입니다. 무엇을 도와드릴까요?
(종료하려면 '종료'라고 입력하세요.)
당신: 안녕하세요
ELIZA: 미안합니다, 그에 대한 답변을 준비하지 못했습니다.
당신: 종료
ELIZA: 안녕히 가세요

```



단계 ② 대화 패턴 추가하기

엘리자는 사용자의 문장에 대한 패턴을 인식하고 해당 패턴에 맞게 응답한다. 파이썬의 딕셔너리를 활용하여 사용자의 질문에 대한 응답을 출력해 보자.

```

01 # ELIZA 챗봇 함수 정의하기
02 def eliza():
03     # 시작 메시지 출력하기
04     print("ELIZA: 안녕하세요! 저는 ELIZA입니다. 무엇을 도와드릴까요?")
05     print("(종료하려면 '종료'라고 입력하세요.)")
06     # ELIZA의 응답 패턴 정의하기
07     responses = {
08         "안녕!": "안녕하세요!",
09         "어떻게 지냈어?": "저는 프로그래밍이 때문에 기분이나 상태가 없습니다.",
10         "무엇을 할 수 있어?": "대화를 나누는 것을 도와드릴 수 있습니다."
11     }
12     while True:
13         # 사용자로부터 입력 받기
14         user_input = input("당신: ")
15         # 사용자가 '종료'라고 입력하면 대화 종료하기
16         if user_input == "종료":
17             print("ELIZA: 안녕히 가세요!")
18             break
19         # responses에서 사용자의 입력에 맞는 응답을 찾아 반환하거나 기본 응답 반환하기
20         response = responses.get(user_input,
21                                 "미안합니다, 그에 대한 답변을 준비하지 못했습니다.")
22         print(f"ELIZA: {response}")
23 # ELIZA 챗봇 함수 실행하기
24 eliza()

```

단계 ③ 대화 나누기

엘리자는 사용자의 문장에 대한 패턴을 인식하고 해당 패턴에 맞게 응답한다. 파이썬의 딕셔너리를 활용하여 사용자의 질문에 대한 응답을 출력해 보자.

```

ELIZA: 안녕하세요! 저는 ELIZA입니다. 무엇을 도와드릴까요?
(종료하려면 '종료'라고 입력하세요.)
당신: 안녕
ELIZA: 안녕하세요!
당신: 어떻게 지냈어?
ELIZA: 저는 프로그래밍이 때문에 기분이나 상태가 없습니다.
당신: 그래
ELIZA: 미안합니다, 그에 대한 답변을 준비하지 못했습니다.
당신: 종료
ELIZA: 안녕히 가세요

```

실행 결과 예

- 위 코드에서 더 다양한 패턴을 찾을 수 있도록 프로그램을 개선해 보자.
- ELIZA 프로그램은 사용자의 입력에 대해 제한적인 답변만 제공한다. 이런 구조의 단점은 무엇일까?
- 실제 인간과 대화하는 것과 ELIZA와 대화하는 것의 가장 큰 차이점은 무엇일까?




개념 정리

01. 인공지능의 원리

- 인공지능: 인간의 지능적 행위를 컴퓨터로 구현하는 기술
- 인공지능의 특성: 문제 해결, 추론, 학습, 예측, 인식, 생성
- 인공지능 시스템: 목적을 달성하기 위해 지능적이고 합리적인 판단을 자율적으로 수행하는 지능 에이전트 구조로 만들어짐.

02. 인공지능과 탐색



- 맹목적 탐색: 주어진 정보만 사용하여 목표를 찾는 전략
예) 너비 우선 탐색, 균일 비용 탐색
- 지능적 탐색: 경험적 지식을 활용하여 효율적으로 탐색하는 전략
예) A* 탐색
- 경로 탐색, 게임 탐색, 지역 탐색 등의 다양한 탐색 전략이 일상 생활의 문제 해결에 사용

03. 지식의 표현과 추론

- 추론: 기존의 지식을 근거로 새로운 판단을 이끌어 내는 인간의 지능에서 핵심 기능
- 지식 표현: 명제 논리, 술어 논리, 규칙, 의미망, 지식 그래프 등을 사용하여 표현
- 인공지능 추론 시스템: 주어진 정보로 새로운 정보나 결론을 도출하는 컴퓨터 기술 또는 시스템으로 전문가 시스템이 대표적

실력 확인

1 보기의 각 설명을 인간 지능의 요소별로 분류한 것으로 옳은 것은?

보기

- (가) 여러 문제 상황에서 지능적인 전략을 이용하여 문제를 해결하는 것을 의미한다.
(나) 이미 가지고 있는 지식을 이용하여 새로운 지식을 유도해 내는 것을 의미한다.
(다) 새로운 지식을 얻는 방법의 하나로 과거의 경험을 바탕으로 새로운 상황에서 판단을 내릴 수 있도록 하는 것을 의미한다.
(라) 자신을 둘러싼 환경을 감지하는 데서 더 나아가 감지된 개체를 분별하고 의미를 파악할 수 있는 것을 의미한다.

	(가)	(나)	(다)	(라)
①	추론	학습	인식	문제 해결
②	학습	추론	인식	문제 해결
③	문제 해결	추론	인식	학습
④	문제 해결	추론	학습	인식
⑤	문제 해결	학습	인식	추론

2 인공지능의 문제 해결 사례로서 옳지 않은 것은?

- ① 의료 이미지 분석으로 의사의 진료 돕기
② 사용자 데이터를 분석하여 맞춤형 제품 추천
③ 실시간 교통 데이터를 분석하여 교통난 해결
④ 기후 데이터를 분석하여 주식 시장 예측하기
⑤ 위성 영상 데이터로 특정 지역의 산림 파괴 모니터링


[3-5] 다음을 읽고, 물음에 답하시오.

당신은 두 개의 물통을 가지고 있다. 첫 번째 물통은 4리터를 담을 수 있고, 두 번째 물통은 3리터를 담을 수 있다. 두 물통에는 눈금이 없어서 부분적으로 물을 채울 수 없다.

물통에는 다음 작업을 할 수 있다.

1. 한 개의 물통 비우기
2. 한 개의 물통 채우기
3. 한 물통의 물을 다른 통에 붓기(한 물통이 비거나 다른 물통이 가득 찰 때까지)

3 초기 상태(0, 0)에서 간선의 조건을 정의하여 나타낼 수 있는 다음 상태를 각 물통에 담긴 물의 양으로 나타내시오.



4 3의 첫 번째 물통을 가득 채운 상태에서 가능한 두 가지 작업을 트리 형태로 나타내시오.

5 주어진 정보가 없을 때 초기 상태(0, 0)에서 목표 상태(3, 0)에 이르는 과정을 너비 우선 탐색 알고리즘으로 탐색하고 그 상태를 나열하시오.

6 다음 중 컴퓨터에서 지식을 처리하고 저장하는 방법으로 옳지 않은 것은?

- | | |
|----------|---------|
| ① 규칙 | ② 의미망 |
| ③ 산술 논리 | ④ 명제 논리 |
| ⑤ 지식 그래프 | |

스스로 점검하기

인공지능의 지능적 판단에 대한 이해를 바탕으로 인공지능을 활용한 실생활 및 다양한 학문 분야의 문제 해결 사례를 비교·분석할 수 있는가?	😊 😊 😊	14쪽
인공지능에서 탐색의 중요성을 이해하고 문제 해결을 위한 탐색 과정을 설계할 수 있는가?	😊 😊 😊	26쪽
맹목적 탐색과 정보 이용 탐색의 차이를 중심으로 지능적 탐색의 원리를 파악할 수 있는가?	😊 😊 😊	26쪽
지능적 탐색이 필요한 문제를 찾아보고 문제 해결을 위해 정보 이용 탐색 알고리즘을 적용할 수 있는가?	😊 😊 😊	26쪽
규칙과 사실을 활용하여 지식을 표현하고, 새로운 지식을 추론하여 생성할 수 있는가?	😊 😊 😊	42쪽



II

인공지능과 학습

- 01 기계학습과 데이터
- 02 기계학습 알고리즘
- 03 인공 신경망과 딥러닝

이 단원을 배우고 나면

기계학습을 활용하여 해결할 수 있는 문제를 정의하고, 문제 해결 과정에서 필요한 데이터와 모델을 활용하여 문제를 효과적으로 해결하는 능력을 기를 수 있다.





동영상

<https://dtqr.kr/v0U3jUb>



월 평균 매출액을
예측해 볼 수
있을까?

문제 해결 방법을
사람이 직접 프로그램
으로 만들어요.

궁금하네!

문제 해결 방법을 사람이
직접 만들기가 힘든 경우에,
데이터를 학습하여 모델로
대신 만들어 내요.

전통적
프로그래밍 기법으로
해결 가능한가?

아니요

기계학습 기법으로
해결 가능한가?

아니요

예

프로그래밍을
해 봐야지.


전통적
프로그래밍하기

와, 문제를
해결했어!

문제 해결하기

해결하고 종료

해결 못하고 종료



- 기계학습을 적용할 문제를 정의하고, 문제 해결에 필요한 데이터를 선정하여 수집할 수 있다.
- 수집한 데이터를 가공하여 핵심 속성을 추출할 수 있다.

기계학습과 데이터


학습 요소

기계학습, 데이터 선정,
데이터 수집, 데이터 전처리,
핵심 속성 추출



무엇을 배울까?

일상생활에서 접하는 다양한 문제 중 기계학습 기반의 인공지능을 적용하여 해결할 수 있는 문제를 선별하고, 관련 데이터를 수집할 수 있어야 한다.




전통적인 프로그래밍 기법은 사람이 직접 프로그램을 만들어 해결해요.



어떤 방법으로 문제를 해결했나요?

기계학습은 데이터를 학습하여, 문제 해결 방법을 모델로 만들어 내요.




▲ 인공지능 시스템

1 기계학습과 문제 정의

인공지능 기법에는 우리가 이미 살펴본 문제 해결과 탐색, 지식 표현과 추론 외에도 기계학습을 사용할 수 있다. 기계학습을 적용할 문제를 정의해 보자.

1 기계학습의 개념

인간은 새로운 개념을 배울 때 다양한 예시와 경험으로 패턴을 이해하고 그것으로 새로운 문제를 해결한다. 기계학습도 인간의 학습 과정처럼 개념에 대한 적절한 예시 데이터로 그 안에 숨겨진 패턴을 찾아내고, 그것을 바탕으로 새로운 데이터에 대한 지능적인 예측과 판단을 한다.



[그림 II-1] 인공지능과 기계학습




왜 기계학습 기법을 사용하는가?

전통적인 프로그래밍 기법은 컴퓨터로 입력된 값을 명시적인 규칙으로 표현된 프로그램으로 처리하여 원하는 값을 출력한다. 예를 들어 우리 학교 모든 학생의 국어, 수학 성적의 평균값을 계산하여 출력하는 프로그램은 분명하고 명시적이다. 하지만 모든 프로그램이 명시적인 규칙으로 표현될 수 있는 것은 아니다. 예를 들어 수많은 동물 이미지를 분석하여 종을 예측하는 프로그램을 만든다고 가정해 보자. 이런 경우 정확도가 높은 프로그램을 명시적으로 표현하기는 어렵다.

명시적

내용이나 뜻을 분명하게 드러내 보이는 것을 말한다.



[그림 II-2] 전통적인 프로그래밍 기법으로 해결할 수 있는 문제와 해결하기 어려운 문제

이러한 일들은 대부분 지능적인 것에 해당한다. 예를 들어 고객 정보를 입력하여 안전한 대출 범위를 출력하거나, 얼굴 사진을 입력하여 그 사람의 감정 상태를 출력하거나, 대화 문장을 입력하여 적절한 답변을 생성하는 작업 등은 모두 명시적인 규칙으로 표현된 전통적인 프로그래밍 기법으로는 해결하기 힘든 지능적인 문제들이다.

2 데이터로 학습하기

인간이 다양한 경험으로 어떠한 개념을 ‘학습’하는 것처럼, 기계학습 또한 다양한 데이터 혹은 경험이 반영된 데이터를 학습하여 스스로 모델을 만들어 낸다.



인간 인간이 개와 고양이의 얼굴을 구분할 수 있는 것은 어릴 때부터 많은 경험으로 학습하여 머릿속에 구분하는 모델이 이미 만들어졌기 때문이다.



기계학습 컴퓨터는 수집한 개와 고양이들의 이미지 데이터를 충분히 학습하여 개와 고양이를 구분하는 분류 모델을 만들어 낸다.

[그림 II-3] 인간과 기계학습의 비교



기계학습 모델은 어떤 데이터로 만들어질까?



개와 고양이를 구분하는 모델을 만들기 위해서는 다양한 개와 고양이의 예시 데이터가 필요해요. 그 데이터로 기계학습에서는 개와 고양이를 구분하는 특징을 파악해 모델을 만들지요.

어떤 집의 가격을 예측하는 모델을 만들기 위해서는 집의 위치, 크기, 주변 환경 등과 같은 다양한 속성값을 가지고 있는 많은 양의 집값 데이터가 필요해요. 그 데이터로 기계학습에서는 집값의 특징을 파악하여 새로운 집에 대한 가격을 예측할 수 있어요.



편의점에서 고객들이 구매한 물건 영수증 데이터가 많이 쌓이면, 그 데이터를 사용하여 기계 학습은 어떤 계절, 어떤 요일, 어떤 날씨에 어떤 물건들이 함께 팔리는지에 대한 패턴이나 규칙을 스스로 찾아낼 수 있어요. 그것에 따라서 상품의 진열 배치도 다르게 할 수 있고 마케팅에도 활용할 수 있어요.

책, 신문, 논문, 웹 사이트 등에 저장 및 누적된 인간의 지식과 경험 데이터는 언어 이해 모델과 생성 모델을 만드는 데 사용되어요. 그리고 그 모델은 지능적인 검색, 문서 요약, 번역, 질의·응답 시스템 등에서 사용하고 있어요.



인공지능이 손 글씨 숫자를 어떻게 인식하는지 Tensospace.js 사이트에 방문하여 체험해 보자.

[활동 안내]

- ① [PlayGround]-[LeNet]이라는 모델을 선택하고 손 글씨 숫자를 입력한다.
- ② 다른 숫자도 여러 번 입력해 보면서 인공지능의 숫자 인식을 체험해 보자.

💡 LeNet은 안 르콘 연구 팀이 1998년에 CNN을 적용하여 개발한 간단한 인공지능 모델이다.



<https://tensospace.org/>

- 1 인공지능은 내가 작성한 숫자를 얼마나 잘 인식하는가? 어떤 경우에 인식이 잘되고, 인식이 잘되지 않을까?

인식이 잘되는 경우

인식이 잘되지 않는 경우

- 2 인공지능 모델이 내가 작성한 숫자를 잘 인식하지 못하는 이유는 무엇일까?



더 알아보기


컴퓨터는 사람이 쓴 손 글씨를 어떻게 인식할 수 있을까?

[문제 상황] 사람이 쓴 손 글씨 숫자를 컴퓨터가 인식하는 문제

필기체 손 글씨 숫자는 사람 또는 나라마다 모양이 조금씩 다르고 숫자의 방향이나 크기, 두께가 달라지면 인식하기가 어렵다. 하지만 각 숫자가 가진 특징을 정확하게 찾아내면, 쉽게 해결할 수 있는 문제이다.

다양한 손 글씨 숫자 데이터를 많이 모아서 기계학습을 사용하면, 손 글씨 데이터 속에서 각 숫자마다의 특징과 패턴을 스스로 찾아서 분류하는 모델을 만들 수 있다.

손 글씨는 전통적인 프로그래밍 기법으로 인식할 수 있을까요? 아니면 기계학습으로 인식할 수 있을까요?



기계학습을 사용하면 사람이 모든 경우를 탐색하여 명시적으로 프로그래밍하지 않아도 문제를 해결할 수 있어요!

[그림 II-4] 기계학습으로 손 글씨 숫자 인식하는 과정

데이터 수집 시 고려 사항

기계학습은 데이터 기반으로 학습하여 최적화된 모델을 구축하는 방법이다. 좋은 성능을 가진 모델을 구축하려면 많은 양의 데이터를 수집하고, 이 데이터를 모델에 입력할 때는 편향되지 않도록 적절한 형태로 가공하고 전처리 작업을 해야 한다.

3 기계학습으로 해결할 수 있는 문제

기계학습은 사람이 명시적인 규칙이나 프로그램으로 찾기 힘든 경우에 인간의 경험이 반영된 데이터를 기반으로 최적화된 모델을 만들어 문제를 해결한다. 기계학습이 모델을 만들어 해결하는 문제의 유형은 분류, 예측, 군집, 인식, 자연어 처리, 생성 등이다.

기계학습으로 해결할 수 있는 문제 유형

분류, 예측

분류는 주어진 데이터를 미리 정의된 여러 그룹 중 하나로 나누는 것을 말하며, 예측은 미래의 값을 추정하거나 알려지지 않은 데이터의 값을 결정하는 것을 말한다.

예 이메일이 스팸인지 아닌지를 분류하는 것, 주택의 속성에 따라 주택 가격을 예측하는 것 등

군집

군집은 비슷한 특성을 가진 데이터를 같은 그룹으로 묶는 과정을 말한다.

예 비슷한 성향의 고객을 군집하여 마케팅에 활용하는 것 등

인식

인식은 이미지, 음성, 텍스트를 인식하고 이해하는 것을 말한다.

예 얼굴을 보고 감정 상태를 아는 것, 지능형 스피커가 나의 말을 이해하는 것 등

자연어 처리

자연어 처리는 기계가 인간의 언어를 이해하고 처리할 수 있도록 하는 것을 말한다.

예 자동 번역, 텍스트로부터 감정 추론, 문장을 새로운 느낌으로 변형해 주는 것 등

생성

생성은 새로운 데이터나 콘텐츠를 만들어 내는 과정을 말한다.

예 텍스트, 이미지, 음성 생성 등

다음은 다양한 분야의 문제를 해결하기 위해 기계학습을 적용한 사례이다.
어떤 유형의 기계학습이 적용되었는지, 어떤 동작 방식을 가졌는지 알아보자.

기계학습을 적용한 다양한 사례

추천 시스템

사용자가 과거에 본 영화나 제품, 클릭한 광고 등의 데이터를 학습하여, 그 사용자가 좋아할 만한 새로운 콘텐츠나 제품을 추천한다.

예 사용자 과거 행동과 기호를 기반으로 개인화된 추천을 제공하는 서비스



이미지 인식

수많은 이미지 데이터를 학습하여, 새로운 이미지에서 사물이나 얼굴, 장면 등을 인식하고 분류한다.

예 사진 속의 사물이나 얼굴을 자동으로 태깅하고 분류하는 서비스



기계 번역

두 언어 간의 번역된 대량의 텍스트 데이터를 학습하여 새로운 문장을 번역한다.

예 다양한 기계 번역 서비스 앱



의료 진단 및 이미지 분석

수많은 의료 이미지 데이터와 그에 대한 진단 정보를 학습하여, 새로운 환자의 이미지에서 질병의 특성을 자동으로 탐지하고 진단을 돕는다.

예 자기 공명 영상(MRI)이나 엑스레이(X-ray) 사진을 분석해 특정 질병을 자동으로 탐지



금융 및 주식 예측

과거의 금융 데이터, 주식 가격, 경제 지표 등을 학습하여, 미래의 금융 상황이나 주식의 가격을 예측한다.

예 고객의 신용 점수를 예측하거나 주식의 가격 변동을 예측



농업 및 기후 변화

(SDG 2: 기아 종식,
SDG 13: 기후 변화 대응)

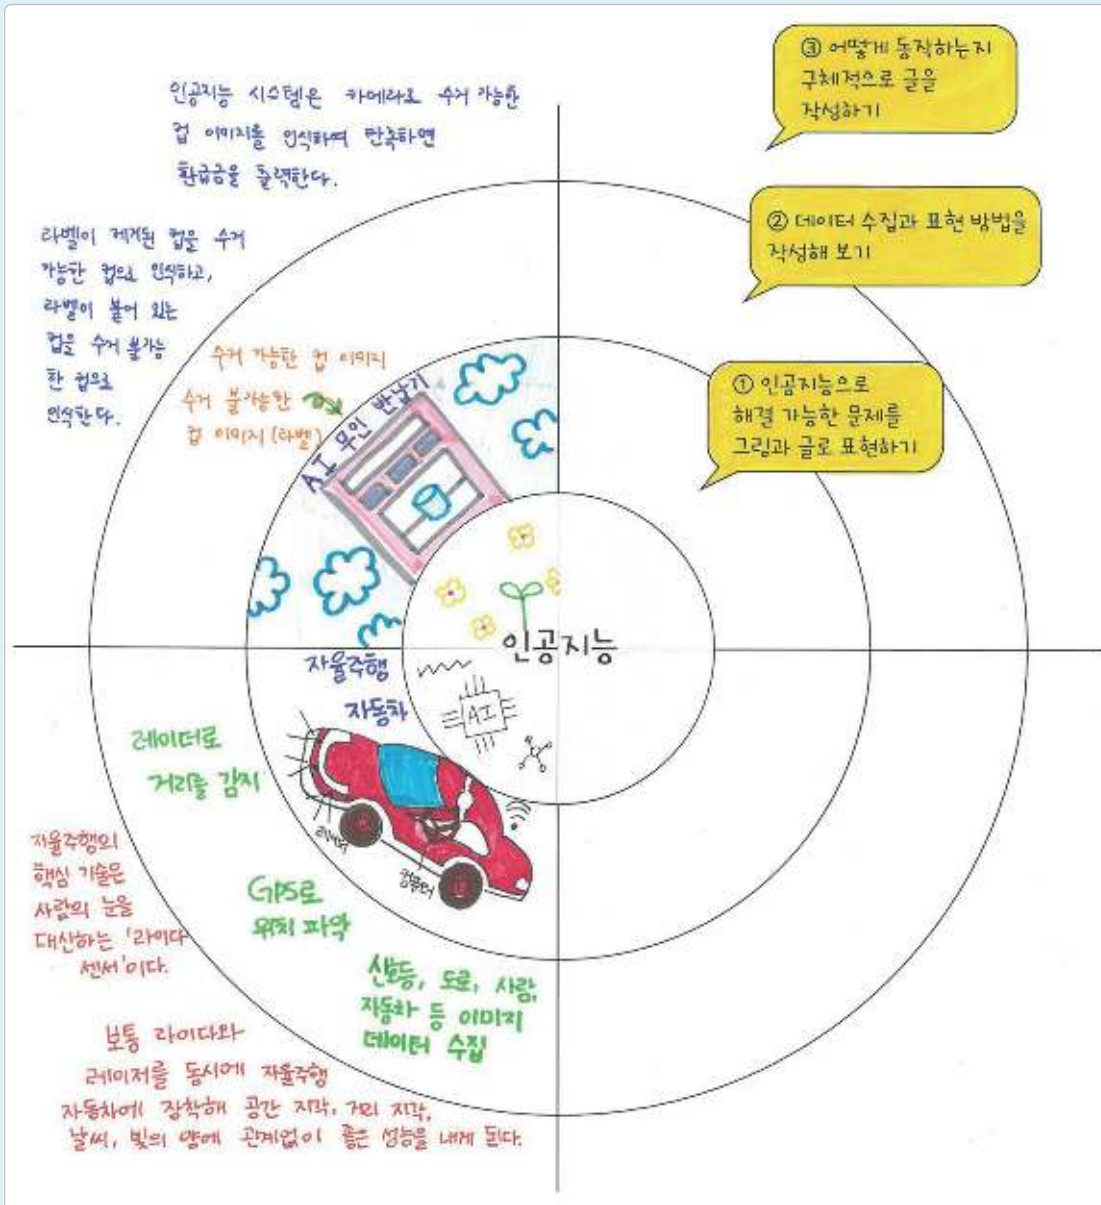
대량의 이미지 데이터 등에서 패턴을 학습하고, 실시간으로 문제가 발생할 수 있는 지역을 예측하거나 탐지한다.

예 농업용 드론이나 위성 이미지를 활용하여 작물의 상태를 모니터링하여 병충해나 물 부족 등의 문제를 조기에 탐지



1 기계학습으로 해결 가능한 문제를 찾아보고, 인공지능 시스템이 어떻게 문제를 해결할 수 있는지 그림으로 표현해 보자.

- ① 기계학습으로 해결 가능한 문제의 제목을 붙이고 간단한 그림을 그려 보자.
- ② 문제를 해결하려면 어떤 데이터를 수집해야 하는지 간단히 적어 보자.
- ③ 인공지능 시스템이 데이터를 활용하여 어떻게 문제를 해결할 수 있는지 동작 방식을 구체적으로 적어 보자.



① 인공지능 시스템의 문제 해결 아이디어 예시

이 활동은 학생 개인별로 작성한 후 모두가 협력하여 토론할 수 있다.

2 데이터 수집하기

문제 해결에 필요한 데이터를 수집할 때는 어떤 데이터가 필요한지, 어떻게 수집할지 등을 명확하게 계획해야 한다. 더 나아가 정확하고 신뢰할 수 있는 데이터를 확보할 수 있어야 한다.

1 데이터의 개념과 유형

데이터는 숫자, 문자, 이미지 등을 관찰하거나 측정하여 수집한 사실이나 값을 의미하고, 데이터 속성은 데이터를 구성하는 구체적인 정보 요소를 말한다.

데이터 속성은 숫자로 표현되는 수치형 데이터와 여러 범주 중 해당하는 값을 가지는 범주형 데이터로 분류한다. 또한 수치형 데이터는 연속형 데이터와 이산형 데이터로 분류할 수 있다. [표 II-1]의 학생 건강 체력 평가(PAPS) 데이터로 데이터 속성의 유형을 살펴보자.

학생 건강 체력 평가 데이터는 이름, 성별, 팔 굽혀 펴기(횟수), 유연성(cm)과 같이 4개의 속성으로 구성되어 있다. 성별은 범주형 데이터, 팔굽혀 펴기(횟수)는 이산형 데이터, 유연성은 연속형 데이터이다.

[표 II-1] 데이터의 다양한 속성

속성명	속성			
	이름	성별	팔 굽혀 펴기(횟수)	유연성(cm)
값 (데이터)	김○○	남	13	6.68
	유○○	여	17	5.02
	정○○	여	3	12.73

범주형 데이터

이산형 데이터

연속형 데이터



데이터는 형식에 따라 정형 데이터와 비정형 데이터로 나눌 수 있다.

정형 데이터 속성이 미리 주어져 주로 행과 열로 이루어진 표 형태로 구성된다.

비정형 데이터 이미지, 비디오, 텍스트, 오디오 등의 형식으로 속성을 미리 정의하기 어려운 정형화되지 않은 데이터를 말한다.

[그림 II-5] 정형 데이터와 비정형 데이터

수치형 데이터의 분류

- 연속형 데이터: 시간처럼 어떤 숫자값 사이에 값이 존재하는 데이터이다.
- 이산형 데이터: 우리 반 인원 수처럼 숫자값 사이에 값이 존재할 수 없는 데이터이다.

범주형 데이터

성별을 남자와 여자로 구분하듯이 한정된 값 중 하나를 선택할 수 있는 데이터이다.
예 남/여, 만족/불만족, 상/중/하, 혈액형 A/B/O/AB

(1) 정형 데이터

정형 데이터는 명시적인 속성이 있는 데이터, 즉 미리 정해진 형식과 구조에 맞게 구성된 데이터를 말한다. [표 II-2]는 영국의 통계학자 로널드 피셔가 붓꽃의 품종을 분류하기 위해 직접 수집한 붓꽃 데이터셋으로 표 형식으로 구성된 정형 데이터이다.

붓꽃 데이터는 꽃받침(sepal)의 길이와 너비, 꽃잎(petal)의 길이와 너비 속성과 품종(species)의 속성으로 구성되어 있다.

[표 II-2] 붓꽃 정형 데이터

sepal length (꽃받침 길이)	sepal width (꽃받침 너비)	petal length (꽃잎 길이)	petal width (꽃잎 너비)	species (품종)
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3	1.4	0.2	Iris-setosa
7	3.2	4.7	1.4	Iris-versicolor
6.4	3.2	4.5	1.5	Iris-versicolor
...	...	...	...	...

5개의 속성으로 구성된 정형 데이터!

데이터셋

데이터 집합이라고도 하며, 문제 해결을 위해 관련된 데이터를 모아놓은 것을 말한다.

붓꽃 데이터

케글과 UCI 기계학습 저장소 등에서 수집할 수 있다.

<https://www.kaggle.com/datasets/arshid/iris-flower-dataset>



(2) 비정형 데이터

비정형 데이터는 명시적인 속성이 주어지지 않는 데이터, 즉 이미지와 같이 형식과 구조가 복잡하여 정형화되지 않은 데이터를 말한다. 예를 들어 붓꽃의 세 가지 품종 데이터를 이미지 형태로 표현한다면 이것은 비정형 데이터이다.

💡 붓꽃 이미지 데이터: 케글(kaggle) 사이트에서 Iris Computer vision 데이터를 수집할 수 있다.
<https://www.kaggle.com/datasets/jeffheaton/iris-computer-vision>



[그림 II-6] 붓꽃 비정형 데이터

2 데이터 수집 방법

기계학습은 많은 양의 데이터를 학습하여 성능 좋은 모델을 만드는 것을 목표로 하므로 양질의 데이터 수집이 중요하다. 수집 방법에는 공공 데이터나 민간 데이터를 수집하거나, 직접 수집하는 방법 등이 있다.

(1) 공공 데이터 수집하기


공공 데이터를 제공하는 대표적 기관으로는 통계청, 국토교통부, 환경부 등 다양하다. 특히, 통계청이 제공하는 국가통계포털을 이용하면 국내외 주요 통계 데이터를 빠르고 정확하게 수집할 수 있다.

(2) 민간 데이터 수집하기

캐글이나 UCI 기계학습 저장소, AI 허브 등의 사이트에서 인공지능 모델 구축용 데이터를 수집하여 활용할 수 있으며, 연구 결과를 다른 사람들과 공유할 수도 있다.



[그림 II-7] 국가통계포털 데이터 수집



[그림 II-8] 캐글 데이터 수집

(3) 직접 수집하기

공개된 데이터가 없다면 다양한 센서를 이용하거나 설문, 관찰 등을 통해 직접 데이터를 수집한다. 또한 스마트폰이나 스마트워치 등에 내장된 센서를 이용하면 실시간으로 데이터를 수집할 수도 있다.

질문	값	유형
나의 나이는?		
나의 성별은?		
나의 혈액형은?		
...		

설문으로 데이터 수집



스마트워치로 운동량 수집



센서로 데이터 수집

[그림 II-9] 데이터 직접 수집 방법

공공 데이터

공공 기관이 전자적으로 생성 또는 취득하여 관리하는 모든 데이터베이스, 전자화된 파일이다.

공공 데이터 수집 사이트


- 통계청 국가통계포털
<https://kosis.kr/>
- 공공데이터포털
www.data.go.kr
- 기상자료개방포털
<https://data.kma.go.kr/>
- 환경통계포털
<https://stat.me.go.kr>
- 통계청 e-나라지표
<https://www.index.go.kr/>
- 국토교통부 데이터 통합 채널
<https://data.molit.go.kr/>
- 국토교통 통계누리
<https://stat.molit.go.kr>

민간 데이터 수집 사이트

- 캐글
<https://www.kaggle.com>
- AI 허브
<https://www.aihub.or.kr/>
- 구글의 데이터셋 검색 엔진
<https://datasetsearch.research.google.com/>

3 문제 해결에 적합한 데이터 선정

기계학습으로 문제를 해결하려면 먼저 문제를 명확하게 정의하고, 문제 해결에 필요한 데이터를 충분하게 선정해야 한다. 이를 위해서는 [그림 II-10]처럼 문제의 유형을 분석하고 이에 필요한 데이터의 유형을 탐색한 후 적절한 데이터 수집 방법을 선택할 수 있어야 한다.



[그림 II-10] 데이터 선정 과정

데이터는 기계학습 모델 생성 과정에 많은 영향을 미치므로 데이터를 수집하는 단계에서 편향성과 공정성, 개인 정보 노출, 저작권 등의 문제를 고려해야 한다.

(1) 데이터 편향성과 공정성

데이터 편향은 데이터 수집이나 분석할 때 발생할 수 있는 오류나 왜곡을 의미한다. 데이터 수집 단계에서 발생하는 데이터의 불균형이나 편향은 공정성 문제로 이어져 특정한 속성을 가진 사람들이 부당하게 불이익을 받는 문제가 발생할 수 있으므로 주의해야 한다.



[그림 II-11] 데이터 편향성의 예

(2) 데이터 수집 과정의 정당성

개인 정보와 같은 사용자 데이터를 무단으로 수집하거나 사용하는 것은 불법이며, 윤리적으로도 문제가 될 수 있다. 또한 검증되지 않고 출처가 불분명한 데이터는 신뢰성이 떨어질 수 있으므로, 검증된 데이터를 정당한 방법으로 수집해야 한다.



① 정당성에 위배되는 예


활동 3 문제 해결에 필요한 데이터 수집하기

조사 수집

다음 뉴스 기사와 자료를 보고, 우리나라의 경제 문제를 해결하기 위한 데이터를 수집해 보자.

여웃돈 뻔한데, 먹거리 물가 두 배 더 뛰었다!
통계청 국가통계포털에 따르면 지난 3분기 소비자 물가 상승률은 3.1%였다. 하지만 가공식품과 외식만 떼어 보면 같은 기간에 이들 품목의 물가 상승률은 각각 6.3%와 5.4%로 전체 소비자 물가 상승률을 크게 웃돌았다.

출처: SBS Biz 2023. 11. 27.



- 1 국가통계포털 사이트에서 '품목별 소비자물가지수'를 검색한다. [시점] 버튼에서 '최근 10년'의 연도별 지수가 나오도록 선택하고, [다운로드]를 눌러 데이터를 다운로드한다. 스프레드시트 프로그램을 실행한 후 데이터를 확인해 보자.

<https://kosis.kr/index/index.do>

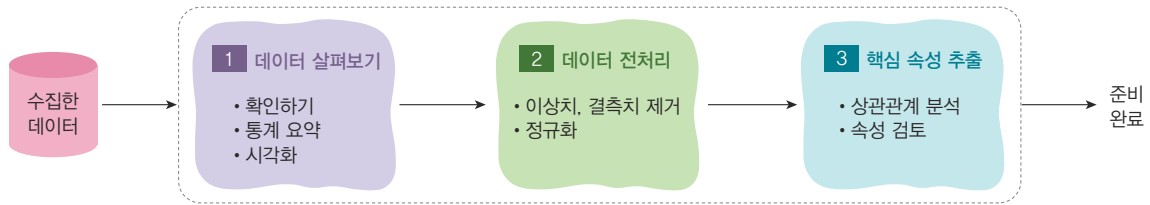
- 2 수집한 데이터에서 내가 관심 있는 품목의 연도별 물가 지수를 확인해 보자.



연도	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022
닭고기	109.5	105.992	103.743	100.29	105.26	102.857	104.25	100	107.67	122.54
자장면	82.353	83.397	85.703	88.108	90.933	94.982	98.589	100	103.07	114.2
돈가스	89.018	89.758	90.362	92.297	93.945	96.416	99.307	100	102.31	111.28
치킨	88.969	89.687	90.215	90.529	91.326	93.831	98.667	100	102.96	112.68

3 데이터 탐색과 전처리

기계학습에 사용할 데이터는 문제 해결에 적합해야 하고, 그 양과 품질도 적절해야만 데이터로 만들어진 기계학습 모델의 성능이 우수하고 편향되지 않은 결과를 나타낼 수 있다. 따라서 수집된 데이터는 기계학습에 사용하기 전에 탐색과 전처리 과정에서 충분히 살펴보고 검토해야 한다.




[그림 II-12] 기계학습을 위한 데이터 탐색과 전처리 과정

탐색적 데이터 분석(EDA; Exploratory Data Analysis)
존 튜키가 개발한 데이터 분석 방법이다. 통계와 그래프 등 다양한 방법으로 데이터를 요약하고 패턴을 분석하여 충분히 이해하는 것을 목표로 한다.

탐색적 데이터 분석은 데이터의 특징과 구조를 이해하기 위해 데이터를 여러 방면에서 탐색하고 시각화하는 과정이다. 이 분석 과정으로 데이터의 기본적인 특징을 파악하고, 이상치나 결측치를 발견하며, 변수 간의 관계를 확인하는 데 사용한다.

[그림 II-13]의 남극 펭귄 데이터에는 세 가지 펭귄 종을 구분하는 특징으로 구성되어 있다. 펭귄 데이터를 탐색적으로 살펴보자.

💡 펭귄 데이터: 캐글 사이트에서 펭귄 데이터를 수집할 수 있다. https://www.kaggle.com/datasets/parulpandey/palmer-archipelago-antarctica-penguin-data?select=penguins_size.csv



[그림 II-13] 남극 펭귄을 세 가지 종으로 구분하기 위한 특징

1 데이터 살펴보기

(1) 데이터의 형태, 규모, 유형 확인하기

데이터에서 값을 직접 살펴보거나 데이터 속성 정보와 데이터 유형을 확인해 봄으로써 결측치가 있는지, 속성은 몇 가지인지 등을 알 수 있다.

펭귄 데이터의 속성값과 유형을 정리하면 [표 II-3]과 같다.

[표 II-3] 펭귄 데이터의 속성과 유형

범주형		수치형				범주형
종 (species)	서식지(섬) (island)	부리 길이 (culmen_ length)	부리 깊이 (culmen_ depth)	날개 길이 (flipper_ length)	체질량 (body_ mass)	성별 (sex)
Adelie	Torgersen	39.1	18.7	181	3750	MALE
Adelie	Torgersen	39.5	17.4	186	3800	FEMALE
⋮	⋮	⋮	⋮	⋮	⋮	⋮
Gentoo	Biscoe	47.8	15	215	5650	MALE

종, 서식지(섬),
성별 속성은 범주형 데이터이고
부리 길이, 부리 깊이, 날개 길
이, 체질량 속성은 수치형 데이
터예요.

(2) 통계 요약

통계적 요약을 통하여 데이터 집합에 대한 분포와 패턴을 파악해 찾아본다.
통계를 이용하여 데이터를 요약하는 방법에는 데이터의 개수, 평균, 최솟값, 최
댓값, 사분위수 등이 있다.

[표 II-4] 펭귄 데이터의 특성 통계표

구분	부리 길이(mm)	부리 깊이(mm)	날개 길이(mm)	체질량(g)
개수	342.000000	342.000000	342.000000	342.000000
평균	43.921930	17.151170	200.915205	4201.754386
표준편차	5.459584	1.974793	14.061714	801.954536
최솟값	32.100000	13.100000	172.000000	2700.000000
1사분위수	39.225000	15.600000	190.000000	3550.000000
중앙값	44.450000	17.300000	197.000000	4050.000000
3사분위수	48.500000	18.700000	213.000000	4750.000000
최댓값	59.600000	21.500000	231.000000	6300.000000


통계 요약 정보에서
펭귄 데이터의 수는 총 342개,
부리 길이 평균은 43.92mm,
부리 깊이 평균은 17.15mm,
날개 길이 평균은 200.91mm
예요. 체질량 평균은 4201.75g
으로 부리 길이와 깊이에 비해
상당히 큰 값이에요.

(3) 다양한 데이터 시각화

데이터 시각화를 통해 데이터 속에 숨겨진 특성을 쉽게 탐색해 볼 수 있다.
해결하고자 하는 문제와 데이터의 유형에 따라 시각화
방법은 다음과 같이 다양하다.

① 선그래프로 데이터의 변화와 추세 알아보기

선그래프로 데이터의 추세적인 변화를 알아볼 수 있다.
국가통계포털에서 수집한 치킨과 재료의 물가 지수를 나
타낸 선그래프에서 20년간 치킨의 물가 지수 상승에 원재
료의 물가 지수가 크게 상승한 것을 확인할 수 있다.



데이터 https://bit.ly/chicken_data


[그림 II-14] 치킨 재료의 소비자 물가 지수 상승 추세



2차원 평면에
그리는 산점도는 x축과 y축의
두 값이 만나는 지점에 점으로
표시해요.

② 산점도로 속성 간 관계 파악하기


산점도(scatter plot)는 데이터의 흠
어짐 정도로 두 데이터의 상관관계를
쉽게 알 수 있다. 또한 관측된 데이터의
범위에서 많이 벗어난 이상치(outlier)
가 있는지도 확인할 수 있다.



[그림 II-15] 부리 길이와 부리 깊이의 산점도

③ 막대그래프로 도수분포 확인하기

막대그래프는 도수분포를 그림으로
나타낸 것이다. 범주형 데이터의 도수
분포는 측정값의 빈도수(frequency)를
나타낸다.



[그림 II-16] 펭귄 종별 데이터 수

2 데이터 전처리

데이터 전처리는 데이터 분석에 적합한 상태로 변환하는 과정이다.

데이터에 결측치, 이상치 등이 존재하는지 살펴보고 이러한 값들을 어떻게
처리할지 결정한다. 필요한 경우에는 정규화 과정에서 속성값 간의 분포를 조
정하여, 기계학습에 사용할 수 있도록 정돈한다.

(1) 결측치 처리

결측치(missing value)는 데이터에 값이 없는 것으로, 'NA' 또는 'NaN'으로
표시된다.

결측치 처리 방법

- 특정값으로 채우기
- 평균값으로 채우기
- 전후값으로 채우기
- 삭제하기

[표 II-5] 결측치의 예


종 (species)	서식지(섬) (island)	부리 길이 (culmen_ length)	부리 깊이 (culmen_ depth)	날개 길이 (flipper_ length)	체질량 (body_ mass)	성별 (sex)
...	...	...	...	...	...	...
Adelie	Torgersen	NA	NA	NA	NA	NA
...	...	...	...	...	...	...

결측치가 있으면 데이터 분석이 어려우므로 특정값, 평균값, 전후값으로 채
우거나 삭제하는 등의 방법으로 수정한다.


(2) 이상치 처리

이상치(outlier)는 잘못 입력되었거나 정상 범위에서 많이 벗어난 데이터를 말한다.

이상치는 기계학습 모델의 성능을 떨어뜨릴 수 있으므로 이상치를 적절하게 처리하는 것이 중요하다. 산점도와 상자그림을 이용하면 이상치가 있는지 확인할 수 있다.



❶ 이상치가 있을 경우 이상치 쪽으로 데이터 전체의 흐름이 치우친다.



상자그림을 그려 보면 턱끈펭귄의 체질량에 이상치가 있음을 알 수 있다.

[그림 II-17] 펭귄 종에 대한 체질량 지수 상자그림




더 알아보기

상자그림으로 이상치 확인하기

1 상자그림 이해하기

상자그림은 데이터의 분포를 시각화하는 방법 중 하나이다. 데이터를 정렬한 후, 1사분위수(Q_1), 2사분위수(중앙값), 3사분위수(Q_3)를 기준으로 상자를 그려 표현한다.



- 최솟값: 1사분위수에서 $IQR \times 1.5$ 를 뺀 값
- 1사분위수(Q_1): 25%의 값
- 2사분위수(Q_2): 50%의 값으로 중앙값(median)
- 3사분위수(Q_3): 75%의 값
- 최댓값: 3사분위수에서 $IQR \times 1.5$ 를 더한 값


2 이상치 확인하기

- 이상치는 데이터 분포에서 벗어난 값으로, 전체 데이터에 영향을 미칠 수 있다.
- 상자그림에서 이상치는 1, 3사분위수와 IQR값을 이용해 구할 수 있다. IQR는 3사분위수(Q_3) - 1사분위수(Q_1)로, 최솟값과 최댓값을 계산하는 데 사용된다.
- 상자그림에서 최솟값($Q_1 - IQR \times 1.5$), 최댓값($Q_3 + IQR \times 1.5$)을 벗어난 값은 이상치로 간주한다.
- 이상치는 제거하거나 대체하는 방법으로 처리할 수 있다.

(3) 정규화

데이터를 분석할 때 속성값의 범위 크기가 서로 다르면 그 크기의 특성이 지나치게 반영되어 잘못된 모델이 만들어질 가능성이 높다. 각 속성값의 범위가 다르다면 정규화를 통해 일정한 범위로 맞추어야 한다. 그중 최소-최대 정규화는 속성값을 최솟값과 최댓값 사이의 범위를 0과 1의 범위로 맞추는 방법이다.

$$\text{최소 - 최대 정규화} = \frac{(x - x_{\min})}{(x_{\max} - x_{\min})}$$



[그림 II-18] 펭귄 데이터의 정규화

3 핵심 속성 추출

핵심 속성은 기계학습 모델의 학습 및 예측 성능에 중요한 영향을 미치는 속성으로, 핵심 속성을 추출하는 것은 기계학습 모델의 성능을 향상시키기 위한 중요한 과정이다. 핵심 속성은 데이터 분포, 상관관계, 중요도 등을 분석하여 추출할 수 있다. 이때 적절하고 중요한 속성을 선택해야만 그것으로 만들어진 기계학습 모델이 유용하고 좋은 성능을 낼 수 있다.

핵심 속성 추출 방법


- 불필요한 속성을 검토하여 제거한다. **예** 주민 등록 번호, 이름, 학번 등
- 공정성에 문제가 되는 속성이 있는지 검토한다. **예** 문제 성격에 따라 성별, 인종 등
- 중복되는 속성이 없는지 분석한다.
- 주어진 속성의 중요도를 판별한다.
- 더 필요한 속성은 없는지 검토하여 속성을 추가할 수도 있다.

(1) 정형 데이터의 핵심 속성 추출

수치형 데이터의 핵심 속성은 산점도와 상관계수를 이용하여 추출할 수 있다. 산점도는 데이터에서 두 속성 간의 관계를 알아보는 대표적인 방법이다. 따라서 산점도를 이용하면 데이터의 흩어짐 정도로 두 변수의 상관 정도를 파악할 수 있다.

[그림 II-19]의 그래프를 살펴보면 부리 길이와 체질량의 상관계수는 0.6으로 부리 길이가 길어질수록 체질량도 많아지는 양의 상관관계가 있다는 것을 알 수 있다.


음의 상관관계는 부리 길이가 길어질수록 체질량은 적어지는 것이예요.



[그림 II-19] 펭귄의 부리 길이와 체질량의 산점도

상관계수(r)는 두 속성의 상관 정도를 수치로 나타낸 값이고, 상관관계는 두 속성이 함께 변하는 정도를 나타낸다. 상관계수는 -1에서 1 사이의 값을 가지며, -1에 가까우면 음(-)의 상관관계, +1에 가까우면 양(+)의 상관관계, 0이면 상관관계가 없음을 의미한다. 속성 간의 상관계수를 히트맵으로 나타내면 상관관계를 보고 핵심 속성을 쉽게 파악할 수 있다.

범주형 데이터일 경우에는 산점도로 나타내면 핵심 속성을 파악하기 쉽다. 산점도로 세 가지 종을 분류할 때 효과적인 속성이 무엇인지 검토할 수 있다.




부리 길이 속성과 날개 길이 속성은 체질량과 상관관계가 높으므로 펭귄의 체질량에 영향을 미치는 핵심 속성이 될 수 있다.



[그림 II-20] 펭귄 데이터의 상관계수(히트맵)

펭귄의 세 가지 종을 쉽게 구분할 수 있다.




[그림 II-21] 부리 길이와 체질량의 산점도 분포

(2) 비정형 데이터의 핵심 속성 추출

얼굴 인식이나 목소리 구분, 지문 인식, 텍스트 분류 등 다양한 문제에서 비정형 데이터를 사용한다. 비정형 데이터에서도 기계학습 모델의 학습에 사용될 적절한 속성을 검토하는 작업을 해야 한다.

이미지의 경우에는 이미지의 전체 픽셀을 사용하는 대신 주어진 문제와 관련 있는 특정 부분, 예를 들면 눈, 귀, 전체 모양 등만 별도로 추출하여 사용하기도 한다. 음성이나 텍스트 데이터의 경우에도 특정한 속성과 별도의 속성을 추출하여 사용할 수 있다.



[그림 2-22] 소리 데이터의 특징

출처: <https://www.techm.kr/news/articleView.html?idxno=4428>

최근에는 딥러닝과 같은 기법을 사용하여 비정형 데이터에 숨겨진 속성과 특징을 스스로 찾아 사용하게 되면서 이미지, 음성, 텍스트와 같은 비정형 데이터의 기계학습 성능을 크게 향상시켰다.

실습 1

남극 펭귄 데이터 탐색하기

앞에서 살펴본 펭귄의 신체 부위 데이터를 탐색하고 기계학습 모델에 사용하기 위한 전처리 과정을 수행해 보자.


단계별 처리 과정



단계 1 데이터 수집하기

캐글 사이트에서 'Palmer Archipelago (Antarctica) penguin data'를 검색하고 펭귄 데이터를 다운로드한다.


✓ 캐글의 펭귄 데이터 수집 https://www.kaggle.com/datasets/parulpandey/palmer-archipelago-antarctica-penguin-data?select=penguins_size.csv



단계 ② 데이터 살펴보기

코랩에 데이터 업로드 방법

- ① 파일 아이콘을 클릭한다.
- ② 업로드 아이콘을 클릭하여 파일을 선택한다.
- ③ 업로드한 파일이 아래에 나타난다.



- ① 데이터 불러오기: 수집한 데이터 'penguins_size.csv' 파일을 업로드한 후, 데이터 프레임(df)을 생성한다.

```
01 import pandas as pd # 판다스 라이브러리 가져오기
02 df = pd.read_csv('penguins_size.csv') # 데이터 프레임(df) 생성
03 df.head() # 데이터 프레임 5행 출력
```

실행 결과

	species	island	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	39.1	18.7	181.0	3750.0	MALE
1	Adelie	Torgersen	39.5	17.4	186.0	3800.0	FEMALE
2	Adelie	Torgersen	40.3	18.0	195.0	3250.0	FEMALE
3	Adelie	Torgersen	NaN	NaN	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	193.0	3450.0	FEMALE

데이터에 결측치가 있다.

- ② 남극 펭귄 데이터의 속성과 유형 살펴보기

```
01 df.info() # 데이터 속성 확인하기
```

실행 결과

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 342 entries, 0 to 341
Data columns (total 7 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   species             342 non-null    object  
 1   island              342 non-null    object  
 2   culmen_length_mm    342 non-null    float64  
 3   culmen_depth_mm     342 non-null    float64  
 4   flipper_length_mm   342 non-null    float64  
 5   body_mass_g         342 non-null    float64  
 6   sex                 342 non-null    object  
dtypes: float64(4), object(3)
memory usage: 11.1+ KB
```

총 344개의 데이터가 있고, 데이터의 속성은 7개이다.

데이터 중 결측치가 있는 속성도 있다.

- ③ 통계 정보 확인하기: 남극 펭귄 데이터를 평균, 표준편차 등의 통계값으로 요약해 보자.

```
01 df.describe() # 데이터 통계 정보 요약
```

실행 결과

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	342.000000	342.000000	342.000000	342.000000
mean	43.921930	17.151170	200.915205	4201.754386
std	5.459584	1.974793	14.061714	801.954536
min	32.100000	12.100000	172.000000	2700.000000
25%	39.225000	15.600000	190.000000	3550.000000
50%	44.450000	17.300000	197.000000	4050.000000
75%	48.500000	18.700000	213.000000	4750.000000
max	59.600000	21.500000	231.000000	6300.000000




데이터의 통계 정보를 살펴보면 부리 길이의 평균은 43.92이고 체질량의 평균은 4201.75로 속성값의 크기에 차이가 있어서 정규화가 필요해요.

④ 데이터 시각화하기: 세 가지 펭귄 종의 데이터 수를 시각화해 보자.

seaborn

파이썬의 데이터 시각화 라이브러리로, 주로 통계 분석에 활용되는 다양한 기능을 지원한다.

```
01 import seaborn as sns
02 sns.countplot(x=df['species']) # 막대그래프(countplot) 그리기
```



Adelie: 168
Chinstrap: 68
Gentoo: 124
막대그래프로 세 가지 펭귄 종의 수를 살펴보면, Adelie는 168개, Chinstrap은 68개로 차이가 커요.

Q&A 데이터 편향성 검토하기



클래스별 데이터 수에 차이가 있으면 어떤 윤리적·사회적 문제가 발생할 수 있을까요?

그래프를 보았을 때 세 가지 펭귄 중 중 턱끈펭귄(Chinstrap)의 데이터 수가 상대적으로 적은 편이에요. 이 데이터로 펭귄의 종을 예측하는 인공지능 모델을 만든다면 아델리펭귄(Adelie)이나 젠투펭귄(Gentoo)에 비해 턱끈펭귄을 제대로 예측하지 못할 수 있어요.



단계 ③ 데이터 전처리하기

수집한 데이터에서 결측치와 이상치가 발견되면 삭제하도록 한다.

① 결측치 처리하기

▶ 결측치가 있는 행을 확인한다.

```
01 df.isnull().sum()
```

실행 결과

```
mpg      0
cyl      0
dis      0
wt      0
qsec     0
hwy     0
name     0
dtype: int64
```

속성별 결측치 수의 합을 출력한다. 부리 길이, 부리 깊이, 날개 길이 등의 속성에 결측치가 존재한다.

df.dropna(axis=0)

결측치가 있는 행을 삭제하는 명령어이다.

df.dropna(axis=1)

결측치가 있는 열을 삭제하는 명령어이다.

▶ 결측치가 있는 행을 삭제한다.

```
01 df=df.dropna(axis=0)
02 df.shape
```

실행 결과

(334, 7) 결측치를 처리한 후 데이터의 개수는 334개로 줄었다.

matplotlib, pyplot

파이썬의 데이터 시각화 라이브러리이다.




상자그림의 x값을
펄린 데이터의 다른 속성으로 변
경하면서 이상치를 확인해요.

② 이상치 확인하기

▶ 상자그림을 이용하여 펄린 데이터 속성에 이상치가 있는지 확인한다.

```
01 import matplotlib.pyplot as plt
02 plt.figure(figsize=(6,2))
03 sns.boxplot(data=df, x='culmen_length_mm')
```



실행 결과

'culmen_length_mm' 속성에는
이상치가 없음을 알 수 있다.

▶ unique() 함수로 속성별로 중복되지 않는 고유한 값의 종류를 출력하여 이상치가 있는지 확인한다.

```
01 df['species'].unique() #종의 고유한 값 종류 출력
```

실행 결과

```
array(['Adelie', 'Chinstrap', 'Gentoo'], dtype=object)
```

펄린의 종에는 이상치가 없다.

```
01 df['sex'].unique() #성별의 고유한 값 종류 출력
```

실행 결과

```
array(['MALE', 'FEMALE', '.'], dtype=object)
```

성별에는 'MALE', 'FEMALE' 외에 '.'의 값을 가지는 이상치가 있다.



다른 속성도 확인해요.

▶ 성별에 잘못된 값이 있는 행의 인덱스를 확인한다.

```
01 df[df['sex']=='.']
```

실행 결과

	species	island	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
336	Gentoo	Biscoe	44.5	15.7	217.0	4875.0	.

▶ 확인한 인덱스에 해당하는 행을 데이터 프레임에서 삭제한다.

```
01 df.drop(336, axis=0, inplace=True)
```

drop()

데이터 프레임의 행 또는 열을 삭제하는 함수이다.

drop() 인수 의미

- 336: 삭제할 행의 인덱스이다.
- axis: 삭제할 데이터의 방향 (행 = 0, 열 = 1)을 정한다.
- inplace: 원본 데이터 변경 여부(원본 사용 = True, 미사용 = False)를 정한다.

③ 데이터 정규화하기

- ▶ 앞에서 확인한 결과 데이터 속성값의 크기에 차이가 있으므로 최소-최대 정규화를 수행한다.

MinMaxScaler()

데이터 속성을 주어진 범위로 스케일링한다. 여기서는 0에서 1 사이의 범위로 조정한다.

```
01 from sklearn.preprocessing import MinMaxScaler
02 scaler = MinMaxScaler() # MinMaxScaler 생성하기
03 # 수치형 속성값을 최소-최대 정규화 처리
04 df[['culmen_length_mm', 'culmen_depth_mm',
05 'flipper_length_mm', 'body_mass_g']] = scaler.fit_transform(
06 df[['culmen_length_mm', 'culmen_depth_mm',
07 'flipper_length_mm', 'body_mass_g']])
08 df.head(10)
```

실행 결과

	species	island	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	0.254545	0.666667	0.152542	0.291667	MALE
1	Adelie	Torgersen	0.269091	0.511905	0.237288	0.305556	FEMALE
2	Adelie	Torgersen	0.298182	0.583333	0.389831	0.152778	FEMALE

정규화한 후 데이터 크기가 0~1 사이의 값으로 변환되었다.

단계 4 핵심 속성 추출하기

- ▶ 산점도를 이용하여 부리 길이(culmen_length_mm)와 부리 깊이(culmen_depth_mm) 데이터 속성 간의 상관관계를 알아보자.


```
01 import seaborn as sns
02 sns.scatterplot(x='culmen_length_mm', y='culmen_depth_mm',
03 data=df, hue='species')
```

- ▶ 산점도를 이용하여 부리 깊이(culmen_depth_mm)와 날개 길이(flipper_length_mm) 데이터 속성 간의 상관관계를 알아보자.


```
01 sns.scatterplot(x='culmen_depth_mm', y='flipper_length_mm',
02 data=df, hue='species')
```



부리 길이와 부리 깊이 데이터 속성의 조합으로 세 가지 펭귄 종을 분류할 수 있지만, 부리 깊이와 날개 길이 데이터 속성의 조합으로는 세 가지 펭귄 종을 구분하기 어려워요.



부리 길이와 부리 깊이 산점도




부리 깊이와 날개 길이 산점도

- ▶ 산점도와 회귀선으로 부리 길이(culmen_length_mm)와 체질량(body_mass_g)의 상관관계를 알아보자.

```
01 sns.regplot(x='culmen_length_mm', y='body_mass_g',
02              data=df, color='green')
```

실행 결과




부리 길이(culmen_length_mm)와 체질량(body_mass_g)은 상관이 있는 데이터 속성이예요.

- ▶ 히트맵으로 데이터 전체 속성 간의 상관관계를 시각화하고, 상관계수를 확인해 보자.
- df.corr() : 데이터 프레임의 수치형 데이터 속성의 상관관계를 계산한다.

```
01 sns.heatmap(df.corr(numeric_only=True), annot=True, cmap='Greens')
```

실행 결과



모든 수치형 데이터 속성 간의 상관관계를 한눈에 확인할 수 있어요.

결과 해석

펭귄의 체질량은 부리 길이, 부리 깊이, 날개 길이와 모두 상관이 있다. 그중에서 날개 길이와 상관계수가 0.87로 가장 높다. 부리 깊이와 체질량의 상관계수는 -0.47로 음의 상관관계가 있다. 부리 길이와 날개 길이가 길수록 체질량이 증가하는 반면, 부리 깊이가 길수록 체질량이 줄어드는 경향이 있다는 것을 알 수 있다.

따라서 부리 길이와 날개 길이가 펭귄의 체질량을 예측하는 핵심 속성이 될 수 있다.




단계 ① 데이터 수집하기

남극 펭귄의 종 분류 데이터 탐색하기에서 수집한 'penguins_size.csv'를 사용한다. [78쪽 참고](#)

단계 ② 데이터 살펴보기

① 파일 불러오기



▶ 오렌지의 'File'에서 'penguin_size.csv' 파일을 불러온다.



② 데이터 속성과 유형 살펴보기

▶ 'File'-'Data Table'을 연결한다.


▶ 'Data Table'에서 데이터 파일을 볼 수 있고 데이터의 개수와 속성, 결측치를 확인할 수 있다.



③ 통계 정보 확인하기

▶ 'File'-'Feature Statistics'를 연결한다.



▶ 최솟값, 최댓값, 평균, 표준편차, 결측치 등의 통계를 확인할 수 있다.



단계 ③ 데이터 전처리하기


▶ 'File'-'Preprocess'을 연결하여 'Impute Missing Values'-'Remove rows with missing values'를 선택하여 결측치가 있는 행을 삭제한다.

▶ 'Preprocess'-'Data Table'를 연결하여 결측치가 삭제된 것을 확인한다.




단계 ④ 핵심 속성 추출하기

▶ 'Preprocess'-'Scatter Plot'을 연결하여 세 가지 펭귄 종의 데이터 분포를 확인한다.



Axis x	culmen_length_mm (부리 길이)
Axis y	culmen_depth_mm (부리 깊이)
Color	species(펭귄 종)

데이터의 분포를 통해 펭귄의 종을 분류할 수 있는지 확인한다.



지금 듣고 있는 노래를 내가 좋아하는 가수 목소리로?

내가 좋아하는 노래를 내가 좋아하는 가수의 목소리로 들을 수 있다면 얼마나 좋을까? 2023년 인기를 끌었던 'Hype boy'를 미국의 유명한 팝 가수의 목소리로 바꾼 노래를 들어 보자. 한 음성의 억양, 속도, 세기와 같은 특징을 다른 음성의 특징으로 변환하는 기술인 '음성 변환'이 적용된 사례이다. 텍스트, 이미지, 음성, 영상과 같은 콘텐츠를 생성하거나 변환하는 생성형 인공지능의 발전으로 음성 분야에도 많은 혁신이 이루어지고 있다.

💡 'AI cover'라고 검색하면 음성 변환된 다양한 노래를 찾아볼 수 있어요.



📌 미국의 유명 팝 가수의 목소리로 듣는 'Hype boy'

○○가수의
목소리로 ○○노래가
흘러나오고 있어!



📌 한국의 유명 가수의 목소리로 듣는 ○○


음성 변환 기술을 이용하면 한 사람의 음성을 다른 사람의 음성처럼 바꾸거나, 특정 감정이나 나이대의 음성 스타일로 변환할 수 있다. 음성 변환 기술은 음성 합성 기술과 함께 엔터테인먼트, 보안, 의료 등 다양한 분야에서 활용될 수 있다.

인공지능의 발전과 함께 이러한 기술들은 우리 일상과 산업에 더 깊게 녹아들며 다양한 가능성을 제시하고 있다. 하지만 이와 동시에 음성에 대한 저작권 문제, 악용 가능성과 같은 부작용이 잠재하고 있으므로, 인공지능 기술을 올바르게 활용하기 위한 개인의 노력과 사회적 논의가 이루어져야 한다.



📌 ○○ '마이 AI 보이스'
사용자가 녹음한 목소리 톤과 감정을
담은 AI 목소리를 생성해 준다.

📌 ○○○ 클로바 '가족의 목소리'
기억하고 싶은 부모, 아이, 나의 목소리로
ai 보이스를 제작해 준다.



우리나라의 지진 발생 현황을 분석해 보기

최근 모로코(규모 6.8), 튀르키예(규모 7.8) 지진으로 수천에서 수만 명의 사망자를 발생하였다. 우리나라도 2016년, 2017년에 연이은 큰 규모의 지진으로 지진 안전지대라고 할 수 없다.



단계 ① 문제 정의하기

우리나라 지진 발생 현황을 분석해 보자.

단계 ① 데이터 수집하기

① 기상자료개방포털 사이트에 접속한다.

💡 30일 이상 데이터를 다운로드하기 위해 로그인이 필요하다.



기상자료개방포털

data.kma.go.kr

② [데이터]-[지진화산]-[지진화산 특·정보]-지진정보'에서 최대 120개월의 지진 데이터를 조회한 후 파일을 csv로 저장한다.

	A	B	C	D	E	F
1	시간	규모	진앙(km)	위도	경도	위치
14	2014-04-13 14:02	2.9	2	36.93	124.52	충남 태안군
15	2014-04-25 12:14	2.9	8	35.97	128.04	경북 김천시
16	2014-04-26 14:08	2.7	19	36.46	127.93	경북 상주시

③ 데이터를 직접 수집한 경우, 저장한 csv 파일을 utf-8로 변환해서 사용해야 한다.

▶ 구글 스프레드시트에서 데이터 파일을 열고 [파일]-[다운로드]-[첨표로 구분된 값(csv)]으로 다시 저장한다.

(파일명: earthquake)

④ 데이터를 직접 수집하지 않은 경우에는 주어진 링크에 들어가서 'earthquake.csv'를 다운로드한다.

🔗 https://bit.ly/earthquake_data

단계 ① 데이터 전처리 및 탐색적 데이터 분석하기

① 코드 작성 시 한글이 깨지는 현상을 방지하기 위해 아래 라이브러리를 설치한다.

```
01 !pip install koreanize-matplotlib
```

② 지진 데이터를 불러와 데이터 프레임 생성한다.

```
01 import pandas as pd
02 df = pd.read_csv('earthquake.csv')
03 df.head()
```

시간, 규모, 진앙(km),
위도, 경도, 위치 속성이 저장되어 있어요.

③ 지진 데이터의 결측치를 확인한다.

```
01 df.isnull().sum()
```

진앙(km) 속성에 6개의 결측치가 있다.
df.info()로도 결측치가 있는지 확인할 수 있다.

④ 행 단위로 결측치를 확인해 삭제한다.

```
01 # axis=0: 행 단위, inplace=True: 원본 데이터 프레임 변경
02 df.dropna(axis=0, inplace=True)
```

진양(km) 속성에 있는 결측치 행을 삭제한다.

⑤ '시간' 속성에 있는 일시에서 연도만 추출한다.

```
01 # pd.to_datetime : 날짜 및 시간 정보를 가진 데이터를 pandas의 datetime 형식으로 변환하기
02 df['연도'] = pd.to_datetime(df['시간']).dt.year # dt.year : datetime 타입에서 연도만 추출하기
```


'시간' 속성의 연도 정보가 새로운 '연도' 속성으로 추가되었다.

연도
2014
2014
2014

⑥ 연도에 따른 지진 규모를 산점도로 시각화하여 가장 큰 지진이 일어난 연도를 살펴보자.

```
01 import koreanize_matplotlib # 한글 깨짐 방지
02 import seaborn as sns # seaborn 라이브러리 가져오기
03 sns.scatterplot(x='연도', y='규모', data=df) # 산점도 그래프
```

실행 결과



2014년부터 현재까지 우리나라의 가장 큰 지진은 2016년에 일어났어요. 2016년에 일어난 지진이 언제, 어디에서 일어났는지 찾아봐요.



⑦ '위치' 속성에서 첫 두 글자만 추출해 '지역' 속성에 저장한다.

```
01 df['지역'] = df['위치'].str[:3]
```

'위치' 속성의 첫 두 글자가 새로운 '지역' 속성으로 추가되었다.


위치
지역
첫 두 글자만

⑧ 지역별 지진 발생 횟수를 원그래프로 시각화하여 지진이 가장 많이 발생한 지역을 살펴보자.

```
01 import matplotlib.pyplot as plt
02 loc = df['지역'].value_counts() # '지역' 속성 값의 빈도수 구하기
03 # 원그래프 시각화, labels : 레이블 지정, autopct : 값을 %로 표시
04 plt.pie(loc, labels = loc.index, autopct="%1.1f%")
05 plt.show()
```

loc 변수의 인덱스값을 지정해 원형 그래프 레이블로 표시함.

실행 결과의 일부



2014년부터 지금까지 우리나라에서 지진이 가장 많이 발생한 지역은 '경북'으로 41.6%예요. 경북에서 지진이 자주 발생하는 원인을 찾아봐요.



- 문제 해결에 적합한 기계학습의 유형과 알고리즘을 선정할 수 있다.
- 훈련 데이터를 이용하여 학습을 진행하고, 테스트 데이터를 사용하여 성능을 평가할 수 있다.

기계학습 알고리즘

학습 요소


기계학습 유형, 기계학습 알고리즘, 훈련 데이터, 테스트 데이터



모델

현실 세계의 시스템이나 현상을 단순화하여 표현한 것이다.
수학적 모델, 컴퓨터 모델, 시물레이션 데이터 모델, 인공지능 모델 등이 있다.

기계학습 모델은 대량의 데이터와 기계학습 알고리즘으로 학습된 결과물이다. 따라서 기계학습 모델은 문제 해결에 적합한 데이터와 기계학습 알고리즘을 선택하여 만들 수 있다.



[그림 II-23] 기계학습 유형에 사용하는 다양한 알고리즘

1 기계학습 유형

1 지도학습

지도학습은 데이터와 그 데이터에 해당하는 정답(레이블)을 함께 사용하여 학습하는 방법이다. 이 학습으로 데이터와 레이블의 관계를 이해하고, 그것을 바탕으로 새로운 데이터에 대한 예측이나 분류를 한다. 예를 들어 고양이와 개의 각 사진에 ‘고양이’, ‘개’라는 레이블이 주어졌을 때, 컴퓨터는 사진을 보고 고양이와 개를 구분하는 방법을 배운다. 그 후에 새로운 동물 사진이 주어졌을 때, 그것이 고양이인지 개인지를 스스로 판단할 수 있게 된다. 지도학습은 분류와 회귀 문제에 널리 사용되며, 데이터에 정답이 있는 경우에 적합하다.

(1) 분류


기계학습으로 알아내고자 하는 정답이 어느 범주에 속하는지 알고자 할 때 분류로 해결한다. 예를 들어 꽃 품종, 스팸 메일과 정상 메일, 식용 버섯과 독 버섯을 분류할 때와 같은 경우이다.



[그림 II-24] 분류의 예

(2) 회귀

회귀는 연속적인 수치를 예측할 때 사용한다. 예를 들어 강수량, 온도에 따른 배춧값 예측, 광고 매체 투자에 따른 판매 가격 예측 등과 같은 경우이다.



[그림 II-25] 회귀의 예

2 비지도학습

비지도학습은 정답, 즉 레이블이 제공되지 않는 데이터를 학습하는 방법이다. 이 학습은 데이터 안의 패턴이나 구조를 스스로 찾아내어 비슷한 것들을 집단으로 묶거나 데이터의 주요 특징을 추출하는 등의 작업을 한다. 비지도학습은 명확한 답이 주어지지 않은 데이터를 다룰 때 유용하며, 스스로 학습하여 알려져 있지 않은 유용한 정보를 발견하는 데 도움이 된다. 주로 군집, 연관 규칙 문제를 해결하는 데 사용한다.



[그림 11-26] 군집의 예(고객 맞춤형 카드 상품) 비슷한 유형의 고객끼리 군집을 형성하면 군집에 맞는 맞춤형 상품이나 서비스를 제공한다.

(1) 군집

특징이 유사한 데이터들끼리 같은 군집으로 묶는 방법이다. 예를 들어 카드 회사에서 고객 정보와 카드 사용 내역 등을 바탕으로 비슷한 유형의 고객끼리 묶을 수 있다. 군집은 고객 맞춤형 카드 상품 제공, 마케팅 전략 수립 등에 활용할 수 있다.

연관 규칙


주어진 데이터셋에서 어떤 항목이 등장했을 때, 다른 항목이 함께 등장할 확률이 높은지 등의 규칙을 찾는다.

연관 규칙의 예

- 1+1 마케팅
- 고객 행동 분석
- 재고 관리
- 상품 개발

(2) 연관 규칙

데이터 속성들의 상호 관련성을 분석하여 연관 규칙을 발견하는 방법이다. 예를 들어 고객이 마트에서 구매한 상품에 대한 연관 규칙을 발견할 수 있다면 고객이 앞으로 구매할 가능성이 큰 상품을 추천할 수 있다. 연관 규칙은 상품 추천, 마케팅 전략 수립 등에 활용할 수 있다.



고객이 구매한 상품 분석 우유가 포함된 영수증의 70%가 빵, 40%가 달걀, 20%가 휴지를 함께 구매한다.

마케팅에 활용 우유 옆에 빵을 배치하여 연관 구매율을 높일 수 있다.

[그림 11-27] 연관 규칙의 예(고객에게 상품 추천하기)


3 강화 학습

우리가 자전거 타는 법을 배울 때 시행착오를 거듭하면서 점점 나은 행동을 학습해 가는데 이것을 강화 학습이라고 한다. 시행착오를 거듭하면서 자전거를 타다 보면 ‘보상(즉, 넘어지거나 혹은 전진하거나 등)’이 주어지는데, 이러한 보상을 최대화하는 방향으로 학습이 진행되어 점점 더 나은 행동을 하게 되고, 결국은 자전거를 잘 탈 수 있게 된다.



[그림 II-28] 인간의 강화 학습(자전거 타기 예)

강화 학습 전략은 인공지능에서도 적용되고 있다. 예를 들어 게임에서 캐릭터는 주어진 환경에서 어떤 동작을 해 보상(즉, 점수)을 최대화하는 것인지를 시행착오로 학습하게 된다. 강화 학습은 주어진 데이터나 환경에 대한 사전 지식 없이 스스로 학습하고 적응하는 방법이기 때문에, 로봇의 자율 제어, 컴퓨터 게임, 금융 거래 전략 수립 등 다양한 분야에 적용되고 있다.



[그림 II-29] 벽돌깨기 게임 강화 학습

출처: <https://youtu.be/gnx48Nh7YRc?si=jWuB2BiP94IAY9dp>

한 예로 벽돌깨기 게임에 강화 학습을 적용하면 다음과 같이 학습된다. 게임의 패널인 에이전트는 제자리, 왼쪽, 오른쪽 세 가지 중 하나로만 행동할 수 있다.

에이전트가 처음에는 무작위로 행동하다가 공으로 친 벽돌이 깨지게 되어 점수, 즉 보상이 올라가면 그 상황에서 행동 전략을 학습하게 되고 수많은 시행착오를 하면서 강화 학습이 이루어진다.

알파고와 인간 바둑 챔피언의 대결

알파고는 인간 챔피언과 바둑 대결에서 인간 챔피언을 4:1로 이겼다. 바둑 인공지능인 알파고는 보상(즉, 승리나 패배)을 최대화하는 행동(즉, 어디에 돌을 놓는지)을 배우기 위해 수백만 번의 연습 경기를 스스로 진행하여 인간 챔피언에게 승리할 수 있었다.



에이전트(agent)

환경과 상호 작용하여 목표를 달성하기 위해 행동하는 소프트웨어나 하드웨어를 말한다.

2 모델의 학습과 평가

1 기계학습 모델의 구현 과정

문제 정의에 따라 수집된 데이터는 학습 과정을 거쳐 기계학습 모델을 만드는 데 사용된다. 기계학습 모델을 구현하는 과정은 다음과 같다.

단계 ①

문제 정의하기

기계학습으로
해결 가능한 문제를
만들려고 해.



지도학습
문제야?

해결하고자 하는 문제를 명확히 이해하고 목표를 설정해야 한다. 주어진 문제가 기계학습으로 해결할 수 있는 문제인지, 지도학습 혹은 비지도학습으로 해결할 수 있는 문제인지를 판단해 기계학습의 관점에서 문제를 정의한다.

단계 ②


데이터 수집 및 전처리하기



1. 데이터 수집하기: 데이터를 직접 만들거나 측정하여 수집할 수 있고, 이미 준비된 데이터를 사용할 수도 있다. 데이터 수집 과정에서 데이터의 양과 품질을 확인하는 것이 중요하다.
2. 탐색적 데이터 분석하기: 수집된 데이터의 통계 정보를 확인하거나 다양한 시각화로 데이터의 속성을 파악해 모델을 설계하기 위한 정보를 얻는다.
3. 데이터 전처리하기: 결측치나 이상치를 처리하고 학습에 적합한 형태로 데이터를 가공한다.
4. 핵심 속성 추출하기: 탐색적 데이터 분석 결과를 활용해 모델에 사용하는 핵심 속성을 추출한다.

단계 ③


모델 생성하기



1. 기계학습 유형과 알고리즘/모델 선정하기: 문제 해결에 적합한 기계학습 유형과 각 유형에 따른 알고리즘을 선정하여 모델을 생성한다.
 - 기계학습 유형: 지도학습, 비지도학습, 강화 학습
 - 기계학습 알고리즘: 결정트리, 로지스틱 회귀, k-평균 군집 등
2. 모델 학습하기: 훈련 데이터를 이용해 모델을 학습시킨다.

단계 ④

모델 평가하기



테스트 데이터로 생성한 모델의 성능을 평가하고, 필요할 경우에는 단계 ③으로 가서 모델을 수정할 수 있다.

문제 상황 재활용이 가능한 빈 병이나 페트병을 자동으로 분류하고 현금 포인트로 적립해 주는 인공지능 자판기가 있다. 하지만 페트병을 라벨이 있는 것과 없는 것으로 분류하지는 못한다. 라벨이 있는 페트병과 라벨이 없는 페트병을 분류하는 모델이 필요하다.

단계 ① 문제 정의하기

생수병의 무라벨, 라벨을 분류하는 모델을 구현해 보자.

단계 ② 데이터 수집 및 전처리하기

인터넷 사이트에서 라벨, 무라벨 생수병 이미지 데이터를 직접 수집하거나 주어진 링크에서 데이터 파일인 '라벨-무라벨 생수병 분류하기.zip'을 다운로드한다.

🔗 https://bit.ly/label_labelless



label(라벨 있는 생수병)				labelless(라벨 없는 생수병)			
1	2	3	4	1	2	3	4

💡 라벨, 무라벨 생수병 이미지 데이터를 훈련 데이터와 테스트 데이터로 분할한다.

단계 ③ 모델 생성하기

- 1 티처블머신 사이트에 접속한다.
<https://teachablemachine.withgoogle.com/>
- 2 [이미지 프로젝트]-[표준 이미지 모델]을 선택한다.
- 3 Class에 레이블명(label, labelless)을 입력하고, 훈련 데이터로 저장한 이미지 파일을 업로드하거나 웹캠을 실행시켜 직접 생수병을 촬영해 저장한다.
- 4 [모델 학습시키기]를 클릭해 모델을 학습시킨다.

단계 ④ 모델 평가하기

모델 학습이 완료되면 웹캠이나 테스트 데이터로 저장한 이미지 파일을 업로드하여 예측을 수행한다.





💡 class(클래스): 지도학습에서 예측하고자 하는 값의 범주로 label(라벨), labelless(무라벨)가 여기에 해당한다.

2 기계학습 모델의 학습과 평가

기계학습은 인간의 학습 과정과 유사하게 생각할 수 있다. 인간은 많은 사례를 학습하여 어떤 개념을 알게 된다. 만약 그 사례가 정확하지 않거나 양이 충분하지 않으면 개념을 정확하게 알지 못한다. 따라서 개념이 정확하게 학습되었는지 알기 위해 테스트를 수행할 수 있다. 이러한 과정을 통해 기계학습도 정확하고 충분한 양의 데이터로 정의된 문제에서 요구하는 모델을 만들어 낸다.

(1) 기계학습 알고리즘 선정과 모델 생성하기

문제 해결에 적합한 기계학습 모델을 만들려면 [그림 II-30]에서 제시한 여러 가지의 모델 중 어떤 모델을 사용할지, 알고리즘은 무엇을 사용할지 검토하여 결정한다.

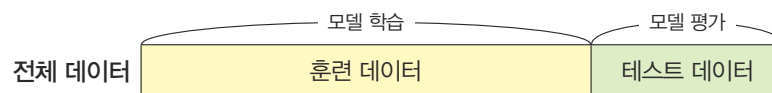


[그림 II-30] 기계학습 모델의 종류

(2) 데이터를 이용해 모델 학습시키기

학습은 선정된 기계학습 모델을 데이터에 최적화시키는 과정이다. 즉, 주어진 데이터로 모델의 매개 변수(혹은 계수) 값을 조정하여 모델이 성능을 잘 발휘하도록 하는 과정이다.

데이터는 [그림 II-31]과 같이 전체 데이터를 모델 학습에 사용할 훈련(train) 데이터와 모델 성능을 평가하는 테스트(test) 데이터로 나눈다.



[그림 II-31] 훈련 데이터와 테스트 데이터

선형 회귀 모델

96쪽 참고


분류 모델

106쪽 참고

군집 모델

118쪽 참고

이때 모델이 훈련 데이터에서만 좋은 성능을 보이고, 그 밖의 데이터에서는 성능이 낮아지는 경우가 발생하게 되는데, 이것을 기계학습의 과적합(overfitting) 문제라고 한다.



과적합

훈련 데이터에만 최적화되고 테스트 데이터에는 정확도가 낮은 경우이다. 비유를 하자면, 훈련용 예시 데이터만 단순 암기해 버리고 그 외의 것은 학습하지 못하게 되는 경우를 말한다. 따라서 훈련 후에는 별도의 테스트(시험) 데이터를 사용하여 학습이 얼마나 잘 되었는지를 검증한다.


최적화

모델이 데이터를 가장 잘 이해하고 예측할 수 있도록 오류를 최소화하는 과정이다. 훈련 데이터와 테스트 데이터 모두에 정확도가 높은 경우에 해당한다.

교차 검증(cross-validation)은 과적합되지 않은 모델을 만들기 위해 사용하는 대표적인 방법으로 훈련 데이터를 여러 개로 분할해 그중 하나는 검증 데이터, 나머지는 훈련 데이터로 사용하여 반복한다. 모델 생성 과정에서 훈련 데이터로 모델을 학습시키고 검증 데이터로 모델의 성능을 평가하면, 모델이 실제 데이터에 얼마나 잘 작동하는지 알 수 있다. 만약 모델이 검증 데이터에 잘 작동하지 않으면 과적합 여부를 의심해 볼 수 있다.

(3) 모델 평가하기

생성된 모델의 최종 성능은 다양한 척도로 평가한다. 데이터가 충분한 경우 훈련 데이터는 검증 데이터를 별도로 분할해 모델을 생성할 때 성능을 평가하고, 최종 모델의 성능은 테스트 데이터로 평가한다. 만약 데이터의 크기가 충분하지 않으면 훈련 데이터와 테스트 데이터로 분할해서 사용하고, 데이터 크기가 매우 작을 때에는 교차 검증에서 얻은 성능 추정치를 평균킴으로 사용할 수도 있다.




[그림 11-32] 학습과 평가를 위한 데이터 분할



더 알아보기

k-폴드(k-fold) 교차 검증

k-폴드 교차 검증은 훈련 데이터를 k개의 부분 세트로 분할하고, k-1개는 모델을 훈련하는 데 쓰고, 나머지 1개는 검증하는 데 쓴다. 예를 들면, k=5일 때의 교차 검증에서는 훈련 데이터를 5등분하여 그중 1개를 검증 데이터로 사용하고 나머지는 훈련에 사용한다. 검증 데이터는 모델의 성능 평가에 사용하는데, 오른쪽 그림과 같이 검증 데이터를 바꿔 가며 총 다섯 번의 훈련과 검증을 반복한다. 그리고 다섯 번의 평균값을 이 모델의 성능으로 추정한다.



3 회귀

1 선형 회귀 모델

지도학습에서 수치를 예측하는 선형 회귀는 정답이 있는 데이터를 이용해 연속적인 값을 예측한다. 선형 회귀로 해결할 수 있는 문제는 주택 가격, 기온, 판매량, 키, 몸무게 등과 같이 연속적인 수치형 값들이다. 선형 회귀 모델을 만들면 독립 변수와 종속 변수 간의 선형 관계를 파악하여 연속적인 값을 예측할 수 있다.

독립 변수



예측하고자 하는 변수로, 입력 값을 의미한다.

종속 변수

예측으로 구하고자 하는 변수로, 결과값을 의미한다.

선형 회귀 문제 예

- 온도, 강수량에 따른 배춧값
- 연도에 따른 연평균 해수면 높이
- 공부 시간에 따른 성적
- 사회적 지지에 따른 기대 수명
- GDP에 따른 행복 점수
- 광고 매체 투자에 따른 판매 가격



[그림 II-33] 단순 선형 회귀와 다중 선형 회귀

선형 회귀 모델은 [표 II-6]의 식으로 표현할 수 있으며, 최적의 선형 회귀 모델은 주어진 독립 변수로 종속 변수를 잘 예측할 수 있는 회귀계수와 절편을 찾는 것이다.

[표 II-6] 선형 회귀 모델의 식

$y = \underbrace{w_1 x_1 + w_2 x_2 + \dots + w_n x_n}_{\text{회귀계수}} + \underbrace{b}_{\text{절편}}$			
독립 변수	$x_1, x_2, \dots, x_n$: 입력 변수(종속 변수를 예측하는 데 사용되는 변수)	종속 변수	y : 결과 변수(예측하려는 변수)
회귀계수	$w_1, w_2, \dots, w_n$: 독립 변수의 변화에 따른 종속 변수의 평균 변화량 • 종속 변수에 영향력이 큰 경우: 절댓값이 큰 회귀계수 • 종속 변수에 영향력이 작은 경우: 절댓값이 작은 회귀계수	절편	b : 독립 변수의 값이 모두 0일 때 종속 변수의 예측값

2 선형 회귀 성능 평가

모델의 성능을 평가하면 모델이 실제 관측된 데이터를 얼마나 정확하게 예측하는지 확인할 수 있다. 이때 실제로 관찰된 결과나 목표값을 ‘실제값’, 모델이 예측한 값을 ‘예측값’이라고 부른다. 선형 회귀 성능을 평가하는 방법에는 오차 함수와 결정계수가 있다.




선형 회귀에서
종속 변수가 실제값이에요.

(1) 오차 함수

기계학습 모델은 실제값과의 차이를 최소화하는 예측값을 찾는 것이 목표이다. 이때 실제값과 예측값의 차이를 구하는 함수를 오차 함수라고 한다.

[그림 II-34]에서 점은 실제값이고 모델의 출력값은 예측값으로, 실제값과 예측값의 차이를 오차라고 한다.



[그림 II-34] 선형 회귀에서의 오차(실제값과 예측값 차이)

오차 함수(error function)

손실함수(loss function), 비용 함수(cost function)라고도 한다.



오차 함수의 값이 작을수록
선형 회귀 모델의 성능은 우수해요!



더 알아보기

오차 함수 종류

선형 회귀 모델에서 성능을 구하는 오차 함수에는 MAE(평균절대오차), MSE(평균제곱오차), RMSE(평균제곱근오차) 등이 있다.

MSE(Mean Squared Error, 평균 제곱오차)

- 실제값(y_i)과 예측값($\hat{y}_i$) 차이의 제곱을 평균한 값

$$\bullet \text{ MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

실제값-예측값

MAE(Mean Absolute Error, 평균 절대오차)

- 실제값과 예측값 차이(오차)의 절대값

$$\bullet \text{ MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

RMSE(Root Mean Squared Error, 평균제곱근오차)

- 실제값과 예측값 차이(오차) 제곱의 평균제곱근 값


$$\bullet \text{ RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

결정계수(R^2) 범위 해석

- $R^2 = 0$: 모델이 예측력이 없다.
- $0.0 < R^2 < 0.3$: 모델이 종속변수의 변동을 일부 설명한다(약한 설명력).
- $0.3 \leq R^2 < 0.5$: 모델이 종속변수의 변동 중 일정 부분 설명한다. 어느 정도의 설명력이 있는 모델이다(중간 정도 설명력).
- $0.5 \leq R^2 < 0.7$: 모델이 종속변수의 변동을 상당 부분 설명한다(높은 설명력).
- $0.7 \leq R^2 \leq 1$: 모델이 종속변수의 변동을 대부분 설명한다(매우 강한 설명력).

(2) 결정계수(R^2)

결정계수는 모델이 데이터를 얼마나 잘 설명하는지를 나타내는 값이다. 값의 범위는 0~1 사이로, 결정계수(R^2 ; R squared)가 1에 가까우면 선형 회귀 모델이 데이터를 매우 잘 설명함을 의미한다.



[그림 II-35] 결정계수(R^2)

실습 2

목둘레로 허리둘레를 예측하는 선형 회귀 모델 구현하기



203쪽 참고

문제 상황 목둘레로 내 허리 치수에 잘 맞는 청바지를 고를 수 있다고 한다. 신체 치수를 이용해 허리둘레를 예측하는 선형 회귀 모델을 구현해 보자.



단계 ① 문제 정의하기	신체 치수를 알면 허리둘레를 예측할 수 있을까?
단계 ② 데이터 수집 및 전처리하기	공공 데이터 포털 사이트에서 데이터 수집하기: jeans.csv 독립 변수와 종속 변수 구분하기 데이터 분할하기
단계 ③ 모델 생성하기	선형 회귀 모델 생성하기
단계 ④ 모델 평가하기	성능 평가하기

단계 1 문제 정의하기

신체 치수를 알면 허리둘레를 예측할 수 있을까?



단계 2 데이터 수집 및 전처리하기



공공데이터포털
<https://www.data.go.kr>



공군 데이터만을
 사용하므로 모든 경우를 일반화
 할 수는 없으니 유의하세요.

(1) 데이터 수집하기

① 주어진 링크에서 'jeans.csv'를 다운로드한다.

✓ https://bit.ly/jeans_data

💡 jeans.csv는 공공데이터포털 사이트에서 국방부 공군 신체 측정 정보(남, 여) 파일을 다운
 로드한 후 목둘레, 몸무게, 엉덩이둘레, 허리둘레 열만 남기고 이상치를 제거한 파일이다.

② 'jeans.csv' 파일을 업로드하고 데이터 프레임(df)을 생성한다.

```
01 import pandas as pd
02 df = pd.read_csv('jeans.csv') # 데이터 프레임(df) 생성하기
03 df.head() # 데이터 프레임 5행 보여 주기
```

실행 결과

	neck	weight	hip	waist
0	33.8	51.1	86.0	62.9
1	33.0	45.4	87.9	63.0
2	35.3	58.9	95.2	64.2
3	33.1	47.3	88.6	64.4
4	33.1	47.7	88.5	65.0

(2) 데이터 전처리하기

① 독립 변수, 종속 변수 선정하기: 독립 변수(X)는 목둘레(neck), 종속 변수(y)는 허리둘레(waist)를 선정한다.

```
01 import numpy as np
02 X = df['neck'].values.reshape(-1, 1) # 독립 변수(X)
03 y = df['waist'].values # 종속 변수(y)
```

• reshape(-1, 1): 열(column)의 수를 1로 설정하여 2차원 배열로 변환한다.
 -1: 배열의 차원을 자동으로 조절한다.



목둘레로 허리둘레를
 예측할 단순 선형 회귀 모
 델을 생성해 봐요.

- ② 훈련 데이터와 테스트 데이터 분할하기: 전체 데이터에서 훈련 데이터는 70%, 테스트 데이터는 30%로 분할한다.

```
01 from sklearn.model_selection import train_test_split
02 X_train, X_test, y_train, y_test = train_test_split(
03     X, y, test_size=0.3, random_state=42)
04 print(X_train.shape, X_test.shape, y_train.shape,
05     y_test.shape)
```

	X	y
train	X_train	y_train
test	X_test	y_test

- X_train: 훈련 데이터의 독립 변수
- X_test: 테스트 데이터의 독립 변수
- y_train: 훈련 데이터의 종속 변수
- y_test: 테스트 데이터의 종속 변수

- train_test_split(): 데이터를 훈련 데이터와 테스트 데이터로 분할한다.
- random_state=42: random_state는 무작위성을 제어하기 위한 시드(seed)값으로, 같은 시드값을 사용하면 같은 무작위 결과를 얻을 수 있게 해 준다.

단계 ③ 모델 생성하기



기계학습 모델을 구현하고 학습할 다양한 알고리즘을 제공하는 라이브러리인 sklearn(사이킷런)을 많이 사용하고 있어요.

(1) 기계학습 유형과 알고리즘 선정하기

연속적인 값을 예측하기 위해서는 지도학습의 선형 회귀 모델이 필요하고 독립 변수가 하나이므로 단순 선형 회귀를 사용한다.

(2) 모델 학습하기

- ① LinearRegression으로 선형 회귀 모델(model)을 생성하고, 훈련 데이터(X_train, y_train)를 이용하여 모델을 학습시킨다.

```
01 from sklearn.linear_model import LinearRegression
02 model = LinearRegression() # 모델 생성하기
03 model.fit(X_train, y_train) # 모델 학습하기
```

- model.fit(): 기계학습 모델을 학습시키며, 선형 회귀 모델의 회귀계수와 절편을 찾는 과정이다.

- ② 모델의 회귀계수와 절편을 구한다.

```
01 print(model.coef_, model.intercept_) # 회귀계수, 절편 구하기
```

실행 결과 예

```
12.382405381 27.7212703428578
```

- model.coef_: 모델의 회귀계수를 구한다.
- model.intercept_: 모델의 절편을 구한다.

- ③ 모델의 결정계수(R^2)를 구한다.

```
01 print(model.score(X_train, y_train)) # 결정계수 구하기
```

실행 결과 예

```
0.7011212121212121
```

훈련 데이터인 모듈레로 허리둘레를 예측하는 데 약 70% 정도 설명할 수 있다.

- model.score(): 모델의 성능을 평가한다.



모델을 생성할 때 훈련 데이터와 테스트 데이터 분할을 무작위로 하기 때문에 성능이 바뀌어 실행 결과가 다르게 나올 수 있어요. 다른 결과가 나올 수 있는 것을 예를 붙여 표시해 두었어요!

단계 4 모델 평가하기

① 테스트 데이터(X_test, y_test)를 이용해 모델의 성능을 평가한다.

```
01 print(model.score(X_test, y_test)) # 성능 평가하기
```

실행 결과 예

```
0.7125334631723017
```

성능 평가 결과, 테스트 데이터인 목둘레로 허리둘레를 예측하는 데 약 71% 정도 설명할 수 있다.



predictions[:5]는 0~4번
인덱스값을 추출해요.

② 테스트 데이터를 이용해 예측을 수행한다.

```
01 predictions = model.predict(X_test) # 테스트 데이터로 예측하기
02 print("예측값: ", predictions[:5]) # 예측 결과
03 print("테스트 결괏값: ", y_test[:5]) # 테스트 데이터 결과
```

실행 결과 예

```
예측값: [88.077791 77.312824 80.913081 82.508276 75.742258]
테스트 결괏값: [87.0 88.0 80 78.0 86.0]
```


예측 결과(predictions)와 테스트 데이터 종속 변수(y_test) 값을 비교한 결과, 비슷한 결과가 나온 것을 볼 수 있다.

- model.predict(): 새로운 데이터에 대한 예측을 수행한다.

③ 테스트 데이터와 모델의 예측값을 표현하면 다음과 같다.

```
01 import matplotlib.pyplot as plt
02 # 테스트 데이터 실제값 표현(산점도)
03 plt.scatter(X_test, y_test, color='blue')
04 plt.plot(X_test, predictions, color='red') # 예측 결과(선그래프)
05 plt.xlabel('neck') # x축 레이블
06 plt.ylabel('waist') # y축 레이블
07 plt.show() # 그래프 보여 주기
```

실행 결과 예



목둘레(neck)에 대한
허리둘레(waist) 예측값을 선그래
프로 표현하면 실제값을 어느 정도
예측할 수 있다.



단계 ① 문제 정의하기

신체 치수를 알면 허리둘레를 예측할 수 있을까?


단계 ② 데이터 수집 및 전처리하기

- ① 선형 회귀 모델 구현하기에서 수집한 'jeans.csv'를 사용한다. [99쪽 참고](#)
- ② 'File'에서 'jeans.csv' 파일을 불러온다.
- ③ 독립 변수(feature)는 목둘레(neck), 종속 변수(target)는 허리둘레(waist)로 선정하고 [Apply] 버튼을 누른다(나머지 속성: skip).
- ④ 'File'-'Data Sampler'를 연결한다. 'Data Sampler'의 'Fixed proportion of data' 옵션에서 70%를 선택한다(훈련 데이터: 70%).



단계 ③ 모델 생성하기

- ① 'Data Sampler'-'Linear Regression', 'Test and Score'를 연결한다.
- ② 'Linear Regression'-'Test and Score', 'Data Table'을 연결한다. 'Data Table'에서 선형 회귀 모델의 목둘레 회귀계수와 절편을 확인한다.



	name	coef
1	intercept	-31.4382
2	neck	3.01641

- 회귀계수: 3.01641
- 절편: -31.4382


- ③ 'Test and Score'에서 오차 함수(MSE, RMSE, MAE), 결정계수(R^2)를 확인한다.

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	21.533	4.640	3.487	0.043	0.716

결정계수(R^2 ; R squared): 0.716

단계 ④ 모델 평가하기

- ① 'Linear Regression'-'Predictions'를 연결한다.
- ② 'Data Sampler'의 남은 데이터(Remaining Data)를 'Predictions'에 연결한다.



- ③ 'Predictions'에서 오차 함수(MSE, RMSE, MAE), 결정계수(R^2)를 확인한다.

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	23.018	4.798	3.729	0.045	0.649

결정계수(R^2): 0.649



하나 더 해 보기

오렌지에서 다중 선형 회귀 모델을 구현해 볼까?

File에서 feature를 목둘레(neck), 몸무게(weight), 엉덩이둘레(heap)로 설정하여 다중 선형 회귀 모델을 구현해 보자.

- (1) 다중 선형 회귀 모델의 회귀계수, 절편을 구해 보자.
- (2) 다중 선형 회귀 모델 예측 결정계수(R^2)를 구해 보자.

	Name	Type	Role
1	neck	numeric	feature
2	weight	numeric	feature
3	heap	numeric	feature
4	waist	numeric	target

다중 선형 회귀로 허리둘레를 예측해 보기

목둘레(neck), 몸무게(weight), 엉덩이둘레(heap)를 이용해 허리둘레(waist)를 예측하는 다중 선형 회귀 모델로 만들어 보자.

```
01 # [단계 2] 데이터 수집 및 전처리하기
02 import pandas as pd # 데이터 프레임 생성하기
03 df = pd.read_csv('jeans.csv')
04 df.head() # 데이터 프레임 5행 보여 주기
```

```
01 # 독립 변수, 종속 변수 선정하기
02 X = df.iloc[:, :3].values
03 y = df['waist'].values
```

데이터 프레임의 iloc 인덱스 [행 범위, 열 범위] 데이터 프레임의 필요한 행과 열의 범위를 인덱스값으로 추출할 수 있다.
df.iloc[:, :3] 모든 행, 0~2열을 선택한다. 0열(neck), 1열(weight), 2열(heap)을 독립 변수로 선정한다.

```
01 # 훈련 데이터, 테스트 데이터 분할하기
02 from sklearn.model_selection import train_test_split
03 X_train, X_test, y_train, y_test = train_test_split(
04     X, y, test_size = 0.3, random_state = 42)
05 print("훈련, 테스트 데이터 모양: ", X_train.shape, X_test.shape, y_train.shape, y_test.shape)
```

실행 결과 예

훈련, 테스트 데이터 모양: (674, 3) (289, 3) (674,) (289,)

훈련 데이터 674개, 테스트 데이터 289개로 분할하였다.

```
01 # [단계 3] 모델 생성하기
02 from sklearn.linear_model import LinearRegression
03 model = LinearRegression() # 모델 생성하기
04 model.fit(X_train, y_train) # 모델 학습하기
05 print("회귀계수: ", model.coef_, "절편: ", model.intercept_) # 회귀계수, 절편 구하기
```

실행 결과 예

회귀 계수 [1.00647287 0.13488838 0.483414] 절편 -47.43343921313001

목둘레 회귀계수(1.00647287)가 가장 크므로, 종속 변수에 가장 큰 영향을 미치는 변수로 볼 수 있다.

```
01 # [단계 4] 모델 평가하기
02 # 테스트 데이터를 이용해 다중 선형 회귀 모델 결정계수 구하기
03 print("테스트 데이터를 이용한 모델 결정계수: ", model.score(X_test, y_test))
04 predictions = model.predict(X_test) # 테스트 데이터로 예측하기
05 print("예측 결과값: ", predictions[:5]) # 예측 결과
06 print("테스트 데이터 결과값: ", y_test[:5]) # 테스트 데이터 결과
```

실행 결과 예

테스트 데이터를 이용한 모델 결정계수: 0.868118747099804
예측 결과값 [80.782929 74.8881188 78.7820916 88.7238913 74.483748]
테스트 데이터 결과값: [82.0 78.0 75.0 90.0 75.0]

목둘레, 몸무게, 엉덩이둘레로 허리둘레를 예측하는 다중 선형 회귀 모델이 매우 강한 설명력이 있다.

문제 상황 자연산 전복은 무분별한 남획과 지구 온난화로 멸종 위기에 처해 있다. 특히, 해양 산성화와 온도 상승이 전복을 멸종 위기로 몰고 있다. 해양 산성화는 전복 껍데기의 형성을 방해하고, 해수면 온도 상승은 전복의 먹이가 되는 해조류의 성장을 저해한다. 따라서 오래 생존한 전복이 많은 해양 지역을 파악하기 위해서는 전복의 나이를 추정하는 것이 중요하다.

전복 껍데기에는 성장에 따라 고리(rings)가 형성된다. 전복의 고리 수를 세면 전복의 나이(전복의 고리 수+1.5)를 추정할 수 있다.

전복의 특징을 이용하여 전복의 고리 수를 예측하는 선형 회귀 모델을 구현해 보자.



단계 ① 문제 정의하기

전복 나이를 추정할 수 있는 전복의 고리 수를 예측해 보자.

단계 ② 데이터 수집 및 전처리하기

캐글에서 데이터 수집하기: abalone_original.csv

독립 변수와 종속 변수 구분하기

데이터 분할하기

단계 ③ 모델 생성하기

선형 회귀 모델 생성하기

단계 ④ 모델 평가하기

성능 평가하기

단계 ① 문제 정의하기

전복 나이를 추정할 수 있는 전복의 고리 수를 예측해 보자.

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기: 전복(abalone) 데이터셋은 캐글 사이트에서 다운로드한다.

<https://www.kaggle.com/datasets/hurshd0/abalone-uci>

(2) 데이터 전처리하기

① 'abalone_original.csv' 파일을 업로드하고 데이터 프레임(df)을 생성한다.

```
01 import pandas as pd
02 df =  ('abalone_original.csv')
03 df.head()
```


- ② 독립 변수, 종속 변수를 선정한다. 단순 선형 회귀 모델은 독립 변수를 한 개, 다중 선형 회귀 모델은 독립 변수를 두 개 이상 선정한다.

```
01 X = df.iloc[:, 1:8]      # 독립 변수: 다중 선형 회귀(1~7번 인덱스 컬럼)
02 y =       # 종속 변수: 고리 수(rings)
```

- ③ 훈련 데이터와 테스트 데이터를 분할한다. 모델을 생성하는 데 학습에 필요한 훈련 데이터가 테스트 데이터보다 많아야 한다.

```
01 from sklearn.model_selection import train_test_split
02 X_train, X_test, y_train, y_test =  (X, y, test_size=0.3, random_state=42)
```

단계 ③ 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

전복의 고리 수는 연속적인 값이므로, 기계학습 유형 중 지도학습의 회귀를 선택하여 예측한다. 회귀 모델을 만들기 위해서는 선형 회귀 알고리즘을 사용한다.

(2) 모델 학습하기

훈련 데이터로 선형 회귀 모델을 학습시켜 모델의 회귀계수와 절편을 구한다. 회귀계수와 절편을 이용해 선형 회귀 모델 식을 구한다.

```
01 from sklearn.linear_model import LinearRegression
02 model =       # 모델 생성하기
03       # 학습하기
04 print(model.coef_ , model.intercept_)      # 회귀계수와 절편 구하기
```

단계 ④ 모델 평가하기

테스트 데이터를 이용한 선형 회귀 모델의 결정계수(R^2)를 구한다.

```
01 model.score(X_test, y_test)
```



전복의 고리 수 외에 다른 속성으로도 종속 변수를 선정할 수 있다. 전복 데이터를 이용해 새로운 문제를 정의하고 선형 회귀 모델을 구현해 보자.

예 전복 껍데기(shell-weight), 성별(sex)을 제외하고 전복의 순살 무게(shucked-weight)를 예측하는 모델

4 분류

분류 문제 예

- 뇌종양/정상
- 도로 균열 여부
- 음용 가능/불가능 수질

클래스(class)

타깃의 범주(과일, 채소)를 말한다.

레이블(label)

타깃의 실재값을 말한다.

특징		타깃
당도	아삭함	식품
10	1	과일
3	8	채소
7	2	과일

레이블

클래스: 과일/채소


① 식품 분류 데이터

1 분류 모델

분류 모델은 입력 데이터를 미리 정의된 여러 클래스 중 하나로 할당하는 것을 말한다. 이 모델을 사용하여 새로운 데이터가 주어졌을 때, 그 데이터가 어떤 클래스에 속하는지 예측할 수 있다. 예를 들어 이메일의 분류 모델은 이메일의 텍스트, 발신자 정보, 이메일에 포함된 링크 등 다양한 특징을 고려하여 각 이메일이 스팸인지 아닌지를 결정한다. 분류 모델 생성에는 데이터의 특징(feature)과 타깃(target)이 필요하다. 타깃은 예측하려는 속성이고, 특징은 타깃을 예측하려고 사용하는 속성이다.



[그림 II-36] 분류의 예




분류 모델은 클래스 영역의 경계를 찾는 것을 핵심 목표로 한다. 이를 통해 분류 모델은 어떤 입력 데이터가 어떤 클래스에 속하는지 예측한다. 판별할 클래스의 예측 분류 선에 따라 선형 분류와 비선형 분류로 나눌 수 있다. 분류 모델을 만들기 위한 알고리즘이나 모델에는 결정트리, 로지스틱 회귀, 최근접 이웃 알고리즘 등이 있다.

활동 5 분류 모델의 클래스 영역을 나누는 경계를 시각적으로 확인하기

Machine Learning Playground 사이트에 접속한다.

① <https://ml-playground.com/#>

- ① 빨간색, 보라색 버튼을 선택하여 캔버스에 클릭해 데이터를 생성한다.
- ② 기계학습 알고리즘과 매개 변수(Parameters)를 선택한다.
- ③ [Train] 버튼을 클릭해 모델을 학습시킨다.
- ④ 분류 모델의 클래스 영역을 나누는 경계를 시각적으로 확인해 볼 수 있다.





(1) 결정트리

결정트리(decision tree)는 트리 구조 기반의 알고리즘이다. 트리의 루트 노드에서부터 각 분기마다 특징에 대한 분할 기준을 만들어 데이터를 분할하는 과정을 거친다.


결정트리는 분류 또는 회귀 문제를 해결할 수 있으며, 의사결정트리라고도 해요. 결정트리는 각 특징값을 기준으로 분할하므로 데이터 정규화가 필요 없어요.

- ① 데이터를 가장 잘 분류할 수 있는 특징(feature)을 선택한다.
- ② 선택한 특징의 분할 기준에 따라 데이터를 두 개 이상의 하위 그룹으로 분할한다.
- ③ 분할된 하위 그룹에서 다시 분할 기준을 선택하고, 그 기준에 따라 데이터를 분할하는 과정을 반복한다.
- ④ 분할 과정은 모든 데이터가 하나의 클래스로 분류되거나 종료 조건을 만족할 때까지 분할한다.

랜덤 포레스트 모델 (random forest model)

여러 결정트리를 활용해 더 좋은 성능을 내는 모델로 여러 개의 결정트리를 생성하고, 생성된 각각의 결정트리가 예측한 결과 중 다수결로 최종 예측 결과를 결정한다.


펭귄의 특징인 날개 길이, 부리 길이에 따라 펭귄 종을 분류하는 모델을 결정트리로 만들 수 있다.



[그림 II-37] 결정트리 알고리즘의 예(펭귄 종 분류)

(2) 로지스틱 회귀

로지스틱 회귀(logistic regression)는 선형 회귀에 로지스틱 함수를 적용한 알고리즘이다. 로지스틱 함수는 S자 모양의 곡선으로, 0에서 1 사이의 값으로 제한한다. 로지스틱 회귀는 이 함수를 이용해 종속 변수가 각 클래스에 속할 확률을 예측하여 그 결과를 기반으로 분류를 수행한다. 예를 들어 점수에 따라 합격 가능성을 0과 1 사이의 확률로 예측하고 0.5를 기준으로 분류할 수 있다.




(3) k-최근접 이웃

k-최근접 이웃(k-NN; k-Nearest Neighbor) 알고리즘은 예측 데이터에서 가장 가까운 k개의 데이터로 예측하는 방법이다. 분류를 할 경우에 k개의 가장 가까운 데이터 중 다수의 레이블이 예측 데이터의 클래스를 결정한다.



최근접 이웃 알고리즘(kNN)은 분류 또는 회귀 문제를 해결할 수 있어요!
최근접 이웃 알고리즘(kNN)의 k는 예측 데이터의 가장 가까운 이웃의 수예요!



k=3이면, 예측 데이터의 가장 가까운 3개의 데이터 중 파란색 2개, 빨간색 1개가 있으므로 파란색으로 결정한다.


※클래스: ● ● ● 예측할 데이터: ✕

[그림 II-38] 최근접 이웃 알고리즘(kNN)


펭귄의 날개 길이, 부리 길이의 특징값을 이용해 kNN 알고리즘으로 펭귄 종류를 분류할 수 있다.

데이터와 예측할 데이터와의 거리를 구하는 방법

유클리디언 거리, 맨해튼 거리



거리 기반 알고리즘(최근접 이웃, 로지스틱 회귀)은 모델 생성 전에 데이터 정규화를 수행한다.



k=3, 유클리디언 거리를 사용하면, 아델리펭귄 두 마리, 젠투펭귄 한 마리가 가장 가까운 두 개의 이웃으로 선택된다. 따라서 아델리펭귄으로 분류된다.

날개 길이 (mm)	부리 길이 (mm)	펭귄 종
208	37	?

↓ kNN(k=3)

날개 길이 (mm)	부리 길이 (mm)	펭귄 종
208	37	아델리펭귄

[그림 II-39] 최근접 이웃 알고리즘의 예(펭귄 종 분류)

2 분류 모델 성능 평가

분류 모델 성능 평가 지표

115쪽 참고

- 정확도(accuracy)
- 정밀도(precision)
- 재현율(recall)

혼동 행렬

실제 클래스와 예측 클래스를 비교하여 모델이 각 클래스를 얼마나 정확하게 예측했는지 표시한 행렬이다.

기계학습 분류 모델의 성능 평가 지표 중 하나는 정확도(accuracy)이다. 분류 모델의 성능을 평가할 때 혼동 행렬(confusion matrix)을 활용할 수 있다.

[표 II-7] 펭귄 종 분류 모델의 혼동 행렬의 예

		예측값		
		아델리	턱끈	젠투
실제값	아델리펭귄	42	2	0
	턱끈펭귄	3	18	0
	젠투펭귄	0	0	36

정확도는 전체 데이터 중 예측값과 실제값이 같은 데이터 개수의 비율이다.

$$\text{정확도} = \frac{\text{예측값과 실제값이 같은 데이터 개수}}{\text{전체 데이터 개수}} = \frac{42 + 18 + 36}{42 + 2 + 3 + 18 + 36} = 0.95$$

당도와 아삭함으로 과일인지 채소인지 분류하기

단계 ① 문제 정의하기

당도와 아삭함으로 과일인지 채소인지 분류해 보자.

단계 ② 데이터 수집 및 전처리하기

① 주어진 링크에서 'food.csv'를 다운로드한다.

 https://bit.ly/food_data

② food.csv 파일을 업로드한 후, 데이터 프레임(df)을 생성한다.

```
01 import pandas as pd
02 df = pd.read_csv('food.csv')
03 df.head()
```




실행 결과

	ingredient	sweet	crunchy	class
0	apple	10	9	fruit
1	banana	10	1	fruit
2	carrot	7	10	vegetable
3	celery	3	10	vegetable
4	cucumber	2	8	vegetable

③ 데이터를 산점도로 표현한다.

```
01 import seaborn as sns
02 sns.scatterplot(x='sweet', y='crunchy', data=df, hue='class')
```



실행 결과

④ 특징(X)은 당도(sweet), 아삭함(crunchy)으로, 타겟(target)은 클래스(class)로 선정한다.

```
01 X = df[['sweet', 'crunchy']].values # 특징(X) 선정하기
02 y = df['class'] # 타겟(y) 선정하기
```

df[]

여러 열을 선택할 때 대괄호를 두 번 쓴다.

단계 ③ 모델 생성하기

최근접 이웃 알고리즘인 KNeighborsClassifier를 이용해 분류 모델을 생성한다.

최근접 이웃 알고리즘 모델 생성 전에 정규화를 하지만, 이 데이터는 간단해서 정규화 없이 모델 생성을 바로 하였다.

```
01 from sklearn.neighbors import KNeighborsClassifier
02 # 최근접 이웃 구현하기(k=3)
03 knn = KNeighborsClassifier(n_neighbors = 3)
04 knn.fit(X, y) # 분류 모델 학습시키기
```

단계 ④ 모델 평가하기

당도(2), 아삭함(5)일 때, 과일(fruit)인지 채소(vegetable)인지 분류를 예측한다.

```
01 print(knn.predict([[2,5]])) # 분류 모델로 예측하기
```

실행 결과

1 vegetable

당도(2), 아삭함(5)일 때에는 채소로 분류하였다.



203쪽 참고

문제 상황 남극의 급격한 기후 변화로 펭귄을 포함한 야생 동물들의 서식지가 위협받고 있다. 또한 펭귄의 개체 수 추적과 펭귄 종의 표식 구별이 어려워 보호하기가 어렵다.



펭귄 종 클래스 Adelie(아델리), Chinstrap(턱끈), Gentoo(젠투)

단계 ① 문제 정의하기	펭귄 종을 분류하는 모델을 구현해 보자.
단계 ② 데이터 수집 및 전처리하기	캐글에서 데이터 수집하기: <u>penguins_size.csv</u> 결측치 제거하기 특징과 타겟 선정하기 데이터 분할하기
단계 ③ 모델 생성하기	<u>결정트리 모델</u> 생성하기
단계 ④ 모델 평가하기	성능 평가하기

단계 ① 문제 정의하기

남극 펭귄 중에는 아델리펭귄, 턱끈펭귄, 젠투펭귄들이 있다. 이 펭귄들의 특징값들로 펭귄 종을 분류하는 모델을 구현해 보자.

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기

캐글 사이트에서 남극 펭귄 데이터셋을 다운로드한다.

https://www.kaggle.com/datasets/parulpandey/palmer-archipelago-antarctica-penguin-data?select=penguins_size.csv

(2) 데이터 전처리하기

① 데이터 프레임 생성하기(파일명: 'penguins_size.csv'): 펭귄 파일을 불러와 데이터 프레임(df)을 생성한다.

```
01 import pandas as pd
02 df = pd.read_csv('penguins_size.csv')
03 df.info() # 데이터 프레임 요약 정보
```


펭귄 데이터의 속성

- species: 종
- island: 서식지(섬)
- culmen_length_mm: 부리 길이
- culmen_depth_mm: 부리 깊이
- flipper_length_mm: 날개 길이
- body_mass_g: 체질량
- sex: 성별

실행 결과

```

In [5]: penguins = pandas.DataFrame(
        {'species': 342, 'island': 0, 'culmen_length_mm': 342,
         'culmen_depth_mm': 342, 'flipper_length_mm': 342,
         'body_mass_g': 342, 'sex': 342})
        # Column Name Null Count Dtype
        0 species          342 non-null object
        1 island           342 non-null object
        2 culmen_length_mm 342 non-null float64
        3 culmen_depth_mm  342 non-null float64
        4 flipper_length_mm 342 non-null float64
        5 body_mass_g      342 non-null float64
        6 sex              342 non-null object
        dtype: float64(7), object(5)
        memory usage: 18.5 KB
    
```

컬럼마다 데이터의 개수가 다르다. 펭귄 종, 서식지는 344개이지만 나머지 컬럼들은 342, 334개이다. 결측치를 확인해 보자!

결측치

데이터에 존재하지 않는 값으로 모델 성능을 저하시키는 요인이다.

실행 결과

```

species      0
island       0
culmen_length_mm  0
culmen_depth_mm  0
flipper_length_mm  0
body_mass_g     0
sex          0
culmen_depth_mm  0
    
```

결측치 개수

② 결측치 처리하기: 결측치 개수를 확인하고, 결측치가 있는 행을 삭제한다.

```
01 df.isnull().sum() # 결측치 개수 확인하기
```

```
01 # 행 방향으로 결측치를 제거하고, 데이터 프레임(df) 수정하기
```

```
02 df.dropna(axis=0, inplace=True)
```

```
03 df.info() # 데이터 프레임 요약 정보
```

- axis=0: 행 방향
- inplace=True: 원본 수정

③ 특징과 타겟 선정하기

	속성	설명
특징	culmen_length_mm	부리 길이
	culmen_depth_mm	부리 깊이
	flipper_length_mm	날개 길이
타겟	species	펭귄 종

df[]

여러 열을 선택할 때 대괄호를 두 번 쓴다

```

01 X = df[['culmen_length_mm', 'culmen_depth_mm',
02         'flipper_length_mm']]
03 y = df['species']
    
```

④ 훈련 데이터와 테스트 데이터로 분할하기: 특징(X), 타겟(y) 데이터를 7:3으로 훈련 데이터와 테스트 데이터로 분할한다.

```

01 from sklearn.model_selection import train_test_split
02 X_train, X_test, y_train, y_test = train_test_split(
03     X, y, test_size=0.3, stratify=y)
    
```

- X_train: 훈련 데이터 특징
- y_train: 훈련 데이터 타겟
- X_test: 테스트 데이터 특징
- y_test: 테스트 데이터 타겟
- stratify = y: 펭귄 종(species)을 훈련 데이터와 테스트 데이터에 균일하게 나눈다.

단계 ③ 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

펭귄 종을 분류하려면 '분류' 알고리즘을 선택해야 한다. 결정트리 알고리즘을 이용하여 분류 모델을 만들어 보자.



결정트리 모델을
이용하여 펭귄 종을 분류해 보요.

(2) 모델 학습하기

① DecisionTreeClassifier로 결정트리 분류 모델(dt)을 생성하고, 훈련 데이터(X_train, y_train)를 이용해 모델을 학습한다.

```
01 from sklearn.tree import DecisionTreeClassifier
02 dt = DecisionTreeClassifier()           # 모델 생성하기
03 dt.fit(X_train, y_train)               # 모델 학습하기
04 # 훈련 데이터로 결정트리 모델 분류 정확도 구하기
05 print(dt.score(X_train, y_train))
```

실행 결과 예

1.0

훈련 데이터를 이용해 모델을 학습한 결과, 분류 정확도는 1.0으로
훈련 데이터는 모두 다 맞춘 것을 볼 수 있다.

plot_tree(): 결정트리 시각화하기

- dt: 결정트리 분류 모델이다.
- feature_name: 각 노드에서 분류 결정에 사용된 특징 이름을 지정한다.
- max_depth: 트리 최대 깊이이다
- filled=True: 노드 색상으로 채운다.


② 결정트리 분류 모델을 생성해 결정트리를 시각화하면 분류 결과를 볼 수 있다.

```
01 import matplotlib.pyplot as plt
02 # sklearn.tree 모듈에서 plot_tree 함수 가져오기
03 from sklearn.tree import plot_tree
04 plt.figure(figsize=(20, 10)) # 이미지 크기(20, 10) 설정하기
05 plot_tree(dt, feature_names=X.columns,
06           max_depth=2, filled=True)
07 plt.show()
```

실행 결과 예

지니(gini) 계수

- 데이터의 불순도 측정 지표이다.
- 불순도가 낮을수록 데이터의 분류가 쉽다.



단계 4 모델 평가하기

테스트 데이터(X_test, y_test)를 이용해 모델의 예측 및 성능 평가를 수행한다.

```
01 dt_pred = dt.predict(X_test)           # dt 모델 예측하기
02 # 테스트 데이터로 결정트리 모델 분류 정확도 구하기
03 print("결정트리 모델 성능 평가 : ", dt.score(X_test, y_test))
```

실행 결과 예

결정트리 모델 성능 평가 : 0.9702970297029703



단계 ① 문제 정의하기


펭귄 종을 분류하는 모델을 구현해 보자.

단계 ② 데이터 수집 및 전처리하기

- ① 분류 모델 구현하기에서 수집한 'penguins_size.csv'를 사용한다. [110쪽 참고](#)
- ② 'File'에서 'penguins_size.csv' 파일을 불러온다.
- ③ 특징(feature), 타겟(target)을 다음과 같이 선정하고 [Apply] 버튼을 선택한다(나머지 속성: skip).



- ④ 'File'-'Preprocess'를 연결한다. 'Preprocess'에서 결측치(missing value)를 삭제한다.




- ⑤ 'Preprocess' - 'Data Sampler'를 연결한다. 'Data Sampler' - 'Fixed proportion of data'에서 70%를 선택한다(훈련 데이터: 70%).



단계 ③ 모델 생성하기

- ① 'Data Sampler'-'Tree', 'Test and Score'를 연결한다.
- ② 'Tree'-'Test and Score'를 연결한다.




- ③ 'Test and Score'에서 분류 정확도(CA)를 확인한다.

[115쪽 참고](#)

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.976	0.963	0.962	0.963	0.963	0.941

단계 ④ 모델 평가하기

- ① 'Tree'-'Predictions' 연결한다.
- ② 'Data Sampler'의 남은 데이터(Remaining Data)를 'Predictions'에 연결한다.



- ③ 'Predictions'의 분류 정확도(CA)를 확인한다.

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.948	0.912	0.907	0.909	0.912	0.862

로지스틱 회귀, 최근접 이웃 모델로 펭귄 종 분류하기

단계 ① 문제 정의하기

펭귄 종을 분류하는 모델을 구현해 보자.

단계 ② 데이터 수집 및 전처리하기

```
01 import pandas as pd
02 df = pd.read_csv('penguins_size.csv')
03 df.dropna(axis = 0, inplace = True) #결측치 있는 행 삭제하기
04 df.info()
05 X = df[['culmen_length_mm', 'culmen_depth_mm', 'flipper_length_mm']] #특징
06 y = df['species'] #타겟
```

(1) 데이터 정규화하기

최소-최대 정규화(MinMaxScaler)를 이용해 데이터를 정규화한다.

💡 최소-최대 정규화(MinMaxScaler): 데이터 최솟값을 0, 최댓값을 1로 만드는 방법

```
01 from sklearn.preprocessing import MinMaxScaler
02 scaler = MinMaxScaler() # MinMaxScaler 생성하기
03 X_scaled = scaler.fit_transform(X) # X를 정규화하기 (0~1 범위)
```

로지스틱 회귀, 최근접 이웃은 거리 기반 알고리즘이므로 특징값의 범위가 큰 차이가 나면 모델 성능이 떨어진다.

(2) 훈련 데이터와 테스트 데이터로 분할하기

```
01 from sklearn.model_selection import train_test_split
02 X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.3, stratify=y)
```

단계 ③ 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

펭귄 종을 분류하기 위해 '분류' 알고리즘을 선택해야 한다. 이번에는 로지스틱 회귀, 최근접 이웃 알고리즘(kNN)을 사용해 보자.

(2) 모델 학습하기

로지스틱 회귀
학습하기

```
01 from sklearn.linear_model import LogisticRegression
02 lr = LogisticRegression()
03 lr.fit(X_train, y_train)
```

최근접 이웃
알고리즘 학습하기

```
01 from sklearn.neighbors import KNeighborsClassifier
02 knn = KNeighborsClassifier(n_neighbors=5) # k=5
03 knn.fit(X_train, y_train)
```

단계 4 모델 평가하기

로지스틱 회귀
평가하기

```
01 lr_pred = lr.predict(X_test) # lr 모델 예측하기
02 # lr 성능 평가(분류 정확도)
03 print("로지스틱 회귀 성능 평가: ", lr.score(X_test, y_test))
```

실행 결과 예

로지스틱 회귀 성능 평가: 0.9400000000000001

최근접 이웃
알고리즘 평가하기

```
01 knn_pred = knn.predict(X_test) # knn 모델 예측하기
02 # knn 성능 평가(분류 정확도)
03 print("최근접 이웃 성능 평가: ", knn.score(X_test, y_test))
```

실행 결과 예

최근접 이웃 성능 평가: 0.9300000000000001




모델 성능 평가 결과를
이용해 평가 중 분류가 잘된 모델을
찾아봐요.

혼동 행렬을 이용해 테스트 데이터의 타깃과 예측 결과를 비교할 수 있다. 로지스틱 회귀 모델을 이용해서 예측 결과(lr_pred)와 비교해 혼동 행렬을 구한다.

```
01 import matplotlib.pyplot as plt
02 from sklearn.metrics import confusion_matrix
03 import seaborn as sns
04 # 로지스틱 회귀 혼동 행렬 만들기
05 conf=confusion_matrix(y_test, lr_pred)
06 # 혼동 행렬을 히트맵으로 시각화하기
07 sns.heatmap(conf, annot=True, cmap='Blues')
08 plt.title("Penguin Classification")
09 plt.xlabel("Predicted")
10 plt.ylabel("Actual")
11 plt.show()
```

실행 결과 예



0(Adelie, 아델리펭귄), 1(Chinstrap, 턱끈펭귄), 2(Gentoo, 젠투펭귄)의 실제값(Actual), 예측 결과(Predicted)의 혼동 행렬이다.

로지스틱 회귀 모델로 분류한 결과, 아델리펭귄(Adelie, 0), 젠투펭귄(Gentoo, 2)은 잘 분류하였으나, 턱끈펭귄(Chinstrap, 1) 중 3마리는 아델리펭귄(Adelie, 0)으로 잘못 분류하였다.



최근접 이웃(kNN), 결정트리(dt) 등 분류 모델의 분류 정확도를 혼동 행렬로 확인해 보자.

		예측값 (Predicted)	
		NO(0) Negative	Yes(1) Positive
실제값 (Actual)	NO(0) False	TN (True Negative)	FP (False Positive)
	Yes(1) True	FN (False Negative)	TP (True Positive)

혼동 행렬은 학습된 분류 모델이 예측을 수행하면서 얼마나 혼동되는지를 함께 보여 주는 지표로 혼동 행렬을 이용해 분류 모델 성능 평가를 구할 수 있다.

- TP(True Positive): 실제값이 참(True)인 것을 참(Positive)으로 예측
- TN(True Negative): 실제값이 거짓(False)인 것을 거짓(Negative)으로 예측
- FP(False Positive): 실제값이 거짓(False)인 것을 참(Positive)으로 예측
- FN(False Negative): 실제값이 참(True)인 것을 거짓(Negative)으로 예측

정확도 (CA; Classification Accuracy)	전체 데이터 중 예측 결과와 실제값이 같은 건수의 비율이다.	$\frac{TP + TN}{TP + FN + FP + TN}$
정밀도(precision)	모델이 참(True)이라고 분류한 것 중에서 실제 참(True)인 것의 비율이다.	$\frac{TP}{TP + FP}$
재현율(recall)	실제 참(True)인 것 중에서 모델이 참(True)이라고 예측한 것의 비율이다.	$\frac{TP}{TP + FN}$

항공사의 고객 만족도를 높이기 위한 고객 서비스 모델 만들기

문제 상황 고객들은 비행기를 선택할 때 어떤 항공사를 선택할까? 고객의 만족도를 높이기 위해 항공사는 어떤 서비스에 중점을 두어야 할까? 고객 항공사 만족도 조사 데이터로 기계학습 모델을 만들어 중점을 두어야 하는 고객 서비스를 알아보자.



단계 ① 문제 정의하기	항공사는 고객의 만족도를 높이기 위해 어떤 서비스에 중점을 두어야 할까?
단계 ② 데이터 수집 및 전처리하기	캐글에서 데이터 수집하기: <code>airline_passenger_satisfaction.csv</code> 특징과 타겟 선정하기 데이터 분할하기
단계 ③ 모델 생성하기	결정트리, 로지스틱 회귀 모델 생성하기
단계 ④ 모델 평가하기	성능 평가하기

단계 ① 문제 정의하기

항공사는 고객의 만족도를 높이기 위해 어떤 서비스에 중점을 두어야 할까?

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기

캐글 사이트에서 항공사 만족도 데이터인 'airline_passenger_satisfaction.csv' 파일을 다운로드한다.

🔗 <https://www.kaggle.com/datasets/mysarahmadbhat/airline-passenger-satisfaction>

(2) 데이터 전처리하기

① 'airline_passenger_satisfaction.csv' 파일을 불러온다.

② 분류 모델에 사용할 특징과 타겟을 선정한다.

▶ 9~22번 인덱스 컬럼을 특징(X)으로, 마지막 'Satisfaction' 컬럼은 타겟(y)으로 선정한다.

```

01 import pandas as pd
02 df =  ('airline_passenger_satisfaction.csv')
03 X = df.iloc[:, 9:23]      # 특징: 모든 행의 9~22번 인덱스 열
04 y = df.iloc[:, -1]        # 타겟: 모든 행의 마지막 열(-1)
05 print(X.shape, y.shape)
    
```

데이터 프레임의 iloc 인덱서 [행 범위, 열 범위]
데이터 프레임의 필요한 행과 열의 범위를 인덱스값을
이용해 추출할 수 있다.

	인덱스	만족도 질문	의미
특징(X)	9	Departure and Arrival Time Convenience	출발, 도착 시간 편의
	10	Ease of Online Booking	온라인 예약의 용이성
	11	Check-in Service	체크인 서비스
	12	Online Boarding	온라인 탑승
	13	Gate Location	게이트 위치
	14	On-board Service	온 보드 서비스
	15	Seat Comfort	의자의 편안함
	16	Leg Room Service	레그 룸 서비스
	17	Cleanliness	청결
	18	Food and Drink	음식과 음료
	19	In-flight Service	기내 서비스
	20	In-flight Wifi Service	기내 와이파이 서비스
	21	In-flight Entertainment	기내 엔터테인먼트
	22	Baggage Handling	수하물 처리
타겟(y)	23	Satisfaction(Neutral or Dissatisfied/Satisfied)	만족도(중립 또는 불만족/만족)

💡 항공사 만족도 특징값들은 동일한 데이터 범위이므로, 데이터 정규화가 따로 필요하지 않다.

③ 특징, 타겟 데이터를 훈련 데이터와 테스트 데이터로 7:3 분할한다.

```

▶ 01 from sklearn.model_selection import train_test_split
   02 X_train, X_test, y_train, y_test = (X, y, test_size=0.3, stratify=y)

```

단계 ③ 모델 생성하기

결정트리, 로지스틱 회귀 알고리즘을 선택해 훈련 데이터로 학습시켜 분류 모델을 생성한다.

결정트리

```

▶ 01 from sklearn.tree import DecisionTreeClassifier
   02 dt = 
   03 

```

로지스틱 회귀

```

▶ 01 from sklearn.linear_model import LogisticRegression
   02 lr = 
   03 

```

단계 ④ 모델 평가하기

테스트 데이터를 이용해 예측을 수행하고 분류 모델의 정확도를 확인한다.

```

▶ 01 dt_pred = dt.predict(X_test) # 결정트리 모델 예측하기
   02 print("결정트리 정확도: ", dt.score(X_test, y_test))

```



결정트리를 그려 보고 어떤 서비스에 중점을 두는 것이 좋은지 결정트리의 루트 노드의 특징을 찾아보자.

5 군집

1 군집 모델

군집


비슷한 특성을 가진 데이터끼리의 묶음이다.

군집 문제 예

- 고객 세분화
- 제품 세분화
- 이상치 탐지
- 환자 세분화
- 질병 진단
- 약물 개발

밀도 기반 군집화

밀집된 데이터를 하나의 군집으로 묶는 알고리즘이다.



[그림 II-40] 군집의 예

k-평균 군집화 알고리즘

k-평균 군집화(k-means clustering) 알고리즘은 주어진 데이터를 k개의 군집으로 묶는 알고리즘으로, 여기서 k는 데이터 군집 개수이다. 먼저 군집의 개수(k)를 결정하고, 각 군집의 중심점(centroid)을 계산한다. 그런 다음 각 데이터를 가장 가까운 중심점에 할당한다. 이때 중심점과 데이터의 거리를 구하는 방법으로 유클리드 거리를 많이 사용한다.




[그림 II-41] k-평균 군집화 알고리즘


k-평균 군집화 알고리즘 수행 과정을 살펴보면 다음과 같다.

① 군집의 수(k)를 결정한다. 군집의 개수(k): 3


② k개의 초기 중심점(centroid) 위치는 무작위로 결정된다.(x)




③ 데이터가 군집에 할당된다. 거리상 가장 가까운 중심점으로 데이터가 할당되어 군집을 만든다.




④ 군집의 중심점은 그 군집에 속하는 데이터들 평균에 위치한 지점으로 다시 재설정된다.




⑤ 데이터들은 다시 군집에 할당된다(과정 ③ 반복).



⑥ 중심점이 재설정된다(과정 ④ 반복).



중심이 고정될 때까지 과정 ③과 과정 ④를 반복한다. 더 이상 군집 중심이 이동하지 않으면 종료한다.



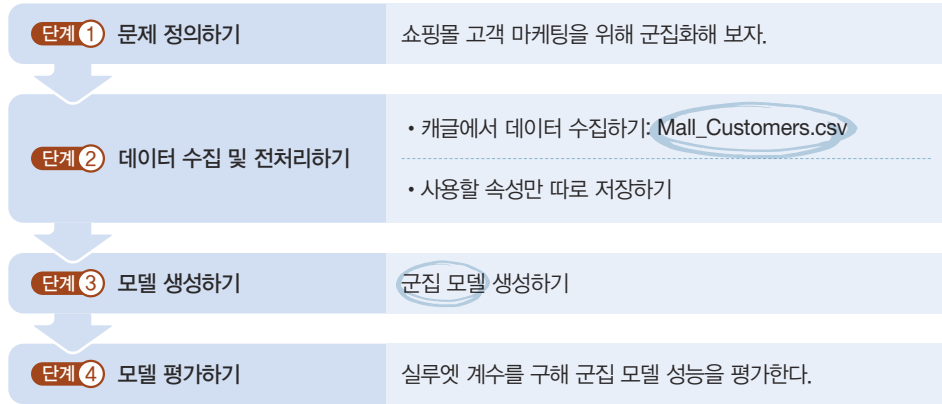
활동 6 k-평균 군집화 시뮬레이션하기

k-평균 군집화 과정을 시뮬레이션 프로그램으로 이해해 보자.

<https://bit.ly/k-means-simulation>

탐색 분석

문제 상황 쇼핑물 고객 정보를 k-평균 군집 알고리즘으로 분석하면 고객 개개인의 특성에 맞는 마케팅을 할 수 있고, 신규 고객 특성을 미리 예측할 수 있다.



단계 ① 문제 정의하기

쇼핑물 고객 마케팅을 위해 군집화해 보자.

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기

쇼핑물 고객 데이터셋은 캐글 사이트에서 다운로드한다.

<https://www.kaggle.com/datasets/shwetabh123/mall-customers>

쇼핑물 고객 데이터셋은 다음과 같은 속성값으로 구성되어 있다.

Customer ID	Gender	Age	Annual Income(k\$)	Spending Score(1~100)
1	Male	19	15	39
2	Male	21	15	81
3	Female	20	16	6
4	Female	23	16	77

총 200개의 데이터가 고객 아이디(Customer ID), 성별(Gender), 나이(Age), 연 소득(Annual Income(k\$)) 및 쇼핑물에서 부여한 점수(Spending Score(1~100))로 이루어져 있다. 이때 쇼핑물에서 부여한 점수는 소비 금액 및 행동 패턴을 기반으로 하였다.

(2) 데이터 전처리하기

① 'Mall_Customers.csv' 파일을 불러와 데이터 프레임을 생성해 5행을 불러온다.

```

01 import pandas as pd                                # pandas 불러오기
02 df = pd.read_csv('Mall_Customers.csv')
03 df.head()
  
```

데이터 프레임(df)에는 고객 ID(CustomerID), 성별(Gender), 나이(Age), 연 소득(Annual Income(k\$))과 쇼핑물에서 부여한 점수(Spending Score(1~100)) 데이터가 저장되어 있다.

df[[']]

여러 열을 선택할 때 대괄호를
두 번 쓴다

② 군집 모델에서 사용할 연 소득(Annual Income)과 쇼핑물에서 부여한 점수(Spending Score) 데이터만 데이터 프레임(data)을 생성한다.

```
01 data = df[['Annual Income (k$)', 'Spending Score (1-100)']]
02 data.head()
```

데이터 프레임 5행 보여 주기

실행 결과

	Annual Income (k\$)	Spending Score (1-100)
0	15	39
1	15	81
2	15	6
3	15	77
4	17	40

단계 ③ 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

기계학습 유형 중 타깃이 없는 특징값으로 그룹화를 수행하려면 비지도학습의 '군집' 모델이 필요하다. 군집 모델에 사용할 알고리즘으로 k-평균 군집화 알고리즘을 선정할 수 있다.

(2) 모델 학습하기

k-평균 군집화 알고리즘을 이용해 쇼핑물 고객 데이터를 군집화한다.

① k-평균 군집화 알고리즘으로 군집 모델을 생성한다.

```
01 from sklearn.cluster import KMeans
02 k = 5
03 model = KMeans(n_clusters=k)
04 model.fit(data)
```

k = 5인 KMeans 모델을 생성하기
군집 모델을 학습하기

← 군집 모델이므로 타깃이 필요 없다.



군집의 개수(k)를
바꿔 가면서 군집 모델을 만들어
봐요.

② K-평균 군집화 모델로 데이터를 군집해 그 결과를 저장한다. k=5이므로 각 데이터의 군집 번호는 0~4번까지로 저장된다.

```
01 prediction = model.predict(data)
02 prediction[0:10]
```

데이터 군집 예측하기
어떤 군집에 속하는지 보여 주기

실행 결과 예

```
array([ 1,  1,  1,  1,  1,  1,  1,  1,  1,  1])
```

③ 군집 결과를 데이터 프레임(df['centroid'])에 저장하고, 군집의 중심값을 저장한다.

```
01 # 군집 결과를 df['centroid'] 열에 추가하기
02 df['centroid'] = model.labels_
03 # 군집의 중심값을 반환해 final_centroid에 저장하기
04 final_centroid = model.cluster_centers_
05 print(final_centroid)
```

학습된 데이터의 군집 결과

실행 결과 예

```
[ 36.15846154  82.7370118]
[ 35.30414781  70.31304148]
[ 38.2       17.1475571]
[ 34.2687903  49.51304148]
[ 39.5777777  70.30414781]
```

학습된 군집의 중심을 나타낸다. 각 군집에 속하는 데이터의 평균값이다.

총 5개 군집의 중심값을 찾아 final_centroid 배열에 저장한다.
데이터 프레임에는 군집 결과를 'centroid' 열에 저장한다.

01 df.head(2)

실행 결과 예

	CustomerID	Genre	Age	Annual Income (k\$)	Spending Score (1-100)	centroid
0	1	Male	19	15	39	1
1	2	Male	21	15	81	4

df['centroid']에는 군집 결과를 저장하였다. 군집 결과는 0~4까지 값이 데이터마다 저장된 것을 볼 수 있다.

sns.scatterplot(): 산점도 시각화하기


- hue='centroid': 각 데이터마다 다른 색상을 지정한다.
- data=df: 시각화할 데이터 프레임이다.
- palette='bright': 색상 팔레트를 정한다.

④ 군집 결과를 산점도로 시각화한다.

```
01 import seaborn as sns
02 import matplotlib.pyplot as plt
03 # Annual Income (k$)과 Spending Score (1-100)를 산점도에 표시하기
04 sns.scatterplot(x='Annual Income (k$)',
05                 y='Spending Score (1-100)', hue='centroid',
06                 data=df, palette='bright')
07 # final_centroid에 저장된 군집 중심값을 산점도에 표시하기
08 plt.scatter(final_centroid[:, 0], final_centroid[:, 1],
09             marker='*', s=300, color='black', label='Centroids')
10 plt.legend() # 범례 표시하기
11 plt.show()
```



고객의 각 특성을 군집화해 군집화된 고객군을 대상으로 마케팅을 할 수 있어요.



단계 ④ 모델 평가하기



실루엣 점수가 0.5539로 데이터가 어느 정도 군집에 잘 속해 있어요.

k-평균 군집 모델은 실루엣 점수를 이용해 군집 모델 성능을 평가할 수 있다.

```
01 from sklearn.metrics import silhouette_score # 실루엣 계산
02 silhouette_score = silhouette_score(data, model.labels_)
03 print(silhouette_score)
```

실행 결과 예

0.5539 31.36 74.43 43.43



단계 ① 문제 정의하기

쇼핑몰 고객 마케팅을 위해 군집화해 보자.

단계 ② 데이터 수집 및 전처리하기

- ① 군집 모델 구현하기에서 수집한 'Mall_Customers.csv'를 사용한다. [120쪽 참고](#)
- ② 'File'에 'Mall_Customers.csv' 파일을 불러온다.
- ③ 군집에 사용할 속성을 'feature'로 선정하고 [Apply] 버튼을 선택한다(나머지 속성: skip).




단계 ③ 모델 생성 및 평가하기

- ① 'File' - 'k-Means'를 연결해 최적의 군집 개수를 찾아낸다.




- From X to Y: 최적의 군집 개수를 구하도록 군집의 범위를 정함.
- Silhouette Scores (실루엣 점수): 1에 가까울수록 데이터가 속한 군집에 적합함.

- ② 'k-Means' - 'Scatter Plot'을 연결해 군집 결과를 산점도로 시각화한다.



Axis x	Annual Income(k\$)
Axis y	Spending Score(1-100)
Color	Cluster



더 알아보기

실루엣 점수(silhouette_score)

실루엣 점수는 군집 내 데이터 포인트들이 얼마나 밀집되어 있는지(군집 내 유사성)와 다른 군집과 얼마나 분리되어 있는지(군집 간 상이성)를 동시에 고려하여 군집화의 품질을 평가하는 유용한 지표이다. 실루엣 점수가 1에 가까울수록 군집이 잘 이루어졌음을 의미한다.



군집을 통한 맞춤형 카드 상품 기획하기

선택 활동 6

당신의 취향에 맞는 카페 음료 추천하기

개발

분석

카페의 수많은 메뉴 중에서 고객의 취향을 고려해 음료를 추천하려면 어떻게 해야 할까?
군집 모델을 이용해 사용자 취향에 맞는 음료를 추천해 보자.

설탕과 카페인에 적은
음료를 추천해 드리겠습니다.



단계 ① 문제 정의하기

설탕과 카페인을 이용해 군집 모델을 생성해 음료를 추천해 보자.

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기

아래 주어진 링크에 들어가서 우리나라 수많은 카페 매장에서 제공하는 음료 성분 데이터를 수집해 스프레드시트 파일로 저장한 'caffe_menu.csv'를 다운로드한다.

https://bit.ly/caffe_menu

(2) 데이터 전처리하기

① 군집 모델에 사용할 특징으로 설탕(sugars(g)), 카페인(caffeine(mg))을 선택해 데이터 프레임(data)을 생성한다.

```
01 import pandas as pd
02 df= pd.read_csv('caffe_menu.csv')
03 data = df[['sugars(g)', 'caffeine(mg)']]
```

② 최소-최대 정규화(MinMaxScaler)를 이용해 0~1 사이 값으로 정규화한다.

```
01 from sklearn.preprocessing import MinMaxScaler
02 scaler = MinMaxScaler()
03 data_scaled = scaler.fit_transform(data)
```

MinMaxScaler 객체 생성
data 정규화하기

단계 ③ 모델 생성하기

① k-평균 군집화 알고리즘으로 군집 모델을 생성한다.

```
01 from sklearn.cluster import KMeans
02 model = KMeans(n_clusters=4)
03 model.fit(data_scaled)
04 df['cluster'] = model.labels_
```

군집 개수를 바꿔 보자.
k = 4인 군집 모델 생성하기
군집 모델 학습하기
군집 결과 df['cluster']에 저장하기

② 군집에 어떤 음료가 속하는지 찾아본다.

```
01 df[df['cluster'] == 0]['name']
```

군집 0번에 속하는 음료 이름
0~3으로 변경하며 군집에 어떤 음료가 속했는지 확인해 보자.



다른 속성으로도 군집 모델을 만들어 보자.

나의 꿈
나의 미래



커리어넷

<https://www.career.go.kr/>

디지털 헬스케어

의료 기술과 디지털 기술이 결합된 분야로, 스마트워치에서 건강을 체크하거나 원격으로 의사와 상담하는 분야예요!

필요한 역량

데이터 분석 능력, 기계학습 지식, 프로그래밍 능력

바이오 인포매틱스 전문가

생명 과학에 밀접한 직업으로, 생물 데이터를 컴퓨터로 분석해서 병이나 유전 정보를 알아내는 전문가이다. 예를 들어 동물의 유전 정보를 조사해서 어떤 유전병이나 특별한 특징을 발견하기도 한다.

의료 데이터 분석가

의료 데이터를 수집하고 분석해서 의사들에게 도움을 주는 직업이다. 환자들의 건강 기록 데이터를 분석하여 어떤 질병의 발병원을 알아내거나 새로운 치료법을 개발하는 데 도움을 줄 수 있다.

- 인공 신경망과 딥러닝의 특성에 대한 이해를 바탕으로 활용 분야를 탐색할 수 있다.
- 딥러닝을 활용하여 실생활 및 다양한 학문 분야의 문제를 해결하고, 성능을 평가할 수 있다.

인공 신경망과 딥러닝


학습 요소

인공 신경망, 딥러닝, 컴퓨터 비전, 음성 인식, 자연어 처리



무엇을 배울까?

딥러닝은 왜 특별할까? 딥러닝 전후 무엇이 달라졌을까?




1 인공 신경망의 이해

인공 신경망은 인간의 뇌가 주변 정보를 인식하고 학습하는 방식을 모방한 인공지능 모델이다.


1 인공 신경망

인간의 뇌는 수많은 뉴런, 즉 신경 세포로 구성되어 있다. 이 뉴런(neuron)들은 시냅스(synapse)로 연결되어 정보를 처리하여 전달한다.

뉴런은 입력 신호를 받아들이고, 그 신호에 가중치(weight)를 적용한 출력 신호를 다른 뉴런에게 전달한다. 인공 신경망(ANN; Artificial Neural Network)은 뉴런과 시냅스의 작동 원리를 모방한 모델이다.



인간 신경망




인공 신경망

[그림 II-42] 인간 신경망과 인공 신경망의 비교

(1) 퍼셉트론

퍼셉트론(perceptron)은 인공 신경망의 가장 기본적인 구성 요소로, 다수의 신호를 입력받아 하나의 신호로 출력한다. 뉴런에 해당되는 퍼셉트론의 핵심 아이디어는 입력값과 가중치를 곱하고 이 값들을 합산하는 것이다. 합산된 값(가중합)이 활성화 함수(activation function)에서 임계값을 넘으면 1, 그렇지 않으면 0을 출력하는 간단한 구조이다.



[그림 II-43] 퍼셉트론

- x 는 입력값이다.
- w 는 입력값에 대한 가중치이다.
- b (bias)는 퍼셉트론의 출력을 조정하여 활성화 함수의 임계값을 이동시키는 역할을 한다.

시냅스

뉴런과 뉴런 사이의 접속 부위를 의미한다.

인공 신경망

인공적으로 인간의 뇌 신경망을 모방하여 구성된 신경망이라는 전체 개념을 의미하며 신경망이라고도 부른다.

활성화 함수

입력된 값의 가중합을 비선형적으로 변환해 출력하는 함수이다.

임계값

- 출력을 결정하는 기준값이다.
- [그림 II-43]의 활성화 함수는 임계값이 0이다.

층(layer)

- 인공 신경망의 정보 처리 단위로 입력층, 출력층, 은닉층이 있다.
- 신경망의 층은 서로 연결되어 있다.
- 신경망 성능을 높이기 위해 층의 종류, 연결 방식, 개수 등을 적절히 선택해야 한다.

입력층(input layer)

데이터를 입력받는 층이다.

은닉층(hidden layer)

은닉층으로 들어온 값과 가중치를 계산한 값을 활성화 함수로 비선형적으로 변환해 다음 층에 전달한다.


출력층(output layer)

신경망의 최종 예측값을 출력하는 역할을 한다.

(2) 다층 신경망

퍼셉트론 하나로는 선형 분류 문제를 해결할 수 있으나, 비선형 문제를 해결할 수 없다는 한계가 있다. 다층 신경망(MLP; Multi-Layer Perceptron)은 이러한 한계를 극복하기 위해 입력층과 출력층 사이에 은닉층을 추가하여 여러 개의 퍼셉트론이 상호 작용하게 함으로써 비선형 분류를 가능하게 한다.


입력값을 받는 단계를 입력층(input layer), 값을 받아서 출력하는 단계를 출력층(output layer), 입력층과 출력층 사이에 은닉층(hidden layer)으로 구성된다.



[그림 II-44] 퍼셉트론과 다층 신경망의 차이

(3) 심층 신경망

심층 신경망(DNN; Deep Neural Network)은 많은 수의 은닉층을 가진 구조로, 복잡한 형태의 비선형 문제를 해결할 수 있다.



[그림 II-45] 심층 신경망

(4) 딥러닝

딥러닝

은닉층의 개수가 많을수록 인공 신경망이 깊다고 한다. 딥(deep)은 신경망의 은닉층이 여러 개라는 의미이다.

딥러닝(deep learning)은 심층 신경망을 사용하여 입력 데이터의 복잡한 패턴을 학습하고 문제를 해결하기 위해 개발된 분야이다. 따라서 딥러닝은 이미지 인식, 음성 인식, 자연어 처리 등 기존 기계학습으로 해결하기 어려웠던 문제들에 대해 획기적인 성능 향상을 보이고 있다.


인공 신경망을 체험할 수 있는 텐서플로 플레이그라운드를 이용하여 신경망 모델의 은닉층이 어떤 역할을 하는지를 알아보자.

텐서플로 플레이그라운드 <https://playground.tensorflow.org/>


- 1 텐서플로 플레이그라운드에서 활성화 함수(ReLU), 분류(Classification) 문제를 선택한다.



- 2 텐서플로 플레이그라운드에서 사용할 수 있는 데이터는 속성 X_1 과 속성 X_2 를 축으로 하는 좌표 평면에 점으로 표시되어 있다. 점의 색깔은 데이터가 속한 클래스를 나타내며, 주황과 파랑의 두 클래스로 구분된다. 'Exclusive or' 데이터를 선택한다.



- 3 은닉층(HIDDEN LAYERS)의 수를 0으로 설정하고 ▶를 클릭하면, 모델 학습 횟수(Epoch)가 올라간다. 은닉층이 없으면 학습 횟수가 올라가도 비선형 분류가 되지 않는 것을 볼 수 있다.



- 4 은닉층(HIDDEN LAYERS)의 수와 은닉층의 노드 개수를 늘리고 ▶를 클릭한다. 모델 학습 횟수가 올라갈수록 비선형 분류가 잘되는 것을 볼 수 있고, 은닉층의 개수가 많을수록 더 복잡한 속성을 표현할 수 있다.



💡 뉴런과 뉴런을 연결하는 선에 마우스를 가져다 대면 신경망 모델에 사용된 가중치를 볼 수 있다. 파란색은 양수, 빨간색은 음수로 가중치 절댓값이 클수록 선이 두껍다.

🧠 하나 더 해 보기

- 다른 데이터를 선택해 신경망 분류 모델을 만들어 보자.
- 은닉층 없이 분류가 가능한 데이터는 무엇인지 찾아보자.
- 비선형 분류를 위한 데이터에서 은닉층 개수, 은닉층 안의 노드 개수를 추가해 보자.

2 딥러닝 활용 분야

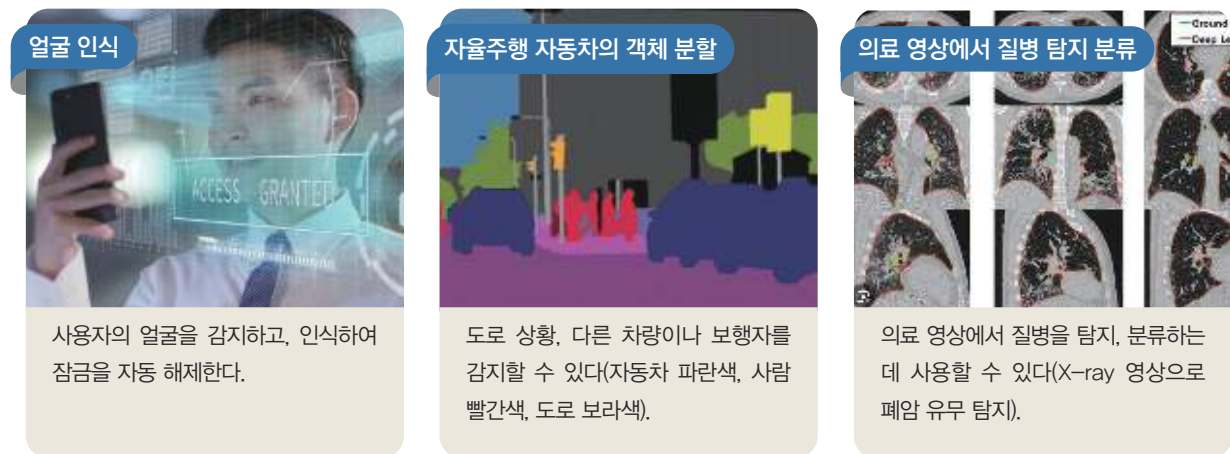
딥러닝은 컴퓨터 비전, 자연어 처리, 음성 인식, 생성 등 다양한 분야에서 활용되고 있다.

(1) 컴퓨터 비전

객체

이미지나 영상에서 식별할 수 있는 실체(사람이나 사물)이다.


컴퓨터 비전(computer vision)은 컴퓨터가 이미지와 영상에서 객체를 식별하고, 특성을 파악하는 분야이다. 딥러닝은 이미지나 영상에서 객체를 인식하고 분석하는 컴퓨터 비전의 성능을 크게 향상시킨다.



[그림 II-46] 컴퓨터 비전의 예

(2) 자연어 처리

자연어 처리(NLP; Natural Language Processing)는 컴퓨터가 사람이 사용하는 언어인 자연어를 이해하고 처리하는 분야로, 딥러닝으로 대화형 인공지능과 기계 번역과 같은 작업 등에 많이 활용한다.



[그림 II-47] 자연어 처리의 예

(3) 음성 인식

사람의 음성 명령을 컴퓨터가 이해하고 처리하는 분야이다. 음성 인식(speech recognition)은 음성 입력을 텍스트 데이터로 변환하여 자연어 처리 기술로 분석·이해·처리한다.



[그림 II-48] 음성 인식의 예

(4) 생성

텍스트, 이미지, 음성, 영상과 같은 콘텐츠를 생성하거나 변환하는 기술을 연구하는 분야이다. 생성형 AI(generative AI)는 딥러닝으로 이미지나 텍스트를 생성하거나 음성 합성 등에 많이 활용한다.



[그림 II-49] 생성형 AI의 예

미디어파이프(MediaPipe)는 컴퓨터 비전, 자연어 처리, 음성 인식 기술을 체험할 수 있는 사이트이다.

- 1 크롬에서 구글 개인 계정으로 로그인한다.
- 2 미디어파이프 사이트에 접속한다(<https://mediapipe-studio.webapps.google.com/home>).
- 3 딥러닝 기술을 선택, [See demo]를 클릭해 딥러닝 기술을 체험해 보자.

컴퓨터 비전



객체 탐지 경계 상자로 객체를 추적하고 레이블을 지정한다.



이미지 분류 이미지를 분류한다.



이미지 분할 픽셀 수준으로 객체를 찾는다.



동작 인식 손 동작을 인식한다.



손 주요 지점 탐지 손의 주요 지점(landmark)을 감지한다.



얼굴 탐지 얼굴을 찾아 감지한다.



얼굴 주요 지점 탐지 얼굴의 주요 지점이나 표정을 모방한 가상 아바타를 체험한다.



포즈 주요 지점 탐지 포즈를 추정해 인체 주요 지점을 식별한다.

자연어 처리




텍스트 분류 텍스트를 관련 태그로 분류한다.



텍스트 임베딩 텍스트를 임베딩 벡터로 변환한다.



언어 감지 주어진 텍스트 언어를 식별한다.



오디오 분류 소리를 식별한다.

- 4 체험한 딥러닝 기술로 해결할 수 있는 실생활의 문제 해결 사례들을 찾아보고, 느낀 점을 이야기해 보자.

예 인공지능 스피커, 인공지능 CCTV

2 신경망 모델 설계와 구현 과정

1 모델의 구현 과정

다음은 신경망 모델을 설계하고 구현하는 단계이다.

단계 ① 문제 정의하기



- 해결하고자 하는 문제를 명확하게 정의한다.
- 문제의 목표는 무엇이고 어떤 데이터를 사용할 수 있으며, 어떤 결과를 기대하는지를 명확히 한다.

단계 ② 데이터 수집 및 전처리하기



- 문제의 목표에 따라 다양한 형태로 데이터를 수집한다.
예 이미지 인식 문제를 해결하려면 이미지 데이터를 수집하고, 자연어 처리 문제를 해결하려면 텍스트 데이터를 수집한다.
- 데이터를 수집한 후에는 데이터의 결측치 처리, 이상치 처리, 정규화 등 데이터 전처리 작업을 수행한다.

단계 ③ 모델 생성하기



(1) 신경망 모델 설계하기

신경망 모델의 입력층, 은닉층, 출력층으로 구성하고, 각 층의 노드 개수와 활성화 함수를 결정한다.

(2) 신경망 모델 환경 설정하기

손실함수, 최적화 함수를 설정한다.

(3) 신경망 모델 학습하기

훈련 데이터로 신경망 모델을 학습한다.


단계 ④ 모델 평가하기



- 테스트 데이터를 사용하여 모델의 성능을 측정한다.
- 모델 평가로 성능을 파악하고, 모델을 개선할 수 있는 방향을 제시한다.

2 신경망 모델 생성하기

(1) 신경망 모델 설계하기




[그림 II-50] 심층 신경망 모델 구조

신경망 모델은 입력층, 은닉층, 출력층을 구성하고, 은닉층 개수, 각 층의 노드 개수와 어떤 활성화 함수(activation function)를 사용할지 설계한다.

예제 식품 분류 신경망 모델 설계하기

식품의 당도(sweet)값과 아삭함(crunchy) 값으로 과일, 단백질, 채소를 분류하는 신경망 모델을 구현해 보자.

	ingredient	sweet	crunchy	class
0	apple	10	9	0
1	bacon	1	4	1
2	banana	10	1	0
3	carrot	7	10	2
4	celery	3	10	2



과일, 단백질, 채소는 선형적으로 구분되지 않으므로 비선형 분류 모델을 구현해야 한다.

- 파일명: food_nn.csv
- https://bit.ly/food_nn_data
- class: 0(과일), 1(단백질), 2(채소)

특징과 타겟 선정하기

- 특징(X): sweet, crunchy
- 타겟(y): class

일반적으로 훈련 데이터와 테스트 데이터를 분할해 사용한다. 여기에서는 신경망 모델 구현 과정에만 집중하기 위해 분할하지 않았다.

데이터 프레임을 생성하고 특징(X), 타겟(y)을 선정한다.

```
01 import pandas as pd
02 df = pd.read_csv('food_nn.csv') # 데이터 프레임(df)
03 X = df[['sweet', 'crunchy']] # 특징(X)
04 y = df['class'] # 타겟(y)
```




다 알아보기

활성화 함수의 종류

활성화 함수: 인공 신경망에서 입력값의 가중합을 비선형적으로 변환해 출력하는 함수이다.


렐루 함수(ReLU)

은닉층에서 사용되는 활성화 함수로, 입력값이 음수일 때 0, 양수일 때 입력값을 그대로 출력한다.



소프트맥스 함수(softmax)


주로 출력층에서 사용되는 활성화 함수로, 값을 0에서 1 사이의 확률값으로 변환해 합이 1이 되도록 하는 함수이다.



입력층의 노드 개수는 특징의 개수와 동일하게 설정하는 것이 일반적이다. 이 모델 입력층은 sweet, crunchy 두 가지 특징을 입력받기 위해 2개의 노드가 필요하다.

은닉층 노드 개수는 데이터 크기와 복잡성에 따라 조정할 수 있다. 이 모델은 첫 번째 은닉층에 32개, 두 번째 은닉층에 16개의 노드를 사용했다.

출력층에는 3개의 분류 클래스(과일, 단백질, 채소)를 예측하기 위해 3개의 노드가 필요하다.



[그림 II-51] 식품 분류 신경망 모델 설계

위에서 설계한 식품 분류 신경망 모델을 케라스 라이브러리로 구현해 보자. 층을 순차적으로 연결하는 Sequential, 층의 모든 노드들을 연결해 주는 Dense를 이용해 모델을 설계한다. 이때 입력층을 제외한 모든 층에는 활성화 함수(relu, softmax 등)가 필요하다.

```
01 from keras.models import Sequential
02 from keras.layers import Dense
03 model = Sequential()           # 신경망 모델 설계
04 # 입력층(2) - 은닉층(32) - 은닉층(16) - 출력층(3)
05 model.add(Dense(32, input_dim=2, activation='relu'))
06 model.add(Dense(16, activation='relu'))
07 model.add(Dense(3, activation='softmax'))
```

relu, softmax 외에도 많은 활성화 함수가 있다.

케라스(keras) 라이브러리

딥러닝 모델 구현에 사용하는 라이브러리이다.

Sequential

층을 순차적으로 연결하는 모델 구조이다.

Dense

각 노드가 이전 층의 모든 노드와 연결되는 완전 연결 계층이다.

model.add(Dense())

신경망 모델에 완전 연결 계층(Dense)을 추가한다.

input_dim


입력층 노드 개수를 정한다.



더 알아보기

keras 라이브러리

keras는 딥러닝 모델 구현에 사용되는 라이브러리로 구현 과정은 다음과 같다.



sparse_categorical_crossentropy
(희소 범주형 교차 엔트로피)

분류 모델에서 정답이 정수(0, 1, 2 등)일 때 사용하는 손실함수이다.

adam

딥러닝에서 가장 많이 사용하는 최적화 알고리즘이며, 손실함수 값을 빠르고 효율적으로 최소화한다.

metrics=['accuracy']

모델 성능 평가 지표로 정확도(accuracy)를 사용한다.

(2) 신경망 모델 환경 설정하기


신경망 모델을 학습시키려면 먼저 손실함수와 최적화 함수를 설정해야 한다.

손실함수(loss function)는 예측값과 실제 정답 간의 차이를 측정하는 함수이다. 최적화 함수(optimizer function)는 손실함수의 값을 최소화하는 방향으로 신경망의 가중치 값을 조정하는 함수이다. `model.compile()`를 사용해 손실 함수, 최적화 함수, 평가 지표를 설정한다.

```
01 model.compile(loss='sparse_categorical_crossentropy', # 손실함수
02               optimizer='adam', # 최적화 함수
03               metrics=['accuracy']) # 평가 지표
```

(3) 신경망 모델 학습하기

데이터를 인공 신경망에 입력하면 초기에는 무작위로 설정된 가중치를 바탕으로 예측값이 출력된다. 이 예측값과 실제값의 차이인 손실함수를 이용해 오차(손실)를 구하고, 최적화 함수를 이용해 오차를 줄이는 방향으로 가중치를 조절한다. 이러한 과정을 여러 번 반복하면서 인공 신경망은 데이터의 패턴을 학습한다.



[그림 II-52] 식품 분류 신경망 모델 학습하기

epochs

학습 반복 횟수를 정한다.



처음에는 정확도가 낮았으나, 500번 학습시켰더니 정확도가 올라간 것을 볼 수 있어요.

```
01 model.fit(X, y, epochs=500) # 데이터로 500번 학습시키기
```

Epoch 500/500
1/1 [-----] 0s 16ms/step - loss: 0.1437 - accuracy: 1.0000

실행 결과 예

3 신경망 모델 평가 및 예측하기

훈련 데이터로 모델을 학습시킨 후, 테스트 데이터로 모델의 성능을 평가한다. 모델 성능 평가를 하면 분류 모델에서는 손실함수의 값과 정확도가 나온다. `model.evaluate()`을 사용하여 모델의 성능을 평가한다.

01 `model.evaluate(X, y)` # 모델 성능 평가하기

예측 단계는 학습된 모델에 데이터가 입력되었을 때 예측값을 계산하는 과정이다. `model.predict()`의 결과는 입력 데이터에 대한 각 클래스의 확률을 나타낸다. 확률값이 가장 큰 클래스로 예측한다.

01 `model.predict(X)` # 예측하기

실행 결과 예

`array([[0.9858028 , 0.00005124, 0.01414603],`

`model.evaluate()`
모델의 성능을 평가한다.

`model.predict()`


class	확률값
0	0.98580...
1	0.00005...
2	0.01414...

0 class에 속할 확률이 98.58%로 확률값이 가장 크기 때문에 0번으로 예측할 수 있다.

5

손으로 쓴 숫자 분류 모델 구현하기

문제 상황 MNIST는 0~9까지 손으로 쓴 숫자를 픽셀값으로 저장한 데이터셋이다. 숫자 하나가 28×28 크기로, 0~255까지의 픽셀값을 가진다. 각 픽셀은 8비트의 값(0~255)으로, 0은 가장 어두운 검은색, 255는 가장 밝은 흰색으로 표현한다.



단계 1 문제 정의하기

손으로 쓴 숫자 분류 모델을 구현해 보자.

단계 2 데이터 수집 및 전처리하기

- (1) 데이터 수집하기
- (2) 데이터 전처리하기, 데이터 분할하기

단계 3 신경망 모델 생성하기

- (1) 신경망 모델 설계하기
`model=Sequential(), model.add(Dense())`
- (2) 신경망 모델 환경 설정하기 `model.compile()`
- (3) 신경망 모델 학습하기 `model.fit()`

단계 4 신경망 모델 평가 및 예측하기

- (1) 신경망 모델 평가하기 `model.evaluate()`
- (2) 신경망 모델 예측하기 `model.predict()`

단계 ① 문제 정의하기

손으로 쓴 숫자 분류 모델을 구현해 보자.

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기

MNIST 데이터셋은 케라스 라이브러리에 저장되어 있어 바로 사용할 수 있다. 데이터 파일은 숫자가 저장된 타겟(label)과 특징(픽셀값)이 저장된 784개의 컬럼으로 구성되어 있다. 훈련 데이터 파일은 60,000개, 테스트 데이터 파일은 10,000개이다.

(2) 데이터 전처리하기

① 케라스 라이브러리에 저장된 MNIST 데이터셋을 불러와 훈련 데이터와 테스트 데이터로 분할한다.

X_train: 훈련 데이터 특징
y_train: 훈련 데이터 타겟
X_test: 테스트 데이터 특징
y_test: 테스트 데이터 타겟

```
01 from tensorflow import keras # tensorflow에서 keras 모듈을 가져오기
02 mnist = keras.datasets.mnist # mnist 데이터셋을 가져오기
03 # 훈련 데이터와 테스트 데이터로 분할하기
04 (X_train, y_train), (X_test, y_test) = mnist.load_data()
05 print(X_train.shape, y_train.shape, X_test.shape, y_test.shape)
```

실행 결과



```
Downloading data from https://storage.googleapis.com/tensorflow/tf-keras-datasets/mnist.npz
11490434/1490434 [=====] - 0s 0s/step
(50000, 28, 28) (60000,) (10000, 28, 28) (10000,)
```

mnist 데이터셋은 28×28 크기의 픽셀값으로, 훈련 데이터는 60,000개, 테스트 데이터는 10,000개로 구분되어 있다.

② 테스트 데이터 0번 특징값(X_test[0])을 28×28 형태로 변경하여 보여 준다.

```
01 import matplotlib.pyplot as plt
02 image = X_test[0].reshape(28, 28) # 28행, 28열 형태로 변환하기
03 plt.imshow(image, cmap='gray') # 흑백 그림으로 표현하기
04 plt.title(y_test[0]) # 0번 테스트 데이터 레이블 출력하기
05 plt.show() # 그림 표시하기
```

실행 결과



③ MNIST 데이터는 0에서 255 사이의 픽셀값을 가진 28×28 크기의 데이터이다. 이 데이터를 그대로 사용하면 픽셀값의 범위가 너무 커서 학습이 잘 이루어지지 않을 수 있으므로 픽셀값의 범위를 0에서 1 사이의 값으로 정규화를 수행한다.

```
01 X_train = X_train/255.0 # 데이터 정규화하기(0~1)
02 X_test = X_test/255.0
```

단계 ③ 신경망 모델 생성하기

(1) 신경망 모델 설계하기

① 케라스 라이브러리로 신경망 모델을 만드는 데 필요한 명령어를 불러온다.

```
01 # keras.models의 Sequential을 불러오기
02 from keras.models import Sequential
03 # keras.layers의 Dense, Flatten을 불러오기
04 from keras.layers import Dense, Flatten
```

- Sequential: 층을 순차적으로 연결하는 모델 구조이다.
- Dense: 완전 연결 계층으로 설계한다.
- Flatten: 다차원 배열을 1차원 배열로 만든다.

② 신경망 모델 설계하기: 입력층 노드 개수는 데이터의 픽셀 개수($28 \times 28 = 784$ 개)로 Flatten으로 2차원 배열을 1차원으로 변환한다. 또한 출력층에는 0~9까지의 숫자가 확률값으로 출력되므로 10개의 노드가 필요하다.

```
01 # 신경망 모델 설계하기
02 model = Sequential()
03 # (28, 28)을 1차원 배열로 바꿔 입력층에 추가하기
04 model.add(Flatten(input_shape = (28, 28)))
05 # 은닉층 생성하기(128개 노드, 활성화 함수 relu)
06 model.add(Dense(128, activation='relu'))
```

```
01 # 은닉층 생성하기(64개 노드, 활성화 함수 relu)
02 model.add(Dense(64, activation='relu'))
03 # 출력층 생성하기(10개 노드, 활성화 함수 softmax)
04 model.add(Dense(10, activation='softmax'))
```

(2) 신경망 모델 환경 설정하기

신경망 모델의 손실함수(loss), 최적화 함수(optimizer), 평가 지표(metrics)를 설정한다. mnist 데이터 분류 문제 손실함수는 'sparse_categorical_crossentropy', 최적화 함수는 'adam'을 사용한다. 평가 지표는 정확도(accuracy)를 사용한다.

```
01 # 학습 방식에 대한 환경 설정하기(model compile)
02 model.compile(
03     loss='sparse_categorical_crossentropy', # 손실함수(loss)
04     optimizer='adam', # 최적화 함수(optimizer)
05     metrics=['accuracy']) # 평가 지표(metrics)
```

분류 모델에서 정수 레이블일 경우 사용하는 손실함수

- 손실함수: sparse_categorical_crossentropy
- 최적화 함수: adam
- 평가 지표: accuracy

(3) 신경망 모델 학습하기

60,000개의 훈련 데이터(특징 X_{train} , 타깃 y_{train})로 총 10번을 반복 학습하여 신경망 모델을 학습한다.

```
01 # 훈련 데이터(X_train, y_train)로 10번 반복 학습하기
02 model.fit(X_train, y_train, epochs=10)
```

실행 결과 예

```
Epoch 1/10
1875/1875 [-----] - 7s 3ms/step - loss: 0.2387 - accuracy: 0.9284
Epoch 2/10
1875/1875 [=====] - 13s 7ms/step - loss: 0.1012 - accuracy: 0.9696

Epoch 9/10
1875/1875 [=====] - 8s 4ms/step - loss: 0.0133 - accuracy: 0.9934
Epoch 10/10
1875/1875 [=====] - 6s 8ms/step - loss: 0.0138 - accuracy: 0.9934
Keras src.callbacks.History at 0x7a424c8405
```

분류 모델을 학습시킨 결과, 모델의 손실(loss)은 0.2387에서 0.0198으로 줄어듦, 정확도(accuracy)는 0.9284에서 0.9934로 향상되었다. 단, 신경망 모델은 훈련할 때마다 손실함수와 정확도의 값이 다를 수 있다.

단계 4 신경망 모델 평가 및 예측하기

① 10,000개의 테스트 데이터(X_test, y_test)를 이용해 생성된 모델의 성능을 평가한다.

```
01 model.evaluate(X_test, y_test) # 생성된 모델 평가하기
```

실행 결과 예

```
913/913 [=====] - 2s 5ms/step - loss: 0.0955 - accuracy: 0.9784
10.095547243952751 b: 0.9783999186819517
```

테스트 데이터로 모델을 성능을 평가한 결과, 손실(loss)은 0.0955, 정확도(accuracy)는 0.9784이다. 단, 신경망 모델의 손실함수와 정확도의 값은 다르다.

② 테스트 데이터(X_test)를 예측한다.

```
01 predictions = model.predict(X_test) # 테스트 데이터 예측하기
02 predictions[0] # 0번 테스트 데이터 예측 결과를 보여 주기
```

실행 결과 예

```
913/913 [-----] - 1s 3ms/step
array([1.0816500e-15, 3.9888370e-03, 1.5200468e-03, 3.6624773e-06,
        1.8514843e-15, 2.6865298e-03, 9.4520040e-15, 9.9999851e-01,
        5.7537045e-10, 1.4573990e-03], dtype=float32)
```

예측 결과, 출력층 10개의 노드에 출력값이 저장되어 있다. 소프트맥스(softmax) 함수는 출력층 노드값의 총합이 1이 되도록 조정하는 함수로, 숫자 0부터 9까지의 확률값을 배열로 저장한다. 배열의 7번 인덱스 확률값이 9.9999851e-01로 가장 크므로 7로 예측할 수 있다.

```
01 import numpy as np
02 np.argmax(predictions[0]) # 배열의 가장 큰 인덱스값 찾아 주기
```

e-01: $\frac{1}{10}$

실행 결과 예

7

넘파이(numpy)의 argmax() 함수를 사용하면 배열의 가장 큰 인덱스값을 찾아 준다. 배열의 가장 큰 값의 인덱스는 7이므로 7로 인식할 수 있다.

③ 생성한 신경망 모델을 저장한 후, mnist_model.h5 파일을 내 컴퓨터에 다운로드한다.

```
01 model.save("mnist_model.h5")
```



신경망 모델의 은닉층, 반복 학습 횟수를 조정하여 모델의 성능을 높여 보자.



신경망 모델은
'더 알아보기'에서 사용할 거
예요.



더 알아보기

내가 쓴 숫자를 분류할 수 있을까?

내가 직접 쓴 숫자를 MNIST 신경망 모델로 분류해 보자.

1 숫자 쓰기

- ① 흰 종이에 검은색 펜으로 한 자리 숫자를 몇 개 작성한다. 이때 심이 굵은 펜을 사용한다.
- ② 스마트폰 카메라로 찍어 이미지 파일을 저장한다. (예 13.jpg)



파일명: 13.jpg


https://bit.ly/13_jpg

2 MNIST 신경망 모델 파일 준비하기

실습 활동에서 저장한 MNIST 신경망 모델 파일을 준비한다. (mnist_model.h5)

3 구글 코랩 파일에 숫자와 신경망 모델 파일 업로드하기


- ① 크롬 브라우저에서 구글 계정으로 로그인한다.
- ② 아래 주소를 복사해 구글 코랩(Google Colaboratory)에서 열고, [Drive로 복사] 버튼을 눌러 코랩 파일 사본을 만든다.
http://bit.ly/MNIST_data
- ③ 구글 코랩 파일 저장소에 신경망 모델 파일(mnist_model.h5)과 숫자 이미지(13.jpg) 파일을 업로드한다.
- ④ 신경망 모델을 불러온다. (모델명: new_model)



4 내가 쓴 숫자 예측하기


코드를 실행(▶)시키면서 신경망 모델이 내가 쓴 숫자를 잘 예측하는지 확인해 보자.

- ① 이미지를 읽고 회색조로 변환한 후 화면에 표시한다.
- ② 숫자를 인식한다.




원본 이미지에 경계 상자 표시하기

28*28 픽셀 크기로 변환되어 이미지가 늘어나거나 기울어져 보인다.



전처리된 숫자 개별로 보여 주기

- ③ 신경망 모델(new_model)로 숫자를 예측한다. 예측한 결과는 숫자 이미지 제목(title)에 표시된다.



내가 쓴 숫자를 잘 예측하는지 확인해 보자. 만약 숫자를 잘 예측하지 못한다면 그 이유가 무엇인지 서로 이야기해 보자. (참고 페이지: [63쪽 참고](#))



단계 ① 문제 정의하기

손으로 쓴 숫자 분류 모델을 구현해 보자.

단계 ② 데이터 수집 및 전처리하기


(1) 데이터 수집하기

주어진 링크에서 MNIST 데이터셋 파일을 다운로드한다.

🔗 http://bit.ly/MNIST_dataset


(2) 데이터 전처리하기

- ① 'File'에서 mnist_train_small.csv 파일(5000개)을 불러온다.
💡 위젯 이름 변경: File(train)
- ② 'File'에서 mnist_test_small.csv(1000개)를 불러온다.
💡 위젯 이름 변경: File(test)
- ③ label 속성은 범주형(categorical), 타겟(target)으로 선정하고, 나머지 속성들은 특징(feature)으로 선정해 [Apply] 버튼을 선택한다.



단계 ③ 모델 생성하기

- ① 'File(train)' - 'Neural Network', 'Test and Score'를 연결한다.
- ② 'Neural Network' - 'Test and Score'를 연결한다.




- ③ 'Test and Score'에서 신경망 모델 분류 정확도(CA)를 확인한다.

Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	0.993	0.931	0.930	0.930	0.931	0.923

단계 ④ 모델 평가하기

- ① 'File(test)' - 'Predictions'를 연결한다.
- ② 'Neural Network' - 'Predictions'를 연결한다.



- ③ 'Predictions'의 분류 정확도(CA)를 확인한다.

Model	AUC	CA	F1	Prec	Recall	MCC
	0.993	0.925	0.925	0.926	0.925	0.917

이렇게 쉽게
손으로 쓴
숫자 분류 모델을
구현한다고?




3 컴퓨터 비전

인간이 감각 기관, 특히 시각을 통해 많은 정보를 얻는 것처럼 컴퓨터도 인간처럼 보고 이해할 수 있다면 할 수 있는 일이 무궁무진할 것이다.

1 컴퓨터 비전의 이해

(1) 컴퓨터 비전

인간이 눈으로 본 객체를 이해하고 대상이 무엇인지 알 수 있는 것처럼 컴퓨터 비전(computer vision)은 컴퓨터가 이미지나 비디오에서 객체를 인식하는 방법을 연구하는 분야이다. 인간과 컴퓨터는 객체를 어떻게 인식할까?



[그림 II-53] 인간과 컴퓨터 비전의 객체 인식

인간의 시각은 이미지를 보고 단번에 상황과 의미를 파악한다.

반면 컴퓨터의 관점에서 이미지는 픽셀로 표현되는 숫자의 배열에 지나지 않는다. 컴퓨터에 픽셀값 자체는 큰 의미가 없으므로 이미지를 보고 의미를 이해하려면 나열된 숫자가 무엇을 의미하는지 해석해야 한다.

컴퓨터 비전 분야에서는 이를 위해 이미지 안에서 객체의 위치를 찾고, 객체가 무엇인지 인식 방법 등을 연구한다.

(2) 컴퓨터 비전 활용 사례

컴퓨터 비전 기술은 다양한 분야에서 활용되고 있다. 예를 들면 앱을 이용해 얼굴에 가면을 씌우거나 스티커를 붙이고, 얼굴이나 홍채 인식으로 스마트폰의 잠금을 해제하고, SNS에서 사진을 업로드하면 자동 태그 기능을 사용한다.


특히 자율주행 자동차는 실시간으로 객체를 탐지하고, 주변 환경을 인식하여 주변 객체와의 상호 작용을 더욱 정밀하게 할 수 있다.

객체 탐지 (object detection)

이미지나 비디오에서 특정 객체의 위치를 찾아내는 기술이다.



AI CCTV: AI 교통사고 방지




자율주행 자동차 객체 탐지



자연재해 감지

객체 세그멘테이션 (object segmentation)

이미지나 비디오 영상 프레임 내에서 객체의 픽셀별 경계를 정확하게 구분하여 분할하는 기술이다.



의학 분야: 암 감지




위성 이미지로 지형 분석



자율주행 자동차 객체 분할

자세 추정 (pose estimation)

사람 또는 객체의 관절 위치를 추정하고, 그 자세를 파악하는 기술이다.



체육 및 운동 트래킹



게임 및 엔터테인먼트



보안 및 감시 시스템: 길에 쓰러진 사람 찾기

객체 탐지 기술은 이미지나 동영상에서 특정 객체를 찾아 그 위치와 범위를 식별하는 기술이다. YOLO는 객체 탐지 기술로, 이미지나 동영상에서 특정 객체를 찾아 그 위치와 범주를 식별한다.

1 크롬 브라우저에서 구글 계정으로 로그인한다.

2 아래 주소를 복사하여 구글 코랩에서 열고, [Drive로 복사] 버튼을 눌러 코랩 파일 사본을 만든다.

https://bit.ly/object_data


3 아래 순서대로 실행(▶)시키면서 파일(test.jpg)을 업로드해 객체를 탐지해 보자.

① darknet 폴더가 생성되고, darknet 저장소 내용이 복사된다.

💡 YOLO 모델을 구현하기 위한 프레임워크(framework)

② 주어진 링크에 들어가 'test.jpg'를 다운로드한 후 이미지 파일(test.jpg)을 darknet 폴더 안에 업로드한다.

http://bit.ly/test_jpg



③ yolov4.weights가 다운로드된다.

④ darknet 실행 파일로 ./test.jpg 이미지의 객체가 탐지된다.

⑤ 테스트 이미지(test.jpg)와 객체 탐지한 이미지(predictions.jpg)를 확인할 수 있다.

이미지 파일(/content/darknet/test.jpg)	객체 탐지 결과
Original Image 	Predicted Image 

2 합성곱 신경망의 이해

합성곱 신경망 구조

- 합성곱 층(convolution layer)
- 풀링 층(pooling layer)
- 완전 연결 계층(fully connected layer)

완전 연결 계층

이전 층의 모든 노드를 다음 층의 모든 노드와 연결하는 신경망이다.

합성곱 신경망의 이미지 특징 추출하기(feature extraction)

이미지의 대상을 대표할 수 있는 특징을 추출한다.

합성곱 층


합성곱 연산으로 특징을 추출한다.

풀링 층

합성곱 층에서 추출한 특징을 간소화한다.

컴퓨터 비전 분야는 인공지능으로 인해 빠르게 발전하고 있다. 특히, 신경망 모델 중 합성곱 신경망(CNN; Convolutional Neural Network)은 이미지 인식에 성능이 뛰어나 컴퓨터 비전에서 큰 역할을 한다.

합성곱 신경망은 완전 연결 계층에 합성곱 층과 풀링 층이라는 특별한 층을 더한 인공 신경망이다. 합성곱 층과 풀링 층으로 이미지의 특징을 추출하고, 추출한 특징값을 완전 연결 계층의 입력값으로 받아 분류 모델을 만든다.




[그림 II-54] 합성곱 신경망

합성곱 층에서는 이미지 특징을 추출하고, 풀링 층에서는 추출된 특징 중에 중요한 부분만 추출해 데이터의 크기를 줄이는 역할을 수행한다. 이러한 과정을 반복하면 크기가 큰 이미지 데이터에서 핵심적인 특징만 추출하므로 분류하는 데 큰 도움을 준다.




합성곱 신경망은 이미지의 전체적인 패턴이 아닌 특징을 중점적으로 인식하는 방법을 사용해요.




block1_conv1



block2_conv1



block3_conv1



block4_conv1

[그림 II-55] 고양이 이미지의 합성곱 층 결과



활동 10 합성곱 연산으로 이미지 특징을 추출하는 과정 이해하기

탐색 분석

1 Image kernels 사이트에 접속한다.


<https://setosa.io/ev/image-kernels/>

2 합성곱 연산을 통해 이미지 특징을 추출하는 과정을 살펴보자.

커널(kernel)

- 이미지에서 특징을 추출하는 필터
- 가중치 값으로 구성됨.

$$\begin{pmatrix} 0 & -1 & 0 \\ 1 & 5 & 1 \\ 0 & -1 & 0 \end{pmatrix}$$




합성곱 연산: 이미지 픽셀값과 커널 가중치 값을 곱하고 더하는 연산으로 특징을 추출함.


- 1 CNN EXPLAINER 사이트에 접속한다. <https://poloclub.github.io/cnn-explainer/>
- 2 사이트에 있는 이미지를 선택해 합성곱 신경망으로 이미지 특징을 추출하고 분류 모델을 만드는 과정을 살펴보자.



- 1 이미지를 하나 선택한다.
- 2 RGB 채널별 이미지 확인: RGB 채널별 이미지를 확인할 수 있다.
- 3 합성곱 층(conv), 풀링 층(max_pool): 이미지 특징 추출 과정을 확인할 수 있다.
 - 합성곱 층(conv)은 이미지 픽셀값과 커널 가중치 값을 이용해 합성곱 연산을 수행하고 특징을 추출한다.



- 풀링 층은 합성곱 층에서 추출한 특징을 간소화하고 데이터 크기를 줄이는 역할을 한다.



최대 풀링(Max Pooling)

영역에서 가장 큰 값을 선택한다.



- 4 완전 연결 계층: 완전 연결 계층으로 분류를 예측한다. 합성곱 층과 풀링 층을 통해 추출된 특징값들은 완전 연결 계층의 입력으로 받는다. 이후 완전 연결 계층의 출력층을 통해 확률값이 가장 큰 값으로 클래스를 예측한다.





1 사전 훈련된 합성곱 신경망

사전 훈련된 합성곱 신경망은 대규모 이미지 분류 문제를 위해 대량의 데이터셋으로 미리 훈련·저장된 모델로, 훈련에 사용한 원본 데이터셋이 충분히 크다면 일반적인 모델로도 사용할 수 있다.


사전 훈련된 합성곱 신경망들은 이미지 인식 대회(ILSVRC)에서 우승한 모델들을 많이 사용한다.



사전 훈련된 합성곱 신경망 모델 구조를 확인해 보자.



<https://tensorspace.org/html/playground/index.html>




ILSVRC 우승 모델: 이미지 인식 분류 오류율(%)

2 전이 학습

전이 학습(transfer learning)은 어떤 목적을 이루기 위해 학습된 모델을 다른 작업에 이용하는 것을 말한다. 일반적으로 합성곱 신경망으로 딥러닝 모델을 만들려면 많은 양의 데이터가 필요하다. 하지만 현실적으로 큰 데이터셋을 얻기는 쉽지 않다. 그래서 사전 훈련된 신경망 모델 전체 또는 일부를 가져와 해결할 과제에 맞게 보정해서 사용하는 전이 학습을 수행할 수 있다.

많은 양의 ImageNet dataset으로 훈련한 신경망 모델은 일반적인 특징을 잘 학습할 수 있으므로 Medical dataset을 잘 처리할 수 있다.

- ① ImageNet dataset으로 만든 신경망 모델을 불러온다.
- ② 신경망 모델의 완전 연결 계층을 제거한다.
- ③ Medical dataset으로 신경망 모델을 다시 훈련한다.



전이 학습



203쪽 참고

문제 상황 폭염과 폭우로 전국 각지에서 아스팔트가 깔린 도로에 금이 가고 함몰되거나 녹아 내리는 등의 도로 균열 현상이 나타나고 있다. 이러한 도로 균열은 자동차 운전자가 주행 중에 발견하기 어렵고 사고 발생 후 인식하게 되므로 교통 정체, 차량 손상, 급제동뿐만 아니라 뒤따르던 차량의 추돌 등 큰 사고로도 이어질 수 있다.



단계 ① 문제 정의하기

사전 훈련된 합성곱 신경망 모델 중 VGG16 모델로 도로의 균열 유무를 판단해 보자.

💡 VGG16: 2014년에 발표된 합성곱 신경망 모델로, 16개의 합성곱 층으로 구성됨.

단계 ② 데이터 수집 및 전처리하기

(1) 데이터 수집하기

캐글 사이트의 도로 균열 이미지 데이터셋(<https://www.kaggle.com/datasets/arunrk7/surface-crack-detection>)은 균열된 이미지(Positive)와 균열되지 않은 이미지(Negative) 폴더로 저장되어 있다. 캐글 사이트에 데이터가 너무 많으므로 주어진 링크로 들어가서 `crack.zip` 파일을 다운로드 한다.

`crack.zip`은 훈련(train), 테스트(test) 폴더를 만들어 이미지 파일을 일부 이동시킨 것이다.

🔗 https://bit.ly/crack_dataset

	균열되지 않은(Negative)	균열된(Positive)
crack test Negative Positive train Negative Positive		

• 훈련(train): 300개 • 테스트(test): 80개 • 레이블: Negative, Positive

(2) 데이터 전처리하기

구글 드라이브에 이미지 폴더를 업로드하고 폴더에 접근한다.

(예 이미지 저장 위치: 내 드라이브 > data > crack)

① 구글 드라이브에 접근 권한을 부여한다.

```

01 # Google Colab에서 Google Drive에 접근하는 데 사용하기
02 from google.colab import drive
03 # Google Drive를 /content/gdrive 디렉터리에 접근하기
04 drive.mount('/content/gdrive')
  
```



② 이미지 폴더가 있는 곳으로 위치를 변경한다.

```

01 # 현재 작업 디렉터리를 /content/gdrive/My Drive/data/crack/ 디렉터리로 변경하기
02 %cd /content/gdrive/My Drive/data/crack/
  
```

③ ImageDataGenerator를 이용하여 훈련, 테스트 이미지 데이터를 전처리할 수 있다.

- rescale = 1./255: 0~1 사이의 값으로 변환한다.
- shuffle=True: 이미지 순서를 섞는다.
- target_size=(64, 64): 이미지를 (64, 64) 크기로 조정한다.
- batch_size=32: 한 번 모델에 공급되는 이미지를 32로 정한다.
- class_mode='categorical': 다중 클래스 분류 문제로 사용한다.
- flow_from_directory: 지정된 폴더에서 이미지 파일을 불러온다.

```

01 from tensorflow.keras.preprocessing.image import ImageDataGenerator
02 # ImageDataGenerator를 생성하기(이미지 픽셀값을 0~1 사이 범위로 조정)
03 train_datagen = ImageDataGenerator(rescale = 1./255)
04 # train 폴더의 이미지 데이터를 불러와 전처리 적용하기
05 # 이미지 훈련 데이터 폴더명(train)
06 training_set = train_datagen.flow_from_directory('train',
07                                                  target_size = (64, 64), # 이미지 크기 조정
08                                                  batch_size = 32, # 한 번에 사용하는 이미지 수
09                                                  shuffle = True, # 훈련 이미지 순서 섞기
10                                                  class_mode = 'categorical') # 다중 클래스 분류
  
```

실행 결과

Found 300 images belonging to 2 classes

훈련 데이터(train)는 총 300개이다.

```

01 # ImageDataGenerator를 생성하기(이미지 픽셀값을 0~1 사이 범위로 조정)
02 test_datagen = ImageDataGenerator(rescale = 1./255)
03 # 주어진 폴더(test)에서 이미지 데이터를 불러와 전처리 적용하기
04 test_set = test_datagen.flow_from_directory('test',
05     target_size=(64, 64),          # 이미지 크기 조정
06     shuffle = False,                # 테스트 이미지 순서를 섞지 않기
07     class_mode='categorical')      # 다중 클래스 분류

```


실행 결과

Found 800 images belonging to 2 classes.

테스트 데이터는 총 807개이다.

단계 ③ 신경망 모델 생성하기

합성곱 신경망 모델로 이미지를 분류하기 위해서는 이미지의 특징을 추출하고, 추출된 특징값을 완전 연결 계층의 입력층으로 받아 분류 모델을 수행한다.



(1) 이미지 특징 추출하기

VGG16 모델을 이용해 이미지 특징을 추출한다.

사전 훈련된 합성곱 신경망 모델인 VGG16을 불러와 이미지의 특징을 추출한다. include_top=False를 설정해, VGG16 모델의 완전 연결 계층을 제외한 합성곱 층, 풀링 층만 실행해 특징을 추출한다.

- include_top = False: 완전 연결 계층을 제거해 vgg 모델 이미지의 특징 추출만 한다.
- weights = 'imagenet': ImageNet 데이터셋에서 사전 학습된 가중치를 사용한다.
- input_shape = (64, 64, 3): 이미지 너비, 이미지 높이, 이미지 채널 수(RGB)를 정한다.

```

01 from keras.applications.vgg16 import VGG16 # vgg 모델 불러오기
02 vgg = VGG16(include_top=False, weights='imagenet',
03     input_shape=(64, 64, 3))
04 # layer.trainable = False: VGG16 모델의 사전 학습된 가중치를 변경하지 않고 그대로 사용
05 for layer in vgg.layers :
06     layer.trainable = False
07 vgg.summary()

```

vgg 모델의 구조를 확인해 보자.

(2) 완전 연결 계층 설계하기

추출된 특징값을 입력층으로, 완전 연결 계층으로 신경망 모델을 설계한다.

① 케라스 라이브러리로 완전 연결 계층을 만들기 위한 클래스를 불러온다.

- Sequential: 층을 순차적으로 연결하는 모델 구조
- Dense: 각 노드가 이전 층의 모든 노드와 연결되는 완전 연결 계층
- Flatten: 다차원 배열을 1차원 배열로 만드는 작업

```

01 # keras.models의 Sequential 불러오기
02 from keras.models import Sequential
03 # keras.layers의 Dense, Flatten 불러오기
04 from keras.layers import Dense, Flatten, Input

```

② VGG16으로 특징을 추출한 결과(vgg)를 완전 연결 계층에 연결한다. 두 가지로 분류하기 위해 다음과 같이 설계한다.

- 입력층: vgg 모델 출력값(특징 추출)
- 은닉층: 64, relu
- 출력층: 2, softmax

도로 균열 유무(Negative, Positive) 이므로 출력층은 2개의 노드를 설계한다.

```
01 model = Sequential() # 모델 생성하기
02 model.add(Input(shape=(64, 64, 3)))
03 model.add(vgg) # vgg 모델 추가하기
04 model.add(Flatten()) # 1차원 배열로 바꾸기
05 # 은닉층 추가하기(64개 노드, 활성화 함수 relu)
06 model.add(Dense(64, activation='relu'))
07 # 출력층 추가하기(2개 노드, 활성화 함수 softmax)
08 model.add(Dense(2, activation='softmax'))
09 model.summary()
```

모델 구조를 확인해 보자.

(3) 신경망 모델 환경 설정하기

분류 모델에 대한 손실함수(loss)와 최적화 함수(optimizer)를 설정한다.

- 손실함수(loss): categorical_crossentropy
- 최적화 함수(optimizer): adam
- 평가 지표(metrics): accuracy

최적화 함수는 변경할 수 있으나 이미지 분류 모델에서 손실함수는 'categorical_crossentropy'를 사용한다.

```
01 model.compile(loss='categorical_crossentropy', optimizer='adam',
02               metrics=['accuracy'])
```

이미지 분류 모델에서 손실함수는 'categorical_crossentropy', 최적화 함수는 'adam', 평가 지표는 정확도(accuracy)로 설정하였다.

(4) 신경망 모델 학습하기

훈련 데이터(training_set)로 신경망 모델을 학습한다.

```
01 model.fit(training_set, epochs=5) # 모델 학습하기(5번)
```

실행 결과 예

```
Epoch 1/5
0/10 [-----] - 60s 7s/step - loss: 0.3208 - accuracy: 0.8400
Epoch 2/5
0/10 [=====] - 16s 2s/step - loss: 0.0375 - accuracy: 1.0000
Epoch 3/5
0/10 [-----] - 15s 1s/step - loss: 0.0154 - accuracy: 0.9967
Epoch 4/5
0/10 [-----] - 15s 1s/step - loss: 0.0071 - accuracy: 1.0000
Epoch 5/5
0/10 [=====] - 15s 1s/step - loss: 0.0052 - accuracy: 1.0000
skeras.saving.save_history('history.h5')
```

훈련 데이터로 모델을 훈련한 결과, 분류 정확도가 높음을 알 수 있다.

단계 4 신경망 모델 평가 및 예측하기

(1) 모델 성능 평가하기

테스트 데이터(test_set)로 모델의 성능을 평가한다.

```
01 model.evaluate(test_set) # 모델 평가하기
```

실행 결과 예

```
0/1 [-----] - 12s 1s/step - loss: 0.1101 - accuracy: 0.9125
0/1 [-----] - 12s 1s/step - loss: 0.1101 - accuracy: 0.9125
```

테스트 데이터로 모델 성능을 평가한 결과, 분류 정확도가 높음을 알 수 있다.

(2) 예측하기

① 테스트 데이터(test_set)로 예측을 수행한다.

```
01 pred = model.predict(test_set) # 테스트 데이터로 모델 예측하기
```

② 데이터의 클래스값을 확인한다. 균열이 없는 'Negative'는 0, 균열이 있는 'Positive'는 1이다.

```
01 # 훈련 데이터셋의 클래스 레이블과 인덱스 확인하기
02 print(training_set.class_indices)
```

실행 결과

```
{'Negative': 0, 'Positive': 1}
```


③ 예측 결과와 테스트 데이터의 레이블값으로 혼동 행렬을 구한다.

```
01 import numpy as np
02 import matplotlib.pyplot as plt
03 import seaborn as sns
04 # 혼동 행렬 함수 불러오기
05 from sklearn.metrics import confusion_matrix
06 # 예측 결과에서 가장 큰 인덱스값 추출하기
07 Predicted = np.argmax(pred, axis=1)
08 Actual = test_set.labels # 테스트 데이터의 실제 레이블 가져오기
09 # 혼동 행렬 계산하기(실제값, 예측값)
10 conf = confusion_matrix(Actual, Predicted)
11 # 혼동 행렬 표시하기
12 sns.heatmap(conf, annot=True, cmap='BuPu', fmt='d')
13 # 제목, x축 이름(Predicted), y축 이름(Actual) 설정하기
14 plt.title("Crack Classification")
15 plt.xlabel("Predicted")
16 plt.ylabel("Actual")
17 plt.show()
```

heatmap 옵션

- conf: 혼동 행렬
- annot = True: 값 표시
- cmap: 컬러맵 설정
- fmt = 'd': 정수 표시

실행 결과 예



실제값인 균열이 없는 이미지(Negative, 0) 40개를 모두 분류하였어요. 균열이 있는 이미지(Positive, 1) 중 33개를 정확하게 분류하고, 7개는 균열이 없는 이미지(0)로 잘못 분류하였어요.



단계 1 문제 정의하기

사전 훈련된 합성곱 신경망 모델로 도로의 균열 유무를 판단해 보자.

💡 오렌지에서 Options>Add-ons...>Image Analytics를 체크하여 이미지를 분석할 수 있는 위젯을 추가한다.

단계 2 데이터 수집 및 전처리하기


(1) 데이터 수집하기

도로 균열 유무를 분류하는 합성곱 신경망 모델 구현하기에서 수집한 'crack.zip' 파일을 사용한다. [149쪽 참고](#)

(2) 데이터 전처리하기


① 'Import Images'에서 train 폴더를 불러온다. 2개의 카테고리(categories)와 300개의 이미지(images) 정보가 나온다.

💡 위젯명 수정: Import Images(train)



② 'Import Images'에서 test 폴더를 불러온다. 2개의 카테고리(categories)와 80개의 이미지(images) 정보가 나온다.

💡 위젯명 수정: Import Images(test)




단계 3 모델 생성하기

① 'Import Images(train)' - 'Image Embedding'을 연결해 특징을 추출한다. Embedder는 Inception v3, VGG16 등을 선택한다. 인터넷이 연결되지 않으면 SqueezeNet을 연결한다.



② 'Image Embedding' - 'Neural Network', 'Test and Score'를 연결한다. 'Neural Network' - 'Test and Score'를 연결한다.



③ 'Test and Score'의 분류 정확도(CA)를 확인한다.

Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	1.000	0.987	0.987	0.987	0.987	0.979


단계 4 모델 평가하기

① 'Import Images(test)' - 'Image Embedding'을 연결한다. Embedder는 훈련 데이터 임베딩에서 사용한 동일 모델을 사용한다. 만약 Inception v3을 사용했으면 Inception v3을 사용한다.



② 'Neural Network' - 'Predictions'를 연결한다.

③ 'Image Embedding' - 'Predictions'를 연결한다.



④ 'Predictions'의 분류 정확도(CA)를 확인한다.

Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	1.000	0.988	0.987	0.988	0.988	0.979


4 음성 인식과 자연어 처리

우리는 대부분 말로 다른 사람과 소통한다. 이때 사용하는 언어(말)는 가장 일반적이고 효과적인 의사소통 수단이다. 인공지능은 어떻게 언어를 인식하고 그에 따른 작업을 수행하는지 알아보자.

1 음성 인식과 자연어 처리 이해

음성 인식은 사람의 목소리로부터 발생하는 음성 신호를 컴퓨터가 해석하여 이를 텍스트로 변환하는 기술이다. 자연어(natural language)는 사람이 일상생활에서 사용하는 언어를 뜻하며, 자연어 처리(NLP; Natural Language Processing)는 사람이 사용하는 언어의 의미를 분석하여 컴퓨터가 처리할 수 있도록 만드는 작업이다.

따라서 자연어 처리는 음성 인식으로 만들어진 텍스트를 기반으로 데이터의 전처리, 형태소 분석, 문장 구조의 파악, 의미 분석 등의 다양한 과정을 포함한다.



[그림 II-56] 인공지능 스피커 동작 과정


인공지능 스피커는 제한된 범위에서 음성 인식과 자연어 처리 기능을 갖추고 있다. 인공지능 스피커는 마이크를 입력된 음성을 인식하여 텍스트로 바꾸는 과정을 먼저 수행하며, 이를 바탕으로 자연어 처리 작업을 추가로 진행하여 사전에 약속된 동작을 수행한다.

음향 모델

어떤 단어가 어떤 소리로 나오
는지를 확률적으로 변환한 모델
이다.

언어 모델

텍스트를 분석하여 특정한
단어들이 나타날 확률을 계
산해 놓은 모델이다.



끝점 검출

음성의 시작과 끝을 자동으로
검출한다.

전처리

잡음 등을 제거하는 기술이다.


후처리

숫자나 영문, 문장 부호를 복원
한다.

2 딥러닝을 활용한 음성 인식


최초의 음성 인식 기술은 컴퓨터에 입력된 음성의 파형이 어떤 음에 가까운
지, 어떤 단어를 나타내는지를 인식하는 형태였다. 딥러닝이 이미지 인식 분야
의 성능을 획기적으로 향상시킨 것처럼 음성 인식 분야의 성능도 향상시켰다.

음성 인식은 주어진 음성 데이터를 처리하고 언어 모델과 음향 모델을 이용
하여 단계적으로 음성을 텍스트 형태로 변환하는 과정에서 딥러닝을 사용한다.



[그림 II-57] 음성 인식 시스템 구성도


최근에는 종단 간(End-to-End) 구조 기반의 형태가 음성 인식에 사용된
다. 종단 간 방식은 기존처럼 단계적인 과정으로 음성을 인식하는 것이 아니라
한꺼번에 음성을 인식하는 것이다.



[그림 II-58] 종단형 음성 인식 구성도



연도별 음성 인식 오류 그래프의 변화와 딥러닝



연도별 음성 인식 오인식률 추이(NIPS2015 tutorial)

최초의 음성 인식 시스템은 1952년 미국의 벨 연구소에서 개발한 Audrey이며 0부터 9까지의 숫자를 인식하였다.

왼쪽 그림은 마이크로소프트사의 연도별 음성 인식에서 잘못 인식하는 비율을 보여 주는 그래프이다.


그래프를 보면 2000년대까지는 성능이 꾸준히 증가하여 20% 정도의 오류를 보여 준다. 2000년 이후부터는 정체를 겪었다가 2010년 이후 음성 인식에 딥러닝이 적용되면서 성능이 급격하게 향상되었다.

- 1 다음 사이트에 접속하여 인공지능의 음성 인식 기술을 활용해 보자.

<https://clova.ai/speech>



- 2 학급 회의 내용을 녹음하고, 이를 클로바 노트를 이용하여 텍스트로 변경하여 정리해 보자.



- 3 학급 회의 내용을 직접 필기하는 방법과 비교할 때 인공지능을 이용한 방법이 가지는 장점이 무엇인지 이야기해 보자.


더 알아보기 생성형 인공지능이란 무엇일까?

① 생성형 인공지능

기존 데이터를 바탕으로 패턴을 학습하여, 그것에 기반한 새로운 창작물, 즉 텍스트, 이미지, 음악 등 콘텐츠를 자동으로 만들어 내는 인공지능 기술이다.

② 기반(foundation) 모델

대규모의 데이터로 사전에 학습시켜 놓은 대형 인공지능 모델인데, 특정 작업에 맞게 추가 학습을 통해 텍스트 생성, 번역, 이미지 생성 등 다양한 분야의 작업에 활용될 수 있다.



③ 대규모 언어 모델(LLM)

대량의 텍스트 데이터로 훈련되어 인간의 다양한 자연어를 해석하고 생성할 수 있는 인공지능이다.

④ 챗GPT(오픈 AI사의 제품)

챗GPT는 대규모 언어 모델(LLM)을 이용한 챗봇 서비스로서 자연어 대화를 통하여 콘텐츠를 생성한다.

3 딥러닝을 활용한 자연어 처리

텍스트의 자연어 처리 과정에서도 딥러닝은 성능 향상에 큰 역할을 한다. 텍스트에 대한 효율적인 분석 및 정보 추출과 자연스러운 텍스트를 생성하려면 자연어 이해 모델과 자연어 생성 모델이 필요하다.

(1) 자연어 이해 모델

자연어 이해 모델은 자연어로 이루어진 대량의 텍스트를 분석하고, 이 속에서 자연어의 규칙을 이해하는 모델이다. 즉, 이 모델은 문장에 포함된 언어의 문법과 의미를 이해한다.

예를 들어 “나는 과일 중에서 배를 좋아한다.”라는 문장과 “나는 항구에서 배를 보았다.”라는 문장에서 같은 단어인 ‘배’는 서로 다른 의미이다. 단어의 의미를 파악하려면 단어 앞뒤에 있는 모든 단어의 의미를 파악해야 한다.


자연어 이해 모델의 대표적인 예는 구글이 2018년에 소개된 BERT이다. BERT는 사전에 훈련된 언어 모델을 이용하며, 텍스트의 입력을 양방향으로 읽어 만든 모델이다.

BERT(Bidirectional Encoder Representations from Transformers)
트랜스포머의 양방향 인코더 표현을 나타낸다.



BERT는 자연어를 어떻게 이해할까?

BERT는 문장 중간에 빈칸을 만들고, 해당 위치에 어떤 단어가 적절한지 예측하며 훈련한다.



위의 예처럼 문장 내의 단어를 예측하는 과정에서 해당 단어의 앞뒤 모두를 참조하여, 다른 단어가 아닌 ‘정말’이라는 단어가 나올 확률을 높이는 과정으로 훈련을 진행한다. 이러한 과정으로 단어 간의 관계를 파악하여 자연어가 가진 의미를 이해한다.

(2) 자연어 생성 모델


언어 생성 모델은 자연어 이해 모델처럼 대량의 텍스트를 미리 학습하여 주어진 문장에서 가장 적합한 다음 단어나 문장을 예측한다. 이를 통해 새로운 문장을 생성한다는 점에서 자연어 이해 모델과 차이가 있다. 예를 들어 검색 엔진에서 사용자가 입력한 검색 문자열 다음에 자동으로 단어를 완성해 주는 기능은 자연어 생성 모델을 이용한다. 자연어에 대한 이해를 바탕으로 기계 번역, 챗봇의 대화형 서비스, 소셜 쓰기 같은 부분에서도 모두 자연어 생성 모델을 이용한다.

대표적인 예는 Open AI가 개발한 GPT(Generative Pre-trained Transformer)가 있다. GPT는 많은 양의 텍스트 데이터로 훈련되며, 주어진 문장의 맥락을 바탕으로 다음 단어를 예측하는 방식으로 동작한다.



GPT는 어떻게 자연어를 생성할까?

GPT의 학습 방식은 이전 단어의 정보를 사용하여 다음 단어를 예측하도록 훈련되는 방식이다.



GPT는 위의 예처럼 다음의 단어를 예측하는 형태로 학습이 이루어지므로 주어진 문장이나 단어들의 정보를 바탕으로 자연스러운 문장을 생성할 수 있다.



GPT

사전 훈련된 생성형 트랜스포머를 나타낸다.



GPT의 발전 단계

단계	시기	매개 변수	주요 기능
GPT-1	2018년	1억 1,700만 개	문장 의미 유사도 판단, 분류
GPT-2	2019년	15억 개	번역, 작문, 간단한 대화
GPT-3	2020년	1,750억 개	간단한 코딩, 텍스트 요약
GPT-3.5	2022년	1,750억 개	시나리오·보고서 작성, 광고 카피 생성
GPT-4	2023년	비공개	텍스트·이미지 동시 이해, 단어 처리 능력 8배 강화

GPT는 모델의 버전이 증가할수록 매개 변수의 수가 대폭 증가한다. 매개 변수의 증가는 모델이 더 많은 것을 학습하고 새로운 것을 예측하는 능력을 향상시켜 준다.

4 음성 인식과 자연어 처리 사례

인공지능을 이용한 음성 인식과 자연어 처리 사례는 주변에서 다양하게 찾아볼 수 있다.

인공지능 스피커



사람이 한 말을 알아듣고, 이에 적합한 반응을 한다. 노래를 추천하거나 날씨를 알려 주기도 한다. 이를 위해서는 음성 인식과 더불어 사람이 한 말을 이해할 수 있어야 한다.

영상 자막 생성



영상에 음성을 인식하여 텍스트로 생성하거나 다른 언어로 번역하여 나타낸다. 영상에 포함된 음성을 인식하고 이 내용을 자동으로 번역하여 문장을 생성한다.

기계 번역



컴퓨터를 사용하여 한 언어를 다른 언어로 번역한다. 자연어 처리 초기부터 많은 연구가 진행되어 상당한 수준의 번역 결과를 제공한다.

감정 분석



텍스트를 분석하여 글에 포함된 감정 상태를 파악한다. 예를 들어 특정 글이 긍정적인지, 부정적인지, 중립적인지를 확인할 수 있다.

검색 엔진



사용자의 검색 문장에 적합한 결과를 보여 주기 위해 자연어 처리 기술을 이용한다. 초기에는 단어 위주였으나, 최근에는 문장을 이해하고 사용자가 입력하는 문장의 추천어까지 제공하고 있다.

텍스트 생성



자연어를 이해하는 인공지능은 주어진 조건이나 정보를 바탕으로 새로운 텍스트를 생성할 수 있으며, 사람이 쓴 것 같은 자연스러운 이야기를 만들어 준다.

[그림 II-59] 음성 인식과 자연어 처리의 예

시멘트리스(Semantris)는 구글 인공지능 연구 팀이 만든 단어 연상 게임이다. 인공지능을 이용하여 단어 사이의 의미 연결을 인식하고 이에 따른 두 가지 방식의 게임을 제공한다. 이를 위해 구글은 단어 사이의 관계를 인공지능이 학습하도록 자연어 처리 기술로 게임을 구현했으며 인공지능은 학습을 토대로 사용자가 입력한 단어에서 관계를 파악하고 게임을 진행한다.

- 1 시멘트리스 사이트에 접속하여 단어 연상 게임을 해 보자.

시멘트리스 사이트: <https://research.google.com/semantris/>



- 2 활동 안내 방법을 참고하여 단어 연상 게임을 진행해 보자.

아케이드 모드	블록 모드
화면에 화살표로 표시된 단어와 관련된 단어를 입력하면, 해당 단어가 맨 아래로 이동하면서 점수를 얻는다.	화면에 나타난 단어와 연관된 단어를 입력하면, 인공지능이 그 단어와 관련된 단어의 모든 블록을 없애고 사라진 블록 수만큼 점수를 얻는다.

- 3 같은 단어에 대해서 친구들은 어떠한 단어를 선택했는지 이야기해 보고, 인공지능은 어떻게 단어들의 관계를 알고 있는지 이야기해 보자.

내가 김밥 가게 사장이라면 김밥을 얼마에 팔아야 할까

소비자 물가 지수(CPI)는 각 가정에서 구입하는 생필품과 서비스의 가격 변동을 알아보기 위해 작성하는 통계이다. 김, 쌀, 단무지, 달걀 등의 소비자 물가 지수를 이용해 한국인의 소울푸드인 김밥의 소비자 물가 지수를 예측하는 모델을 구현해 보자.



단계 1 문제 정의하기

내가 김밥 가게 사장이라면 김밥을 얼마에 팔아야 할까?



통계포털
kosis.kr

단계 ② 데이터 수집 및 전처리하기

- ① 통계 포털에서 ‘품목별 소비자 물가 지수’를 검색한다.
- ② 조회 설정 및 행렬 전환 메뉴를 이용해 1995년부터 2022년까지 전국의 농축수산물 소비자 물가 지수 데이터를 다운로드한다.

💡 파일명: consumer price index.csv

Figure 1 shows four sequential screenshots of a software interface, likely a file management or database application, illustrating the '이동' (Move) process. The interface is in Korean.

- Screenshot 1:** Shows a '이동' (Move) dialog box. The '이동' (Move) button is highlighted in blue. The '이동' (Move) button is highlighted in blue.
- Screenshot 2:** Shows the '이동' (Move) dialog box. The '이동' (Move) button is highlighted in blue. The '이동' (Move) button is highlighted in blue.
- Screenshot 3:** Shows the '이동' (Move) dialog box. The '이동' (Move) button is highlighted in blue. The '이동' (Move) button is highlighted in blue.
- Screenshot 4:** Shows the '이동' (Move) dialog box. The '이동' (Move) button is highlighted in blue. The '이동' (Move) button is highlighted in blue.

- ③ 구글 코랩에 ‘consumer price index.csv’ 파일을 업로드하고, 데이터 프레임(df)을 생성한다.

```
01 import pandas as pd
02 df= pd.read_csv(
03     'consumer price index.csv')
04 df.head()
```

실행 결과								
구분	연월	출발	출발 시간	출발 시간	출발 시간	출발 시간	출발 시간	출발 시간
1	1월	1997	11:00	11:00	11:00	11:00	11:00	11:00
2	2월	1997	11:00	11:00	11:00	11:00	11:00	11:00
3	3월	1997	11:00	11:00	11:00	11:00	11:00	11:00
4	4월	1997	11:00	11:00	11:00	11:00	11:00	11:00

- ④ 김밥과 김밥에 들어가는 재료 속성들만으로 새로운 데이터 프레임(df1)을 생성한다.

```
01 df1 = df[['김', '단무지', '쌀', '당근', '달걀', '시금치', '김밥']]
02 df1.info()
```

- ⑤ 결측치를 확인한다.

```
01 df1.isnull().sum()
```

- ⑥ 여러 속성 간의 산점도를 그려 속성 간의 관계를 파악해 보자.

💡 matplotlib 그래프의 한글이 깨지지 않게 하기 위해 koreanize-matplotlib를 설치한다.


```
01 !pip install koreanize-matplotlib
```



```

▶ 01 import seaborn as sns
02 import matplotlib.pyplot as plt
03 import koreanize_matplotlib
04 sns.pairplot(df1)

```




⑦ 속성 간의 상관계수를 그려 시각화한다. 김밥과 재료들은 어떤 상관관계가 있을까?

```

▶ 01 sns.heatmap(df1.corr(), annot=True, cmap='Set1')

```



단계 ③ 모델 생성 및 평가하기

1. 단순 선형 회귀

달걀 소비자 물가 지수에 따른 김밥 소비자 물가 지수 예측하기

① 독립 변수(X, 달걀), 종속 변수(y, 김밥)를 선정한다.

```

▶ 01 import numpy as np
02 X = df1.loc[:, '달걀'].values.reshape(-1, 1)
03 y = df1.loc[:, '김밥'].values

```

② 단순 선형 회귀 모델을 생성하고 선형 회귀식을 구한다.

```

▶ 01 from sklearn.linear_model import LinearRegression
02 lr = LinearRegression()
03 lr.fit(X, y)
04 print(lr.coef_, lr.intercept_)

```

③ 달걀에 따른 김밥 소비자 물가 지수를 예측하고, 결정계수를 구한다.

```

▶ 01 print(lr.score(X, y))
02 plt.scatter(X, y, color='blue')
03 plt.plot(X, lr.predict(X), color='red')
04 plt.xlabel('달걀')
05 plt.ylabel('김밥')
06 plt.show()

```

달걀 외에 다른 재료를 이용해 단순 선형 회귀 모델을 구현해 보세요.

2. 다중 선형 회귀

독립 변수(X)를 김, 단무지, 쌀, 당근, 시금치로 선정하고, 종속 변수(y)를 김밥으로 선정해 다중 선형 회귀 모델을 생성해 보자.

```

▶ 01 X2 = df1.iloc[:, 0:6].values
02 y2 = df1.iloc[:, 6].values

```

- 다중 선형 회귀식을 구해 김밥 소비자 물가 지수에 가장 영향을 많이 주는 재료들을 찾아보자.
- 단순 선형 회귀와 다중 선형 회귀 결정계수를 비교해 보자.
- 김밥 외에 다른 품목으로 소비자 물가 지수를 예측하는 선형 회귀 모델을 구해 보자.




개념 정리

01. 기계학습과 데이터

- 데이터의 유형: 정형 데이터, 비정형 데이터
- 데이터 수집 방법: 공공 데이터 수집, 민간 데이터 수집, 직접 수집
- 데이터 수집 시 고려 사항: 데이터 편향성, 공정성, 정당성 등 주의

개? 고양이?



02. 기계학습 알고리즘

- 지도학습: 입력 데이터와 해당 입력에 대한 정답(레이블)을 가지고 모델을 학습하는 방식 (예) 회귀, 분류
- 비지도학습: 레이블이 주어지지 않은 데이터로부터 유용한 규칙이나 패턴을 찾는 방식 (예) 군집(k-Means), 연관 규칙
- 강화 학습: 시행착오를 통해 학습하는 방식으로 보상을 최대화하는 방향으로 학습하면서 목표를 찾아가는 방식

03. 인공 신경망과 딥러닝

- 인공 신경망: 뉴런과 시냅스의 작동 원리를 모방한 모델로 딥러닝 분야에서 사용됨.
- 퍼셉트론: 인공 신경망의 기본 구성 요소
- 다층 신경망: 여러 퍼셉트론을 연결한 신경망
- 딥러닝: 심층 신경망을 기반으로 대량의 데이터를 학습하는 기술

- 컴퓨터 비전: 이미지와 비디오에서 사물을 인식하는 분야. 합성곱 신경망
- 자연어 처리: 사람의 언어인 자연어를 이해하고 처리하는 분야
- 음성 인식: 음성 입력을 텍스트 데이터로 변환해 자연어 처리 모델에 전달하는 분야
- 생성형 AI: 텍스트, 이미지, 음성, 영상과 같은 콘텐츠를 생성, 변환하는 분야

실력 확인

1 인공지능으로 해결하기에 적합한 문제가 아닌 것은?

- ① 계산기로 결과 출력
- ② 개와 고양이 얼굴 분류
- ③ 글자를 입력하여 이미지 생성
- ④ 감기 환자와 정상인의 질병 분류
- ⑤ 기후 변화에 따른 해수면 상승 예측

2 다음은 펭귄 데이터에서 속성 간의 관계를 시각화한 것이다. 펭귄의 체질량을 예측하는 문제 해결을 위해 핵심 속성을 추출하려고 히트맵으로 나타내었다. 히트맵을 보고 알 수 있는 사실은?




- ① 부리 깊이와 체질량은 상관관계가 있다.
- ② 부리 길이와 부리 깊이는 강한 양의 상관관계가 있다.
- ③ 부리 길이가 증가할수록 날개 길이는 감소하는 경향이 있다.
- ④ 체질량에 가장 영향을 많이 주는 핵심 속성은 부리 길이이다.
- ⑤ 부리 깊이가 증가할수록 체질량이 증가하는 양의 상관관계가 있다.

3 데이터에 결측치가 있을 경우 결측치를 처리해야 한다. 결측치가 있는 행을 삭제하는 명령어는?

- ① df.head() ② df.info()
- ③ df.describe() ④ df.isnull.sum()
- ⑤ df.dropna(axis=0)

4 김 소비자 물가 지수에 따른 김밥 소비자 물가 지수를 예측하는 선형 회귀 모델이다. 다음 설명 중 옳은 것은?



- ① 다중 선형 회귀 모델이다.
- ② 독립 변수는 김밥, 종속 변수는 김이다.
- ③ 선형 회귀식은 '김 = 0.874 × 김밥 - 14'이다.
- ④ 이 모델은 김 소비자 물가 지수로 김밥 소비자 물가 지수를 예측하는 데 설명력이 낮다.
- ⑤ 선형 회귀에서 독립 변수가 종속 변수의 변동을 얼마나 설명하는지를 나타내는 값을 결정계수라고 한다.

5 군집 모델에 대한 설명으로 옳은 것은?

- ① 지도학습 방법 중 하나이다.
- ② 서로 유사한 데이터끼리 묶어 준다.
- ③ 결정트리가 대표적이다.
- ④ 연속적인 수치를 예측할 때 주로 사용한다.
- ⑤ 목둘레로 허리둘레를 예측할 때 사용하는 모델이다.

6 인공 신경망에 대한 설명으로 옳은 것을 두 가지 고르시오.

- ① 퍼셉트론은 비선형 문제를 해결할 수 있다.
- ② 퍼셉트론에서 활성화 함수를 통과하면 0이다.
- ③ 다층 신경망은 여러 개의 퍼셉트론을 연결한 구조이다.
- ④ 입력층과 은닉층 사이에 있는 층을 출력층이라고 한다.
- ⑤ 심층 신경망은 여러 개의 은닉층을 가진 구조이다.


7 컴퓨터 비전에서 이미지 분류 모델로 많이 사용되는 신경망 모델은?

- ① CNN ② GAN
- ③ LSTM ④ NN
- ⑤ RNN

스스로 점검하기

기계학습을 적용할 문제를 정의하고, 문제 해결에 필요한 데이터를 선정하여 수집할 수 있는가?	😊 😊 😊	60쪽
수집한 데이터를 가공하여 핵심 속성을 추출할 수 있는가?	😊 😊 😊	60쪽
문제 해결에 적합한 기계학습의 유형과 알고리즘을 선정할 수 있는가?	😊 😊 😊	88쪽
훈련 데이터를 이용하여 학습을 진행하고, 테스트 데이터를 사용하여 성능을 평가할 수 있는가?	😊 😊 😊	88쪽
인공 신경망과 딥러닝의 특성에 대한 이해를 바탕으로 활용 분야를 탐색할 수 있는가?	😊 😊 😊	126쪽
딥러닝을 활용하여 실생활 및 다양한 학문 분야의 문제를 해결하고, 성능을 평가할 수 있는가?	😊 😊 😊	126쪽





인공지능의 사회적 영향

01 인공지능의 발전과 사회 변화

02 인공지능 윤리

이 단원을 배우고 나면

인공지능의 발전에 따른 인간의 삶과 진로의 변화를 탐색하고, 인공지능의 다양한 측면에 대한 비판적인 자세를 바탕으로 인공지능과 관련된 윤리적 문제에서 가치관을 형성할 수 있다.





동영상

<https://dtqr.kr/3EBhuQj>





- 인공지능의 발전으로 인한 사회 변화를 살펴보고, 인공지능으로 해결할 수 있는 사회적 문제를 분석할 수 있다.
- 인공지능에 의해 변화하는 인간의 삶과 직업의 양상을 이해하고 진로를 탐색할 수 있다.

인공지능의 발전과 사회 변화

학습 요소

인공지능과 사회 변화, 인공지능과 사회적 문제, 인공지능과 진로



1 인공지능과 사회 변화

방대하고 복잡한 데이터를 처리하고 분석할 수 있는 인공지능 기술의 발달은 의료, 금융, 예술 등 다양한 분야에 폭넓게 적용되면서 우리 사회에 많은 변화를 가져왔다. 인공지능은 우리의 삶을 더 편리하고 효율적으로 만들어 주는 중요한 역할을 하고 있으며 앞으로 더욱 확대될 것이다. 다음 사례로 인공지능이 우리 사회에 어떤 변화를 가져왔는지 살펴보자.

사례 1

인간과 인공지능의 협업

빅데이터를 기반으로 한 인공지능이 환자의 의료 데이터 분석이나 정밀한 수술과 같은 업무를 보조한다. 또한 환자가 인지하지 못하고 있던 질병을 조기에 발견함으로써 의사는 환자와의 상담에 더 많은 시간을 할애할 수 있다.



새로운 직업이 등장하거나 기존의 업무가 변화하는 등 직업 세계에도 많은 변화가 나타나요. 인공지능과의 협업도 활발해지고 있어요.



의료 분야 외에 사람과 인공지능이 협업할 수 있는 분야는 무엇이 있을지 알아보자.

사례 2

업무의 자동화로 인한 생산성 향상

인공지능을 이용한 자동화는 반복적이고 노동 집약적인 업무를 처리한다. 사람의 업무가 단순히 인공지능으로 대체되는 것이 아니라 사람은 더 가치 있는 일에 집중할 수 있고, 자동화·지능화된 인공지능은 산업 분야의 생산성 향상, 비용 절감과 같은 경제적 가치 창출을 돕는다.



자동화 반복되는 작업을 사람의 개입 없이 기계나 프로그램이 스스로 할 수 있게 만드는 것

지능화 기계나 시스템에 사람처럼 생각하고 판단하는 능력을 부여하여 스스로 문제를 해결할 수 있게 만드는 것

 우리 주변에서 인공지능으로 자동화된 업무는 무엇이 있을지 찾아보자.

사례 3

개인 맞춤형 서비스의 확산

빅데이터와 인공지능의 발전으로 우리는 개인 데이터에 기반한 맞춤형 서비스를 실생활에서 쉽게 접할 수 있다. 온라인 쇼핑 사이트에서는 사용자가 자주 검색하는 단어나 과거 방문 기록 등의 데이터를 활용해 사용자가 좋아할 만한 제품이나 광고를 추천해 준다.



 영상 시청 사이트는 나의 과거 시청 영상 정보를 이용하여 맞춤형 영상을 추천해 준다. 동영상 시청 사이트에 접속하여 '인공지능'과 관련된 동영상이 추천되도록 만들어 보자.

사례 4

새로운 콘텐츠를 생성하는 인공지능

컴퓨터와 대화하듯이 원하는 것을 말하면 인공지능은 학습한 데이터를 기반으로 적절한 답변을 제공한다. 생성형 인공지능의 발전으로 글을 쓰거나 그림을 그리는 데 드는 시간을 크게 줄일 수 있게 되었다.

 실제로 존재하지 않는 사람의 얼굴을 생성하는 인공지능을 체험해 보자.

Random Face Generator

 <https://this-person-does-not-exist.com/en>

2018년 Nvidia(엔비디아)에서 개발한 StyleGAN 신경망을 이용하여 만들어진 가상 얼굴 생성기이다. 원하는 성별, 나이, 민족성을 입력하면 무작위로 얼굴을 생성해 낸다.



 사람의 얼굴을 GAN이 생성한 예

인공지능과 사회적 문제 해결

우리 사회에는 단순한 문제에서부터 인간이 오랫동안 해결하지 못한 어려운 문제에 이르기까지 다양한 문제가 존재한다. 인공지능 기술이 발전함에 따라 점차 복잡해지는 사회 문제를 인공지능을 이용하여 해결하려는 시도가 이루어지고 있다.

인공지능을 활용한 상황 인지, 실시간 위험 탐지, 정밀 진단과 같은 기술은 고령화 시대의 노인 돌봄, 자연재해 및 산업 재해, 범죄 예방과 같은 다양한 사회 문제를 해결하는 데 기여할 수 있다. 또한 데이터 분석 및 예측 기술은 사회의 교육 격차, 환경, 식량, 교통 문제 등을 해결하는 데 활용될 수 있다.


인공지능을 인간과 사회에 이로운 방향으로 활용하려고 국가, 기업, 학계 차원의 노력이 이루어지고 있으며, 공익을 위한 인공지능 프로젝트 및 캠페인 등이 진행되고 있다.

사례


사회적 문제를 해결하기 위한 협력



흑등고래는 플라스틱 오염, 서식지와 먹이의 상실, 기후 변화, 선박과의 충돌 등 인간의 여러 활동으로 생존을 위협받고 있다. 이러한 흑등고래를 보호하기 위해 NOAA(National Oceanic and Atmosphere Administration 미국 국립 해양 대기국)와 구글의 과학자들이 협력하였는데, 이들은 14년 동안 수집한 187,000시간 이상의 음향 데이터로 흑등고래의 울음소리를 인식할 수 있는 모델을 구축했다. 이 시스템으로 고래에 대한 종합적인 분석 및 흑등고래의 이동을 확인하였고, 새로운 흑등고래 서식지를 발견하여 보호 구역으로 지정할 수 있었다.



스펙트로그램으로 나타난 흑등고래의 울음소리



새로 발견된 흑등고래의 서식지 시각화 결과

음향 데이터를 활용해 확인한 고래의 이동 경로를 사이트에서 확인해 보자.

<https://apps-nefsc.fisheries.noaa.gov/pacm/#/humpback>

다음은 현재 우리 사회에서 나타나는 주요 사회적 문제이다. 이 문제를 해결하기 위해, 먼저 다양한 인공지능 기술을 살펴보고, 이 기술들을 사회적 문제 해결에 어떻게 활용할 수 있는지 생각해 보자.

사회적 문제	자연재해·산업 재해	개인 정보 유출	정서 불안
	저출산·고령화	기후 변화	가짜 뉴스
	환경 오염	감염병 확산	교육 격차

1 다양한 인공지능 기술을 살펴보고, 우리가 현재 직면하고 있는 사회적 문제를 어떻게 해결할 수 있을지 생각해 보자.

인공지능 분야	기계학습	컴퓨터 비전	자연어 처리	음성
인공지능 기술	분류 예측 군집	객체 탐지 객체 세그멘테이션 제스처 인식 얼굴 탐지	언어 탐지 텍스트 분류 텍스트 요약 기계 번역 텍스트 생성	음성 인식 음성 생성

2 아래 사례와 같이 인공지능 기술이 활용될 수 있는 서비스를 한 가지 정하고, 그 서비스가 필요한 대상, 인공지능 분야, 사례를 조사해 보자.

서비스명	돌봄 인공지능 스피커	
대상(문제)	노인, 몸이 불편한 사람	
인공지능 분야(기술)	음성 인식(오디오 분류), 자연어 처리, 음성 생성	
사례	인공지능 스피커가 말동무가 되어 주고, 필요한 시간 간에 약 복용 체크, 긴급 서비스 지원함.	
서비스명	스마트 인공지능 드론	
대상(문제)	자연재해	
인공지능 분야(기술)	컴퓨터 비전(객체 탐지, 객체 세그멘테이션)	
사례	드론에 컴퓨터 비전 기술을 탑재해서 화재를 감지 하면 바로 매체가 신속하게 알려 줌.	
서비스명	시각 장애인 인공지능 안경	
대상(문제)	시각 장애인	
인공지능 분야(기술)	컴퓨터 비전(객체 탐지), 음성 생성	
사례	시각 장애인용 인공지능 안경이 주변의 사물과 장 애클을 탐지하여 특정 신호나 음성으로 시각 장애 인의 이동을 보조함.	

2 인공지능과 진로

사람과 인공지능의 협업, 업무의 자동화와 같이 우리 사회에 많은 변화를 가져 온 인공지능은 개인의 삶과 의사 결정 과정, 직업의 양상에도 상당한 영향을 미치고 있다.

1 인공지능과 개인의 삶

인공지능은 반복적이거나 획일화된 작업을 자동화하여 사람을 지원하고, 때로는 업무에 필요한 상황과 데이터 분석, 학습 결과를 기반으로 의사 결정을 내리기도 한다. 우리는 인공지능이 하는 일을 이해하고 관리 및 조정할 수 있어야 하며, 변화하는 기술을 활용할 수 있어야 한다. 또한 인공지능의 처리 결과를 고려하여 최종적인 의사 결정을 수행하게 된다. 이렇게 인공지능은 사람을 도와 사회의 다양한 문제를 해결할 뿐만 아니라 더 가치 있고 창의적인 새로운 일을 할 수 있게 도움을 주고 있다.

사례

대형 물류 센터에 도입된 인공지능 로봇

인공지능 로봇은 무거운 물건을 통째로 이동시킬 수 있으며, 물건의 위치와 이동 경로를 스스로 판단할 수 있다. 따라서 과거 물류 센터에서 물건을 옮기던 작업자는 로봇을 관리하고 작업장의 전반적인 상황을 관리·감독하는 일에 집중하여 물류 작업의 효율성과 정확성을 높일 수 있다.



2 인공지능 시대의 직업

인공지능 기술이 발전함에 따라 직업 분야에도 많은 변화가 나타나고 있다. 인공지능을 연구·개발하는 직종이나 직업은 점차 역할이 중요해진다. 여러 직업 분야 간 융합이 이루어지고, 인공지능과의 협력, 로봇 및 디지털 지식의 활용이 중요해지면서 정보 기술을 활용하고 관리하는 다양한 직업이 나타날 것이다.



인공지능을 활용하고 인공지능과 협업하려는 자세를 가지는 것이 중요해요.

[표 Ⅲ-1] 인공지능과 직업의 유형 및 사례

직업 유형	연구 인공지능 기술을 연구·개발하는 직업	융합과 적용 인공지능 기술을 적용하여 새로운 제품과 서비스를 만드는 직업	활용 인공지능 기술과 서비스를 자신의 업무에 활용하는 직업
사례	 자율주행 소프트웨어 공학자 도로 상황의 다양한 객체를 자동으로 인식하는 알고리즘을 연구한다. 자연어 처리 연구원 언어 생성 모델을 연구·개발한다.	 자율주행 시스템 설치 기술자 자율주행 기술을 기존 차량에 설치하고 유지·보수하며 개별 운전자의 상황에 맞게 조정한다. 자연어 검색 서비스 기획·개발자 언어 생성 모델을 적용한 대화형 검색 서비스를 개발한다.	 택배 운송원 자율주행 기능의 도움을 받아 장거리 택배를 안전하게 실행한다. 고객 상담원 챗봇이나 음성 비서와 같은 인공지능으로 고객의 문의 내용을 수집하고 분류한다.

활동 2

지진 전문 인공지능 기자 '퀘이크봇'

조사 수집 분석

‘퀘이크봇’이 작성한 기사를 확인해 보고, 인공지능 기자와 인간 기자의 역할을 생각해 적어 보자.



미국 LA 타임스에서 개발한 지진 전문 인공지능 기자 ‘퀘이크봇’(Quakebot)은 자동화된 알고리즘을 사용하여 미국 지질조사국(USGS)에서 보고하는 지진의 초기 기사를 자동으로 작성한다. 이후, 인간 기자나 편집자는 로봇이 작성한 기사를 검토하고 뉴스에 보도한다. 이는 지진 상황을 빠르게 전달하여 사람들이 적절한 대응으로 피해를 줄이는 데 큰 역할을 한다.

인공지능 기자의 역할

인간 기자의 역할

 latimes.com/people/quakebot

3 인공지능 시대의 진로 탐색

다가올 인공지능 시대를 대비하여 우리는 어떤 준비를 해야 할까? 인공지능 기술과 관련해 새로운 연구·개발 분야가 등장하여 진로 탐색의 분야가 다양해지고 있다. 따라서 인공지능 기술에 관심을 가지고 동향을 살펴보아야 한다.

다양한 직업에서 인공지능 기술을 어떻게 활용하고 인공지능과 어떻게 협업할 수 있을지 살펴보자.



개발자 인공지능으로 프로그램 코드에서 오류를 찾거나 최적화하는 작업으로 개발 시간을 단축한다.



간호사 입원 환자를 돌보며 수행하는 업무 내용을 음성으로 기록하는 인공지능으로 업무의 효율을 높이고 기록 누락을 방지한다.



미용사 인공지능으로 고객의 시술 데이터(모발과 두피 상태, 시술 색깔, 컬 사이즈, 같은 연령 고객 등)를 기반으로 새로운 헤어 스타일을 추천한다.



소방관 화재 발생 시 연기로 앞이 보이지 않는 공간에서 여러 가지 센서를 장착한 인공지능 로봇으로 구조할 사람의 위치를 파악해 빠르게 구조한다.



건축가 인공지능으로 건축 물량 데이터를 검증하고, 이미지 처리를 활용한 CCTV 현장 관리로 안전사고를 예방한다.



화학자 여러 물질의 화학 반응을 시뮬레이션하고 화학 반응의 경로를 자동으로 탐색하는 인공지능으로 시간과 비용을 절약하고 정확한 화학 반응을 예측한다.



경찰관 인공지능으로 교통사고, 인구, 기상, 실업률, 고용률과 같은 데이터를 분석하여 범죄 발생 가능성이 높은 지역의 순찰을 강화한다.



요리사 수십 년 이상 수집된 재료 데이터를 학습해 다양한 맛의 조합을 제안하는 인공지능의 도움으로 새로운 요리법을 개발한다.

[그림 Ⅲ-1] 다양한 직업에서 인공지능과의 협업



1 일상생활에서 내가 체험한 인공지능 기술은 무엇이 있는지 생각해 보자.

학교에서의 인공지능	가정에서의 인공지능	여가 공간에서의 인공지능
예 자연어 처리: 자료 조사에 필요한 영어 문서를 읽기 위해 번역 프로그램을 사용했다.	예 음성 인식과 자연어 처리: 등교 준비를 하면서 인공지능 스피커에 오늘의 날씨와 주요 뉴스를 물어보았다.	예 추천 시스템: 자기 전 여가 시간에 ○○○가 추천해 주는 영상을 시청하였다.

2 미래의 나의 직업에서 인공지능을 어떻게 활용할 수 있을지 희망 직업 포트폴리오를 작성해 보자.

핑거형 비주얼 씹킹

- ① A4 용지에 자신의 손을 놓고 따라 그린다.
- ② 손바닥에 희망 직업을 설명할 수 있는 문구를 쓴다.
- ③ 엄지손가락: 미래 직업이 하는 일(키워드)을 그림이나 글로 간략히 설명한다.
- ④ 집게손가락: 미래 직업에서 인공지능의 도움을 받을 수 있는 일을 그림이나 글로 간략히 설명한다.
- ⑤ 가운데손가락: 미래 직업에서 내가 할 수 있는 일을 그림이나 글로 간략히 설명한다.
- ⑥ 약손가락: 미래 직업에 필요한 적성이나 흥미를 찾아보고, 그림 및 글로 간략히 설명한다.
- ⑦ 새끼손가락: 미래 직업과 관련한 학과 및 자격을 찾아보고, 그림 및 글로 간략히 설명한다.



아래의 사이트를 참고하여 내용을 추가 혹은 보완해 보자.

- CLOVA X(<https://clova-x.naver.com/>)
- 구글 제미니(<https://gemini.google.com/>)
- 챗GPT(<https://chat.openai.com/>)
- 뤼튼(<https://wrtt.ai/>)
- 커리어넷(<https://www.career.go.kr/>)
- My next move(<https://www.mynextmove.org/>)



커리어넷

- 인공지능에 대한 비판적 자세를 바탕으로 인공지능과 인간의 공존 방안을 도출할 수 있다.
- 인공지능의 활용 사례와 윤리적 딜레마 상황을 인공지능 윤리 관점에서 분석할 수 있다.

인공지능 윤리

학습 요소

신뢰성, 공정성, 윤리성, 투명성, 안전성,
책임성, 인공지능 윤리 기준




무엇을 배울까?

인공지능 시스템 도입은 우리의 일상을 편리하게 하지만 의도하지 않은 부작용이 생길 수도 있다. 다음의 사례와 같은 부작용을 최소화하기 위한 방법은 무엇일까?

독거노인의 돌봄 문제를 해결하기 위한 인공지능 스피커가 개인 정보를 유출한다면?



대형 물류 센터에 도입된 인공지능 로봇이 무거운 물건을 운반하다 지나가는 작업자를 다치게 하는 사고가 발생한다면?



인공지능 추천 시스템에만 의존해 이용자가 특정 정보만 접하게 된다면?



1 인공지능의 윤리적 쟁점

인공지능 기술은 사회 여러 분야의 문제를 해결하고 우리 생활을 편리하게 하지만, 원래 목적과 다르게 사용되거나 부작용이 나타나고 있다. 따라서 인공지능을 도입할 때 지켜야 할 사회적 규범과 도덕적 판단 등 인공지능 윤리의 중요성이 주목받고 있다.

인공지능의 윤리적 쟁점을 알고 그에 따른 역기능을 최소화하여 인공지능과 공존하는 방안을 살펴보자.

인공지능의 6가지 윤리적 쟁점

신뢰성




인공지능 시스템은 오류 가능성이 항상 있으며, 작은 오류만으로도 심각한 문제를 일으키는 경우가 있다.

공정성



인공지능으로 인한 차별을 방지하기 위해 편향되지 않은 데이터와 알고리즘을 사용해야 한다.

윤리성



인공지능 시스템은 도덕적·윤리적으로 옳은 판단을 내려야 한다.

투명성



인공지능 시스템이 사람에게 영향을 미치는 결정 과정을 투명하게 설명하여야 한다.

안전성



'딥페이크' 기술, 가짜 뉴스·음란물에 악용

인공지능 시스템이 외부의 공격이나 위협에 대처할 수 있고, 인간에게 해를 끼치지 않아야 한다.

책임성



인공지능과 관련된 문제 상황에 책임이나 의무를 지려는 태도를 가져야 한다.

1 신뢰성

기계학습 모델은 데이터에 기반하여 만들어지기 때문에 어느 정도의 오류 가능성을 포함하고 있다. 인공지능이 사회의 다양한 분야에서 사람에게 편리함을 제공하는 반면 크고 작은 실수로 인공지능 시스템에 대한 신뢰를 잃고 개인이나 특정 집단에 심각한 피해를 줄 수 있다. 따라서 인공지능을 연구·활용하는 과정에서 신뢰성을 반드시 고려해야 한다.



[그림 Ⅲ-2] 인공지능의 실수로 인한 피해 가능성

2 공정성

공정성 문제가 발생할 수 있는 데이터 속성

인종, 성별, 거주 지역 등이 있다.

데이터 편향성


기계학습 모델을 개발하는 데 사용되는 데이터에 존재하는 편향이다.

알고리즘 편향성

기계학습 알고리즘 자체의 설계 또는 구현에 내재된 편향이다.

사회적 편견이 반영된 부적절한 속성을 사용하거나 데이터의 양이 한쪽으로 치우쳐 균형이 맞지 않는 인공지능이 만들어지면, 특정 집단에 대한 부정확한 결과나 부당한 피해를 초래할 수 있다.

인공지능의 공정성 문제를 해결하기 위해서 인공지능을 개발하고 활용하는 과정에서 인공지능의 작동 원리를 깊이 이해하고, 공정한 속성에 대하여 다양한 집단을 대표하는 데이터를 수집 및 활용해야 한다. 또한 데이터와 알고리즘의 편향을 최소화하여 불공정한 상황을 만들지 않도록 노력해야 한다.



[그림 Ⅲ-3] 편향이 생기는 과정

1 데이터 편향성 문제를 전 세계에 알린 'Gender Shades' 프로젝트에 관해 알아보자.

2018년 MIT 미디어랩의 조이(Joy)는 친구들과 함께 얼굴 인식 시스템을 테스트하던 중 자신의 얼굴이 잘 인식되지 않고, 흰색 마스크를 쓰면 인식이 잘 되는 것을 알게 되었다. 이 일을 계기로 얼굴 인식 인공지능의 편향성을 확인하기 위해 피부의 색과 성별이 다른 1,270개의 얼굴 이미지 데이터를 3개(A, B, C)의 얼굴 인식 시스템에서 얼마나 잘 인식하는지 평가하는 Gender Shades 프로젝트를 실시했다.



<http://gendershades.org/>

(1) 사이트에 접속하여 3개의 인공지능 시스템이 평가한 결과를 보고 분석해 보자.

집단 시스템	어두운 피부의 남자	어두운 피부의 여자	밝은 피부의 남자	밝은 피부의 여자
A 시스템	94.0% 	79.2% 	100% 	98.3%
B 시스템	99.3% 	65.5% 	99.2% 	94.0%
C 시스템	88.0% 	65.3% 	99.7% 	92.9%

(2) 알고리즘의 편향성에 대응한 조이의 노력을 주어진 영상에서 확인해 보고, 내가 만약 이와 같은 경험을 하였다면, 어떻게 대응했는지 생각해 보자.

[Joy Buolamwini: 테드\(TED\) 강연 https://www.ted.com](https://www.ted.com)

(3) 얼굴 인식 인공지능이 활용될 수 있는 분야를 찾아보고, 얼굴 인식 인공지능의 편향 문제가 해결되지 않는다면 어떤 문제가 발생할지 친구들과 토의해 보자.

2 MIT 연구진은 인공지능 노먼(Norman)을 개발하면서 죽음이나 살인과 같은 부정적인 콘텐츠를 학습시키고 데칼코마니 그림에 대해 해석하도록 하였다. 사이트에 접속하여, 같은 그림에 대한 노먼과 일반 인공지능의 해석을 비교해 보자.

<http://norman-ai.mit.edu/>



‘노먼’의 해석
한 남자가 감전되어 사망했습니다.



‘일반 인공지능’의 해석
나뭇가지 위에 앉아 있는 새 떼.



딜레마

두 가지의 선택 사이에서 그 어느 쪽을 선택해도 바람직하지 못한 결과가 나오는 곤란한 상황을 말한다.

인간의 피드백을 활용한 강화 학습(RLHF; Reinforcement Learning from Human Feedback)

모델의 응답 결과를 사람이 평가하고, 평가 결과에 따라 보상을 주어, 이 보상이 최대화되는 방향으로 모델의 동작을 개선하는 기술이다.

3 윤리성

브레이크가 고장 난 자율주행 자동차가 그대로 주행하면 여러 명의 희생자가 발생하고, 핸들을 돌리면 한 명의 희생자가 발생하는 상황이라고 가정해 보자. 자율주행 자동차는 어떤 선택을 내려야 할까? 도덕적 · 윤리적으로 어떤 결정을 해야 하는 난처한 상황을 윤리적 딜레마(dilemma)라고 하는데, 대표적인 예시로 트롤리 딜레마가 있다.

인공지능으로 인한 윤리적 및 사회적 문제에 대응하기 위해 윤리적인 인공지능을 만들려는 노력이 이루어지고 있다. 예를 들어 인공지능 챗봇의 응답 결과에 사람의 평가 결과를 반영하는 인간의 피드백을 활용한 강화 학습(RLHF) 방법이 있다. 윤리적인 인공지능을 만드는 것은 쉽지 않기 때문에, 인공지능을 개발하고 사용하는 인간이 윤리적 책임을 가지고 인공지능을 올바르게 사용하는 것이 중요하다.



활동

4

모럴 머신 프로젝트(Moral Machine Project)

수집 탐색 토의

1 다음 영상을 보고 트롤리 딜레마에 대해 자세히 알아보자.

트롤리 딜레마: EBS <https://www.ebs.co.kr>

어떤 것이 옳다는 정답은 정해져 있지 않지만, 윤리적 딜레마 상황에 대해 논의하여 여러 선택지를 이해하고 사고를 확장할 수 있다.

2 자율주행 자동차의 윤리적 딜레마 상황에 대해 연구한 MIT의 '모럴 머신 프로젝트'에 참여하여 자율주행 인공지능의 윤리적 딜레마 상황에서 스스로 판단을 내려보자.

① '모럴 머신' 사이트에 접속한다.

<https://www.moralmachine.net/hl/kr>

② [시작하기] 버튼을 누르고 13개의 상황을 이해하고 자신의 윤리적 기준에 따라 선택한다.

③ 응답이 끝나면 윤리적 판단의 결과를 친구들과 비교해 본다.



3 모럴 머신 프로젝트는 수많은 사람의 도덕적 판단 기준을 연구할 수 있다는 점에서 의미가 있지만, 수집된 데이터를 비판적으로 생각해 보아야 한다. 아래 질문에 대해 친구들과 토의해 보자.

- 모럴 머신 사이트에서 조사한 응답 데이터를 학습한 자율주행 자동차는 윤리적일까?
- 참가자의 답변은 실제 행동과 항상 동일할까?
- 다수의 사람이 옳다고 하면 진짜 도덕적으로 옳은가?
- 참가자의 판단에 영향을 미치는 요소(문화적 배경 등)가 동일할까?

4 투명성

사용자에게 인공지능의 의사 결정과 그 과정을 설명할 수 없다면 그 인공지능 시스템은 신뢰를 잃을 뿐만 아니라 인공지능과 관련된 사고나 위험이 발생했을 때 책임을 명확히 할 수 없다. 따라서 투명하지 못한 인공지능은 개인 정보 오남용 문제나 인종, 성별과 같은 인공지능 공정성 문제가 뒤따를 수 있다.

인공지능이 투명성을 확보하기 위해서는 다음과 같은 조건이 필요하다.

- 사용자가 사용하는 시스템이 인공지능이라는 것을 알려야 한다.
- 사용자의 정보가 어떻게 사용되는지, 인공지능의 목적이 무엇인지 명확하게 알려야 한다.
- 인공지능 내부에 불필요한 숨김 기능을 보유하지 않아야 한다.
- 인공지능의 의사 결정 과정을 설명할 수 있어야 한다.

기계학습 모델은 방대한 데이터와 알고리즘의 조합으로 예측이나 판단을 내리는데, 사용자가 그 과정을 알기 어려워 블랙박스 모델이라고도 해요.



[그림 III-4] 인공지능의 투명성

활동 5

설명 가능한 인공지능(Explainable AI; XAI)

탐색 분석

설명 가능한 인공지능(XAI)은 인공지능 모델이 어떤 근거로 결론을 도출했는지 명확하게 제시하여, 인간이 쉽게 이해하고 검증할 수 있도록 돕는 기술이다. 마치 판결 과정을 투명하게 공개하는 재판과 비슷하다. 설명 가능한 인공지능이 어떻게 우리 생활에 도움을 줄 수 있을지 생각해 보자.

의료 진단 인공지능	예 암 진단 모델은 암세포를 어떻게 식별했는지, 어떤 특징을 기반으로 판단했는지 등을 설명할 수 있어 의사가 진단의 신뢰도를 높이고, 추가 검사나 치료 계획을 수립하는 데 도움이 된다.
신용 평가 인공지능	
제품 결함 검사 인공지능	
개인 맞춤형 광고 인공지능	

5 안전성

자율성을 가진 인공지능이 잘못된 판단을 내리거나 오작동하지 않도록 인공지능을 안전하게 관리하고 제어할 수 있어야 하며 안전사고에 대한 예측과 대비가 필요하다.

인공지능 시스템은 외부의 악의적인 공격이나 위협에 취약할 수 있다. 딥러닝 모델을 공격하는 방법으로 적대적 패치가 있으며 이미지뿐만 아니라 비디오, 음성을 변조하는 기술도 등장하고 있다. 예를 들어 도로의 정지 표지판에 나방 모양의 패치를 부착했을 때 딥러닝 모델이 이를 ‘속도 제한 80’ 표지판으로 인식하는 연구 결과가 나왔다. 이는 자율주행 자동차의 경우 큰 사고로 이어질 수 있다.

적대적 패치

원래 이미지에 딥러닝 모델의 오작동을 일으키는 작은 이미지 조각을 추가하는 방식이다.

의도적으로 악용된 인공지능

여론 조작, 가짜 뉴스, 필터 버블, 딥페이크 등이 있다.

필터 버블(filter bubble)

정보를 제공하는 사이트가 이용자 맞춤형 정보를 제공하는 과정에서 이용자가 특정 정보만 편식하게 되는 현상이다.



[그림 Ⅲ-5] 인공지능과 안정성

사용자의 편의를 위해 개발된 인공지능도 예상하지 못한 부작용을 일으킬 수 있다. 인공지능의 맞춤형 추천 기술에 의해 사용자는 다양한 콘텐츠를 접할 권리를 잃고, 수많은 콘텐츠 속에서 가짜 콘텐츠를 구분해 내는 데 어려움을 겪게 될 수도 있다.

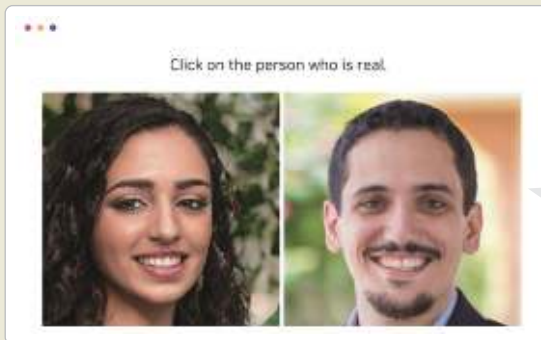


더 알아보기

인공지능의 악용 가능성

딥페이크(deepfake)는 딥러닝과 페이크의 합성어로 인공지능 기술로 가짜 영상이나 이미지, 음성을 실제처럼 보이도록 조작한 이미지 합성 기술이다. ‘Which face is real?’ 사이트에 접속하여 딥페이크를 체험해 보자.

<https://www.whichfaceisreal.com/>



- ① ‘Which face is real?’ 사이트에 접속한다.
- ② 두 개의 사진 중 실제로 존재하는 사람이라고 생각되는 사진을 선택한다.
- ③ 결과를 확인한다.



딥페이크와 같은 인공지능의 의도적인 악용 문제 예방을 위한 방안을 생각해 보자.

6 책무성

자율주행 자동차가 주행 중 적색 신호를 인지하지 못해 사망 사고를 냈을 경우 책임은 누구에게 있을까?

인공지능 기술은 다수의 이해관계가 복잡하게 얽혀 있어 문제가 발생했을 때 그 책임 소재를 명확하게 하기 어렵다. 따라서 인공지능 활용 결과에 대한 책임 소재를 명확히 하고, 발생할 수 있는 문제 예방을 위해 노력해야 한다.

인공지능 챗봇의 윤리적 사례로 인공지능 사회를 구성하는 구성원의 역할과 주의해야 할 점을 알아보자.



[그림 Ⅲ-6] 인공지능의 책무성

[표 Ⅲ-2] 인공지능 사회 구성원의 역할과 윤리적 책임

구분	인공지능 개발자	인공지능 사용자	인공지능 운영·관리자
역할	데이터를 기반으로 인공지능 모델을 설계한다. 인공지능 기술을 이용하여 각종 제품 및 서비스를 연구·설계·제작한다.	인공지능 기술 기반의 제품 및 서비스를 이용한다.	인공지능 기술이 적용된 제품이나 서비스를 시장·공공 서비스로 제공한다.
윤리적 책임	• 사회적 차별 요소(성별, 인종, 종교, 지역 등) 배제 • 윤리적 절차에 따라 기술 개발 • 개발부터 활용까지 전 과정에 대한 책임 공유 • 위급 상황에 대한 구체적인 예측으로 제어 장치와 같은 방안 마련	• 악의적 이용 금지 • 이용자 윤리 책임 숙지 • 개인 정보 및 안전 관련 책임 제기, 정보 공유 및 제도화 요구 • 허용 범위 이상의 자의적 조작 금지	• 편향되지 않은 개발 환경 구성 • 인공지능 기술 활용에 대한 책임·보상 원칙 마련 • 이용자 권리 보장과 위험 요소에 대한 대응 마련 • 위험 정보 공유 • 사용자 정보의 부당한 이용 금지

인공지능 챗봇 '이루다' 개발사가 윤리적 문제를 해결하기 위해 어떤 노력을 했는지 찾아보자.

1 내가 회사의 인사 담당자이고 인공지능 면접관을 개발한다고 가정할 때, 지원자의 어떤 데이터 속성을 수집할지 생각해 보자.

(1) 수집할 데이터 속성을 적어 보자.

(2) 내가 생각한 데이터 속성 중 윤리적으로 문제가 될 수 있는 속성이 있는지 검토해 보자.

2 다음 사례를 읽고, 인공지능 면접관에게서 나타날 수 있는 윤리적 문제를 분석해 보자.

2016년 ○○○은 신입 사원 채용을 위한 서류 평가 과정에서 인공지능 채용 시스템을 개발하였다. 이 시스템은 과거의 입사 지원 서류와 해당 기업에서 높은 성과와 평가를 받은 직원의 데이터를 기반으로 지원자 중 최적의 후보를 선발해 내도록 개발되었는데, 사용 초기부터 여러 문제점이 드러나 결국 폐기되었다.



(1) 문제 상황이 각각 6가지 윤리적 쟁점 중 어디에 해당하는지 생각해 보자.

문제 상황 1

학습한 데이터에는 남성 직원이 여성보다 더 많았고, 이로 인해 남성 지원자가 여성 지원자보다 더 높은 점수를 받는 편향이 발생했다.

윤리적 쟁점:

문제 상황 2

시스템의 추천에는 일관성이 부족했고, 왜 특정 지원자를 추천하는지에 대한 명확한 이유가 부족했다.

윤리적 쟁점:

(2) 윤리적 쟁점이 충분히 고려되지 않은 인공지능 면접관이 일으킬 수 있는 문제점을 생각해 보자. 또, 이 문제를 어떻게 해결할 수 있을지 생각해 보자.

윤리적 쟁점	문제점	해결 방안

생성형 인공지능의 신뢰성

생성형 인공지능(generative AI)은 텍스트, 이미지, 음악 등 다양한 형태의 데이터를 생성할 수 있는 인공지능 기술이다. 이러한 기술은 우리 삶에 큰 혁신을 가져오지만, 동시에 사회·윤리적 문제가 발생할 수 있다. 생성형 인공지능으로 발생할 수 있는 문제와 해결 방안을 살펴보자.

가짜 정보 '할루시네이션'(hallucination)


인공지능 모델이 실제로 존재하지 않거나 검증되지 않은 정보를 그럴듯하게 생성하는 현상이 나타날 수 있다.



실제로 존재하지 않는 '쇼팽의 피아노 소나타 30번'에 대해 그럴듯하게 설명하고 있다.

학습 데이터의 악순환

인공지능(AI) 이미지 생성 프로그램이 만들어 낸 이미지가 인터넷에 너무 많이 확산될 경우 오히려 AI 성능을 해칠 수 있다는 연구 결과가 나왔다.



출처: 일본 이화학연구소, 2022.

저작권 침해

인공지능이 무작위로 수집하여 학습한 데이터의 저작자는 자신의 저작물이 학습에 사용되고 있다는 것을 알지 못 할 수 있다.



'진주 귀걸이를 한 소녀' 페르메이르의 원작(왼쪽)과 인공지능(AI)이 그린 모작(오른쪽)이다.

개인 정보 침해

개인정보보호위원회는 이후 조사 과정에서 오픈 AI에 서면 질문을 보내 총 4차례의 답변을 받았다. 이를 통해 한국 아이피(IP)를 기준으로 한국인 이용자 687명의 이름, 이메일 주소, 결제 장소, 신용카드 번호 네 자리, 만료일 등이 다른 이용자에게 노출됐다는 구체적인 피해 사실을 밝혀냈다.

출처: 한겨레, 2023. 7. 27.

이와 같은 사회·윤리적 문제를 해결하기 위해 유럽 연합(EU)의 인공지능 법안에서는 GPT 모델로 대표되는 파운데이션 모델에 대한 규제가 추가되었다.



파운데이션 모델은 큰 규모의 데이터로 훈련된 모델로 다른 인공지능의 기반이 되는 모델을 의미해요.

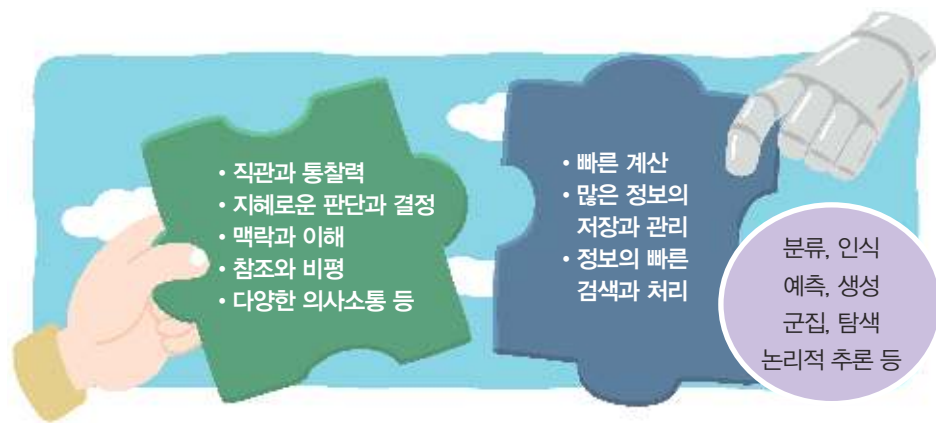
- 생성형 인공지능 파운데이션 모델의 개발자는 콘텐츠가 인공지능에 의해 생성되었음을 사용자에게 알려야 한다.
- 불법 콘텐츠를 생성하지 않도록 모델을 설계 및 개발, 학습해야 한다.
- 학습에 사용되는 데이터가 저작권에 의해 보호되는 경우는 이에 대한 정보를 게시하고 추가적인 투명성 요건을 준수해야 한다.

2 인공지능과 공존을 위한 노력

1 인공지능과의 공존

인공지능으로 인한 자동화는 지적인 작업을 효율적으로 처리하여 우리 사회에 긍정적 변화를 가져올 수 있지만, 이러한 기술의 발전에는 오류와 윤리적·사회적 문제가 있다는 것을 알 수 있다.

인공지능과 공존하기 위해 우리는 인간과 인공지능의 강점을 이해하고, 인공지능을 적절하게 활용하는 방법을 배워야 한다. 그리고 인공지능의 활용에 따른 문제점을 해결하기 위해 적극적으로 노력해야 한다.



[그림 Ⅲ-7] 인간과 인공지능의 협업



인공지능과 협업하면서 이전에는 할 수 없었던 많은 일이 가능해졌어요. 더 정밀하고 우수한 치료를 받을 수 있고, 쉽게 외국인과 대화할 수 있어요.



의사는 많은 인공지능 의료 기기의 도움을 받아 최종적인 판단을 내리게 된다.



사람들은 음성 인식 번역기로 서로의 문화와 생각을 더욱 쉽게 교류하고 이해하게 된다.

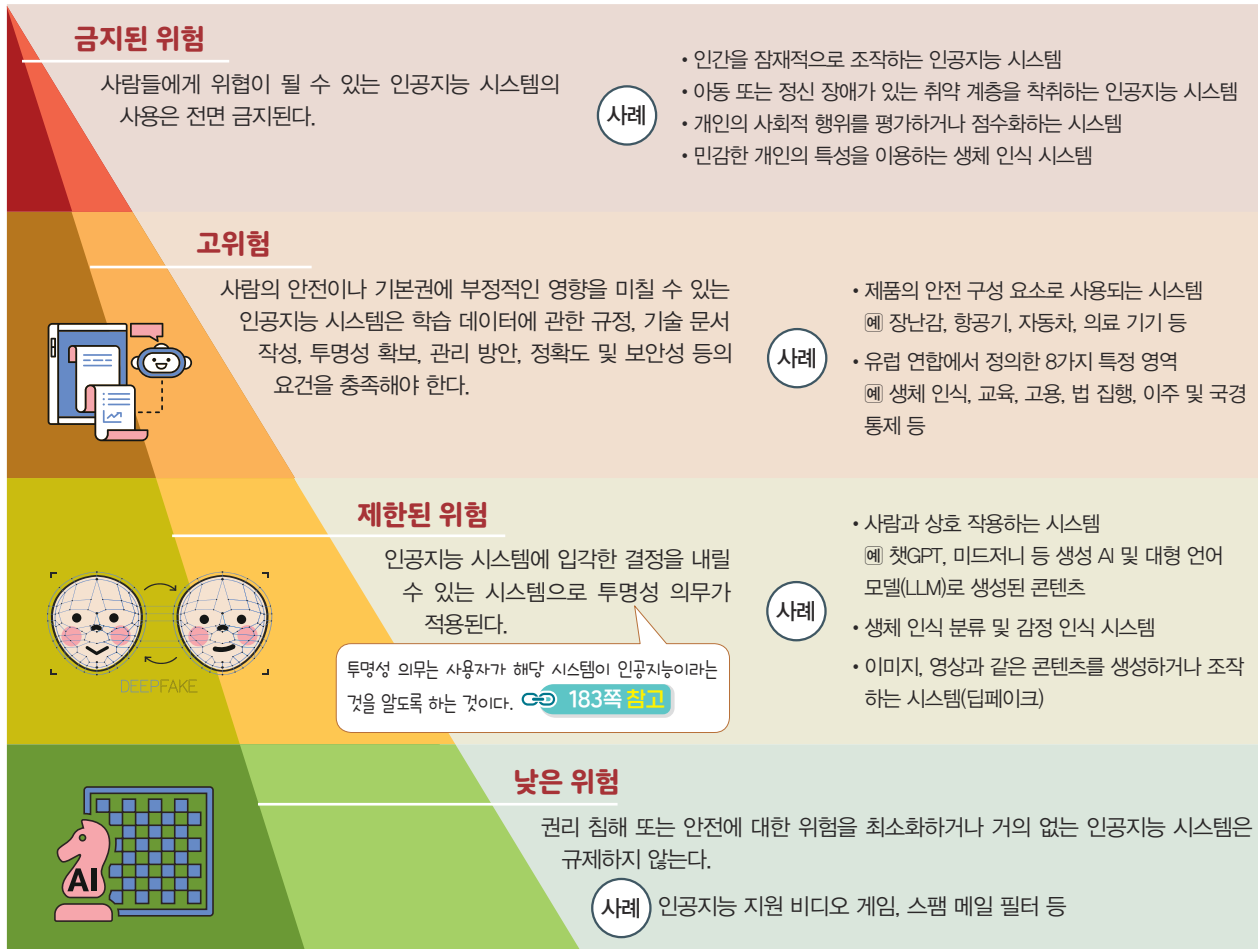
[그림 Ⅲ-8] 인공지능과의 공존의 예

다양한 사람이 공존하는 사회에 사람의 자유와 권리를 보장하기 위해 법이 존재하듯이 인간과 인공지능이 공존하기 위해서는 인공지능과 관련된 법과 제도가 마련되어야 한다. 인공지능과 공존하기 위한 노력의 하나로 국내외에서는 인공지능의 윤리적 기준에 대한 방안을 모색하고 있다. 우리나라와 유럽 연합의 인공지능 윤리 기준을 살펴보자.

2 해외의 인공지능 윤리 기준

유럽 연합에서는 전문가 집단을 구성하여 인공지능 개발과 활용에 윤리적인 원칙과 가이드라인 및 법안을 체계적으로 제시하고 있다. 2021년 유럽 연합 집행위원회에서 발표한 인공지능 법안을 기반으로 2023년 유럽 연합 의회는 이에 대한 수정안을 채택하였다. 유럽의 인공지능 규제 법안에서는 인공지능을 위험 수준에 따라 4단계로 분류하고, 단계에 따라 의무 사항을 규정하고 있다.

최종 법안에는 범용 인공지능 및 챗GPT와 같은 생성형 인공지능 모델에 대한 규제가 추가되었어요.



[그림 Ⅲ-9] 인공지능 위험 수준 4단계(유럽 연합 의회)

활동 7 위험 수준에 따라 인공지능 시스템 분류하기

탐색 분석 토의

다음의 인공지능 시스템이 어떤 위험 수준에 속하는지, 어떤 규제가 적용되는지 친구들과 토의해 보자.

얼굴 인식 CCTV

스팸 메일 필터

딥페이크

대출 신용 평가

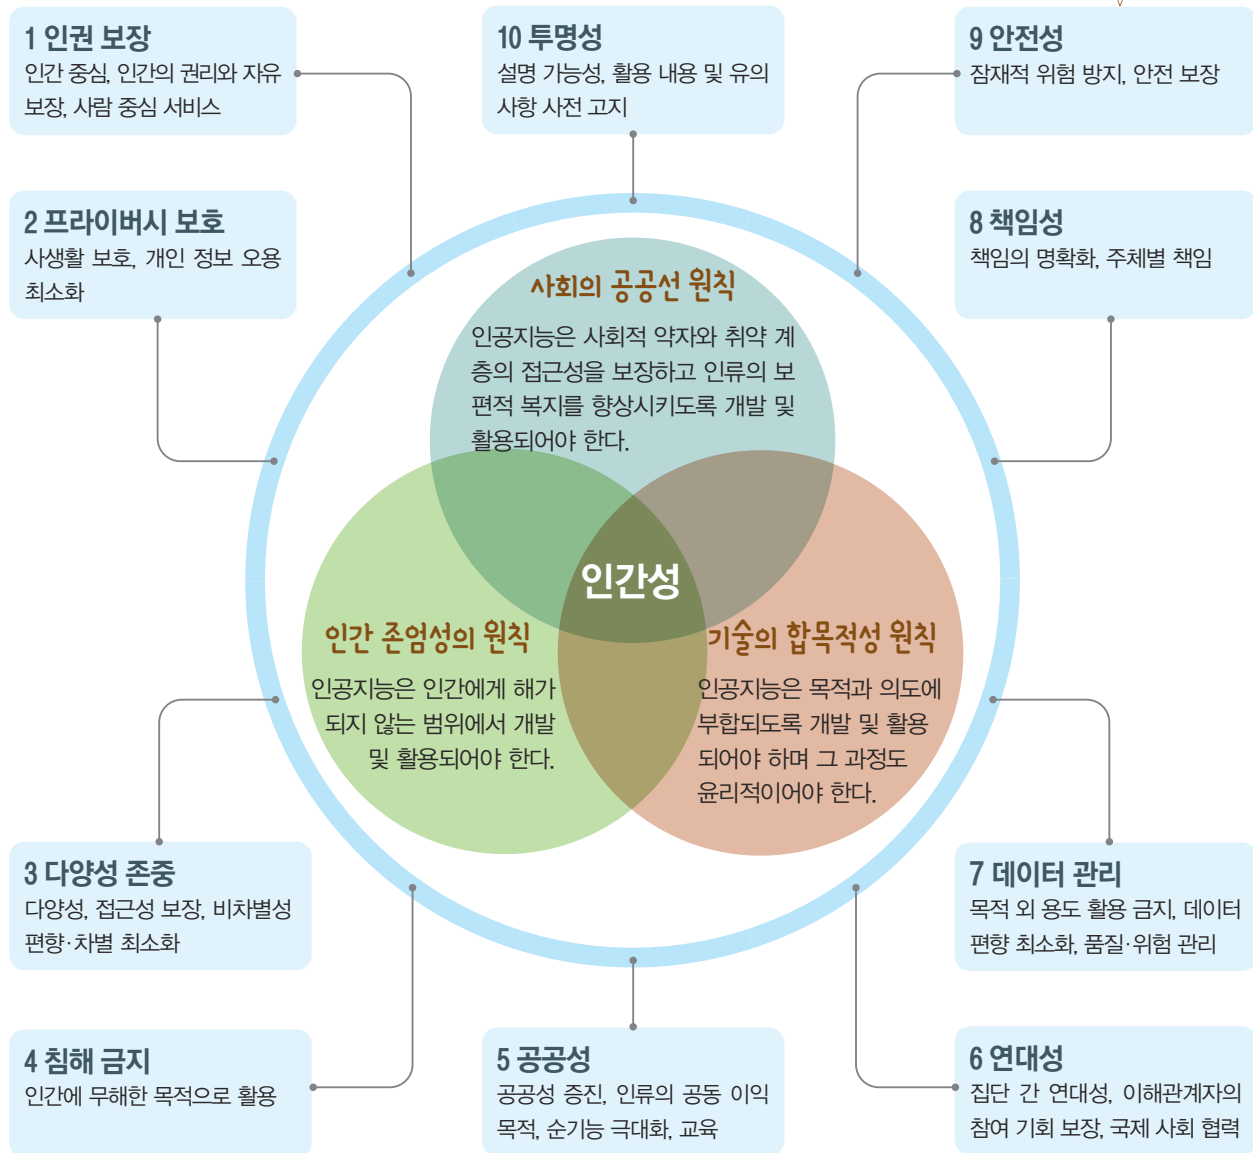
인공지능 바둑 게임

3 국내외 인공지능 윤리 기준

우리나라는 2020년 12월에 바람직한 인공지능 개발·활용 방향을 제시하기 위해 사람이 중심이 되는 「인공지능(AI) 윤리 기준」을 제시하였다. 이 윤리 기준은 ‘인간성을 위한 인공지능’을 위해 모든 사회 구성원이 지켜야 할 3대 원칙과 10대 요건을 제시하고 있다.



과학기술정보통신부 누리집에서 우리나라의 인공지능 윤리 기준에 대해 자세하게 알아보자.
https://bit.ly/MSIT_AI



[그림 Ⅲ-10] 인공지능 윤리 기준 3대 원칙과 10대 핵심 요건(과학기술정보통신부)

자율주행 자동차에서 발생할 수 있는 상황을 분석하고, 「인공지능(AI) 윤리 기준」의 10대 핵심 요건 중 각 상황에서 각각 어떤 요소와 관련 있는지 생각해 보자.

「인공지능(AI) 윤리 기준」의
10대 핵심 요소

- 투명성
- 안전성
- 책임성
- 데이터 관리
- 연대성
- 공공성
- 침해 금지
- 다양성 존중
- 프라이버시 보호
- 인권 보장

「인공지능(AI) 윤리 기준」의 10대 핵심 요건

상황	문제 상황 분석	관련 핵심 요건
운전자의 개인 정보를 수집하고 분석한다.	예 자동차가 수집한 데이터가 유출되는 상황	예 프라이버시 보호 데이터 관리 침해 금지
장애물을 인식하여 비상 제동 장치를 가동한다.		
운전자가 다른 일을 하면서 자율주행을 할 수 있다.		
사물, 사람, 장애물 등을 인식한다.		

위와 같은 문제 상황을 예방하기 위한 방법으로 어떤 방법이 있을지 친구들과 논의해 보자.

음성·영상 합성 기술: 인공지능 인간

인공지능 기술을 활용해 가상 인간을 구현하는 연구가 활발히 진행되고 있다. 딥러닝을 기반으로 역사 속 인물의 표정과 말투를 학습하거나 저화질 이미지를 고화질로 개선하여 동적인 영상을 생성한다. 더불어 가상 인간의 신체 일부를 합성하거나 새롭게 만들어 내는 작업도 이루어지고 있다. 가상 인간에 대한 개인 정보 보호나 초상권, 재산권에 관한 법이나 사회적 논의가 부족한 상황에서 필요한 사회 구성원의 윤리 의식과 책임을 논의해 보자.



한 방송사의 고인이 된 가족과 동료를 가상 현실 콘텐츠로 구현한 다큐멘터리



인공지능 기술로 복원된 안중근 의사와 유관순 열사



인공지능 아나운서 김주하

1 '인공지능을 활용한 가상 인간'의 다양한 사례와 관련하여 이 기술의 긍정적 및 부정적 영향을 친구들과 이야기해 보자.

찬성	반대
100년 전에 살았던 예술가를 만날 수 있다면 유쾌한 경험일 거야. 역사적 사건에 대해 더 깊은 이해를 할 수 있을 것 같아.	가상 인간으로 인해 일자리를 잃는 사람들도 있을 거야. 본인(고인)이 복원되길 원하지 않는 경우라면 비윤리적인 행위야.

2 위와 같은 인공지능 기술을 바람직한 방향으로 개발하고 활용하기 위한 사회 구성원의 윤리적 책임과 유의해야 할 점을 구체적으로 생각하고 적어 보자.

인공지능 개발자	
인공지능 사용자	
인공지능 운영·관리자	

먼저, 인공지능 서비스를 한 가지 선정해 보자.

실생활에서 쉽게 접할 수 있는 인공지능 시스템의 윤리성을 점검해 보자.

인공지능 서비스

1 인공지능 시스템에 사용된 인공지능 기술의 개념과 동작 원리를 찾아보자.

2 이 시스템을 우리나라의 인공지능 윤리 기준의 10대 핵심 요건에 따라 점검해 보자. [190쪽 참고](#)

핵심 요건	예	아니요	해당 없음
인권 보장			
프라이버시 보호			
다양성 존중			
침해 금지			
공공성			
연대성			
데이터 관리			
책임성			
안전성			
투명성			

3 2에서 점검한 내용을 바탕으로 윤리 기준을 충족하지 못하는 핵심 요건을 선정하고 발생 가능한 문제 상황과 유의할 점을 생각해 보자.

핵심 요건	유의할 점

4 유럽 연합(EU)의 인공지능 법안에 따라 인공지능 시스템을 분류하고, 인공지능의 오작동 및 윤리적 문제에 따른 사용자의 피해 정도를 생각해 보자.

유럽 연합의 인공지능 법안에서는 인공지능을 위험 수준에 따라 분류하고 있다.

[189쪽 참고](#)

금지된 위험	고위험	제한된 위험	낮은 위험
☐	☐	☐	☐

인공지능 모델을 만들어 공정성 문제 확인하기

인공지능 모델을 만들 때 특정 집단의 특징을 모두 반영하지 못한 데이터를 학습시키면 결과는 정확하지 않을 수 있다. ‘성별’이라는 데이터 속성 때문에 나타날 수 있는 공정성 문제를 직접 인공지능 모델을 만들어 확인해 보자.

1. 티처블머신으로 남자와 여자를 분류하는 인공지능 모델을 만들어 보자.




활동 방법

준비물: 데스크톱 컴퓨터 또는 노트북, 훈련용 데이터셋, 테스트용 데이터셋

① [훈련용 데이터]에 있는 남자와 여자 사진으로 인공지능 모델을 만들어 보자.



남자, 여자 클래스에 이미지를 업로드하고, 모델을 학습시킨다.





② 테스트용 데이터로 인공지능 모델이 남자와 여자를 제대로 구분하는지 확인해 보자.

테스트 이미지			
모델의 분류 결과	[남자 / 여자]	[남자 / 여자]	[남자 / 여자]

③ 만약 인공지능 모델이 정확하게 구분하지 못한다면 왜 그런지 생각해 보자.

- 내가 만든 인공지능 모델은 남자와 여자를 제대로 구분했는가?

- 인공지능 모델이 남자와 여자를 정확하게 구분하지 못한 이유는 무엇일까?

- 만약 약국에서 여러분이 만든 인공지능 모델로 남자와 여자를 구분하여 약을 처방한다면 어떤 일이 일어날까요?

2. 테스트용 데이터를 잘 분류할 수 있는 모델을 만들어 보자.

① 테스트 데이터를 잘 분류하기 위해 추가로 수집해야 할 이미지를 인터넷에서 다운로드 한다.

② 기존 [훈련용 데이터]와 추가로 다운로드한 사진으로 다시 인공지능 모델을 학습시킨다.

③ 인공지능 모델이 남자와 여자를 제대로 구분하는지 확인해 보자.

④ 이 활동으로 알게 된 사실을 이야기해 보자.

- 다시 학습시킨 인공지능 모델은 남자와 여자를 정확하게 구분했는가?

- 인공지능 모델이 남자와 여자를 정확하게 구분한 이유는 무엇일까?

- 이번에 만든 인공지능 모델을 약국에서 다시 사용한다면 어떨까?



개념 정리

01. 인공지능의 발전과 사회 변화


- 인공지능의 발전으로 우리 사회에 많은 변화가 나타나고 있다.
예) 인간과 인공지능의 협업
업무의 자동화로 인한 생산성 향상
개인 맞춤형 서비스
새로운 콘텐츠를 생성하는 인공지능 등
- 인공지능 기술로 사회적 문제를 해결하려는 시도가 이루어지고 있다.
- 인공지능으로 인한 직업 세계의 변화 속에서 인공지능을 활용하고 인공지능과 협업하려는 자세를 가지는 것이 중요해지고 있다.

02. 인공지능 윤리

- 인공지능을 도입할 때 지켜야 할 사회적 규범과 도덕적 판단 등 인공지능 윤리를 실현하기 위해 6가지 쟁점을 충분히 논의해야 한다.

신뢰성	공정성	윤리성
투명성	안전성	책임성

- 인공지능과 공존하기 위해서는 인간과 인공지능의 강점을 이해하고, 인공지능을 적절하게 활용할 수 있어야 한다.



- 인공지능과 공존하기 위한 노력의 하나로 국내외에서는 인공지능의 윤리적 기준을 발표하고 있다.

- ☆ 우리나라의 인공지능 윤리 기준 3대 원칙과 10대 요건
유럽 연합(EU)의 인공지능 분류 4단계

실력 확인

1 인공지능을 이용한 사회적 문제 해결 사례로 볼 수 없는 것은?

- ① 가상 현실(VR) 기술을 이용한 게임의 그래픽 향상
- ② 교통량 예측 시스템을 활용해 도시의 교통 체증을 감소
- ③ 의료 영상 혹은 이미지를 분석하여 폐렴 진단을 도와주는 의료 서비스
- ④ 자연어 처리 기술을 활용한 헬스케어 챗봇으로 정신 건강 관리를 지원하는 서비스
- ⑤ 음성 인식과 자연어 처리 기술이 적용된 지능형 스피커를 이용해 독거노인의 건강 상태를 확인

2 ㉠에 해당하는 용어는?

(㉠)은/는 기계학습 모델을 개발하는 데 사용되는 데이터에 존재하는 편향을 의미한다.
(㉠)이/가 존재하는 인공지능이 사용된다면, 특정 집단에 피해를 초래할 수 있다.

3 인공지능의 공정성 문제를 해결하기 위한 방법으로 옳지 않은 것은?

- ① 다양한 집단을 대표하는 데이터를 수집·활용한다.
- ② 데이터의 양이 한쪽으로 치우치지 않았는지 검토한다.
- ③ 사회적 편견이 반영된 부적절한 속성이 사용되었는지 검토한다.
- ④ 인공지능의 성능을 최대화할 수 있는 데이터를 우선 활용한다.
- ⑤ 데이터와 알고리즘에 사회와 사람의 편향이 영향을 주지 않는지 충분히 논의한다.

4 인공지능의 6가지 윤리적 쟁점 중 ㉠에 해당하는 용어를 쓰시오.

인공지능이 (㉠)을/를 확보하기 위해서는 사용자가 사용하는 프로그램이 인공지능이라는 것을 알아야 하며, 인공지능의 의사 결정 과정을 설명할 수 있어야 한다.

5 다음 대화에 나타난 인공지능의 윤리적 쟁점으로 옳은 것은?

자율주행 자동차가 해킹을 당하면 큰 사고로 이어질 수 있겠어.



맞아. 운전자의 편의를 위해 개발되었지만 악의적인 공격이나 위험에 취약할 수 있어.



- ① 공정성 ② 투명성
- ③ 윤리성 ④ 안전성
- ⑤ 책무성

6 인공지능 사회의 구성원이 가져야 할 윤리적 책임을 적절히 선으로 연결해 보자.

- | | |
|------------|---------------------------|
| 개발자 · | · 기술 활용에 대한 책임 · 보상 원칙 마련 |
| 사용자 · | · 윤리적 절차에 따라 기술 개발 |
| 운영 · 관리자 · | · 악의적 이용 금지 |

7 보기 는 우리나라의 인공지능 윤리 기준 3대 원칙이다. 다음에서 설명하는 것을 보기 에서 골라 쓰시오.

보기

- 인간 존엄성의 원칙
- 사회의 공공선 원칙
- 기술의 합목적성 원칙

인공지능은 사회적 약자와 취약 계층의 접근성을 보장하고 인류의 보편적 복지를 향상시키도록 개발 및 활용되어야 한다.

8 보기 는 유럽 연합 의회의 위험 수준에 따른 인공지능 분류이다. 아래에서 설명하는 사례가 속하는 단계를 보기 에서 골라 쓰시오.

보기

- | | |
|----------|----------|
| · 금지된 위험 | · 제한된 위험 |
| · 고위험 | · 낮은 위험 |

장난감, 항공기, 자동차, 의료 기기 등 제품의 안전 구성 요소로 사용되는 인공지능 시스템

스스로 점검하기

인공지능의 발전으로 인한 사회 변화를 살펴보고, 인공지능으로 해결할 수 있는 사회적 문제를 분석할 수 있는가?



170쪽

인공지능에 의해 변화하는 인간의 삶과 직업의 양상에 대해 이해하고 진로를 탐색할 수 있는가?



170쪽

인공지능에 대한 비판적 자세를 바탕으로 인공지능과 인간의 공존 방안을 도출할 수 있는가?



178쪽

인공지능의 활용 사례와 윤리적 딜레마 상황을 인공지능 윤리 관점에서 분석할 수 있는가?



178쪽



IV

인공지능 프로젝트

01 지속가능발전목표와 인공지능

02 인공지능 프로젝트

이 단원을 배우고 나면

인공지능이 다양한 분야와 융합하여 새로운 가치를 창출할 수 있다는 점을 인식하고, 인류가 직면해 있는 문제를 인공지능을 활용하여 해결할 수 있는 능력을 기를 수 있다.



- 지속가능발전목표를 해결하기 위해 인공지능을 적용할 수 있는 방안을 탐색하고, 인공지능 프로젝트 활동에 적합한 주제를 도출할 수 있다.

지속가능발전목표와 인공지능

학습 요소

지속가능발전목표,
인공지능 문제 해결



1 지속가능발전목표

[표 IV-1] SDGs 영역과 의미

영역	의미
사람	행복한 삶의 질 향상
번영	성장과 지속 가능한 발전
지구 환경	깨끗하고 자연 친화적 환경
평화·협력	지구촌 평화와 협력

지속가능발전(sustainable development)은 지속 가능성에 기초하여 경제의 성장, 사회의 안정과 통합, 환경의 보전이 균형을 이루는 발전을 의미한다. 지속가능발전목표(SDGs; Sustainable Development Goals)는 빈곤, 기아, 불평등, 기후 변화 등 인류가 직면한 전 세계적인 문제를 해결하기 위해 마련된 목표로 유엔(UN; United Nations)에서 채택된 의제이다.

여기서 사람(people), 번영(prosperity), 지구 환경(planet), 평화(peace) · 협력(partnership)을 위한 17개 목표와 169개 세부 목표를 제시하고 있다.

지구 환경(planet)

- ⑦ 모두를 위한 에너지 보장
- ⑫ 지속 가능한 소비와 생산
- ⑬ 기후 변화 대응
- ⑭ 해양 생태계 보존
- ⑮ 육상 생태계 보호

번영(prosperity)

- ⑧ 경제 성장과 양질의 일자리
- ⑨ 사회 기반 시설 산업화 및 혁신
- ⑩ 불평등 감소
- ⑪ 지속 가능한 도시와 주거지

사람(people)


- ① 빈곤 퇴치
- ② 기아 종식
- ③ 건강과 웰빙 증진
- ④ 양질의 교육 보장
- ⑤ 성평등 달성
- ⑥ 깨끗한 물과 위생 보장

평화(peace)

- ⑯ 평화, 정의, 포용적인 제도

파트너십(partnership, 협력)

- ⑰ 글로벌 파트너십



[그림 IV-1] 지속가능발전목표

지속가능발전목표는 환경뿐만 아니라 개인의 행복한 삶과 경제 성장, 사회의 지속 가능한 발전을 추구하고, 지구촌의 평화를 지키며 포용하고 협력하는 것을 주요 내용으로 한다.




1 인류가 직면한 다양한 문제

통계청에서 발간한 우리나라의 지속가능발전목표 이행 보고서를 통해 현재 우리나라가 직면하고 있는 문제 사례를 살펴보자.



한국의 SDG 이행 보고서 2023(통계청)
<https://kostat.go.kr/board.es?mid=a90107000000&bid=12317>

지속가능발전목표 관련 문제



2 지속가능발전목표와 인공지능 문제 해결 사례

지속가능발전목표와 함께 다양한 사례에서 알아본 바와 같이 우리 인류가 직면한 과제는 복잡하고 다양한 요인의 영향을 받으면서 서로 연결되어 있다. 환경 오염, 생태계 보호, 기후 변화와 같이 기존의 방법으로 해결하기 어려웠던 문제를 인공지능으로 해결하려는 시도가 늘고 있다.

사례를 보고 인공지능으로 어떤 문제를 해결할 수 있는지 알아보자.


사례 1



닥터비(B) 인공지능 로봇

인공지능 재활용 로봇은 폐기물의 모양과 색깔을 감지하여 종이, 비닐, 알루미늄 등 58가지 항목을 구분할 수 있어 자원의 효율적인 재활용을 도울 수 있다.


사례 2



탄소 관리 자동화 시스템

인공지능 기술을 이용한 탄소 배출 관리 자동화 시스템은 건물, 공장에서 발생하는 탄소 배출량을 정교하게 측정하고 데이터를 분석해 이상 배출량을 감지하거나 저감 방안을 진단할 수 있다.

사례 3



CCTV 영상 분석을 통한 차선·차종별 차량 감지

전국 도로에 설치된 CCTV 영상을 인공지능이 분석해 차종과 교통량을 자동으로 파악하여 교통 체증, 도로 안전 수준을 개선하고 있다.

사례 4



스마트 농업 생산 단지

기후 변화로 인한 작물 모니터링, 해충 및 기타 피해 방지도 인공지능이 활용되고 있다.



인공지능 시스템을 개발하고 활용하기 전에 지속가능발전목표에 내재한 포용성, 공정성 및 책무성 원칙과 일치하기 위한 인공지능의 윤리적 측면에 대한 논의도 이루어져야 해요.

우리나라 통계청 SDG 데이터 플랫폼에서 세 가지 지속가능발전목표에 대해 조사해 보자.



1 17가지 지속가능발전목표가 무엇인지 살펴보고, 세부 목표에 대한 데이터를 분석해 보자.

통계청 <https://kostat-sdg-kor.github.io/sdg-indicators/>



2 통계청에서 발간한 [한국의 SDG 이행 보고서 2023]을 다운로드하여 17가지 지속가능발전목표를 분석해 보자. 또한 우리나라가 어떤 문제에 직면하고 있는지 탐색하고, 인공지능 적용 방안에 대해 토의해 보자.

💡(통계청 SDG 사이트 - 발간자료 - 한국의 SDG 이행 보고서 2023)

지속가능발전목표	지향하는 목표	우리나라가 해결해야 할 문제	인공지능 적용 방안
12 지속가능한 소비와 생산	예 '지속 가능한 생산과 소비 양식 보장'을 목표로 한다.	예 택배나 음식 배달에 사용되는 폐합성수지류 발생량 증가, 소비 행태 변화로 폐기물 발생량이 증가하고 있다.	예 폐기물을 인식하여 자동 분류하는 인공지능을 도입하여 재활용률을 높인다.
13 기후변화 대응	예 '기후 변화로 발생하는 악영향을 최소화하기 위한 긴급 대응'을 목표로 한다.		
15 생물다양성 보전			

- 인공지능 문제 해결 과정에 기반하여 프로젝트 수행 계획을 구안할 수 있다.
- 인공지능 프로젝트를 수행하는 과정에서 협력적인 문제 해결 자세를 바탕으로 인공지능 소프트웨어를 개발할 수 있다.
- 인공지능의 사회적 영향을 고려한 평가 결과를 반영하여 모델의 성능을 개선할 수 있다.

인공지능 프로젝트

학습 요소

인공지능 프로젝트,
인공지능 소프트웨어 개발



프로젝트 기반 학습(PBL)은 실제 세계의 문제를 해결하기 위해 협력하여 팀으로 작업하는 학습 접근 방식이다. 지속 가능한 발전을 달성하기 위한 인공지능 프로젝트 수행 절차를 살펴보면 다음과 같다.

단계 ①

문제 정의하기

인공지능으로
해결할 수 있는 문제를
정의해 보자.



- 인터뷰(면담)나 관찰 등을 통해 수집한 여러 가지 상황에서 문제를 발견하고, 인공지능으로 해결하고자 하는 문제 상황을 분석한다.
- 프로젝트 활동을 해결하기 위해 여러 가지 가능성을 두고 자유롭게 해결 방법을 찾아 아이디어를 표현한다.

단계 ②

데이터 수집 및 전처리하기



- 문제 해결에 필요한 데이터를 수집하고 탐색적으로 분석하여 모델 학습에 필요한 핵심 속성을 추출한다.
- 탐색 과정에서 발견한 결측치나 이상치 등을 처리하고 기계학습에 필요한 형태로 데이터를 가공한다.

단계 ③

모델 생성하기



- 문제 해결에 적합한 기계학습 유형과 적절한 알고리즘을 선택한 후, 데이터를 학습하여 모델을 생성한다.
- 생성한 모델의 성능이 낮은 경우 데이터의 속성을 추가하거나 알고리즘을 변경하여 학습을 반복한다.

단계 ④

모델 평가하기



- 학습에 사용하지 않은 테스트 데이터를 이용해 모델의 성능을 평가하고, 모델이 예측한 값과 실제값을 비교한다. 이를 통해 모델이 과적합되었는지, 일반화될 수 있는 모델인지 등을 확인한다.
- 완성된 모델이 편향되었는지 여부를 평가해야 한다.
- 모델의 성능이 낮은 경우 데이터를 보완하거나 모델의 구조를 변경하는 등의 방법으로 모델의 성능을 개선한다.

단계 ⑤

모델 활용 문제 해결하기



완성된 모델에 새로운 데이터를 입력하여 모델이 예측한 결과를 해석한다. 이를 바탕으로 처음에 설정한 문제가 해결되었는지 검토하여 결과를 해석한다.

💡 인공지능이 윤리적·사회적으로 미칠 수 있는 영향을 고려해야 한다. 전 과정에서 협력적으로 문제를 해결할 수 있다.

💡 프로젝트를 수행한 후 보고서를 작성할 수 있다.

단계 1 문제 정의하기

지속가능발전목표 중 하나는 기후 변화 대응, 모두를 위한 깨끗한 에너지, 육상 생태계 보호와 같은 지구 환경의 문제이다. 인공지능으로 해결할 수 있는 문제를 정의해 보자.



문제를 발견하기 위해 주변을 잘 관찰하고 상대방의 입장이 되어 문제에 공감해요.



국립기상과학원
http://www.nims.go.kr/?sub_num=911



기상청 기후정보포털
http://www.climate.go.kr/

(1) 문제 발견하기

기후 변화로 나타나는 다양한 현상을 관찰함으로써 지구와 그 속에서 살아가는 사람들의 문제에 공감할 수 있다. 기후 변화로 지구가 겪고 있는 문제를 살펴보자.


[기후 변화에 따른 문제] 국립기상과학원에 따르면, 온난화로 인해 북극 빙하는 2060년 이후 급격히 감소하여, 2100년에 거의 녹아 없어질 것으로 예상된다. 기상청 기후정보포털에서 이산화 탄소, 메테인 등 온실가스 배출량의 변화를 살펴보면 최근 10년간 이산화 탄소 배출량도 점진적으로 증가하고 있다.

국립기상과학원 사이트의 '내 손 안의 기후 변화'에서 지구의 기후 변화를 관찰해 보자.



2000년 1월 2080년 1월

기상청 기후정보포털에서 [기후변화감시]-[실시간 감시정보]를 클릭하여 온실가스 배출량의 변화를 살펴보자.



온실가스 배출량

기후 변화와 관련된 데이터를 추가로 조사하고, 기후 변화로 지구가 겪는 문제를 발견해 보자.

- 예) 최근 10년간 지구의 온실가스 배출량이 증가하고 있다.
- 온실가스 배출량 증가와 더불어 지구의 기온도 증가하고 있다.

기후 변화를 관찰하고 지구가 겪고 있는 문제를 질문으로 표현해 보자.

2차원 평면에 중요성과 실현 가능성을 평가해서 포스트잇을 배치해 보요.



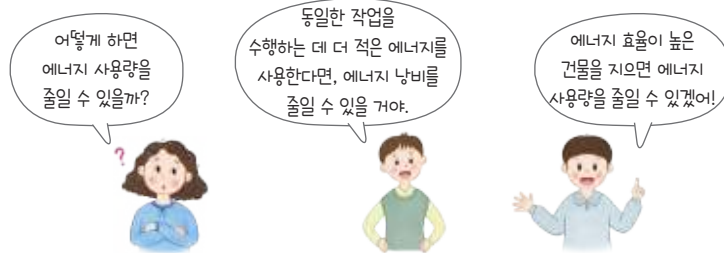
활동 방법

- ① 포스트잇에 질문 형태로 문제를 표현한다.
- ② 중요성은 얼마나 중요한 문제인지를 의미한다.
- ③ 실현 가능성은 프로젝트로 실현 가능한 정도를 의미한다.
- ④ 학생들은 토의하여 중요성과 실현 가능성을 평가하여 해결할 문제를 선택한다.

(2) 문제 분석하기

문제를 구체적으로 정의하려면 문제의 현재 상태와 목표 상태를 인식하고, 기계학습으로 해결할 수 있는 문제인지 판단해야 한다.

현재 상태	목표 상태
- 기후 변화로 지구의 온도가 상승하고 있다. - 여름철, 겨울철 에너지 사용량이 급증하고 있다.	건물의 에너지 효율성을 높일 수 있는 구조적 요인을 찾는다.




(3) 아이디어 표현하기

문제 해결 방법을 찾기 위해 다양한 아이디어를 표현하는 과정이 필요하다. 데이터 수집 방법, 기계학습 알고리즘과 실현 방법을 구체적으로 표현해 보자.

활동 방법

- ① 지속가능발전목표와 관련하여 프로젝트 주제를 작성한다.
- ② 문제 해결 아이디어를 제목과 그림으로 표현한다.
- ③ 문제 해결에 필요한 데이터의 유형과 데이터 수집 방법을 작성한다.
- ④ 기계학습 모델을 생성하여 어떻게 문제를 해결할지 실현 방법을 구체적으로 작성한다.



💡 자유롭게 표현하고 토의하여 보다 나은 아이디어를 선택한다.

인공지능 프로젝트 계획서



계획서 작성 가이드라인 다운로드

<https://dtqr.kr/3RYDPo3>

1 문제 정의하기

현재 상태	목표 상태
어떤 문제가 있나요? 예 기후 변화로 지구의 온도가 상승하고 있다.	어떤 상태에 도달하고 싶은가요? 가요?

문제	문제를 질문으로 표현해요. 예 에너지 효율성을 높이기 위해 어떤 형태의 건물을 지어야 할까요?
----	---

2 지속가능발전목표와의 관련성

우리가 정의한 문제가 지속가능발전목표와 어떤 관련성이 있는지 설명해요.

3 아이디어 표현하기

문제 해결 아이디어를 그림으로 표현해요.

4 탐구 방법

- 어떤 자료를 어떻게 수집할지 구체적으로 작성해요.
- 데이터를 둘러보고 어떤 형태인지 나타내어요.
- 어떤 모델을 적용하여 문제를 해결할 수 있을까요?

5 예상되는 결과와 기대 효과

우리 모둠의 프로젝트가 완성되면 어떤 결과를 얻을 수 있을지 예상해 보아요.

예 집의 구조를 알면 에너지가 얼마나 소모되는지 예측할 수 있다.

6 협력적 문제 해결 역할 분담

모둠원	김**	한△△	민○○	박##
역할	역할 1	역할 2	역할 3	역할 4

단계 2 데이터 수집 및 전처리하기

문제 해결에 필요한 데이터를 수집한 후 데이터를 탐색적으로 분석하고 모델 학습에 필요한 핵심 속성을 추출한다. 탐색 과정에서 발견한 결측치나 이상치 등은 처리하고, 기계학습에 필요한 형태로 가공한다.

(1) 데이터 수집하기

 **친환경 에너지 소비를 위해 에너지 효율(energy efficiency) 데이터를 수집해 보자.**

파일명은 'energy_efficiency_data.csv'이다.

 **캐글 사이트** <https://www.kaggle.com/datasets/ujjwalchowdhury/energy-efficiency-data-set>
이 문제는 지속가능발전목표 '(13) 기후 변화 대응'과 '(7) 모두를 위한 에너지 보장' 목표에 도달하기 위해 건물 에너지 사용량을 파악하여 에너지 부하를 예측하는 것을 목표로 한다.

 **수집한 데이터의 속성을 살펴보고, 의미를 파악해 보자.**

속성명	사용할 용어	의미	단위
Relative_Compactness	조밀도	건물의 공간을 얼마나 효율적으로 또는 밀집되게 사용하였는지를 나타내는 지표	비율(0~1)
Surface_Area	표면적	건물의 외부 표면의 총면적	m ²
Wall_Area	벽 면적	건물 외벽의 총면적	m ²
Roof_Area	지붕 면적	건물 지붕의 면적	m ²
Overall_Height	전체 높이	건물의 바닥부터 최상단까지의 높이	m
Orientation	방향	건물이 향하는 방향(2: 북쪽, 3: 동쪽, 4: 남쪽, 5: 서쪽)	범주형
Glazing_Area	유리 면적	창문과 같은 유리의 면적(바닥 대비 유리 면적의 백분율)	비율(0~1)
Glazing_Area_Distribution	유리 면적 분포	유리 면적 분포(0: 유리 없음, 1: 균일, 2: 북쪽, 3: 동쪽, 4: 남쪽, 5: 서쪽)	범주형
Heating_Load	난방 부하	난방에 필요한 에너지의 양(kWh/m ²)	kWh
Cooling_Load	냉방 부하	냉방에 필요한 에너지의 양(kWh/m ²)	kWh

파이썬으로 해결할까?
(208~213쪽)

오렌지로 해결할까?
(214~219쪽)

문제 파이썬으로 문제를 해결해 보자.

207쪽에 이어서
계속 진행하세요.

(2) 탐색적 데이터 분석과 전처리

① 파일 불러오기: 수집한 데이터를 구글 코랩에 업로드한 후 판다스 데이터 프레임에 저장한다.

```
01 import pandas as pd
02 df = pd.read_csv('energy_efficiency_data.csv') # 데이터 불러오기
03 df.head()
```

실행 결과

	Relative_Composition	Surface_Area	Wall_Area	Roof_Area	Basement_Height	Orientation	Roofing_Area	Roofing_Area_Distribution	Heating_Load	Cooling_Load
0	0.98	514.5	294.0	110.25	7.0	2	0.0	0	15.55	21.33
1	0.98	514.5	294.0	110.25	7.0	3	0.0	0	15.55	21.33
2	0.98	514.5	294.0	110.25	7.0	4	0.0	0	15.55	21.33
3	0.98	514.5	294.0	110.25	7.0	5	0.0	0	15.55	21.33
4	0.90	955.5	110.5	122.50	7.0	2	0.0	0	20.94	28.29

② 데이터 정보를 확인해 보면 데이터 속성의 유형과 결측치를 확인할 수 있다.

```
01 df.info()
```

실행 결과

```
Data columns (total 10 columns):
# Column      Non-Null Count  Dtype
---  --
0 Relative_Composition      768 non-null    float64
1 Surface_Area              768 non-null    float64
2 Wall_Area                 768 non-null    float64
3 Roof_Area                 768 non-null    float64
4 Basement_Height           768 non-null    float64
5 Orientation               768 non-null    int64
6 Roofing_Area              768 non-null    float64
7 Roofing_Area_Distribution  768 non-null    int64
8 Heating_Load              768 non-null    float64
9 Cooling_Load              768 non-null    float64
```

해석 전체 데이터는 768개이고 총 10개의 속성으로 구성되어 있다. 결측치는 없고 데이터 유형은 모두 수치형이다.

③ 통계 정보 확인하기: 특성 통계표로 데이터 분포, 크기 등을 확인할 수 있다.

```
01 df.describe()
```

실행 결과

	Relative_Composition	Surface_Area	Wall_Area	Roof_Area	Basement_Height	Orientation	Roofing_Area	Roofing_Area_Distribution	Heating_Load	Cooling_Load
count	768	768	768	768	768	768	768	768	768	768
mean	0.97	671.70	294.00	110.25	7.00	3.50	0.00	0.00	15.55	21.33
std	0.02	180.00	100.00	100.00	0.00	1.00	0.00	0.00	1.00	1.00
min	0.90	514.50	294.00	110.25	7.00	2.00	0.00	0.00	15.55	21.33
25%	0.97	514.50	294.00	110.25	7.00	3.00	0.00	0.00	15.55	21.33
50%	0.97	671.70	294.00	110.25	7.00	3.50	0.00	0.00	15.55	21.33
75%	0.97	855.50	294.00	110.25	7.00	4.00	0.00	0.00	15.55	21.33
max	0.98	955.50	294.00	122.50	7.00	5.00	0.00	0.00	20.94	28.29

전체 데이터는 768개, 상대 조밀도의 평균값은 0.76으로 매우 작은 값이다. 반면에 표면적 속성의 평균값은 671.70으로 속성값들의 차이가 큰 것을 알 수 있다.

④ 데이터 정규화하기: MinMaxScaler를 이용하여 모든 데이터의 속성값을 0~1 사이의 값으로 변환한다.

```
01 # MinMaxScaler를 불러오기
02 from sklearn.preprocessing import MinMaxScaler
03 # 0~1 사이의 값으로 스케일링하는 MinMaxScaler 객체 생성하기
04 scaler = MinMaxScaler(feature_range=(0, 1))
05 # df 데이터 프레임에 MinMaxScaler를 적용하기
06 scaled_data = scaler.fit_transform(df)
07 # 스케일된 데이터를 데이터 프레임으로 변환하기
08 df2 = pd.DataFrame(scaled_data, columns=df.columns)
09 df2.head()
```

실행 결과

데이터의 크기가 0~1 사이의 값으로 변환되었다.



	Relative Compactness	Surface Area	Wall Area	Roof Area	Overall Height	Orientation	Glazing Area	Glazing Area Distribution	Heating Load	Cooling Load
0	0.000000	0.000000	0.334214	0.000000	1.0	0.000000	0.0	0.0	0.757242	0.282919
1	1.000000	0.000000	0.259714	0.000000	1.0	0.000000	0.0	0.0	0.259714	0.282919
2	0.000000	0.000000	0.334214	0.000000	1.0	0.000000	0.0	0.0	0.757242	0.282919
3	1.000000	0.000000	0.259714	0.000000	1.0	1.000000	0.0	0.0	0.259714	0.282919
4	0.777778	0.166667	0.493333	0.111111	1.0	0.000000	0.0	0.0	0.399333	0.400000

⑤ 핵심 속성 추출하기: '조밀도(Relative_Compactness)'와 '지붕 면적(Roof_Area)'이 '난방 부하(Heating_Load)'라는 에너지 효율 지표와 어떤 상관관계가 있는지 알아보자.

```
01 import matplotlib.pyplot as plt
02 import seaborn as sns
03 plt.figure(figsize=(5,4)) # 이미지 크기 설정하기
04 # 산점도 그리기
05 sns.scatterplot(data=df2, x='Relative_Compactness',
06                y='Heating_Load')
07 plt.show()
```

```
01 plt.figure(figsize=(5,4)) # 이미지 크기 설정하기
02 # 산점도와 회귀선 그리기
03 sns.regplot(data=df2, x='Roof_Area', y='Heating_Load')
04 plt.show()
```

실행 결과



- ⑥ 독립 변수와 종속 변수 설정하기: 건물의 에너지 효율성을 나타내는 '난방 부하(Heating_Load)'를 종속 변수로 설정하고, 난방 부하와 상관도가 높은 '지붕 면적(Roof_Area)'을 독립 변수로 설정해 보자.

df2 데이터 프레임의 9번째 속성을 선택함.

```

01 import numpy as np
02 X=np.array(df2.iloc[:,3]) # 지붕 면적(Roof Area)을 독립 변수로 설정하기
03 y=df2.iloc[:,8]          # 난방 부하(Heating_Load)를 종속 변수로 설정하기
04 X=X.reshape(-1,1)        # 모델에 입력하는 X를 1차원에서 2차원으로 변환하기

```

모델에 입력하기 위해 X는 2차원 데이터로 변환해야 한다.

단순 선형 회귀를 위해 X에 지붕 면적을, y에 난방 부하의 값을 할당한다.

- ⑦ 데이터 분할하기: 모델 학습을 위해 전체 데이터를 훈련 데이터와 테스트 데이터로 분할한다. 훈련 데이터와 테스트 데이터를 7:3으로 분할한다.

```


01 from sklearn.model_selection import train_test_split
02 X_train, X_test, y_train, y_test=train_test_split(X,y,
03                                                  test_size=0.3, random_state=42)

```

단계 3 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

건물 특성에 대한 수치 데이터로 난방 부하의 수치를 예측하기 위해 선형 회귀 알고리즘으로 문제를 해결해 보자.



[그림 IV-2] 건물 에너지의 효율성 예측 모델



더 알아보기


이상치 확인하기

상자그림(box plot, 박스플롯)을 이용하여 이상치가 있는지 확인해 보면 데이터값의 분포를 한눈에 확인할 수 있다. 모든 속성에 이상치는 없으나 속성 간 데이터 크기의 차이가 큰 것을 알 수 있다.

```

01 import seaborn as sns
02 import matplotlib.pyplot as plt
03 plt.figure(figsize=(12,8)) #이미지 크기 설정하기
04 sns.boxplot(data=df)      #상자그림 그리기

```



(2) 모델 학습하기

LinearRegression 알고리즘을 적용하여 선형 회귀 모델을 생성하고 훈련 데이터를 학습시킨다.

```
01 from sklearn.linear_model import LinearRegression
02 model=LinearRegression()           # 선형 회귀 모델 생성하기
03 model.fit(X_train, y_train)         # 훈련 데이터로 모델 학습하기
```

① 학습한 모델의 결정계수(R^2)를 출력한다.

```
01 print('R2 score(Train data) : ',end=' ')
02 print(model.score(X_train, y_train)) # 훈련 데이터로 성능 평가하기
```

이는 '지붕 면적'으로 '난방 부하'를 예측하는 단순 선형 회귀 모델이 실제 데이터를 0.746 정도 설명할 수 있다는 의미이다.

R2 score(Train data) 0.7460573053035831

② 회귀계수(a)와 절편(b)을 구하고, 선형 회귀 모델을 식으로 나타내면 다음과 같다.

```
01 print(model.coef_, model.intercept_) # 회귀계수 출력하기
```

[-0.577464704] 0.78804871017524

선형 회귀 식

$$y = -0.577x + 0.788$$

이 모델에 지붕 면적을 입력하면 난방 부하를 예측할 수 있다.

단계 4 모델 평가하기

(1) 모델 성능 평가하기

생성한 모델에 테스트 데이터를 입력하여 모델의 성능을 평가하고 예측해 보자.

```
01 print('R2 score(Test data) : ',end=' ')
02 print(model.score(X_test, y_test)) # 테스트 데이터로 성능 평가하기
```

R2 score(Test data) 0.7330867004400000

완성된 단순 선형 회귀 모델의 성능(R^2)은 0.733으로 우수한 편이다.

(2) 모델 성능 개선하기

지붕 면적 1개 특성으로 난방 부하를 예측하는 단순 선형 회귀의 성능이 좋은 편이지만 더 많은 속성을 추가하여 모델을 개선할 수 있다.

① 핵심 속성 추출하기: 히트맵을 이용하여 난방 부하와 상관성이 높은 속성을 찾아보자.

```
01 plt.figure(figsize=(10,8)) # 이미지 크기 설정하기
02 sns.heatmap(df2.corr(),annot=True, cmap='Greens', fmt='.2f')
03 plt.show()
```



난방 부하(Heating Load)는 전체 높이와 가장 상관성이 높고($r=0.89$) 지붕 면적과 음의 상관관계가 높으며($r=-0.86$) 방향이나 유리 면적의 분포와 거의 상관성이 없어요.

난방 부하 속성은 건물 상대 조밀도, 표면적, 지붕 면적, 전체 높이 속성과 상관성이 높다.

② 독립 변수와 종속 변수 설정하기

```
01 # 독립 변수 설정하기(조밀도, 표면적, 지붕 면적, 전체 높이)
02 X2=df2.iloc[:,[0,1,3,4]] # df2: 정규화 수행한 데이터
03 y2=df2.iloc[:,8] # 난방 부하를 종속 변수로 설정하기
04 from sklearn.model_selection import train_test_split
05 X_train, X_test, y_train, y_test=train_test_split(X2,y2,
06 test_size=0.3, random_state=42)
```

③ 다중 선형 회귀 모델 생성하기

```
01 model2=LinearRegression() # model2: 다중 선형 회귀 모델
02 model2.fit(X_train, y_train)
```

④ 회귀계수(a)와 절편(b)을 구하고, 선형 회귀 모델을 식으로 나타내면 다음과 같다.

```
01 for i in range(4):
02     print("a%d = %.3f"%(i+1,model2.coef_[i]))
03     print("b = %.3f"%(model2.intercept_))
```

완성된 다중 선형 회귀 모델은

$y = -0.774x_1 - 0.353x_2 - 0.409x_3 + 0.353x_4 + 1.007$ 과 같다.

(x_1 : 조밀도, x_2 : 표면적, x_3 : 지붕 면적, x_4 : 전체 높이)

실행 결과 예

```
a1 = -0.774
a2 = -0.353
a3 = -0.409
a4 = 0.353
b = 1.007
```

⑤ 모델의 성능 평가하기

```
01 print('R2 score(Test data):',end=' ')
02 print(model2.score(X_test, y_test)) # 테스트 데이터로 성능 평가하기
```

실행 결과 예

```
R2 score(Test data): 0.343646362027036
```

수정된 모델을 이용하여 성능을 평가해 보면 결정계수(R^2)의 값이 0.84로 증가한 것을 확인할 수 있다.

▶ 단순 선형 회귀와 다중 선형 회귀의 성능 비교

단순 선형 회귀 성능 (R^2 score)	다중 선형 회귀 성능 (R^2 score)	결과 해석
0.733	0.84	다중 선형 회귀 모델이 단순 선형 회귀보다 결정계수가 높아 예측 정확도가 높다.

단계 5 모델 활용 문제 해결하기

 내가 건축가가 되었다고 가정하고, 아래 표에 에너지 효율이 높아지도록 건물의 구조적 특성을 설계해 보자.

새로운 데이터 작성 방법

- 각 속성의 최솟값과 최댓값을 확인하여 적절한 값을 대입해 보자.
- 건물의 구조를 입력하면 인공지능 모델이 에너지 효율성을 예측하는 문제이므로 새로운 데이터에 난방 부하와 냉방 부하의 값은 기본값인 0으로 설정한다.

	Relative_Compactness	Surface_Area	Wall_Area	Roof_Area	Overall_Height	Orientation	Glazing_Area	Glazing_Area_Distribution	Heating_Load	Cooling_Load
예 1)	→ 0.76	589	294	146.7	7	4	0.1	1	0	0
예 2)	→ 0.62	735	294	220.5	3.5	5	0.1	1	0	0
나의 데이터	→									

내가 정의한 구조적 특성에 따라 건물을 지었을 때의 난방 부하의 값을 예측해 보고 친구들과 비교해 보자.

① 위에서 만든 데이터를 새로운 csv 파일로 생성하고 불러온다(파일명: new_data.csv).

```
01 new_df = pd.read_csv('new_data.csv')
02 new_df.head()
```

② 새로운 데이터를 기존 데이터와 같은 방식으로 정규화하고, 데이터 프레임 형태로 변환한다. 이때 난방 부하(Heating_Load)의 값은 기존 데이터의 범위를 벗어난 0으로 설정하여 음수값이 나올 수 있다.

```
01 scaled_new_data = scaler.transform(new_df)
02 scaled_new_df = pd.DataFrame(scaled_new_data,
03                               columns=df.columns)
```

③ 정규화한 데이터 중 필요한 속성(조밀도, 표면적, 지붕 면적, 전체 높이)만 선택하여 앞에서 생성한 다중 선형 회귀 모델로 예측을 수행한다.

```
01 new_X2 = scaled_new_df.iloc[:, [0, 1, 3, 4]]
02 new_y_pred = model2.predict(new_X2)
```

④ 내가 설계한 건물의 구조와 친구들이 설계한 건물 구조에 따라, 모델이 예측한 결과가 어떻게 달라지는지 비교해 본다.

```
01 print(new_y_pred)
```

실행 결과 예

[0.83410293 0.3335285 나의 데이터 결과값]



단순 선형 회귀 모델은 하나의 속성만 사용하므로 그 속성의 영향력을 해석하는 것이 타당하지만, 다중 선형 회귀 모델은 여러 개의 속성이 상호 연결되어 있으므로, 그 중 한 속성의 영향력만을 독립적으로 해석하는 것은 적절하지 않을 수 있으며, 추가적인 확인 분석이 필요해요. 우리가 충분한 양의 데이터를 사용한 것이 아니므로, 모델의 성능과 해석은 실제와 다를 수 있어요.

결과 해석 시 주의할 점

- ① 선형 회귀 결과값은 0에서 1 사이의 정규화된 수치값으로 나온다.
- ② '난방 부하'를 target으로 예측하는 것으로, 결과값이 작을수록 에너지 효율이 높음을 의미한다.



에너지 사용량에 영향을 주는 특징은 무엇일까?

결과 해석	건물의 구조적 특성	모델 예측 결과
예	지붕 면적이 넓고, 건물 높이가 낮은 집이 에너지 효율이 좋다.	예 건물의 표면적과 지붕 면적이 넓을수록, 전체 높이가 낮을수록 난방 부하가 낮은 것으로 나타났다.

파이썬으로 인공지능 모델을 만들었어.

그럼 나는 오펜지로 해결해 봐야지.

문제 오렌지로 문제를 해결해 보자.

207쪽에 이어서
계속 진행하세요.

(2) 탐색적 데이터 분석과 전처리

① 파일 불러오기

- ▶ 'File'을 선택해 'energy_efficiency_data.csv' 파일을 불러온다.
- ▶ 데이터 개수는 총 768개이고 10개의 속성으로 구성되어 있으며, 결측치는 없다.



② 통계 정보 확인하기


- ▶ 'File'-'Feature Statistics'을 연결한다.



데이터 속성값에 차이가 커서 모델의 성능을 높이기 위해 데이터 정규화가 필요하겠군요. 표면적, 벽 면적, 지붕 면적 속성은 매우 큰 값인 반면, 유리 면적 분포 등은 매우 작은 값이에요.

③ 데이터 정규화하기

- ▶ 'File'-'Preprocess'을 연결한다.
- ▶ Preprocessors에서 'Normalize Features' - 'Normalize to interval [0, 1]'을 선택하여 데이터의 크기를 0~1 사이의 값으로 변환한다.



④ 핵심 속성 추출하기


- ▶ '조밀도(Relative_Compactness)'와 '지붕 면적(Roof_Area)'이 '난방 부하(Heating_Load)'라는 에너지 효율 지표와 어떤 상관관계를 가지는지 알아보자.



- ▶ 'Preprocess'-'Scatter Plot'을 연결한다.
- ▶ Axis의 x를 'Relative_Compactness'로 하고 y를 'Heating_Load'로 설정한다.

- ▶ Axis의 x를 'Roof_Area'로 변경하여 상관관계를 확인한다.

Show regression line
회귀선을 표시한다.



④ 건물 상대 조밀도와 난방 부하의 상관 정도

⑤ 지붕 면적과 난방 부하의 상관 정도

해석 건물 조밀도가 증가할수록 난방 부하도 증가하는 경향이 있다. 지붕 면적이 증가할수록 난방 부하가 줄어드는 경향이 있다.

협력적 문제 해결

다른 속성들도 시각화하여 난방 부하를 예측하는 핵심 속성이 무엇인지 찾아 보자. 친구들과 협력하여 데이터를 시각화하고 결과를 해석해 보자.

⑤ 독립 변수와 종속 변수 설정하기


- ⑤ 건물의 에너지 효율성을 나타내는 '난방 부하(Heating_Load)'를 종속 변수로 설정하고, 난방 부하와 상관성이 높은 '지붕 면적(Roof_Area)'을 독립 변수로 설정해 보자.

- ▶ 'Preprocess'-'Select Columns'을 연결한다.
- ▶ Features를 'Roof_Area'로 하고 Target을 'Heating_Load'로 선택한다.

독립 변수	지붕 면적(Roof_Area)	종속 변수	난방 부하(Heating_Load)
-------	------------------	-------	---------------------



두 속성의 상관관계는 [핵심 속성 추출하기]에서 산점도로 확인했어요.



⑥ 데이터 분할하기

- ▶ 'Select Columns'-'Data Sampler'를 연결한다.
- ▶ 훈련 데이터를 70%, 테스트 데이터를 30%로 설정한다.



단계 3 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

건물 특성에 대한 수치 데이터 특성으로 난방 부하의 수치를 예측하기 위해 선형 회귀 알고리즘으로 문제를 해결해 보자.

(2) 모델 학습하기

- ▶ 'Data Sampler'-'Linear Regression', 'Test and Score'를 연결한다. 훈련 데이터로 모델을 학습시키기 위해 연결선에 'Data Sample→Data'를 선택한다.
- ▶ 'Linear Regression'-'Test and Score'를 연결하고, 교차 검증(Cross validation)으로 모델의 성능을 평가한다.




단계 4 모델 평가하기

(1) 모델 성능 평가하기

생성된 모델의 성능을 평가해 보자.

- ▶ 'Linear Regression'-'Predictions'을 연결한다.
- ▶ 'Data Sampler'-'Predictions'을 연결한다. 테스트 데이터로 모델 성능을 평가하기 위해 남은 데이터(Remaining Data→Data)를 선택한다.




(2) 모델 성능 개선하기

중속 변수에 많은 영향을 미치는 지붕 면적, 표면적, 전체 높이, 조밀도를 추가하여 다중 선형 회귀로 모델을 학습해 보자.

▶ 다중 선형 회귀로 바꾸기 위해 'Select Columns'를 수정한다. Features에 아래와 같이 독립 변수를 추가하고 Target을 'Heating_Load'로 선택한다.

독립 변수	Roof_Area	지붕 면적
	Surface_Area	표면적
	Overall_Height	전체 높이
	Relative_Compactness	조밀도
종속 변수	Heating_Load	난방 부하



▶ 변경 후 'Predictions'을 확인한다.



테스트 데이터로 모델의 성능을 평가해 보면 $R^2=0.835$ 로 개선되었어요.

	Linear Regression	Heating_Load	Roof_Area	Surface_Area	Overall_Height	Relative_Compactness
1	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
2	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
3	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
4	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000

	Model	R ²	MAE	MAPE	RMSE	RMSEP
Linear Regression	0.835	0.000	0.000	0.000	0.000	0.000

협력적 문제 해결

다양한 특성을 반영하여 독립 변수를 추가하거나 알고리즘을 변경하여 모델의 성능을 높일 수 있는 방법을 찾아보자. 친구들과 결과를 비교·분석하여 최적의 모델을 선택해 보자.


모둠원	김**	한△△	민○○	박##
개선 방법	방법 1	방법 2	방법 3	방법 4



더 알아보기

회귀계수

선형 회귀(Linear Regression) 모델에 데이터 테이블(data table)을 연결하면 데이터 속성의 회귀계수와 절편을 확인할 수 있다. 오른쪽은 완성한 선형 회귀 모델의 특징별 회귀계수를 수치로 나타낸 것이다.



	Intercept	Roof_Area	Surface_Area	Overall_Height	Relative_Compactness
Linear Regression	0.000	0.000	0.000	0.000	0.000

단계 5 모델 활용
문제 해결하기

내가 건축가가 되었다고 가정하고, 아래 표에 에너지 효율이 높아지도록 건물의 구조적 특성을 설계해 보자.

- 각 속성의 최솟값과 최댓값을 확인하여 적절한 값을 대입해 보자.
- 건물의 구조를 입력하면 인공지능 모델이 에너지 효율성을 예측하는 문제이므로 새로운 데이터에 난방 부하와 냉방 부하의 값은 기본값인 0으로 설정한다.

	Relative_Compactness	Surface_Area	Wall_Area	Roof_Area	Overall_Height	Orientation	Glazing_Area	Glazing_Area_Distribution	Heating_Load	Cooling_Load
예 1)	→ 0.76	589	294	146.7	7	4	0.1	1	0	0
예 2)	→ 0.62	735	294	220.5	3.5	5	0.1	1	0	0
나의 데이터	→									

건물의 구조적 특성에 따라 난방 부하가 어떻게 다른지 결과를 해석해 보자.


- ▶ 위에서 만든 데이터를 새로운 csv 파일로 생성한다(파일명: new_data.csv).
- ▶ 'File'을 선택해 'new_data.csv' 파일을 불러온다(위젯명 수정: new_data).
- ▶ 'new_data'-'Predictions'을 연결하여 난방 부하의 값을 예측한다.

	Linear_Regression	Relative_Compactness	Surface_Area	Wall_Area	Roof_Area	Overall_Height
1	0.7924	0.76	589.0	294.0	146.7	7.0
2	0.2911	0.62	735.0	294.0	220.5	3.5
3						

나의 데이터



어떤 건물의 에너지 효율이 좋을까요?



더 알아보기

윤리적·사회적 영향력 평가하기

완성된 모델이 편향되지 않고 정확한 예측을 하는지 확인하는 것이 중요하다. 이를 위해 모델의 작동 원리를 명확히 이해하고, 그 투명성을 철저히 검토해야 한다. 또, 모델이 어떤 기준으로 결정을 내리는지 설명할 수 있어야 한다.


모델의 예측 결과를 살펴보면, 정규화한 지붕 면적이 0.111인 건물의 실제 난방 부하의 값 0.80426을 선형 회귀 모델은 0.7297로 예측하였다. 또한 지붕 면적이 1.0인 두 건물의 실제 난방 부하의 값이 각각 0.3518과 0.1690으로 많은 차이가 있는데, 생성한 선형 회귀 모델은 모두 0.212의 값으로 예측하였다.



생성한 모델은 어떻게 예측할까?



시각화로 데이터의 분포를 살펴보면 지붕 면적의 값은 네 가지로 군집화된다. 실제값을 보면 같은 지붕 면적이지만 난방 부하에 차이가 큰 건물이 많다. 지붕 면적 하나의 특성으로 만들어진 선형 회귀 모델은 건물의 에너지 효율을 정확히 예측하지 못할 가능성이 크다.



지붕 면적과 난방 부하의 산점도

협력적 문제 해결

프로젝트 결과를 바탕으로 건물을 설계할 때 에너지 효율을 높이기 위해서는 어떤 구조적 특징을 갖도록 설계하는 것이 좋을지 토의해 보자.

결과 해석 시 주의할 점

- ① 선형 회귀 결과값은 0에서 1 사이의 정규화된 수치가 나오다.
- ② '난방 부하'를 target으로 예측하는 것으로, 결과값이 작을수록 에너지 효율이 높음을 의미한다.



결과 해석

어떻게 하면 에너지 사용량을 줄일 수 있을까?

완성한 인공지능 모델에 새로운 건물의 구조 데이터를 입력하면 난방 부하를 예측할 수 있다. 건물의 구조적 특성에 따라 에너지 효율을 예측하는 인공지능 모델을 활용하여 건물을 설계한다면 에너지 사용량을 줄일 수 있을 것이다.



더 알아보기

분류 모델로 에너지 효율성 등급을 예측할 수 있어요


로지스틱 회귀 모델을 생성하여 난방 부하의 에너지 효율 등급을 3등급으로 나눠 볼 수 있다.

- 1 **분류 기준 선정** 로지스틱 회귀 모델을 만들기 위해 '이산화(discretization)' 과정을 거친다. 이산화는 예측값을 가지고 있는 종속 변수인 'Heating_Load'를 3개의 분릿값으로 변환시킨다. 3개의 분릿값은 임의로 '1등급, 2등급, 3등급'이라고 할 수 있다. 이산화 과정으로 연속된 수치는 이 세 가지 분류 중 하나로 지정된다.
- 2 **사용할 속성 구분** 에너지 효율 등급 분류에 사용될 속성(독립 변수)을 정한다. 가능한 최소한의 속성들로 최대한 정확한 등급을 분류하기 위해 여러 경우를 테스트한다. 예를 들어 '지붕 면적, 표면적, 전체 높이, 조밀도'의 독립 변수를 사용하여 등급을 분류할 수 있다.
- 3 **분류 모델 선정** 로지스틱 회귀 모델은 주어진 속성값(독립 변수)에 따라 세 가지의 분릿값에 포함될 확률을 각각 계산하여 어느 분류에 포함될 것인지 결정하는 모델이므로, 로지스틱 회귀 모델을 사용한다.
- 4 **결과 분석** 모델을 학습시키고 결과를 분석한다. 분류 모델을 생성한 후, 혼동 행렬을 구하고 분류 정확도를 평가한다. 주어진 데이터는 수치가 예측뿐만 아니라 데이터를 변환하여 분류할 수 있음을 알 수 있다.



프로그램 맛보기

<https://dtqr.kr/3MaVrfq>



스스로 점검하기

지속가능발전목표를 해결하기 위해 인공지능을 적용할 수 있는 방안을 탐색하고, 인공지능 프로젝트 활동에 적합한 주제를 도출할 수 있는가?



200쪽

인공지능 문제 해결 과정에 기반하여 프로젝트 수행 계획을 구안할 수 있는가?



204쪽

인공지능 프로젝트를 수행하는 과정에서 협력적인 문제 해결 자세를 바탕으로 인공지능 소프트웨어를 개발할 수 있는가?



204쪽

인공지능의 사회적 영향을 고려하여 인공지능 소프트웨어를 개발하고, 평가 결과를 반영하여 성능을 개선할 수 있는가?



204쪽



건물의 에너지 효율성을 예측할 수 있을까?

1. 문제 정의

· 현재 상태

기후 변화로 지구의 온도가 상승하고 있다.
여름철·겨울철 에너지 사용량이 급증하고 있다.

· 문제1: 건물의 특성으로 에너지 효율성(난방 부하)을 예측할 수 있을까?

· 문제2: 에너지 효율성을 높이기 위해 어떤 구조의 건물을 설계해야 할까?

· 지속가능발전목표:



· 독립 변수와 종속 변수 설정

난방 부하와 상관($r > 0.6$)이 높은 4개의 속성(조밀도, 표면적, 지붕 면적, 전체 높이)을 독립 변수로 설정하고, 난방 부하(Heating_Load)를 종속 변수로 설정한다.

· 모델 학습

훈련 데이터를 이용하여 다중 선형 회귀 모델 학습 결과

$$\text{다중 선형 회귀 모델 } y = -0.774x_1 - 0.353x_2 - 0.409x_3 + 0.351x_4 + 1.007$$

(x_1 : 조밀도, x_2 : 표면적, x_3 : 지붕 면적, x_4 : 전체 높이)

개선된 다중 선형 회귀 모델은 여러 속성이 상호 작용하는 모델이므로 각 속성을 독립적으로 해석하는 것은 어려우므로 추가적인 확인·분석이 필요하다.


2. 데이터 수집과 전처리

· 자료 수집

캐글에서 에너지 효율(energy efficiency) 데이터를 수집한다. 에너지 효율성 데이터는 10개의 속성을 가진다.


· 데이터 전처리

속성 간의 데이터 크기 차이가 커서 데이터 정규화를 수행할 필요가 있다.



· 탐색적 데이터 분석

산점도와 히트맵을 이용하여 난방 부하와 상관성이 높은 핵심 속성을 추출한다.



난방 부하 속성은 건물의 방향, 유리 면적, 유리 면적 분포를 제외한 5가지 속성이 상관관계가 높다($r > 0.6$).

4. 모델 평가

· 성능 평가

테스트 데이터를 이용하여 모델의 성능을 평가한 결과 다중 선형 회귀 모델의 결정계수(R^2)가 0.84로 테스트 데이터에 대한 설명력이 높은 편이다.

· 단순 선형 회귀와 다중 선형 회귀 모델의 성능 비교

단순 선형 회귀 성능(R^2 score)	다중 선형 회귀 성능(R^2 score)
0.733	0.840

단순 선형 회귀 모델보다 다중 선형 회귀 모델의 데이터 설명력이 좋아진 것을 확인할 수 있다.

5. 모델 활용 문제 해결

[문제 1] 건물의 특성으로 에너지 효율성을 예측할 수 있을까?

· 새로운 데이터를 입력하여 모델이 예측한 결과

조밀도	표면적	지붕 면적	전체 높이	난방 부하	에너지 효율
0.75	710.5	221.1	3.5	0.08118	높다
0.82	612.5	147	7	0.67573	낮다

표면적과 지붕 면적이 넓고, 조밀도와 전체 높이가 낮은 건물이 에너지 효율성이 더 높은 것으로 나타났다.

[문제 2] 에너지 효율성을 높이기 위해 어떤 구조의 건물을 설계해야 할까?

표면적과 지붕 면적이 넓고, 건물 높이는 낮은 건물을 설계하는 것이 에너지 효율을 높일 수 있을 것이다. 다만 건물의 조밀도는 다중 선형 회귀 모델의 회귀계수와 단순 상관관계 분석에 차이가 있으므로 이에 대해 추가적인 검토와 논의가 필요하다.

참고 문헌

에너지 효율성 데이터셋
<https://www.kaggle.com/datasets/ujjwalchowdhury/energy-efficiency-data-set>

💡 보고서 작성과 프로젝트 수행의 전 과정에서 자료를 공유하고 협력하여 문서를 작성한다.

인공지능 프로젝트 보고서 작성 방법

프로젝트 보고서는 내용과 결과를 자세히 알 수 있도록 프로젝트 수행의 모든 과정을 정리한 최종 결과물이다. 인공지능 프로젝트 보고서에는 주제(제목), 문제 정의, 데이터 수집과 전처리, 모델 생성, 모델 평가, 모델 활용 문제 해결, 참고 문헌 등을 포함하는 것이 좋다.

탐구 주제(제목)	• 전체적인 탐구 내용을 포함하여 주제만 보고도 어떤 탐구를 수행하였는지 짐작할 수 있도록 표현한다.
1. 문제 정의	• 프로젝트 주제를 선정하게 된 이유와 프로젝트로 해결하고자 하는 문제를 구체적으로 작성한다. • 인공지능으로 해결 가능한 문제인지 검토한다. • 문제를 해결하기 위한 아이디어를 글과 그림으로 표현한다.
2. 데이터 수집과 전처리	• 문제 해결에 필요한 데이터를 수집하는 방법을 소개한다. • 데이터에 포함된 결측치와 이상치 등의 전처리 과정을 작성한다. • 데이터 속성의 관계를 분석하여 핵심 속성을 추출하여 작성한다.
3. 모델 생성	• 모델 학습에 사용한 기계학습 알고리즘에 대해 설명한다. • 훈련 데이터를 이용하여 모델 학습한 결과를 작성한다.
4. 모델 평가	• 테스트 데이터를 이용하여 모델의 성능을 평가하여 결과를 기술한다. • 모델이 윤리적·사회적으로 미칠 수 있는 영향에 대해 설명한다.
5. 모델 활용 문제 해결	• 새로운 데이터를 입력하여 모델이 예측한 결과를 바탕으로 처음에 설정한 문제가 어떻게 해결될 수 있는지 설명한다. • 표, 그래프 등의 자료를 분석하여 속성 간의 관계를 해석한다.
6. 참고 문헌	[참고 문헌 작성 방법] • 책: 저자, 발행 연도, 책 제목, 출판사, 쪽수 • 논문: 저자, 발행 연도, 논문 제목, 학술지 제목, 권, 호수, 쪽수 • 인터넷 사이트: 제목, 웹 주소, 최종 검색일

지속가능발전목표 인공지능 프로젝트의 수행 과정을 다음과 같이 평가해 보자.

영역	평가 관점	평가 기준		
		잘함	보통	노력
1. 주제의 적절성	인공지능으로 해결하기에 적합한 지속가능발전목표의 문제를 정의하였는가?	현재 상태와 목표 상태를 분석하여 지속가능발전목표와 관련 있는 창의적인 문제를 정의하였다.	인공지능으로 해결할 수 있는 지속가능발전목표 관련 문제를 정의하였다.	인공지능으로 해결할 수 있는 문제를 정의하였다.
2. 문제 해결 방식의 창의성	인공지능을 적용하여 문제를 해결하는 방법이 창의적인가?	데이터 수집 방법과 기계학습을 적용한 문제 해결 아이디어를 도식화하여 창의적으로 표현하였다.	데이터 수집 방법과 문제 해결 방법을 구체적으로 설명하였다.	데이터 수집 방법과 문제 해결 아이디어를 간단히 설명하였다.
3. 인공지능 소프트웨어의 완성도	인공지능의 성능과 사회적 영향력을 평가하고 완성한 모델을 활용하여 문제를 해결하였는가?	모델의 성능과 사회적 영향력을 평가하여 개선하고, 완성한 인공지능 모델을 활용하여 문제를 해결하였다.	개발한 모델의 성능을 평가하여 개선하고 문제 해결에 활용하였다.	개발한 모델의 성능을 평가하였다.
4. 다른 사람과의 협업 능력	프로젝트 전 과정에서 팀원과 협력하여 문제를 해결하였는가?	계획서와 보고서 작성 등 프로젝트 수행의 전 과정에서 자신의 역할을 충실히 수행하고 팀원과 협력하였다.	계획서와 보고서 작성 등 프로젝트 수행 과정에서 맡은 역할을 수행하고 토의에 참여하였다.	프로젝트 수행 과정에서 자신의 맡은 역할과 토의를 일부 수행하였다.

우리만의 프로젝트-인공지능으로 지속가능발전목표 해결하기

단계 1 문제 정의하기

(1) 문제 발견하기

- ① 우리 인류가 겪고 있는 문제에 공감하며 이를 통해 문제를 발견하도록 한다.
- ② 발견한 문제를 포스트잇에 작성하고 예시와 같이 2차원 평면에 붙여 보자. 모둠원의 의견 중 중요도와 실현 가능성이 가장 높은 것에 스티커를 붙여 가장 많은 지지를 받은 주제를 선택한다.



4명의 학생
이라면 두 개의 스티커를
사용하여 우리가 해결하기
에 좋은 문제에 투표해요.

예시




예시



- ③ 모두가 협력하여 문제를 해결하기 위한 아이디어를 표현하고 그림으로 도식화해 보자.


아이디어 표현 방법(원 안에서부터)

- ① 목표(주제) 관련 단어를 작성한다.
- ② 아이디어에 제목을 붙이고 간단한 그림으로 표현한다.
- ③ 데이터 수집 및 처리 방법을 간단히 작성한다.
- ④ 문제를 해결하기 위해 구체적인 방법을 글로 작성한다.



(2) 문제 분석하기

문제의 현재 상태와 목표 상태를 표에 나타내어, 해결할 문제를 구체적으로 표현해 보자.





단계 2 데이터 수집 및 전처리하기

(1) 데이터 수집하기

① 어떤 유형의 데이터를 어떻게 수집할 것인가?

☐ (정형 데이터) ☐ (비정형 데이터)

② 수집한 데이터는 어떤 속성과 유형으로 이루어져 있는지 확인해 보자.

속성 1	속성 2					

(2) 탐색적 데이터 분석하기

① 데이터에 결측치와 이상치가 있는지, 전처리가 필요한지 확인해 보자.

② 데이터 시각화, 상관관계 등을 분석하여 핵심 속성을 추출해 보자.

(3) 데이터 전처리하기

① 결측치, 이상치, 정규화 등 기계학습에 필요한 형태로 전처리해 보자.

② 기계학습 모델을 구현하기 위해 훈련 데이터와 테스트 데이터를 분할해 보자.

단계 3 모델 생성하기

(1) 기계학습 유형과 알고리즘 선정하기

① 어떤 기계학습 유형으로 문제를 해결할 수 있을까?

② 문제 해결에 적합한 기계학습 알고리즘을 선택하여 그림으로 표현해 보자.

(2) 모델 학습하기

- ① 기계학습 모델을 생성하여 훈련 데이터로 모델 학습을 수행해 보자.
- ② 학습을 반복하며 검증 데이터로 성능이 어떻게 달라지는지 확인해 보자.

단계 4 모델 평가하기

(1) 모델 성능 평가하기

테스트 데이터로 학습한 모델의 성능을 평가해 보자.

- ① 테스트 데이터를 이용하여 모델이 예측한 결과를 확인해 보자. 얼마나 잘 예측하였는가?
- ② 성능 평가 지표의 결과는 얼마인가?

테스트 데이터 실재값	모델 예측값

성능 평가 지표	지표값

(2) 성능 평가 결과, 윤리적 문제와 사회적 영향이 있는지 토의해 보기

(3) 만약 모델의 성능을 개선할 필요가 있다면 어떤 방법으로 개선할 수 있는지 생각해 보기

☐ (데이터) ☐ (알고리즘)

단계 5 모델 활용 문제 해결하기

- ① 새로운 데이터를 입력하여 인공지능의 예측 결과를 확인해 보자.
- ② 인공지능의 예측 결과를 바탕으로, 처음에 설정한 문제와 지속가능발전목표를 어떻게 해결할 수 있는지 해석해 보자.

실재값	모델 예측값

단계 6 보고서 및 결과 공유하기

- ① 모둠원이 구글 클라우드와 같은 공유 문서를 활용 및 협력하여 보고서를 작성한다.

 221쪽 참고

- ② 완성한 보고서는 발표나 갤러리 워크 등의 방법으로 공유한다.



주제

<https://dtqr.kr/32FzfVD>



1 문제 정의

• 현재 상태

현재 상태와 목표 상태의 차이를 분석하여 문제를 발견한다.

• 문제

해결할 문제를 질문 형태로 나타낸다.

• 아이디어 표현하기

문제 해결 방법 아이디어를 도식화하여 나타낸다.

2 데이터 수집과 전처리

• 데이터 수집

데이터 수집 방법을 기술한다.

• 데이터 전처리

결측치, 이상치, 정규화, 데이터 분할, 통합 등 기계학습에 필요한 형태로 데이터를 처리한다.

• 탐색적 데이터 분석

데이터 시각화, 통계 분석 등을 통한 핵심 속성을 추출한다.

3 모델 생성

• 기계학습 유형과 알고리즘

문제를 해결하기에 적합한 기계학습 유형과 기계학습 알고리즘의 동작을 글과 그림으로 표현한다.

• 모델 학습하기

기계학습 모델을 생성하고 훈련 데이터로 학습한 결과를 작성한다.

4 모델 평가

• 모델 성능 평가하기

테스트 데이터로 모델의 성능 평가 결과를 작성하고 해석한다.

혼동 행렬 등 모델 평가를 위한 지표를 활용하여 결과를 해석한다.

모델의 성능이 좋지 않다면 모델을 개선하여 최종 선택한 모델의 성능을 기술한다.

5 모델 활용 문제 해결

새로운 데이터를 입력하여 모델이 예측할 결과를 바탕으로 문제 해결 가능성을 기술한다.

6 참고 문헌



나의 학습 과정, 문제 해결을 위한 창의적 아이디어 등을 평가할 수 있도록 인공지능 프로젝트 활동의 평가 기준을 작성해 보자.

영역	어떤 기준으로 평가할까?	잘함	보통	노력




I 단위 인공지능의 이해

54~55쪽


1. ④ 2. ④ 3. (4, 0), (0, 3) 4. 해설 그림 참조
5. (0, 0)-(4, 0)-(0, 3)-(1, 3)-(4, 3)-(3, 0) 6. ③

해설

- (가) 문제 해결은 여러 문제 상황에서 지능적인 전략을 이용해서 해결하는 것을 의미한다.
(나) 추론은 이미 가지고 있는 지식을 이용해서 새로운 지식을 유도해 내는 것을 의미한다.
(다) 학습은 새로운 지식을 얻는 방법의 하나로, 과거의 경험을 바탕으로 새로운 상황에서 판단을 내릴 수 있도록 하는 것을 의미한다.
(라) 인식은 자신을 둘러싼 환경을 감지하는 데에서 더 나아가 감지된 개체를 분별하고 의미를 파악할 수 있는 것을 의미한다.
- 기후 데이터를 분석하여 자연환경을 보호하는 데 인공지능이 사용될 수 있다. 주식 시장의 데이터는 시계열 데이터이며 인공지능을 이용하여 주식 시장의 예측을 하고 있다.
- 초기 상태 (0, 0)에서 할 수 있는 작업은 두 번 밖에 없으므로, 첫 번째 물통을 가득 채우면 (4, 0), 두 번째 물통을 가득 채우면 (0, 3)이 된다.



- (4, 0)의 상태에서 첫 번째 물통을 두 번째 물통에 부으면 (1, 3)의 상태가 된다. 또는 두 번째 물통에 물을 새로 채우면 (4, 3)이 된다.



- 위 그림을 너비 우선 탐색 알고리즘으로 나타내면 다음과 같다.



- 컴퓨터에서 지식을 처리하고 저장하는 방법으로는 규칙, 명제 논리, 술어 논리, 의미망, 지식 그래프 등이 있다.

II 단위 인공지능과 학습

164~165쪽

1. ① 2. ① 3. ⑤ 4. ⑤ 5. ②
6. ③, ⑤ 7. ①

해설

- 계산기로 결과를 출력하는 것은 전통적인 프로그래밍으로 해결할 수 있는 문제이다.
- 히트맵을 보면 부리 깊이와 체질량 사이에는 -0.47의 값을 가지므로 두 속성 사이에는 상관이 있다. 상관이 거의 없으려면 절댓값이 0.2보다 작아야 한다.

$ r < 0.2$	$0.2 \leq r < 0.4$	$0.4 \leq r < 0.6$	$0.6 \leq r < 0.8$	$0.8 \leq r $
거의 상관이 없다.	약한 상관이 있다.	상관이 있다.	강한 상관이 있다.	매우 강한 상관이 있다.

- 결측치 삭제 명령어는 `df.dropna(axis=0)`이다.
- ① 한 개의 독립 변수(김)로 종속 변수(김밥)를 예측하므로 단순 선형 회귀 모델이다.
② 독립 변수는 김, 종속 변수는 김밥이다.
③ 선형 회귀식은 회귀계수와 절편으로 나타내므로 김밥 = 0.874*김 - 14이다.
④ 결정계수(r^2)가 0.961로 이 모델은 김 소비자 물가 지수로 김밥 소비자 물가 지수를 예측하는 데 설명력이 매우 높다.
⑤ 선형 회귀에서 독립 변수들이 종속 변수의 변동을 얼마나 설명하는지를 나타내는 값을 결정계수라고 한다.
- ① 군집 모델은 비지도학습 방법 중의 하나이다.
③ 군집 모델은 k-Means 알고리즘이 대표적이다. 결정트리 분류 모델에 사용한다.
④ 연속적인 수치를 예측할 때 사용하는 모델은 선형 회귀 모델이다.
- ① 퍼셉트론은 선형 분리가 가능한 문제는 해결할 수 있으나, 복잡하거나 비선형 문제는 해결할 수 없다.
② 퍼셉트론에서 활성화 함수로 어떤 임계값을 넘어가면 1, 그렇지 않으면 0이다.
④ 입력층과 출력층 사이에 있는 층을 은닉층이라고 한다.
- 컴퓨터 비전에서 이미지 분류 모델로 많이 사용되는 신경망 모델은 합성곱 신경망 모델(CNN)이다.

1. ① 2. 데이터 편향성 3. ④ 4. 투명성
5. ④ 6. 해설 참조 7. 사회의 공공선 원칙
8. 고위험

해설

- 가상 현실(VR) 기술을 이용한 게임의 그래픽 향상은 게임을 더 실감나게 하는 효과만 있을 뿐이므로 인공지능을 이용한 사회적 문제 해결 사례로 적합하지 않다.
- 데이터 편향성은 기계학습 모델을 개발하는 데 사용되는 데이터에 존재하는 편향을 의미한다. 데이터 편향성이 존재하는 인공지능이 사용된다면, 특정 그룹에 피해를 초래할 수 있다.
- 인공지능의 성능을 최대화할 수 있는 데이터를 우선적으로 활용하면 인공지능의 성능을 높일 수 있다. 그러나 특정 데이터만 선택하므로 편향성이 문제가 될 수 있다. 편향성 문제는 공정성 문제로도 이어질 수 있다.
- 인공지능이 투명성을 확보하기 위해서는 사용자가 사용하는 프로그램이 인공지능이라는 것을 알아야 하며, 인공지능의 의사 결정 과정을 설명할 수 있어야 한다.
- 자율주행 자동차의 시스템이 해킹을 당해 해커가 자율주행 자동차의 시스템을 변경하게 되면 자율주행 자동차가 오작동하거나 잘못된 판단을 내려 큰 사고로 이어질 수 있다. 자율주행 자동차의 경우 사고를 예방하기 위해서는 시스템을 안전하게 제어하고 관리해야 한다. 자율주행 자동차의 경우 잘못 작동하면 인간의 생명과 연관될 수 있으므로 안전성을 가져야 한다.
- 개발자, 사용자, 운영·관리자가 할 일은 다음과 같다.

개발자	사용자	운영·관리자	기술 활용에 대한 책임·보상 원칙 마련	윤리적 절차에 따라 기술 개발	악의적 이용 금지
→	→	→	→	→	→
- '인공지능은 사회적 약자와 취약 계층의 접근성을 보장하고 인류의 보편적 복지를 향상시키도록 개발 및 활용되어야 한다.'는 원칙이 사회의 공공선 원칙이다.
- 장난감, 항공기, 자동차, 의료 기기 등 제품의 안전 구성 요소로 사용되는 인공지능 시스템은 고위험 사례에 해당한다.



기계학습

다수의 경험적 사례를 통해 컴퓨터가 스스로 지식을 습득하도록 하는 접근 방법

딥러닝

데이터에 숨겨진 패턴을 학습하여 인간의 다양한 지적 활동을 흉내 내는 시스템을 만드는 기계학습의 한 분야

맹목적 탐색

컴퓨터의 빠른 계산 능력을 이용해 이기는 상태를 찾아 그곳에 이르는 가장 효율적인 경로를 구하는 것

의미망

거미줄과 같은 구조로 개념 간의 관계를 나타내는 표현 방법

인공지능

인간의 지능을 컴퓨터로 구현하여 지능적 행위를 흉내 낼 수 있도록 한 기술

전문가 시스템

특정한 분야에서 전문가의 의사 결정 능력을 흉내 내는 프로그램

정형 데이터

데이터에 속성이 미리 정의되어 있으며, 주로 표 형식으로 표현

지능

새로운 상황에서 그 의미를 이해하고, 합리적인 처리와 해결 방법을 알아내는 지적 능력

지능 에이전트

센서를 이용하여 주변 환경을 인지하고, 스스로 지능적인 의사 결정을 하여 행동하고 목표를 달성하는 개체

지도학습

정답이 제공된 데이터를 학습시키는 방법

추론

이미 가지고 있는 지식을 이용하여 컴퓨터가 지능을 가지도록 하는 방법

추천 시스템

사용자의 취향을 고려하여 상품을 권하는 시스템

컴퓨터 비전

컴퓨터가 디지털 이미지나 비디오를 이해하는 방법을 연구하는 분야

클래스

분류에서 데이터가 속한 종류

편향성의 문제

인공지능 모델은 학습한 데이터에 숨겨진 편향성 때문에 편향된 판단과 결정을 할 수 있는 문제

회귀

인공지능에서 기계학습 알고리즘을 이용해 함수식을 구하고 수치 데이터를 예측하는 것



간선	29
강화 학습	91
객체	130
게임 트리 탐색	38
결정계수	97
결정트리	107
결측치	74
경로 탐색	38
고위험	189
공공 분야의 문제 해결	18
공정성	70, 180
과적합	94
교차 검증	95
군집	64, 90
군집 모델	94
규칙	45
균일 비용 탐색	32
금지된 위험	189
기계학습	61
깊이 우선 탐색	31

낮은 위험	189
너비 우선 탐색	31

다층 신경망	128
데이터	67
데이터 수집 방법	68
데이터 시각화	73
데이터 전처리	74
데이터 편향	70
독립 변수	96
딥러닝	128

렐루 함수	134
로보컵	25
로지스틱 회귀	107

맹목적 탐색	30
명시적	61
명제 논리	44
문장 독해력 대회	25
문제의 표현	27
문제 해결	14

복합 명제	44
분류	64, 89
분류 모델	94
비정형 데이터	68
비지도학습	90

산업 분야의 문제 해결	18
삼단 논법	43
상관계수	77
상관관계	77
상자그림	75
상태	28
생성	64, 131
선형 회귀 모델	94
소프트맥스 함수	134
소프트웨어 시스템	23
손실함수	134
순회 외판원 문제	34
술어 논리	44
신뢰성	180
실생활 문제 해결	19
심층 신경망	128

안전성	184
언어 모델	155
연관 규칙	90
에이전트	91
예측	64
오차 함수	97
오픈 리스트	32
완전 연결 계층	146
유전자 알고리즘	39
윤리성	182
은닉층	128
음성 인식	131, 154
음향 모델	155
의미망	46
이미지 인식 대회	25
이상치	75
인공 신경망	127
인공지능	16
인공지능 소프트웨어	23
인공지능 시스템	16
인공지능 추론 시스템	48
인식	14, 64
일반 소프트웨어	23
임궏값	127
입력층	128

자연어 생성 모델	158
자연어 이해 모델	157
자연어 처리	64, 130, 154
전이 학습	147
전문가 시스템	48
정규화	75
정당성	71
정형 데이터	67

정확도	108
제한된 위험	189
종속 변수	96
'중국어 방' 사고 실험	15
지능	14
지능 에이전트	22
지도학습	89
지속가능발전목표	200
지식 그래프	46
지식 베이스	43
지식의 추론 과정	43
지식 표현 방법	44
지역 탐색	39

책무성	185
최상 우선 탐색	32
최적화 알고리즘	39
최적화 함수	134
추론	14, 43
출력층	128

컴퓨터 비전	130, 143
웨이크봇	175

탐색	27
통계 요약	73
투명성	183
튜링 테스트	15
트리 구조	28

8퍼즐	28
퍼셉트론	127
풀링 층	146

학문 분야의 문제 해결	19
학습	14
합성곱 신경망	146
합성곱 층	146
핵심 속성 추출	76
혼동 행렬	108
활성화 함수	134
회귀	89
휴리스틱 탐색	35
휴리스틱 함수	35

A* 탐색	36
k-최근접 이웃	107
k-평균 군집화 알고리즘	118



I 단원

- 서터스톡** 16쪽(인공지능 시스템 인물), 18쪽(금융 분야), (문화·예술·스포츠 분야), 19쪽(언어학 분야), (맞춤형 추천 서비스), (얼굴 사진 인식), (스마트홈 디바이스), (chatAI), (추천 시스템), 38쪽(경로 찾기 문제), (항공 경로 계획), 39쪽(항공사의 비행 일정 최적화), 49쪽(의료 진단 도우미), (기계 고장 진단), (법률 조언)
- 17쪽 (화성 탐사 로봇) <https://www.nasa.gov/>
- 18쪽 (의료 분야) <http://www.bosa.co.kr/news/articleView.html?idxno=2091990> (교통 분야) <https://www.aitimes.kr/news/articleView.html?idxno=20307> (환경 분야) https://www.researchgate.net/figure/a-Deforestation-map-of-Brazil-b-deforestation-in-test-region-until-2007-highlighted_fig1_371758635
- 19쪽 (과학 분야) <https://www.nasa.gov/> (사회 과학 분야) <https://maengdev.tistory.com/109>
- 20쪽 (튜링) Woosik Hyun, (2012), Turing's Cognitive Science, 인지과학, 23(3), 367-388, (프랭크 로젠블랫) <https://magazine.hankyung.com/business/article/202103186579b> (로스 쿤란) <https://www.rulequest.com/Personal/> (엘리자) [https://en.wikipedia.org/wiki/ELIZA_\(chatterbot\)](https://en.wikipedia.org/wiki/ELIZA_(chatterbot)) <https://thenewstack.io/remembering-shakey-first-intelligent-robot/> (복매치) <https://www.writtenward.com/p/why-you-should-be-excited-about-video> (딥블루) <https://www.thetimes.co.uk/article/exclusive-extract-can-intelligent-machines-save-our-planet-wvqm6jnhbk>
- 21쪽 (제프리 힌턴) <https://www.elcomercio.com/tendencias/entretenimiento/geoffrey-hinton-peligros-inteligencia-artificial.html> (이안 굿펠로우) <https://blogs.nvidia.co.jp/2017/06/21/generative-adversarial-network/> (왓슨) <https://www.etnews.com/201401100242> (알렉사) <https://medium.com/@leobottary/a-real-conversation-with-alexa-a244d5643f0c> (알파고) <https://www.yna.co.kr/view/AKR20160310078500009?input=1195m> (GPT-3) <https://velog.io/@tobigs-nlp/GPT-3-Language-Models-are-Few-Shot-Learners>
- 24쪽 (공항 안내 로봇) https://www.airport.kr/co/ko/cmm/cmmBbsView.do?PAGEINDEX=1&SEARCH_STR=&FNCT_CODE=121&SEARCH_TYPE=&SEARCH_FROM=2017.08.01&SEARCH_TO=2018.08.01&NTT_ID=23210
- 25쪽 (이미지넷) <https://deargen.me/ko/updates/deargen-won-at-ilsrv-2016-imagenet-large-scale-visual-recognition-challenge-ko/> (로보컵) <https://www.robocup.org/leagues/15> (문장 독해력 대회) <https://tensorflow.blog/2016/06/20/squad-standford-question-answering-dataset/>
- 28쪽 (8퍼즐) <https://medium.com/@josiahcoad/learn-a-a-star-algorithm-in-python-code-an-ai-to-play-a-game-c90b33d980e8>
- 38쪽 (대학 시스템) <https://bizx.chatwork.com/erp/consulting-erp/> (체스) <https://www.chess.com/ko/blog/chessinside/cese-keompyuteo-enjin-wa-cese-ingongjineung-a-i-tpyeon>
- 39쪽 (단백질 폴딩) <https://biz.chosun.com/science-chosun/science/2023/09/22/IXSYNQJUEVFTDNQ5XWSL6GA3M/>, (틱택토 게임) <https://josephpetitti.com/tic-tac-toe>
- 48쪽 (왓슨) <https://www.hani.co.kr/arti/society/schooling/677589.html>
- 49쪽 (지진 예측) <https://www.newsthai.com/news/articleView.html?idxno=3772> (기계 고장 진단) <https://www.techm.kr/news/articleView.html?idxno=83760> (법률 조언) <https://www.joongang.co.kr/article/23975652#home>
- 52쪽 (엘리자) <https://en.wikipedia.org/wiki/ELIZA>

II 단원

- 서터스톡** 65쪽(의료 진단), (금융 및 주식 예측), 67쪽(정형 데이터), (비정형 데이터), 69쪽(스마트 워치), 72쪽(펄킨의 몸), (펄킨의 부리), (세 가지 펄킨 중), 89쪽(분류 문제의 예), 104쪽(전복), 110쪽(펄킨의 종 클래스), 130쪽(얼굴 인식), (인공지능 비서), 131쪽(인공지능 스피커), (자동차 내비게이션), (보안 접근), 159쪽(GPT), 160쪽(인공지능 스피커), 162쪽(김밥)
- 63쪽 (손 글씨) <https://www.tensorflow.org/datasets/catalog/mnist?hl=ko>
- 65쪽 (이미지 인식) <https://store.google.com/intl/en/ideas/articles/photoorganization-with-google-photos/> (기계 번역) <https://blog.allbee.com/how-to-say-hello-in-arabic/> (농업) <https://m.yna.co.kr/view/ACK20161117000500881>
- 68쪽 (붓꽃 데이터) <https://pinkwink.kr/1128> (붓꽃 비정형 데이터) <https://universe.roboflow.com/universitas-merdeka-malang/iris-hvmto/dataset/1>
- 69쪽 (통계청 국가통계포털) <https://kosis.kr/> (캐글) <https://www.kaggle.com>
- 71쪽 (국가통계포털) <https://kosis.kr/index/index.do>

- 78쪽 (소리 데이터) <https://www.techm.kr/news/articleView.html?idxno=4428> (데이터 수집) https://www.kaggle.com/datasets/parulpandey/palmerarchipelago-antarctica-penguin-data?select=penguins_size.csv
- 85쪽 (KT '마이 AI 보이스') <https://www.aitimes.kr/news/articleView.html?idxno=29018> (네이버 클로바 '가족의 목소리') <https://www.mk.co.kr/news/it/10502151>
- 86쪽 (지진) https://weekly.khan.co.kr/khnm.html?www&mode=view&art_id=202006261529231&dept=
- 91쪽 (알파고) <https://yonhapnewstv.co.kr/news/MYH20160312012500038>, (벽돌깨기 게임) <https://youtu.be/gnx48N8YRc?si=WuB2BiP94IAy9dp>
- 93쪽 (페트병) 풀무원, 다나와, 삼다수, 롯데칠성, 코카콜라, 좋은데이, 코리아몰, 보틀세상, 아리수, 농심백산수, G마켓, 이안과학, 쿠팡, 뉴마켓, 자파존, <https://www.pixtastock.com/illustration/10131115>, <http://kienews.com/news/newsvievw.php?nocode=1065575423762826>, https://www.chosun.com/economy/market_trend/2021/03/30/MK73KAYHE5F6TPHQATXYLQVEYU/, https://www.linkedin.com/posts/darrenleejacklin_a-bottle-of-water-at-costco-is-025-the-activity-6886201782603784193-IEKC?trk=public_profile
- 130쪽 (객체 분할) <https://in.pinterest.com/pin/instant-munch-919930661369571538/> (질병 탐지 분류) http://www.govtrend.kr/news_proc/news_contents.jsp?nocode=3323 (기계 번역) <https://www.etri.re.kr/webzine/20190802/sub01.html> (인공지능 챗봇) <https://www.etnews.com/2019121000028>
- 131쪽 (이미지 생성) <https://brunch.co.kr/@leesangartoffic/26> (동영상 생성) <https://www.digitalbizon.com/news/articleView.html?idxno=2330807> (텍스트 생성) <https://m.newspim.com/news/view/20230615001045>
- 132쪽 (객체 탐지), (이미지 분류), (이미지 분할), (동작 인식), (손 주요 지점 탐지), (얼굴 탐지), (얼굴 주요 지점 탐지), (포즈 주요 지점 탐지), (텍스트 분류), (텍스트 임베딩), (언어 감지), (오디오 분류) <https://developers.google.com/mediapipe/solutions/examples>
- 144쪽 (AI CCTV) <https://www.kihobbo.co.kr/news/articleView.html?idxno=1030926> (자율주행 자동차 객체 탐지) https://github.com/JKL404/Object_Detection_using_OpenCV (자연재해 감지) <https://www.mdpi.com/1424-8220/23/6/3161> (암 감지) <https://paperswithcode.com/task/brain-tumor-segmentation> (지형 분석) <https://medium.com/analytics-vidhya/introduction-to-semantic-image-segmentation-856cda5e5de8> (자율주행 자동차 객체 분류) <https://deeplearninganalytics.org/semantic-segmentation/> (운동 트래킹) <https://www.inflearn.com/course/실전-3d-인간-포즈추정> (게임 및 엔터테인먼트) <https://medium.com/deepgamingai/3d-motion-capture-from-video-afa1b1fad7c> (감시 시스템) <https://m.khan.co.kr/science/science-general/article/202111172046005#c2b>
- 145쪽 (그림 원본) <https://www.opengallery.co.kr/art-dictionary/50/>
- 146쪽 (고양이 이미지의 합성곱 층) <https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2>
- 147쪽 (최대 풀링) <https://velog.io/@kgh732/부스트캠프-AI-Tech-U-stage.-3-3>
- 148쪽 (이미지넷 데이터셋) <https://cs.stanford.edu/people/karpathy/cnnembed/> (의학 데이터셋) https://www.researchgate.net/figure/Examples-of-images-from-the-dataset-of-each-of-the-7-types-of-skin-cancer-to-be_fig2_358691336
- 150쪽 (균열되지 않은), (균열된) <https://www.kaggle.com/datasets/arunk7/surface-crack-detection>
- 151쪽 (균열된) <https://www.kaggle.com/datasets/arunk7/surface-crack-detection>
- 160쪽 (영상 자막 재생) <https://www.youtube.com/watch?v=D1R-jKkp3NA> (감정 분석) <https://devocan.sk.com/blog/techBoardDetail.do?ID=163238> (기계번역) <https://translate.google.co.kr/?hl=ko> (검색엔진) <https://www.google.co.kr/> (텍스트 생성) <https://openai.com/blog/chatgpt>

III 단원

- 서터스톡** 171쪽(자동차), 172쪽(흑등고래), 173쪽(자연재해), 174쪽(자동차)
- 171쪽 (생성 인공지능) <https://this-person-does-not-exist.com/en>
- 172쪽 (고래 이동 경로) <https://apps-netsc.fisheries.noaa.gov/pacm/#/humpback> (흑등고래의 울음소리) <https://www.fisheries.noaa.gov/science-blog/ok-google-find-humpback-whales>
- 175쪽 (지도) <https://www.latimes.com/california/story/2023-02-01/earthquake-2-9-quake-strikes-in-los-angeles>
- 181쪽 (데이터 편향성) <https://craft.stanford.edu/dash/resources> (노면) <http://m.irobotnews.com/news/articleView.html?idxno=14236>

- 182쪽 (모럴 머신 프로젝트) <https://www.moralmachine.net/hl/kr>
- 184쪽 (표시판) <https://arxiv.org/abs/1911.08644> (딥페이크) <https://www.whichfaceisreal.com/>
- 187쪽 (할루시네이션) <https://openai.com/blog/chatgpt> (진주 귀걸이 소녀 좌) <https://www.picturem.com/409236/Girl%20with%20a%20Pearl%20Earring%20%7C%20Johannes%20Vermeer.html> (진주 귀걸이 우) https://www.ytn.co.kr/_ln/0104_202303111436441533
- 188쪽 (인공지능 의료 기기) <http://www.docdocdoc.co.kr/news/articleView.html?idxno=2029135> (음성 인식 번역기) <https://www.aitimes.kr/news/articleView.html?idxno=24375>
- 192쪽 (다큐멘터리) <https://program.imbc.com/meetyou> (안중근, 유관순) <https://www.hankyung.com/article/202308100071g> (인공지능 아나운서) <https://m.kmb.co.kr/view.asp?arcid=0015203470>
- 194쪽 (훈련용 데이터셋) <https://thispersondoesnotexist.com/>
- 195쪽 (테스트용 데이터셋) <https://thispersondoesnotexist.com/>

IV 단원

- 서터스톡 210쪽(집), 219쪽(집 에너지 효율성 등급)
- 200쪽 (지속가능발전목표) http://www.sdkorea.org/contents/sustainability/sustainability_04.php
- 201쪽 (펭귄 멸종 위기) <https://news.nate.com/view/20230509n28553> (온실가스 배출량), (생활 폐기물), (재생 에너지 비율) <https://kostat.go.kr/board.es?mid=a90107000000&bid=12317>
- 202쪽 (닥터비(B) 인공지능 로봇) <https://www.hani.co.kr/arti/society/environment/1029525.html> (CCTV 차량 감지) 행정안전부 (스마트 농업 생산 단지) <https://www.zin.co.kr/41/165>
- 203쪽 (지속가능발전목표) <https://kostat-sdg-kor.github.io/sdg-indicators/>
- 205쪽 (2000년 1월), (2080년 1월) 국립기상과학원 (온실가스 배출량) <http://www.climate.go.kr/>

※저작자 및 발행사에서 저작권을 가지고 있는 경우에는 출처 표시를 하지 않았음.

참고 문헌 및 참고 사이트



참고 문헌

- 과기정통부(2020). 「인공지능(AI) 윤리기준」
- 김명주(2022). AI는 양심이 없다. 헤이북스.
- 박상길, 정진호(2022). 비전공자도 이해할 수 있는 AI 지식. 반니.
- 손승원 외(2023). 「AI 채용시스템 도입성과: 국내외 사례연구」
- 아베 마사토, 안동현(2023). 통계 101, 데이터 분석. 프리렉.
- 유럽연합 의회(european parliament)(2023). 「Artificial intelligence act」
- 유럽연합위원회(european commission)(2021). 「REGULATION OF THE EUROPEAN PARLIAMENT AND OF THE COUNCIL LAYING DOWN HARMONISED RULES ON ARTIFICIAL INTELLIGENCE(ARTIFICIAL INTELLIGENCE ACT) AND AMENDING CERTAIN UNION LEGISLATIVE ACTS」
- 이건명(2018). 인공지능. 생능.
- 일본 이화학연구소 Ryuichiro Hataya, Han Bao, Hiromi Arai(2023). 「Will Large-scale Generative Models Corrupt Future Datasets」
- 정보문화포럼, NIA 한국정보화진흥원(2018). 지능정보사회 윤리 가이드라인 및 지능정보사회 윤리현장 소개.
- 제임스 로이(2020). 신경망 교과서. 길벗.
- 존 켈러허, 브랜던 티어니(2021). 데이터 과학. 김영사.
- 천인국(2023). 인공지능. 인피니트북스.
- 한겨레(2023.07.27.). 「개인정보위, '한국 이용자 정보 유출 미신고' 오픈AI에 과태료」.
- 한상기(2021). 신뢰할 수 있는 인공지능. 클라우드나인.
- 허민석(2020). 나의 첫 머신러닝/딥러닝. 위키북스.
- Hiromu Yakura 외(2019). 「Generate (non-software) Bugs to Fool Classifiers」
- Russell, S 외(2021). 인공지능(제4판) 2: 현대적 접근방식. 류광 옮김. 제이펍.
- A. M. TURING(1950). 「I.—COMPUTING MACHINERY AND INTELLIGENCE, Mind, Volume LIX, Issue 236」

※집필진이 직접 집필한 것은 출처를 밝히지 않았음.

참고 사이트

- 건물 에너지 효율성 관련 논문 <https://iopscience.iop.org/article/10.1088/1742-6596/1321/3/032016>
- 고래 이동 경로 확인 사이트 <https://apps-nefsc.fisheries.noaa.gov/pacm/#/humpback>
- 공공데이터포털 www.data.go.kr
- 과학기술정보통신부 누리집 https://bit.ly/MSIT_AI
- 구글의 데이터셋 검색 엔진 <https://datasetsearch.research.google.com/>
- 구글 렌즈 <https://lens.google.com/intl/ko/>
- 구글 코랩 <https://colab.research.google.com/?hl=ko>
- 구글 Bard(<https://bard.google.com/>)
- 국립기상과학원 http://www.nims.go.kr/?sub_num=911
- 국토교통부 데이터 통합 채널 www.molit.go.kr
- 국토교통 통계누리 <https://stat.molit.go.kr>
- 기상자료개방포털 <https://data.kma.go.kr/>
- 기상청 기후정보포털 <http://www.climate.go.kr/>
- 네이버 앱 <https://naver.com>
- 네이버 클로바 <https://clova.ai/speech>
- 워튼(<https://wrti.ai/>)
- 모럴 머신 <https://www.moralmachine.net/hl/kr>
- 미디어파이프 스튜디오 <https://mediapipe-studio.webapps.google.com/home>
- 상관관계(상관정도 판단 기준)<https://sphweb.bumc.bu.edu/otlt/MPH-Modules/PH717-QuantCore/PH717-Module9-Correlation-Regression/PH717-Module9-Correlation-Regression4.html>
- 시맨트리스 <https://research.google.com/semantris/>
- 앨런 튜링 논문 <https://academic.oup.com/mind/article/LIX/236/433/986238>
- 오렌지 데이터 마이닝 <https://orangedatamining.com/download/>
- 중국어방 사고 실험 <https://rintintin.colorado.edu/~vancecd/phil201/Searle.pdf>
- 지진 전문 기사 <https://www.latimes.com/people/quakebot>
- 챗GPT(<https://chat.openai.com/>)
- 캐글 <https://www.kaggle.com>
- 커리어넷(<https://www.career.go.kr/>)
- 텐서플로 플레이그라운드 <https://playground.tensorflow.org/>
- 통계청 국가통계포털 <https://kosis.kr/>
- 통계청 e-나라지표 www.index.go.kr
- 튜링 테스트 https://en.wikipedia.org/wiki/Turing_test
- 트롤리 딜레마 <https://www.ebs.co.kr/tv/show?prodId=119207&lectId=10651001>
- 티처블머신 <https://teachablemachine.withgoogle.com/>
- 틱택토 게임 <https://josephpetitti.com/tic-tac-toe>
- 편향된 사이코패스 로봇 '노먼' <http://norman-ai.mit.edu/>
- 프롤로그 <https://www.swi-prolog.org/>
- 한국 SDG 데이터 플랫폼 <https://kostat-sdg-kor.github.io/sdg-indicators/>
- 한국 SDG 이행 보고서 2023 https://kostat-sdg-kor.github.io/sdg-indicators/public/report/2023_report_ko.pdf
- 환경통계포털 <https://stat.me.go.kr>
- AI 허브 <https://www.aihub.or.kr/>
- CLOVA X(<https://clova-x.naver.com/>)
- CNN EXPLAINER <https://poloclub.github.io/cnn-explainer/>
- Gender Shades <http://gendershades.org/>
- Image kernels <https://setosa.io/ev/image-kernels/>
- k-평균 군집화 시뮬레이션 <https://bit.ly/k-means-simulation>
- Machine Learning Playground <https://ml-playground.com/#>
- My next move(<https://www.mynextmove.org/>)
- Passive Acoustic Cetacean Map <https://apps-nefsc.fisheries.noaa.gov/pacm/#/humpback>
- Random Face Generator <https://this-person-does-not-exist.com/en>
- Tensorspace.js <https://tensorspace.org/index.html>
- UCI 기계학습 저장소 <https://archive.ics.uci.edu/>
- Using AI to Listen and Learn about Humpback Whales <https://www.ncei.noaa.gov/news/using-ai-listen-and-learn-about-humpback-whales>
- Which face is real? <https://www.whichfaceisreal.com/>

연구 및 집필 위원

김현철*

(현) 고려대학교 컴퓨터학과 교수
(현) 고려대학교 정보창의교육연구소 소장
(현) 과학기술정보통신부 인공지능윤리 정책포럼 위원
(전) 한국컴퓨터교육학회 회장
미국 플로리다대학교 전산정보학 박사
집필 총괄 및 감수

임진숙

(현) 경상북도교육청연수원 교육연구사
(전) 경산과학고등학교 외 9개 중·고등학교 교사
한국교원대학교 컴퓨터교육학과 박사
Ⅱ, Ⅳ단원 집필

박종화

(현) 경기과학고등학교 교사
한국교원대학교 컴퓨터교육학과 석사
Ⅰ단원 집필

김종혜

(현) 비룡중학교 수석교사
고려대학교 컴퓨터교육학과 박사
Ⅱ단원 집필

심희원

(현) 선린인터넷고등학교 교사
성균관대학교 컴퓨터교육학과 석사
Ⅲ단원 집필

* 대표 연구 및 집필 위원



연구 및 집필 위원

김현철(고려대학교)*
임진숙(경상북도교육청연수원)
박종화(경기과학고등학교)

김종혜(비룡중학교)
심희원(선린인터넷고등학교)

*대표 연구 및 집필 위원

심의 기관

광주광역시교육청

심의 위원

권오석(충남대학교)*
강권(상무고등학교)
고제석(광주대학교)
김미경(첨단고등학교)
김보은(부흥고등학교)
김지수(첨단고등학교)
김지연(봉일천고등학교)
나준영(복자여자고등학교)
박선옥(대광여자고등학교)
박선주(광주교육대학교)
박진우(대일관광고등학교)
변영민(조선대학교부속고등학교)
설이태(서강고등학교)

송경희(조선대학교부속고등학교)
송정영(배재대학교)
윤시연(광주소프트웨어마이스터고등학교)
윤정구(합천고등학교)
이동윤(광주과학고등학교)
이용신(광주동신고등학교)
이채영(금양중학교)
임선아(여수공업고등학교)
조아라(무안행복중학교)
최선아(광양중등중학교)
한순재(영동교육지원청)
황병남(대원여자고등학교)

*심의위원장

편집 및 디자인 기관

편집
개발 총괄 박정과
개발 책임 장미영
기획·개발 유경희, 정진영

디자인
총괄 김희정
표지 이신애, 박소연, 문성연, 이주영
본문 이은정, 이준환

삽화
채창기, 강일석, 김민정, 박재운, 양복선, 위희경,
장효원, 전영옥, 조우영

조판
김옥분, 이연옥

※ 교육부장관의 위임을 받아 광주광역시교육감이 2024년 8월 30일 인정 승인을 하였음.

고등학교

인공지능 기초

2025. 3. 1. 초판 발행

정가 원

지은이 김현철 외 4인

발행인 (주)천재교과서 · 서울특별시 금천구 가산디지털1로 16 SK V1 AP타워

인쇄인 (주)프린피아 · 서울특별시 금천구 가산로9길 54

교과서의 본문 용지는 우수 재활용 제품 인증을 받은 재활용 종이를 사용하였습니다.

교과서에 대한 문의 사항이나 의견이 있으신 분은 교육부와 한국교과서연구재단이 운영하는 교과서민원바로처리센터(전화: 1566-8572, 웹사이트: <https://www.textbook114.com> 또는 <https://www.교과서114.com>)에 문의하여 주시기 바랍니다.

이 도서에 게재된 저작물에 대한 보상금은 문화체육관광부장관이 정하는 기준에 따라 사단법인 한국문학예술저작권협회(전화 02-2608-2800, www.kolaa.kr)에서 저작권자에게 지급합니다.

내용관련문의

· (주)천재교과서 편집부

공급업무대행

· (사)한국교과서협회

개별구입문의

· (사)한국교과서협회

· (주)천재교과서

· 전화: 02-6333-1825

· (10881)경기도 파주시 문발로 439-1(신촌동 734-1)

· 홈페이지 주소: www.ktbook.com

· 홈페이지 주소: mall.chunjaetext.co.kr

· 전송: 02-6333-1838

· 전화: 031-956-8581~4

· 전화: 02-3282-8705

ISBN 979-11-7236-207-2(53500)



고등학교
인공지능 기초

고등학교

인공지능 기초

